

認識可能な同値関係によって規定される代入について
閉じた文脈自由言語のクラスに対する正の例からの
学習アルゴリズムの提示とその収束性

栗山貴之

2015 年 2 月 21 日

目次

第 1 章	この論文の概要	5
第 2 章	前提となる内容	7
第 3 章	クラスの定義と Yoshinaka の k, l -代入可能クラスとの関係性	9
第 4 章	学習のアルゴリズム	11
第 5 章	文脈間の代入も可能な言語のクラス	13
第 6 章	モノイドによる文脈自由文法の型付け補題	15
第 7 章	最大包含クラスに対する学習アルゴリズム	17
第 8 章	正しい学習に必要な特徴的有限集合の大きさについて	21
第 9 章	クラスの性質と言語の具体例	23
参考文献		25

第 1 章

この論文の概要

日本語で「私は美しい花を好む。」という文と「私は赤い花を好む。」という 2 文を比較したとき、《赤い～美しい》という単語上の類が発生していると考えerことは自然であり、人は言語の習得の各段階でそのような学習方法を無意識にとっていると考えられる。ある言語が代入可能であるとは $\{x_0y_0z_0, x_0y_1z_0, x_1y_0z_1\} \subseteq L$ ならば常に $x_1y_1z_1 \in L$ であることと定義される。Clark と Eyraud[1] は代入可能な文脈自由言語の正の例からのアルゴリズム的学習の可能性を証明した。

学習の対象となる言語のクラスに対して、個別的な言語に因らないある 1 つのアルゴリズム $\mathcal{A}$ が具体的に存在し、学習の目的言語からとられた十分多くの有限個の例文 $w_0, \dots, w_{n-1}$ が与えられたとき、そのアルゴリズムは目的言語を正しく表現する文法 $\hat{G}(w_0, \dots, w_{n-1})$ を出力し、停止する。これがアルゴリズム的な正の例からの言語学習の枠組みである。

さて、今度は英語で「He speaks loudly every time.」と「He speaks fluently every time.」という 2 文を比較したとき、同様に《loudly～fluently》という同一視が存在することに気づくが、さらに《*ly》という語尾 2 文字がその類を特徴づけていることが識見される。《赤い～美しい》類も《い》という語尾 1 文字が特徴づけていることに気づく。

Yoshinaka[5] の定義による k, l -代入可能言語とは、 L が $u \in \Sigma^k, v \in \Sigma^l, \{x_0uy_0vz_0, x_0uy_1vz_0, x_1uy_0vz_1\} \subseteq L$ ならば常に $x_1uy_1vz_1 \in L$ であることで定義される。Yoshinaka[5] はこの言語のクラスもアルゴリズム的学習可能であることを証明した。

本論文は《語～語'》という同一視が“数学的な類”を定義する状況を一般化して定義し、その一般的な代入が可能言語がアルゴリズム的に学習可能であることを数学的に簡明に整理された形で証明する。一般に $\sim$ を認識可能^{*1}な同値関係としたとき、ある言語が $\sim$ -代入可能であることを $\{x_0y_0z_0, x_0y_1z_0, x_1y_0z_1\} \subseteq L \wedge y_0 \sim y_1$ ならば常に $x_1y_1z_1 \in L$ であると定義する。

Yoshinaka[5] の言語のクラスは $x \sim_{k,l} y \Leftrightarrow x = y \vee (\exists u \in \Sigma^k \exists v \in \Sigma^l, x, y \in u\Sigma^*v)$ と定義することにより一般化された定式化が与えられる。

この一般化されたクラスに対する学習アルゴリズムは Yoshinaka[5] のものにいくらかの一般化の修正を加えたものが役割を果たす。

^{*1} ある Σ^* 上の二項関係 $\sim$ 認識可能であるとは、ある有限モノイド M と部分集合 $F \subseteq M^2$ 、準同形写像 $\Sigma^* \rightarrow M$ が存在して $\forall xy \in \Sigma^*, x \sim y$ iff $(h(x), h(y)) \in F$ であることと定義する。

正の例からのアルゴリズム的学習の数理的枠組みではそのクラスの言語はその部分集合としてその言語のエッセンスとなる有限個の例文、「特徴的有限集合」を持ち、それをすべて含んだ正の例を与えられたとき必ず目的言語は復元可能であると仮定する。副次的な結果としてこの論文では“代入可能言語がより強く圧縮できること”を示した。つまり、先行研究より小さなサイズの特徴的有限集合でわれわれのアルゴリズムは正しく機能することを証明した。

第 2 章

前提となる内容

有限集合 Σ 上で、連結を演算として自由生成されたモノイドを Σ^* と表記する。その元を語または文と呼ぶ。言語とは Σ^* の部分集合のこととする。

自然言語の場合 Σ は固有名詞を含んだすべての単語の有限集合のこととする。例えば英語を対象とする場合 $\Sigma = \{a, b, \dots, z\}$ とはせず $\Sigma = \{a, absent, attend, Adam, \dots, toy, Tom, talk, \dots\}$ などのようにとる。

直感的には言語に対して秩序構造をもたらす動的な機構を文法と呼ぶ。数理として文法とはいかにあるべきかの議論はこの論文ではせず、もっぱら文脈自由文法 (**context-free grammar, CFG**) のみを扱うことにする。それとは組 $G = \langle V, \Sigma, P, S \rangle$ で、(i) V は非終端記号からなる有限集合、(ii) P は導出規則からなる有限集合（但し導出規則とは $A \in V, \beta \in (V \cup \Sigma)^*$ の条件の下での形式 $A \rightarrow \beta$ をいう）(iii) $S \in V$ であること、を満たすもののことをいう。文脈自由文法により生成される言語を、(1) $\alpha, \gamma \in (V \cup \Sigma)^*$ に対して $A \rightarrow \beta \in P$ であるとき、 $\alpha A \gamma \Rightarrow_G \alpha \beta \gamma$ とし、(2) $\Rightarrow^*$ を二項関係 $\Rightarrow$ の反射推移的閉包だとし、(3) $\mathcal{L}(\alpha) := \{w \in \Sigma^* \mid \alpha \Rightarrow_G^* w\}$ として、 $\mathcal{L}(S)$ で定義する。これは $\mathcal{L}(G)$ と表記し、文脈自由言語 **context-free language (CFL)** であるという。異なる二つの文脈自由文法 G, G' が $\mathcal{L}(G) = \mathcal{L}(G')$ のとき同値であると定義し、記号 $G \approx G'$ で書く。

例えば $L_0 = \{\lambda, ab, aabb, \dots\} = \{a^n b^n \mid n < \omega\}$ という言語に対しては、 $G_0 = \langle \Sigma, V, P, S \rangle$ 但し $\Sigma = \{a, b\}, V = \{S\}, P = \{S \rightarrow aSb, S \rightarrow \lambda\}$ という文脈自由文法が存在し、 $L_0 = \mathcal{L}(G_0)$ となっている。

任意の文脈自由文法には **Chomsky 標準形 (Chomsky normal form, CNF)** なる同値な標準形が存在することが知られている。それは導出規則の形が $S \rightarrow \lambda, A \rightarrow BC$ 、ないし $A \rightarrow a$ であること ($A, B, C \in V, a \in \Sigma$ として) と規定される。

例えば上の例でいえば $G'_0 = \langle \Sigma, V', P', S \rangle$ 但し $V = \{S, X_a, X_b, X_{aS}\}, P = \{S \rightarrow X_{aS}X_b, X_{aS} \rightarrow X_aS, X_a \rightarrow a, X_b \rightarrow b, S \rightarrow \lambda\}$ は Chomsky 標準形であり $G_0 \approx G'_0$ となっている。

この論文では Gold[3] による古典的なアルゴリズム的学習の定義を採択する。このパラダイムは **Identification in the Limit (IIL)** と言われる。 $\mathcal{X}$ を文法をメンバとする帰納的可算集合（たとえば文脈自由文法のサブクラス）だとする。この集合上の演算子 $\mathcal{L}(\cdot)$ は $\mathcal{X}$ から $\mathcal{P}(\Sigma^*)$ への写像と理解する。つまり文法 $G \in \mathcal{X}$ に対し、 $\mathcal{L}(G)$ はその文法の生成する Σ^* の部分集合（言語）である。学習アルゴリズム $\mathcal{A}$ とは $\mathcal{P}_F(\Sigma^*)$ から $\mathcal{X}$ への計算可能な写像であると定義する（但し $\mathcal{P}_F(\Sigma^*) := \{L \subseteq \Sigma^* \mid \#L < \omega\}$ ）。学習の目的とする

言語 $L_* \subseteq \Sigma^*$ に対し、その正の枚挙 (*positive presentation*) とは $L_* = \{w_i \mid i < \omega\}$ となる列 $w_0, w_1, \dots$ とする。第 n -推定文法を $G_n = \mathcal{A}(\{w_0, \dots, w_{n-1}\})$ で定義する。これが「収束」すること、つまり $L = \mathcal{L}(G_N) \wedge \forall n \geq N, \mathcal{L}(G_n) = \mathcal{L}(G_N)$ となることを学習達成の定義とする。略記としてこの論文では正の例の系列 $(w_0, \dots, w_{n-1})$ に対し、学習文法 $\mathcal{A}(w_0, \dots, w_{n-1})$ を $\hat{G}(K)$ という書き方をすることにする。但しここに $K = \{w_i\}_{i < n}$ である。

以下では更に学習の「有限性」、ないし「有効性」を要請する。これは Collin de la Higuera[4] の提示による規範を採択する。つまり、

任意の目的文法 $G_* \in \mathcal{X}$ に対応する言語 $L_* = \mathcal{L}(G_*)$ の任意の有限サンプル集合 $S \subseteq L_*$ に対し、学習アルゴリズムは S の大きさの多項式時間で出力し停止することを要請する。さらに

任意の目的文法 $G_* \in \mathcal{X}$ に対し、ある特徴的有限部分集合 (*characteristic set*) である $CS(G_*)$ が存在し、 $CS(G_*)$ の大きさは文法 G の多項式量であり、かつ任意の正のサンプル $S \supset CS(G_*)$ を与えられたときアルゴリズムは目的文法 G_* と外延的に等しい出力 $\hat{G}(S)$ を返し、停止する (すなわち $\mathcal{L}(G_*) = \mathcal{L}(\hat{G}(S))$ である)。ここに、語からなる有限集合 S に対する大きさの定義は $\|S\| := \sum_{w \in S} \text{Len}(w)$ であり、文脈自由文法 $G = \langle \Sigma, V, P, S \rangle$ の大きさは $\|G\| := \sum_{A \rightarrow \beta \in P} \text{Len}(A\beta)$ で定義されるものであるとする。

文脈自由言語に対する具体的な形式については Clark と Eyraud の定式化を採択することとする。

CFG に対する特徴的集合の定義 (Clark および Eyraud, 2007). 文脈自由文法

$G = (V, \Sigma, P, S), \alpha \in (V \cup \Sigma)^*, A \in V$ に対して $\omega(\alpha) := \min\{w \in \Sigma^* \mid \alpha \Rightarrow_G^* w\}$, $\chi(A) := \min\{\langle x, z \rangle \in (\Sigma^*)^2 \mid S \Rightarrow_G^* xAz\}$ とし^{*1}、 $\beta \in (V \cup \Sigma)^*$ に対して、 $A \rightarrow \beta \in P$ のとき $\chi(\beta) := \min\{\chi(A) \mid A \rightarrow \beta \in P\}$ であるとする。このとき特徴的有限部分集合を $CS(G) := \{\omega(\beta) \odot \chi(A) \mid A \rightarrow \beta \in P\}$ で定める。但し $y \odot \langle x, z \rangle := xyz$ と定める。

Remark 1 任意の $A \in V$ に対して、 $\omega(A) \odot \chi(A) \in CS(L_*)$ である。

この論文の出発点となる、先行研究によりアルゴリズム的で有効な学習の可能性が証明された言語のクラスで、基本的なものを2つ確認する。

代入可能言語 (Clark および Eyraud, 2007). $L \subseteq \Sigma^*$ が代入可能であるとは

$\forall x, y \in \Sigma^*, C_L(x) \cap C_L(y) \neq \emptyset \Rightarrow C_L(x) = C_L(y)$ となること。但し文脈 $C_L(x) := \{(u, v) \in (\Sigma^*)^2 \mid uxv \in L\}$ とする。

k, l -代入可能言語 (Yoshinaka, 2008). $L \subseteq \Sigma^*$ が k, l -代入可能であるとは

$\forall x, y \in \Sigma^*, u \in \Sigma^k, v \in \Sigma^l, C_L(uxv) \cap C_L(yv) \neq \emptyset \Rightarrow C_L(uxv) = C_L(yv)$ となること。

このうち文脈自由言語であるものにクラスを制限したものがアルゴリズム的学習の対象として研究された。これらのクラスを以降の章で拡張・一般化することを議論する。

^{*1} ここで “min” は Σ^* 、ないし $(\Sigma^*)^2$ 上の辞書式順序に関して最少のものを返すものとする。

第 3 章

クラスの定義と Yoshinaka の k, l -代入可能クラスとの関係性

この章では Yoshinaka[5] のクラスの一般化の定式化を行う。以下では関係 $\sim$ は任意に与えられた Σ^* 上の認識可能な同値関係であるとする。

定義 1 $L \subseteq \Sigma^*$ が $\sim$ -代入可能であるとは $\forall x, y \in \Sigma^*, C_L(x) \cap C_L(y) \neq \emptyset \wedge x \sim y \Rightarrow C_L(x) = C_L(y)$ であることと定義する。

議論を明確に行うために以下の表記を与える；

定義 2 $\mathcal{C}_{k,l} := \{L \subseteq \Sigma^* \mid L \text{ は } k, l\text{-代入可能}\}$, $\mathcal{C}_\sim := \{L \subseteq \Sigma^* \mid L \text{ は } \sim\text{-代入可能}\}$.

$\sim_{k,l}$ が認識可能な同値関係になることから以下の命題が成り立つ。

主張 1 $\forall k, l \in \mathbb{N}, \exists \sim, \mathcal{C}_{k,l} = \mathcal{C}_\sim$.

以下では我々のクラスが Yoshinaka のクラスの真の拡大となっていることを示したい。まず、具体的な別の認識可能な同値関係を以下で与える；

記号の数の代入 $a \in \Sigma, d \in \mathbb{N}$ に対して、 $x, y \in \Sigma^*, x \sim_{\#a,d} y :\Leftrightarrow \#(a, x) = \#(a, y) \leq d \vee (\#(a, x) > d \wedge \#(a, y) > d)$ とする^{*1}。

事実 1 $\sim_{\#a,d}$ は認識可能な同値関係となる^{*2}。

その上で以下で k, l -代入可能でない言語の例を与える；

主張 2 $b^* \cup b^*ab^*$ は $d \geq 1$ のとき $\sim_{\#a,d}$ -代入可能であるが、どんな k, l に対しても k, l -代入可能にはなりえない。

証明 $L = b^* \cup b^*ab^*$ は任意の $d \geq 1$ に対して $\sim_{\#a,d}$ -代入可能言語となっている。任意の $k, l \in \mathbb{N}$ に対して、 $L \ni b^kbb^l, b^kab^l$ であるから $b^kbb^l \sim_{k,l} b^kab^l$ となる。また $C_L(b^kab^l) \cap C_L(b^kbb^l) \ni (b^i, b^j)$ である。しかし $C_L(b^kbb^l) \setminus C_L(b^kab^l) \ni (b^i, ab^j)$ である。

^{*1} $a \in \Sigma, w \in \Sigma^*$ に対して、 $\#(a, w)$ はストリング w 中の文字 a の出現回数を自然数値で返す関数とする。

^{*2} $\Sigma^* / \sim_{\#a,d}$ の各同値類が正規言語となることに因る。

集合和に関する補題を示す。以下では $h(x, y) := (h(x), h(y))$ という表記を用いる。

補題 1 $\forall \sim_1, \sim_2 \exists \sim, \mathcal{C}_{\sim_1} \cup \mathcal{C}_{\sim_2} \subseteq \mathcal{C}_{\sim}$.

証明 $x \sim y : \Leftrightarrow x \sim_1 y \wedge x \sim_2 y$ と仮定する。 $\sim$ は認識可能な同値関係となっている*³。
言語 L が $\sim_i$ -代入可能 ($i = 1, 2$) のとき L は $\sim$ -代入可能である。

以上により、我々のクラスが真の Yoshinaka の拡大となっていることが示された；

主張 3 $\forall k, l \in \mathbb{N}, \exists \sim, \mathcal{C}_{k,l} \subseteq \mathcal{C}_{\sim}$ かつ $\exists \sim, \forall k, l, \mathcal{C}_{\sim} \not\subseteq \mathcal{C}_{k,l}$ である。

各 k, l -代入可能言語のクラスでは、 $\forall k, l \in \mathbb{N}$ について、 $k \leq k' \wedge l \leq l'$ ならば $\mathcal{C}_{k,l} \subseteq \mathcal{C}_{k',l'}$ が成り立つ。以下はこのクラス間の「階層性構造」の一般化である。

事実 2 $\sim \subseteq \sim'$ ならば $\mathcal{C}_{\sim'} \subseteq \mathcal{C}_{\sim}$

³ $\sim$ が同値関係となるのは自明。 $h_i : \Sigma^ \rightarrow M_i$ が準同形写像で $x \sim_i y \Leftrightarrow h_i(x, y) \in F_i (i = 1, 2)$ であるとする。このとき $M_1 \times M_2$ は有限モノイドとなり、 $h(x) := (h_1(x), h_2(x))$ 、 $F := F_1 \times F_2$ とすると、 h は準同形写像であり、 $x \sim y \Leftrightarrow x \sim_1 y \wedge x \sim_2 y \Leftrightarrow h_1(x, y) \in F_1 \wedge h_2(x, y) \in F_2 \Leftrightarrow h(x, y) \in F_1 \times F_2$ となる。

第 4 章

学習のアルゴリズム

k, l -代入可能文脈自由言語のクラスに対しては、[5] では以下のような学習アルゴリズムが与えられている。 L_* が学習の目的となる言語、 K をその正の例の有限部分集合としたとき ($K \subseteq L_* \wedge \#K < \infty$)、

$$\begin{aligned}\hat{V}(K) &= \{[x] \mid \exists uv \in \Sigma^*, uvx \in K \wedge x \neq \lambda\} \cup \{\hat{S}\}, \\ \hat{P}(K) &= \{[xy] \rightarrow [x][y] \mid [xy], [x], [y] \in \hat{V}(K)\} \cup \\ &\quad \{[uxv] \rightarrow [ux'v] \mid zw \in \Sigma^* \wedge u \in \Sigma^k \wedge v \in \Sigma^l \wedge [uxv], [ux'v] \in \hat{V}(K) \wedge C_K(x) \cap C_K(x') \neq \emptyset\} \cup \\ &\quad \{[a] \rightarrow a \mid [a] \in \hat{V}(K) \wedge a \in \Sigma\} \cup \\ &\quad \{\hat{S} \rightarrow [w] \mid w \in K\},\end{aligned}$$

によって $\hat{G}(K)$ を定義したとき、学習アルゴリズムは

以上の下で学習アルゴリズムは以下となる；

Data: A sequence of strings $w_1, w_2, \dots$

Result: A sequence of CFGs $G_1, G_2, \dots$

Let $\hat{G}$ be a CFG generating empty language;

For $n = 1, 2, \dots$ **do**

 Read the next string w_n ;

If $w_n \notin \mathcal{L}(\hat{G})$ **then**

 let $\hat{G} = \langle \Sigma, \hat{V}(K), \hat{P}(K), \hat{S} \rangle$ where $K = \{w_1, w_2, \dots, w_n\}$

end if

output $\hat{G}$

End For

—— 定義されている。

これを修正した $\sim$ -代入可能文脈自由言語のクラスに対する学習アルゴリズムを以下に与える。 $\sim$ が既知の二項関係でそれが準拠している準同形写像が学習者にとって使用可能なりソースであるとする。 L_* がこのクラスに属する目的言語であり、 K をその正の例

の有限部分集合としたとき、($K \subseteq L_* \wedge \#K < \infty$)、

$$\begin{aligned}\hat{V}(K) &= \{[x] \mid \exists uv \in \Sigma^*, uvx \in K \wedge x \neq \lambda\} \cup \{\hat{S}\}, \\ \hat{P}(K) &= \{[xy] \rightarrow [x][y] \mid [xy], [x], [y] \in \hat{V}(K)\} \cup \\ &\quad \{[x] \rightarrow [x'] \mid x \sim x' \wedge [x], [x'] \in \hat{V}(K) \wedge C_K(x) \cap C_K(x') \neq \emptyset\} \cup \\ &\quad \{[a] \rightarrow a \mid [a] \in \hat{V}(K) \wedge a \in \Sigma\} \cup \\ &\quad \{\hat{S} \rightarrow [w] \mid w \in K\},\end{aligned}$$

として推定文法 $\hat{G}(K)$ を定義すればよい。

以上が最初の結果であるが、その後の研究で Coste et. al.[2] を包含する形で、文脈を拾う学習アルゴリズムを新たに定式化した。今度は文脈間の代入にも閉じた言語のクラスまで学習の対象を一般化する。

第 5 章

文脈間の代入も可能な言語のクラス

以下では前節までで与えたクラスを包含するさらに一般化させた文脈自由言語のクラスを与える。今度は文脈の代入について一般化している。以下では、 h は Σ^* からある有限モノイドへの準同形写像とし、また $\sim$ 、 R をそれぞれ Σ^* 、 $(\Sigma^*)^2$ 上の認識可能な同値関係とする。

定義 3 $L \subseteq \Sigma^*$ が h -代入可能であるとは $\forall uvxu'v'x' \in \Sigma^*, uvx, ux'v \in L \wedge h(u, x, v) = h(u', x', v')$ ならば $(u'xv' \in L \Leftrightarrow u'x'v' \in L)$ となること。

このクラスは別の表現がなされる；

定義 4 $L \subseteq \Sigma^*$ が $(R, \sim)$ -代入可能であるとは $\forall uvxu'v'x' \in \Sigma^*, uvx, ux'v \in L \wedge (u, v)R(u', v') \wedge x \sim y \Rightarrow (u'xv' \in L \Leftrightarrow u'x'v' \in L)$ となること。

言語のクラスを以下の表記で総括する。

定義 5 $\mathcal{C}_{\sim} := \{L \subseteq \Sigma^* \mid L \text{ は } \sim \text{-代入可能}\}$, $\mathcal{C}_h := \{L \subseteq \Sigma^* \mid L \text{ は } h\text{-代入可能}\}$, $\mathcal{C}_{R, \sim} := \{L \subseteq \Sigma^* \mid L \text{ は } R, \sim\text{-代入可能}\}$

k, l クラス間の「階層性構造」の一般化は以下になる。

事実 3 $\sim \subseteq \sim' \wedge R \subseteq R'$ ならば $\mathcal{C}_{\sim} \subseteq \mathcal{C}_{R, \sim}$ 、また $\mathcal{C}_{R', \sim'} \subseteq \mathcal{C}_{R, \sim}$

また h -代入可能クラスと $R, \sim$ -代入可能クラスの関係は以下となる。

事実 4 $\forall R, \sim, \exists h, \mathcal{C}_{R, \sim} \subseteq \mathcal{C}_h$ であり、また $\forall h, \exists R, \sim, \mathcal{C}_h \subseteq \mathcal{C}_{R, \sim}$ である。

第 6 章

モノイドによる文脈自由文法の型付け補題

学習の収束性の数学的な証明のために、本節では任意の文脈自由文法の非終端記号を型付けし、その生成文と付随する文脈を条件をつけた振る舞いに制限した同値な文法の存在定理を証明する。

補題 2 M を有限モノイドとし、 $h : \Sigma^* \rightarrow M$ を準同形写像とする。任意の文脈自由文法 G に対してある同値な文脈自由文法 $G' = (V', \Sigma, P', S')$ が存在し、

- i) $\forall A \in V' \setminus \{S'\}, S' \Rightarrow_G^* y_1 A z_1 \wedge S' \Rightarrow_G^* y_2 A z_2$ ならば $h(y_1) = h(y_2) \wedge h(z_1) = h(z_2)$.
- ii) $\forall A \in V' \setminus \{S'\}, A \Rightarrow_G^* y_1 \wedge A \Rightarrow_G^* y_2$ ならば $h(y_1) = h(y_2)$.
- iii) $\forall B, C \in V' \setminus \{S'\}, S' \Rightarrow_G^* y_1 B C z_1 \wedge S' \Rightarrow_G^* y_2 B C z_2$ ならば $h(y_1) = h(y_2) \wedge h(z_1) = h(z_2)$ が成立する。

証明 Chomsky 標準形である CFG (V, Σ, P, S) に対して、 $G' = (V', \Sigma, P', S')$ を以下で定義する。 $V' := \{A_p^{m,n} \mid A \in V \wedge m, n, p \in M\} \cup \{S'\}$, $P' := \{A_{pq}^{m,n} \rightarrow B_p^{m,qn} C_q^{mp,n} \mid A \rightarrow BC \in P\} \cup \{A_p^{m,n} \rightarrow a \mid A \rightarrow a \in P \wedge p = h(a)\} \cup \{S' \rightarrow X \mid X \in S\}$ (但し $S := \{S_p^{1,1} \mid S \in V \wedge p \in M\}$) とする。このとき

(1) $\forall A_p^{m,n} \in V' \setminus \{S'\}, A_p^{m,n} \Rightarrow_{G'}^* w$ ならば $p = h(w)$ が成り立つことは容易に示せる。また、

(2) $\forall A_p^{m,n}, B_q^{s,t} \in V' \setminus \{S'\}, A_p^{m,n} \Rightarrow_{G'}^* y B_q^{s,t} z$ ならば $s = mh(y) \wedge t = h(z)n$ である。なぜなら、 $A_{p'q'}^{m,n} \Rightarrow C_{p'q'}^{m,q'n} D_{q'}^{mp',n} \Rightarrow^* y B_q^{s,t} z$ だと仮定する。左右の対称性より $C_{p'}^{m,q'n} \Rightarrow^* y B_q^{s,t} z_1 \wedge D_{q'}^{mp',n} \Rightarrow^* z_2 \wedge z = z_1 z_2$ だと仮定してよい。 $C_{p'}^{m,q'n} \Rightarrow^* y B_q^{s,t} z_1$ に帰納法の仮定を用いて $s = mh(y)$ 、 $t = h(z_1)q'n$ となる。 $D_{q'}^{mp',n} \Rightarrow^* z_2$ に (1) を用いて $q' = h(z_2)$ となり、 $t = h(z_1)h(z_2)n = h(z)n$ となる。最短である $A_{p'q'}^{m,n} = B_q^{s,t} \wedge y = z = \lambda$ の場合は明らか。

(3) $\forall A_p^{m,n}, B_{q_1}^{s,t'}, C_{q_2}^{s',t} \in V' \setminus \{S'\}, A_p^{m,n} \Rightarrow_{G'}^* y B_{q_1}^{s,t'} C_{q_2}^{s',t} z$ ならば $s = mh(y) \wedge t = h(z)n$ である。なぜなら $A_{p'q'}^{m,n} \Rightarrow C_{p'q'}^{m,q'n} D_{q'}^{mp',n} \Rightarrow^* y B_{q_1}^{s,t'} C_{q_2}^{s',t} z$ であると仮定する。 $C_{p'}^{m,q'n} \Rightarrow^* y B_{q_1}^{s,t'} \wedge D_{q'}^{mp',n} \Rightarrow^* C_{q_2}^{s',t} z$ の場合、(2) より明らか。 $C_{p'}^{m,q'n} \Rightarrow^* y B_{q_1}^{s,t'} C_{q_2}^{s',t} z_1 \wedge D_{q'}^{mp',n} \Rightarrow^* z_2 \wedge z = z_1 z_2$ の場合、 $C_{p'}^{m,q'n} \Rightarrow^* y B_{q_1}^{s,t'} C_{q_2}^{s',t} z_1$ に帰納法の仮定を適用し $s = mh(y) \wedge t = h(z_1)q'n$ となる。 $D_{q'}^{mp',n} \Rightarrow^* z_2$ に (1) を適用し $q' = h(z_2)$ となるので、 $t = h(z_1)h(z_2)n = h(z)n$ となる。最短である $A_{p'q'}^{m,n} \Rightarrow B_{q_1}^{s,t'} C_{q_2}^{s',t}$ の場合

は、明らか。

(1) より $\forall A_p^{m,n} \in V' \setminus \{S'\}, \mathcal{L}(A_p^{m,n}) \subseteq \mathcal{L}(A) \cap h^{-1}(p)$ である。逆に $\mathcal{L}(A) \cap h^{-1}(p) \ni w$ ならば $A_p^{m,n} \Rightarrow^* w$ であることを示す。 $p = h(w)$ である。 $A \Rightarrow_G BC \wedge B \Rightarrow_G^* w_1 \wedge C \Rightarrow_G^* w_2 \wedge w = w_1 w_2$ であるが、帰納法の仮定より $B_{h(w_1)}^{m,qn} \Rightarrow_{G'}^* w_1 \wedge C_{h(w_2)}^{mp,n} \Rightarrow_{G'}^* w_2$ である。また $A_{h(w_1)h(w_2)}^{m,n} \rightarrow B_{h(w_1)}^{m,qn} C_{h(w_2)}^{mp,n} \in P'$ である。 $A \Rightarrow_G w \wedge p = h(w)$ の場合は P' の定義より $A_p^{m,n} \Rightarrow_{G'} w$ となる。以上より $\mathcal{L}(A_p^{m,n}) \supseteq \mathcal{L}(A) \cap h^{-1}(p)$ となり、 $\mathcal{L}(G) = \mathcal{L}(G')$ となる。

第 7 章

最大包含クラスに対する学習アルゴリズム

本節では最も包含的なクラス (Definition 3 および Definition 4) に対する学習アルゴリズムを与える。以下では表記 $h(x, y) := (h(x), h(y))$ を用いる。

$$\begin{aligned}\hat{V}(K) &= \{ [x; u, v] \mid uxv \in K \}, \\ \hat{P}(K) &= \{ [xy; u, v] \rightarrow [x; u, yv][y; ux, v] \mid [xy; u, v], [x; u, yv], [y; ux, v] \in \hat{V}(K) \} \cup \\ &\quad \{ [x; u, v] \rightarrow [x; u', v'] \mid h(u, v) = h(u', v') \wedge [x; u, v], [x; u', v'] \in \hat{V}(K) \} \cup \\ &\quad \{ [x; u, v] \rightarrow [x'; u, v] \mid h(x) = h(x') \wedge [x; u, v], [x'; u, v] \in \hat{V}(K) \} \cup \\ &\quad \{ [a; u, v] \rightarrow a \mid [a; u, v] \in \hat{V}(K) \wedge a \in \Sigma \} \cup \\ &\quad \{ \hat{S} \rightarrow [w, \lambda, \lambda] \mid w \in K \},\end{aligned}$$

以上の下で学習アルゴリズムは以下となる ;

Data: A sequence of strings $w_1, w_2, \dots$

Result: A sequence of CFGs $G_1, G_2, \dots$

Let $\hat{G}$ be a CFG generating empty language;

For $n = 1, 2, \dots$ **do**

 Read the next string w_n ;

If $w_n \notin \mathcal{L}(\hat{G})$ **then**

 let $\hat{G} = \langle \Sigma, \hat{V}(K), \hat{P}(K), \hat{S} \rangle$ where $K = \{w_1, w_2, \dots, w_n\}$

end if

output $\hat{G}$

End For

以下でこのアルゴリズムの正当性を証明する。 $L_* = \{w_i \mid i < \omega\}$ を h -代入可能な CFL であると仮定する。まず不正な学習を行わないこと、つまり $\mathcal{L}(\hat{G}(K)) \subseteq L_*$ を示す。そのための補題を証明する。

補題 3 $[x; u, v] \Rightarrow^* w$ ならば $uwv \in L_* \wedge h(x) = h(w)$.

証明 (1) $[x; u, v] \Rightarrow a$ の場合、 $a = x$ であり、また $uav = uxv \in L_*$ である。

(2) $[x; u, v] \Rightarrow [x; u', v'] \Rightarrow^* w$ の場合、 $\{uxv, u'xv', u'wv'\} \subseteq L_*$ かつ $h(u, v) = h(u', v')$ 、帰納法の仮定より $h(x) = h(w)$ であるから L_* の h -代入可能性より $uwv \in L_*$ となる。

(3) $[x; u, v] \Rightarrow [x'; u, v] \Rightarrow^* w$ の場合、 $h(x) = h(x')$ であり、また帰納法の仮定より $h(x') = h(w) \wedge uwv \in L_*$ となる。

(4) $[xy; u, v] \Rightarrow [x; u, yv][y; ux, v] \wedge [x; u, yv] \Rightarrow^* w_1 \wedge [y; ux, v] \Rightarrow^* w_2 \wedge w = w_1 w_2$ の場合、帰納法の仮定より $\{uw_1yv, uxw_2v, uxyv\} \subseteq L_* \wedge h(w_1) = h(x) \wedge h(w_2) = h(y)$ であり、それゆえ $h(uw_1, v) = h(ux, v)$ となる。よって L_* の h -代入可能性より $uw_1w_2v \in L_*$ となる。

Remark 2 ちなみにルールを $[x; u, v] \rightarrow [x'; u', v']$ if $h(u, x, v) = h(u', x', v')$ としてしまうと言語の獲得の段階で支障が出てしまう。これは $u'xv' \in K$ という“証拠”が不足してしまう為である。

定理 4 $\forall K \in \mathcal{P}_F(\Sigma^*), \mathcal{L}(\hat{G}(K)) \subseteq L_*$.

証明 $\hat{S} \Rightarrow^* w$ ならば、ある $x \in K$ が存在して $\hat{S} \Rightarrow^* [x; \lambda, \lambda] \Rightarrow^* w$ である。Lemma 3 より $w \odot \langle \lambda, \lambda \rangle \in L_*$ である。

以下で学習が成功すること ; $\mathcal{L}(\hat{G}(K)) \supseteq L_*$ を示す。以下の学習の仮定を要請する ;

L_* を学習の目的の h -substitutable 文脈自由言語とし、**lemma2** で保障されている文脈自由文法の形に変形された $G_* = \langle \Sigma, V, P, S \rangle$ で生成されているものとする。さらに $K \supseteq \text{CS}(G_*)$ を正の例の条件として仮定する。また言語は空語を含まないと仮定しておく。すなわち $\lambda \notin L_*$ とする。

Remark 3 任意の presentation は $\text{CS}(G_*)$ を必ず何らかの段階で含みうる。

補題 5 学習の仮定の下で、 $A \rightarrow B_1 B_2 \in P$

ならば $[\omega(B_1)\omega(B_2); \chi(B_1 B_2)] \Rightarrow_{\hat{G}(K)}^* [\omega(B_1); \chi(B_1)][\omega(B_2); \chi(B_2)]$ となる。

証明

Lemma2 より $h(\omega(A)) = h(\omega(B_1)\omega(B_2))$ である。同様に $h(\langle u, \omega(B_2)v \rangle) = h(\chi(B_1))$ 、 $h(\langle u\omega(B_1), v \rangle) = h(\chi(B_2))$ となる (但し $\langle u, v \rangle := \chi(B_1 B_2)$ 、 $h(\langle x, y \rangle) := \langle h(x), h(y) \rangle$ としている。) 然るに $\omega(B_1 B_2) = \omega(B_1)\omega(B_2)$ 、 $\omega(B_1) \odot \chi(B_1), \omega(B_2) \odot \chi(B_2)$ 、 $\omega(B_1 B_2) \odot \chi(B_1 B_2) \in \text{CS}(G_*)$ となり、学習アルゴリズムの定義より $[\omega(B_1)\omega(B_2); u, v] \Rightarrow_{\hat{G}(K)} [\omega(B_1); u, \omega(B_2)v][\omega(B_2); u\omega(B_1), v]$ 、 $[\omega(B_1); u, \omega(B_2)v] \Rightarrow_{\hat{G}(K)} [\omega(B_1); \chi(B_1)]$ 、 $[\omega(B_2); u\omega(B_1), v] \Rightarrow_{\hat{G}(K)} [\omega(B_2); \chi(B_2)]$ が導かれる。

補題 6 学習の仮定の下で、 $\forall A \in V \forall w \in \Sigma^*, A \Rightarrow_{G_*}^* w$

ならば $[\omega(A); \chi(A)] \Rightarrow_{\hat{G}(K)}^* w$ となる。

証明 Lemma5 を使う。更に、 $A \rightarrow B_1 B_2 \in P$ ならば $[\omega(A); \chi(A)] \Rightarrow^* [\omega(B_1)\omega(B_2); \chi(B_1 B_2)]$ である。なぜなら $h(\omega(A)) = h(\omega(B_1 B_2)) \wedge h(\chi(A)) = h(\chi(B_1 B_2)) \wedge \omega(A) \odot \chi(A), \omega(B_1 B_2) \odot \chi(A), \omega(B_1 B_2) \odot \chi(B_1 B_2) \in \text{CS}(G_*) \wedge$

$\omega(B_1B_2) = \omega(B_1)\omega(B_2)$ であるため $[\omega(A); \chi(A)] \Rightarrow [\omega(B_1)\omega(B_2); \chi(A)] \Rightarrow [\omega(B_1)\omega(B_2); \chi(B_1B_2)]$ であるから。

定理 7 学習の仮定の下で、 $\mathcal{L}(\hat{G}(K)) \supseteq L_*$.

証明 Lemma 6 より $S \Rightarrow_{G_*}^* w$ ならば $[\omega(S); \chi(S)] \Rightarrow_{\hat{G}(K)}^* w$ となる。ところで $\chi(S) = \langle \lambda, \lambda \rangle$ であるから $[\omega(S); \chi(S)] = [\omega(S); \lambda, \lambda]$ となりまた $\omega(S) \odot \chi(S) \in \text{CS}(G_*)$ であるから $S \rightarrow [\omega(S); \chi(S)] \in P'$ となる。

第 8 章

正しい学習に必要な特徴的有限集合の大きさについて

本節では先行研究よりいくらか特徴的有限集合が圧縮できたことを主張する。

Yoshinaka[5] の論文では目的文法を $G_* = \langle \Sigma, V_*, P_*, S_* \rangle$ とした言語 $L_* = \mathcal{L}(G_*)$ の学習に必要な特徴的有限集合を $K_{G_*} := \{y \odot \chi(A) \in \Sigma^* \mid y \in K_A \wedge A \in V_*\}$ (但し、各 $A \in V_*$ に対し $K_A := \{u\omega(\beta_0)\dots\omega(\beta_{n-1})v \in \Sigma^* \mid n \geq 2 \wedge A \rightarrow uB_0\dots B_{n-1}v \wedge \forall i < n(B_i \rightarrow \beta_i)\} \cup \{w \in \Sigma^* \mid A \rightarrow w \in P_*\}$) で定義している。但し、目的文法 G_* は k, l -グライバッハ標準形のかたちになっているものとする (ある文脈自由文法 $G = \langle \Sigma, V, P, S \rangle$ が k, l -グライバッハ標準形であるとは全ての P_* のメンバがある $w \in \Sigma^{\leq k+l} A \rightarrow w$ またはある $x \in \Sigma^k, z \in \Sigma^l$ について $A \rightarrow x\alpha z$ のかたちであるものと定義される。)。

この論文の学習アルゴリズムでは学習に必要な特徴的有限集合の定義 $CS(G_*) := \{\omega(\beta) \odot \chi(A) \mid A \rightarrow \beta \in P_*\}$ は K_{G_*} に包含される集合である。これは $A \rightarrow \beta \in P_*$ ならば $\omega(\beta) \in K_A$ となることから明らかである。

第 9 章

クラスの性質と言語の具体例

この節では言語の具体例を与えつつ導入したクラス間の集合的、代数的性質などを議論する。

主張 4 ある準同形写像 h に対して h -代入可能であり、かつその Kleene 閉包がどんな準同形 h' に対しても h' -代入可能にならない言語が存在する。

証明 $L := \{a^n b a^n \mid n \geq 0\}$ とする。 L は 0,0-代入可能言語である。 M を有限モノイドとし、 $h' : \Sigma^* \rightarrow M$ を準同形写像とする。鳩ノ巣論法より $\exists k, l \in \mathbb{N}, h'(a^k) = h'(a^l) \wedge k < l$ であるから、 $h'(ba^k ba^k b) = h'(ba^l ba^l b)$ 、 $C_{L^*}(ba^k ba^k b) \cap C_{L^*}(ba^l ba^l b) \ni \langle a^k, a^k \rangle$ となる。しかし $\langle a^l, a^l \rangle \in CL^*(ba^l ba^l b) \setminus CL^*(ba^k ba^k b)$ である。

以下の命題が成り立つ；

主張 5 任意の正規言語 L に対しある準同形写像 h が存在し、 L は h -代入可能である。

証明 正規言語 $L \subseteq \Sigma^*$ に対して有限モノイド M と準同形写像 $h : \Sigma^* \rightarrow M$ 、部分集合 $F \subseteq M$ が存在して $L = h^{-1}(F)$ であるとする。このとき、 L は h -代入可能である。つまり、 $\{uxv, ux'v, u'xv'\} \subseteq L$ かつ $h(u, x, v) = h(u', x', v')$ ならば $u'x'v' \in L$ となる。

言語の共通部分に関しては以下が成り立つ；

主張 6 L_i が h_i -代入可能 ($i = 1, 2$) ならば、ある準同形写像 h が存在し $L_1 \cap L_2$ は h -代入可能である。

証明 準同形写像を $h_i : \Sigma^* \rightarrow M_i$ とする。 $h(x) := (h_1(x), h_2(x))$ とすれば、 $h : \Sigma^* \rightarrow M_1 \times M_2$ は準同形写像となり $h(x) = h(y)$ iff $h_1(x) = h_1(y) \wedge h_2(x) = h_2(y)$ となる。 $\{uxv, ux'v, u'xv'\} \subseteq L_1 \cap L_2$ かつ $h(u, x, v) = h(u', x', v')$ ならば $\{uxv, ux'v, u'xv'\} \subseteq L_i$ かつ $h_i(u, x, v) = h_i(u', x', v')$ ($i = 1, 2$) となり $u'x'v' \in L_i$ ($i = 1, 2$) となる。つまり $u'x'v' \in L_1 \cap L_2$ となる。

言語の連結に関しては以下の命題が成り立つ。

主張 7 L_i が h_i -代入可能 ($i = 1, 2$) であっても $L_1 \cdot L_2$ がどんな準同形写像 h に対しても h -代入可能とならない場合がある。

証明 そうでないと仮定する。 $L_0 := \{a^n b a^n \mid n \geq 0\}$ 。 L_0 は 0,0-代入可能であるので、 $L := L_0 \cdot L_0 \cdot L_0$ はある準同形写像 h に対して h -代入可能とならねばならない。 M を有限モノイドとし、 $h : \Sigma^* \rightarrow M$ を準同形写像とする。鳩ノ巣論法より、 $\exists k, l \in \mathbb{N}, h(a^k) =$

$h(a^l) \wedge k < l$ であるから、 $h(ba^kba^kb) = h(ba^lba^lb)$ および $C_L(ba^kba^kb) \cap C_L(ba^lba^lb) \ni \langle a^k, a^k \rangle$ となる。しかし、 $\langle a^l, a^l \rangle \in C_L(ba^lba^lb) \setminus C_L(ba^kba^kb)$ であり矛盾する。

言語の準同形写像の逆像に関しては以下の事実が成立する。

事実 5 $L \subseteq \Sigma^*$ が h -代入可能言語であり、 $g: T^* \rightarrow \Sigma^*$ を別のアルファベット T への準同形写像とする。このとき $g^{-1}(L) \subseteq T^*$ は $h \circ g$ -代入可能言語となる。

以下の言語はどんな k, l に対しても $C_{k,l}$ に属さないことが Yoshinaka(2008) で示されているが、これはどんな準同形写像 h に対しても C_h に属さないことを示す。

主張 8 CFG $G = \{S \rightarrow aSS, S \rightarrow b\}$ に対して $L := \mathcal{L}(G)$ とする。 L はどんな準同形写像 h に対しても h -代入可能ではない。

証明

M を有限モノイドとし、 $h: \Sigma^* \rightarrow M$ を準同形写像とする。仮に L が h -代入可能であるとする。有限集合 M^2 上で $\{\langle h(a^n), h(b^n) \rangle\}_{n < \omega}$ を動かす鳩ノ巣論法より、 $\exists N, k \in \mathbb{N}$ 、 $h(a^N) = h(a^{N+k}) \wedge h(b^N) = h(b^{N+k})$ となる。また $h(b^{N+1}) = h(b^{N+k+1})$ であり、さらに $a^{N+k}(b^N a^N) b^{N+k+1} = a^k(a(a^{N-1}b^N)(a^N b^{N+1}))b^k \in L$ 、
 $a^{N+k}(b^{N+k} a^{N+k}) b^{N+k+1} = a(a^{N+k-1}b^{N+k})(a^{N+k} b^{N+k+1}) \in L$ 、そして
 $a^N(b^N a^N) b^{N+1} = a(a^{N-1}b^N)(a^N b^{N+1}) \in L$ であるが、然るに
 $a^N(b^{N+k} a^{N+k}) b^{N+1} \notin L$ となり矛盾する。最後の部分は $a^N(b^{N+k} a^{N+k}) b^{N+1} = aSS$ の形にならねばならないが、これは補題； $a^n b^m \in L \Rightarrow m = n + 1$ を示せば
 $a^N(b^{N+k} a^{N+k}) b^{N+1}$ を後ろから読むとありえないことがわかる。補題の証明は $\mathcal{L}(G)$ を短い順に出力してゆくと $n = 0, 1$ の場合は正しい事がわかり、一般には $aSS \Rightarrow^* a^n b^m$ とすると後ろから読むことにより $S \Rightarrow^* aSb \wedge S \Rightarrow^* a^{n-1}b^{m-1}$ という場合しかありえないことから帰納的に示される。

参考文献

- [1] Clark, A., Eyraud, R.: Polynomial identification in the limit of substitutable context-free languages. *Journal of Machine Learning Research* 8, 1725–1745 (2007)
- [2] F. Coste, G. Garet, J.N.: Local substitutability for sequence generalization. *JMLR: Workshop and Conference Proceedings* 21, 97–111 (2012)
- [3] Gold, E.M.: Language identification in the limit. *Information and Control* 10(5), 447–474 (1967), <http://groups.lis.illinois.edu/amag/langev/paper/gold67limit.html>
- [4] de la Higuera, C.: Characteristic sets for polynomial grammatical inference. *Machine Learning* 27, 125–138 (1997)
- [5] Yoshinaka, R.: Identification in the limit of k, l -substitutable context-free languages. *Grammatical Inference: Algorithms and Applications Lecture Notes in Computer Science* 5278, 266–279 (2008)
- [6] Yoshinaka, R.: Efficient learning of multiple context-free languages with multidimensional substitutability from positive data. *Theoretical Computer Science* 412, 1821–1831 (2011)