

固定有限モノイド型付けの下での文脈自由言語の分布学習

Takayuki Kuriyama

独立研究者

growup.kuriyama@gmail.com

概要

本論文では、有限モノイドへの準同型 $h: \Sigma^* \rightarrow M$ の核 $\sim_h$ の下で文脈自由言語の分布学習を研究する。同じ h -値をもち、一つの文脈を共有する非空因子は、すべての文脈を共有することを要求する。この h に対し、集合駆動型再構成作用素 $\mathcal{B}_h$ は文脈自由 $\sim_h$ -代入可能標的を有限個の正例証拠から厳密に再構成し、別の保守的逐次学習器はすべての非空標的を Gold の意味で極限同定する。再構成と各更新は多項式時間である。標準証拠の大きさは、標的非終端記号を有限な h -値で分割した後に得られる最短生成語によって制御され、その長さは通常の文法厚みより指数的に大きくなり得る。従って一般の h では、特徴データ上界は通常の文法厚みだけでなく、この型付き厚みによって自然に記述される。局所自明有限半群についての古典的特徴づけから、 h の非空因子上の型が固定接頭辞 – 接尾辞窓で決定されることと、正の像半群 $h(\Sigma^+)$ が局所自明であることが同値である。この場合には通常の文法厚みで十分であり、この局所自明な fixed- h 体制の言語クラスの和は Yoshinaka の固定窓階層とちょうど一致する。任意の固定 h の線形標的では、線形 CFG サイズに関して多項式の特徴データを得る。さらに、Yoshinaka による既知の正則分離を踏まえ、適切な固定準同型に対し、どの固定窓クラスにも属さない非正則線形・非線形文脈自由の標的を与え、種類の括弧の Dyck 言語がどの固定型付けクラスにも属さないことを示す。

キーワード： 文法推論；文脈自由言語；分布学習；正例からの同定；有限モノイド

1 序論

1.1 背景と動機

Gold [3] は、すべての有限言語と少なくとも一つの無限言語を含む言語クラスは、正例データのみから極限同定できないことを示した。文脈自由言語では、比較してよい部分文字列を文脈間で制限する分布学習により正の結果が回復される。古典的な例として Clark-Eyraud の代入可能性 [9] と Yoshinaka の (k, ℓ) -代入可能性 [16] がある。一般的背景は de la Higuera [8] を、範疇文法の正例学習可能性に関する結果は Kanazawa [2, 1] を参照されたい。特に Kanazawa の著書は、rigid grammar の特徴標本および k -valued 範疇文法の文字列言語族についての有限弾力性による議論を扱う [1, Chapters 5 and 8]。これは相補的な研究系列であり、本論文では代わりに終端因子の有限モノイド型付けを固定して分布的代入可能性を要求する。

■2014 年の先行研究と一般 signature による学習。本稿は、著者の 2014 年公開プレプリント [11] を証明と学習器の面で大幅に修正・拡張したものである。その初期稿にはすでに、可認識同値関係に相対化した代入可能性と正例による学習法が提案されていた。その公開は Yoshinaka [12] の一

33 般的な多ソート signature の枠組みの公刊より早い、この時系列は初期稿の全証明や量的主張の
 34 正当性を意味するものではない。Yoshinaka の枠組みでは、本論文で用いる有限モノイド準同型
 35 $h : \Sigma^* \rightarrow M$ によって定まる $h^{-1}(m) \cap \Sigma^+$ の非空な型ごとのコピーを相異なるソートとし、型付
 36 き接続と全文字列ソートへの昇格演算を備えることで、非空因子について本稿と同じ代入可能性条
 37 件が得られる。したがって、固定 h に対する正例学習器の**存在**という質的結論は Yoshinaka [12,
 38 Theorem 1] の一般理論からも導かれる。一方、本稿の特定の再構成・保守的逐次学習器はここで直
 39 接解析する。有限モノイドに固有の寄与は、固定窓の代数的判定条件、型付け変更に伴う閉包性、証
 40 人の個数だけでなく**総符号長**を評価する特徴データ境界、線形クラスの保証、言語クラスの分離であ
 41 る。分布学習の広い背景は Clark–Yoshinaka [13]、局所的代入可能性は Coste–Garet–Nicolas [14]
 42 および Coste–Nicolas [15] を参照されたい。

43 本論文では、この研究計画の可認識合同関係版を考える。 $h : \Sigma^* \rightarrow M$ を有限モノイドへの準同型
 44 とし、 $\sim_h := \ker h$ とする。 $x \in \Sigma^*$ に対し $\mathcal{D}_L(x) := \{(u, v) : uxv \in L\}$ と書く。言語 L が $\sim_h$ -**代入**
 45 **可能**であるとは、非空の x, y について $h(x) = h(y)$ かつ $\mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \emptyset$ ならば $\mathcal{D}_L(x) = \mathcal{D}_L(y)$
 46 が成り立つことをいう。文脈自由な $\sim_h$ -代入可能言語のクラスを $\mathcal{C}_h^{\text{cf}}$ と書き、これを *fixed- h slice*
 47 と呼ぶ。したがって、分布の完全な一致を要求するのは、固定された有限代数的比較の下ですでに一
 48 致する因子だけである。

49 例えば $\Sigma = \{a\}$, $L = \{a, aa\}$ を考える。 $(\lambda, \lambda) \in \mathcal{D}_L(a) \cap \mathcal{D}_L(aa)$ であるが、 $(a, \lambda) \in \mathcal{D}_L(a) \setminus$
 50 $\mathcal{D}_L(aa)$ である。したがって、自明な型付けでは L は代入可能でない。一方、長さの偶奇を記録する
 51 準同型 $h(a^n) = n \bmod 2$ (値域 $\mathbb{Z}/2\mathbb{Z}$) を用いれば、 a と aa は異なる型をもち、 $L \in \mathcal{C}_h^{\text{cf}}$ となる。

52 有限指数のモノイド合同関係、すなわち有限モノイドへの準同型の核は、有限型付けを与える。固
 53 定した h に対し、文脈自由性を仮定しないすべての $\sim_h$ -代入可能言語のクラスを RS_h と書く。表現
 54 力の比較のため、

$$\text{RS} := \bigcup_h \text{RS}_h$$

55 と定める。ここで h は Σ^* 上の有限モノイド準同型全体を動く。すべての正則言語はこの和に属す
 56 る。一方、本論文の学習結果は一つの h をクラス全体に固定した $\mathcal{C}_h^{\text{cf}}$ だけを対象とし、RS 全体の学
 57 習可能性は主張しない。

58 一つの固定接頭辞 – 接尾辞窓と異なり、 h は独立な有限状態の因子特徴を積によって組み合わせら
 59 れる。このように有限型付けそのものを精密化してよいなら、正則フィルタとの交わりや、消去を許
 60 す任意の逆準同型像を、再び有限型付けの枠内で扱える (命題 3.2)。これは一つの *fixed- h slice* を
 61 同じ h のまま閉じるという主張ではない。代数的な判定条件によって、非空因子上で固定接頭辞 –
 62 接尾辞窓がすでに型を決めている場合が特徴づけられ (命題 3.5)、対応する特徴データ上界も得られ
 63 る (系 7.4)。後述の非正則線形例と非線形例は固定窓を超える表現力を示し、カウンタや Dyck 言
 64 語に関する障害はその表現力の限界を示す。

65 h の指定は事前に与えるバイアスの選択であり、オートマトン推論における型付けまたは領域バイ
 66 アス [20] と関連する。ただし本論文では文字の出現とその外側文脈ではなく、終端因子全体を型付
 67 けする。線形文法の場合、生成語型付けは生成規則ラベル列上に正則制御集合も誘導する。これは
 68 Takada の正則 control-set 法 [17, 18] との限定的だが具体的な接点である (第 8 節)。両学習枠組
 69 みの同値性は主張しない。

1.2 貢献と主要結果

本論文の主要な貢献は三つである.

- (1) **固定 h に対する学習.** 集合駆動型作用素 $\mathcal{B}_h$ は, $\mathcal{C}_h^{\text{cf}}$ の任意の標的を有限個の標準正例証拠から厳密に再構成する. 別の保守的逐次学習器 $\mathcal{A}_h$ はすべての非空標的を Gold の意味で同定し, 再構成と各更新は蓄積標本に関して多項式時間である.
- (2) **定量的保証.** 任意の固定 h に対し, 特徴データの大きさを, 文法サイズと, 標的非終端記号を h -値で分割した後の最短終端生成語の長さによって上から抑える. 有限型付けがある固定接頭辞 – 接尾辞窓だけですでに決まる場合には, この上界は元文法の通常の最短生成語パラメータで表せる. 線形 fixed- h 標的では, 線形 CFG のサイズに関する多項式特徴データ上界が得られる. また, 分割後の最短生成語が元文法のものより指数的に長くなり得ることも示す.
- (3) **構造上・表現力上の位置.** 単一の fixed- h slice の閉包性ではなく, 有限型付けの精密化と積によって得られる閉包性を示し, 固定接頭辞 – 接尾辞窓によって決まる有限型付けを特徴づけ, 線形の生成語型付けと正則制御集合とを関連づける. 固定窓の外にある非正則線形・非線形の具体例に加え, カウンタ・Dyck 言語の障害と Clark の congruential family との比較により 枠組みの範囲を明らかにする.

1.3 論文の構成

第 2–3 節で枠組みを準備し, 第 4–5 節で学習可能性を証明する. 第 6–8 節で定量的結果を与え, 第 9 節で表現力を比較する. 長い正規化証明は付録に置く.

2 準備

Σ を有限アルファベットとし, Σ^* を単位元 λ をもつ自由モノイドとする. また $\Sigma^+ := \Sigma^* \setminus \{\lambda\}$ とおく. 対 $(u, v) \in \Sigma^* \times \Sigma^*$ を **終端文脈** と呼ぶ. $L \subseteq \Sigma^*$ と $x \in \Sigma^*$ に対し, L における x の **分布** を $\mathcal{D}_L(x) := \{(u, v) \in \Sigma^* \times \Sigma^* : uxv \in L\}$ と定める. L の **構文合同関係** は, $x, y \in \Sigma^*$ に対して $x \equiv_L y \iff \mathcal{D}_L(x) = \mathcal{D}_L(y)$ により定める. $x \equiv_L y$ のとき, x と y は **構文合同** であるという [5, Chapter III, Proposition 10.2]. 通常通り, $\equiv_L$ はモノイド合同であり, $x \equiv_L x'$ かつ $y \equiv_L y'$ ならば $xy \equiv_L x'y'$ である.

語 $w \in \Sigma^*$ と文字 $a \in \Sigma$ に対し, $|w|_a$ は w における a の出現回数を表す.

文脈自由文法 (CFG) は有限非終端記号集合 V , 開始記号 $S \in V$, および $A \in V, \alpha \in (V \cup \Sigma)^*$ に対する生成規則 $A \rightarrow \alpha$ からなる組 $G = (V, \Sigma, P, S)$ である. **文形式**とは $(V \cup \Sigma)^*$ の任意の語である. G における一段階導出を $\alpha \Rightarrow_G \beta$ と書き, その反射推移閉包を $\Rightarrow_G^*$ と書く. したがって $L(G) := \{w \in \Sigma^* : S \Rightarrow_G^* w\}$. $A \in V$ に対して $L_G(A) := \{w \in \Sigma^* : A \Rightarrow_G^* w\}$ とおく. 非終端記号 $X \in V$ に対し, $S \Rightarrow_G^* uXv$ が成り立つとき, 終端文脈 (u, v) を G における X の **終端到達文脈** と呼ぶ. 非終端記号が S から到達可能な文形式中に現れるとき **到達可能** であるといい, 終端語を導出するとき **生産的** であるという. 到達可能性または生産性の少なくとも一方を欠く非終端記号を **無用** といい, λ を導出する非終端記号を **空語導出可能 (nullable)** という. $A, B \in V$ に対する生成規

則 $A \rightarrow B$ を **単位規則** という。単位閉包とは、単位生成規則が非終端記号上に誘導する関係の反射推移閉包である。すべての非終端記号が到達可能かつ生産的である文法を **縮約済み** という。非空言語を生成する文法について、その **トリム** (縮約部分) とは、まず生産的でない非終端記号とそれらに接続する生成規則を削除し、次に残った文法で開始記号から到達不能な非終端記号とそれらに接続する生成規則を削除して得られる部分文法をいう。各右辺に高々一つの非終端記号しか現れない CFG を **線形** という。二分化とは、新たな非終端記号を用いて長い右辺を同値な二項生成規則の鎖へ置き換えることをいう。CFL を文脈自由言語全体のクラスとする。任意の有限表現 $\mathcal{R}$ に対し、 $|\mathcal{R}|$ は固定した妥当な符号化の長さを表すものとする。文法については、これは通常の生成規則中の記号数と多項式の範囲で同値である。ここでは Wakatsuki–Tomita [10] が用い、Yoshinaka [16] が採用した最短生成語に基づく **厚み** を用いる (Eyraud–Heinz–Yoshinaka [22, Definition 2.11] も参照)。縮約済み文法を $G = (V, \Sigma, P, S)$ として

$$\tau_G := \max_{A \in V} \min \{ |w| : A \Rightarrow_G^* w, w \in \Sigma^* \}$$

と定める。すなわち τ_G は、各非終端記号の最短終端生成語の長さを取り、その最大値をとったものである。

2.1 正例データからの学習

Gold の explanatory model [3] を用いる。 H_0 を、一つの開始記号をもち生成規則をもたない固定 CFG とし、 $L(H_0) = \emptyset$ とする。以下のテキスト規約は非空の標的言語に限定する。空言語はこのテキストに基づく Gold の記述から除外し、別途 H_0 により表す。同値に、通常の pause 記号をテキストに加えることで空標的を含めることもできるが、余分な記法を避けるためにここでは非空テキスト規約を用いる。非空言語 L に対し、**テキスト** とは、 L の各語が少なくとも一度は現れる L 上の無限列 $T = (w_1, w_2, \dots)$ である。 $T[n] = (w_1, \dots, w_n)$ および $K_n := \{w_1, \dots, w_n\}$ と書く。学習器 $\mathcal{A}$ が非空言語 L を **極限同定** するとは、 L の任意のテキスト T に対して、ある n_0 と文法 H が存在し、すべての $n \geq n_0$ について $\mathcal{A}(T[n]) = H$ かつ $L(H) = L$ が成り立つことをいう。したがって、仮説表現そのものが最終的に安定する。逐次学習器が **保守的** であるとは、新たに提示された正例データが現在の仮説によって生成されない場合にのみ、その現在の仮説を変更することをいう。

この逐次学習器とは別に、**集合駆動型再構成作用素** B を考える。これは有限語集合から文法への写像であり、とくにその出力は提示順序や重複回数に依存しない。任意の有限標本 K に対して $K \subseteq L(B(K))$ が成り立つとき、 B は **標本整合的** であるという。有限集合 $C \subseteq L$ が L の B に対する **特徴標本** であるとは、任意の有限 K について $C \subseteq K \subseteq L$ ならば $L(B(K)) = L$ が成り立つことをいう。これは de la Higuera の多項式文法推論枠組み [7] の特徴標本に対応する。学習器に相対的な特徴標本とその符号化サイズについては [8, Section 7.3.3, Definition 7.3.3] も参照されたい。ただし同書の定義は逐次的提示に対するものであり、本論文の条件は明示的に集合駆動型である。標本サイズを $\|K\| := \sum_{w \in K} (|w| + 1)$ で測る^{*1}。したがって λ も 1 を寄与する。以下では **特徴データ** という語を、特徴標本 C の符号化サイズ $\|C\|$ の略称としてのみ用いる。定量的結果では、 $B(K)$ の多項式時間構成と、多項式に抑えられる特徴データサイズを組み合わせる。多項式更新時間と多

^{*1} $+1$ は、 $K = \{\lambda\}$ のような非空標本のサイズが 0 になることを防ぐ。また $|K| \leq \|K\|$ となるため、正例数も同じサイズ尺度で抑えられる。

項式特徴標本サイズは別の評価基準であり [8, Sections 7.3.2–7.3.3], それらの一方だけから逐次的
 な多項式時間・データ同定は導けない. Eyraud–Heinz–Yoshinaka [22, Definitions 2.5 and 2.8] は,
 逐次的な多項式時間・データ同定と集合ベースの基準を区別する. 前者では特徴標本を観測した時点
 で正しい仮説に到達し, その後は仮説が安定しなければならない. 後者は, 特徴標本を含む任意の有
 限標本から正しく再構成できることを要求する. 本論文の多項式特徴データ保証は集合駆動型の B_h
 に対するものであり, 逐次学習器 A_h の多項式データ保証ではない. 後者の Gold 安定化は系 5.5 で
 別途示す.

2.2 固定有限モノイド型付け

有限モノイド M と準同型 $h: \Sigma^* \rightarrow M$ を固定する. これらは M の乗法表および各 $a \in \Sigma$ に対
 する文字像 $h(a)$ によって表現される. したがって $h(w)$ は左から右への積によって $O(|w|)$ 時間で
 計算できる. 以下で固定準同型が **効率的に計算可能** であるというのはこの意味である.

有限半群 S の幂等元全体を $E(S)$ と書く. $e \in E(S)$ と $t \in S$ のすべてについて $ete = e$ が成り
 立つとき, S は **局所自明** であるという. h の**正の像半群**は $h(\Sigma^+)$ であり, これは M の単位元を含
 むとは限らない.

定義 2.1 (固定- h 代入可能性). 言語 $L \subseteq \Sigma^*$ が $\sim_h$ -代入可能 であるとは, すべての $x, y \in \Sigma^+$ に
 ついて, $h(x) = h(y)$ と $\mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \emptyset$ から $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ が従うことをいう.

空語は内部の代入可能因子としては用いない. $\lambda \in L$ の場合には, 再構成において開始記号を通じ
 て別途処理する.

非空内部因子 x に対して, $h(x)$ をその **生成語型** と呼ぶ. 文脈自由 $\sim_h$ -代入可能言語のクラスを
 $\mathcal{C}_h^{\text{cf}}$ と書き,

$$\mathcal{C}_h^{\text{lin}} := \{L \in \mathcal{C}_h^{\text{cf}} : L \text{ はある線形 CFG により生成される}\}$$

と定める. したがって $\mathcal{C}_h^{\text{lin}}$ は線形言語からなる部分クラスである.

3 固定可認識代入可能性

固定 h に対し $\text{RS}_h := \{L \subseteq \Sigma^* : L \text{ は } \sim_h\text{-代入可能}\}$ とおく. fixed- h slice は $\mathcal{C}_h^{\text{cf}} = \text{RS}_h \cap \text{CFL}$
 であり, $\mathcal{C}_h^{\text{lin}}$ はそのうち線形 CFG で生成される言語からなる. 表現力の比較に限り, h を Σ^* 上
 の有限モノイド準同型全体に動かして $\text{RS} := \bigcup_h \text{RS}_h$ とする. アルファベットを明示するときは
 $\text{RS}_h(\Gamma)$, $\text{RS}(\Gamma)$ と書き, 以下の包含はアルファベットごとに解釈する. 学習結果は常に一つの固定
 h を対象とする.

命題 3.1. 言語が正則であることと, ある有限モノイド M への準同型 $h: \Sigma^* \rightarrow M$ と $\text{Acc} \subseteq M$ に
 対して $h^{-1}(\text{Acc})$ の形に書けることは同値である. 正則言語 L については h として構文準同型を取
 ることができ, その核は $\equiv_L$ である. さらに任意の固定 h と $\text{Acc} \subseteq M$ に対し, $h^{-1}(\text{Acc})$ は $\sim_h$ -代
 入可能である. 従ってすべての正則言語は RS に属する.

Proof. 最初の二つの主張は古典的な構文モノイドによる特徴づけから従う [5, Chapter III, Propo-
 sitions 10.1–10.2]. $L = h^{-1}(\text{Acc})$ かつ $h(x) = h(y)$ なら, すべての u, v に対し $h(uxv) = h(uyv)$

171 なので $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ である. □

172 非空アルファベット上では, RS も $RS \cap CFL$ も正例データから極限同定できない. 命題 3.1 に
 173 より両者はすべての有限言語と Σ^* を含むため, Gold の定理が適用されるからである. 同様に
 174 Yoshinaka [16, Section 4] は, 彼の設定では (k, ℓ) -代入可能な文脈自由言語クラス全体の和が正例か
 175 ら極限同定できないことを指摘している. その理由は, その和が λ を含まないすべての有限言語と
 176 少なくとも一つの無限言語を含むからである. 以下で学習可能性を主張するのは, 個別の $\mathcal{C}_h^{\text{cf}}$ のみに
 177 対してである.

178 型付けの精密化には, 定義 2.1 で比較される非空因子上で単調性がある. $\ker h'|_{\Sigma^+} \subseteq \ker h|_{\Sigma^+}$ なら
 179 ば, h' は比較を要求する因子対を減らすので $RS_h \subseteq RS_{h'}$ である. ただし精密化は, 後の定量解析で
 180 使う型付き文法を大きくし得る. 二つの有限型付け h, g に対し $\ker(h \times g)|_{\Sigma^+} = \ker h|_{\Sigma^+} \cap \ker g|_{\Sigma^+}$
 181 だから $RS_h \cup RS_g \subseteq RS_{h \times g}$ であり, 窓情報と別の有限特徴を標的ごとに型付けを変えずに合成で
 182 きる.

183 Yoshinaka [16, Proposition 1] は, 固定窓代入可能言語が正則言語との交わりや消去を許す逆準
 184 同型像について閉じないことを示した. 一方, 非消去準同型の逆像については閉包性が成り立つ. こ
 185 れに対し, 次の命題は, 有限型付けを変更することで, 正則フィルタとの交わりや消去的準同型によ
 186 る逆像を扱えることを示す.

187 **命題 3.2** (有限情報に関する閉包性). $h : \Sigma^* \rightarrow M$ と $g : \Sigma^* \rightarrow N$ を有限モノイド準同型とする.

188 (i) $L \in RS_h$ かつ $J \in RS_g$ ならば $L \cap J \in RS_{h \times g}$ である.

189 (ii) $Q = g^{-1}(F)$ が正規言語で $L \in \mathcal{C}_h^{\text{cf}}$ ならば $L \cap Q \in \mathcal{C}_{h \times g}^{\text{cf}}$ である.

190 (iii) $\varphi : \Gamma^* \rightarrow \Sigma^*$ を, 消去的でもよい任意の準同型とする. $B_\varphi = \{1, \zeta\}$ を零元 ζ をもつ二元モ
 191 ノイドとし, $\varphi(w) = \lambda$ のときかつそのときに限り $e_\varphi(w) = 1$, それ以外では $e_\varphi(w) = \zeta$ と
 192 定め, $\hat{h} = (h \circ \varphi) \times e_\varphi$ とおく. $L \in RS_h$ ならば $\varphi^{-1}(L) \in RS_{\hat{h}}$ であり, さらに $L \in \mathcal{C}_h^{\text{cf}}$ な
 193 らば $\varphi^{-1}(L) \in \mathcal{C}_{\hat{h}}^{\text{cf}}$ である.

194 *Proof.* (i) について, 非空因子 x, y が同じ $(h \times g)$ -型をもち, $L \cap J$ で文脈を共有するとする. する
 195 と L では同じ h -型で文脈を共有し, J では同じ g -型で文脈を共有する. 従って $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ か
 196 つ $\mathcal{D}_J(x) = \mathcal{D}_J(y)$ なので, $\mathcal{D}_{L \cap J}(x) = \mathcal{D}_{L \cap J}(y)$ である. (ii) は (i), 命題 3.1, および CFL の正
 197 規言語との交わりに関する閉包性から従う.

198 (iii) では, $\varphi(uv) = \lambda$ であることと $\varphi(u) = \varphi(v) = \lambda$ であることが同値なので, e_φ は準同型であ
 199 る. 同じ $\hat{h}$ -型をもつ非空因子 x, y が $\varphi^{-1}(L)$ で文脈を共有するとする. $e_\varphi(x) = e_\varphi(y) = 1$ ならば
 200 $\varphi(x) = \varphi(y) = \lambda$ なので, 逆像言語での分布は自明に一致する. そうでなければ両像は非空で, 同じ
 201 h -型をもち, 共有文脈の像が L における共通文脈になる. 従って fixed- h 代入可能性から L での分
 202 布が一致し, 文脈を φ で引き戻せば $\mathcal{D}_{\varphi^{-1}(L)}(x) = \mathcal{D}_{\varphi^{-1}(L)}(y)$ を得る. context-free の主張は CFL
 203 の逆準同型に関する閉包性による. □

204 **■型付けはいつ有用か.** 標的 L に対する正しさという観点では, 定義 2.1 より, h は, 共通文脈を
 205 もつのに分布が異なる任意の二つの非空因子を分離しなければならない. 同値に, 有用な型付けを選
 206 ぶ問題は有限指数モノイド合同による分離問題であり, そのような分布上の衝突を $\ker h$ が潰しては
 207 ならない. 従って型付けの精密化は安全であり, 積型付けでは, 衝突する因子対を少なくとも一方
 208 の成分が分離すればよいので, 独立な有限特徴を組み合わせられる. 後の補題 9.3 は, そのような

衝突因子の無限な pairwise family があれば有限型付け自体が存在しないという対応する障害を与える。一方、定量的効率率は別問題である。精密化は再構成上界で用いる型付き文法を大きくし得る。命題 6.3 は元文法厚みから型付き厚みへの指数ギャップを示し、第 7 節と第 8 節は、そのコストを制御できる十分な場合を与える。

$\ker h$ を Σ^+ に制限した関係が構文合同 $\equiv_L$ を精密化するなら $L \in \text{RS}_h$ である。逆は通常の代入可能性ですでに成り立たない。 $L_c := \{a^n cb^n : n \geq 0\}$ を考える。定義 2.1 の非空因子規約の下で L_c は Clark–Eyraud 代入可能だが、 $\equiv_{L_c}$ は無限指数である。実際 $1 \leq i < j$ に対して文脈 (a, cb^{i+1}) は a^i と a^j を区別する。

3.1 古典的特殊場合

Clark–Eyraud の元の定義 5 は空語を含む因子を扱っている [9]。ここでは Clark [21] に従い λ を比較から除く。この違いは $L = a^+$ でも重要である。 (a, λ) は $\mathcal{D}_L(\lambda)$ と $\mathcal{D}_L(a)$ の双方に属するが、 (λ, λ) は $\mathcal{D}_L(a)$ に属し $\mathcal{D}_L(\lambda)$ には属さない。よって空語も比較すると a^+ は代入可能ではなくなる。すべての $x, y \in \Sigma^+$ について $\mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \emptyset$ から $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ が従うとき、 L を *Clark–Eyraud 代入可能* と呼ぶ。これは定義 2.1 の自明モノイドの場合、従って Yoshinaka の $(0, 0)$ の場合にちょうど一致する。

$k, \ell \geq 0$ に対し、 $\text{pref}_k(w)$ と $\text{suf}_\ell(w)$ をそれぞれ長さ $\min\{k, |w|\}$ の接頭辞と長さ $\min\{\ell, |w|\}$ の接尾辞とする。特に $\text{pref}_0(w) = \text{suf}_0(w) = \lambda$ であり、短い語については語全体を返す。Yoshinaka の変数を、本稿の記法に合わせて改名する。以下では u_i, v_i を外側文脈、 p, q を窓、 r, s をその内側部分に用いる。 L が (k, ℓ) -代入可能であるとは、すべての $p \in \Sigma^k, q \in \Sigma^\ell$ および $u_1, u_2, v_1, v_2, r, s \in \Sigma^*$ について、 $prq, psq \neq \lambda$ のとき

$$\begin{aligned} u_1 prq v_1 \in L, \quad u_1 psq v_1 \in L, \quad u_2 prq v_2 \in L \\ \implies u_2 psq v_2 \in L \end{aligned}$$

が成り立つことをいう。

命題 3.3. 任意の固定 $k, \ell \geq 0$ に対して有限モノイド準同型 $h_{k, \ell}$ が存在し、任意の $L \subseteq \Sigma^*$ について、 L が (k, ℓ) -代入可能であることと $\sim_{h_{k, \ell}}$ -代入可能であることは同値である。

Proof. $m_0 := \max\{1, k + \ell\}$ とし、 $|w| < m_0$ なら $h_{k, \ell}(w) := w$ 、それ以外では、二つの場合を区別するタグを付けて $h_{k, \ell}(w) := \langle \text{pref}_k(w), \text{suf}_\ell(w) \rangle$ とする。有限像を $M_{k, \ell} := h_{k, \ell}(\Sigma^*)$ と書く。長さがともに m_0 未満の語 x, y について

$$\begin{aligned} x \cdot y &:= h_{k, \ell}(xy), & x \cdot \langle p, q \rangle &:= \langle \text{pref}_k(xp), q \rangle, \\ \langle p, q \rangle \cdot y &:= \langle p, \text{suf}_\ell(qy) \rangle, & \langle p, q \rangle \cdot \langle p', q' \rangle &:= \langle p, q' \rangle \end{aligned}$$

と積を定める。すると $h_{k, \ell}(xy) = h_{k, \ell}(x) \cdot h_{k, \ell}(y)$ であり、全射性から結合律が従い、 $h_{k, \ell}(\lambda)$ が単位元になる。

非空 x, y の型が等しいことは、 $x = y$ であるか、共通の長さ k の接頭辞 p と長さ ℓ の接尾辞 q を用いて $x = prq, y = psq$ と書けることを意味する ($k = \ell = 0$ も含む)。 L が (k, ℓ) -代入可能なら、共通文脈と片方の任意の文脈から Yoshinaka の四語条件を適用し、対称性により分布が一致する。逆に Yoshinaka の前提では $x := prq, y := psq$ は非空で、長語側の符号化に属するため同じ $h_{k, \ell}$ -型をもつ。固定- $h_{k, \ell}$ 代入可能性が第三の文脈を移送し、第四の語を与える。 $\square$

■固定窓代入可能性の反例基準. x, y が長さ $\max\{1, k + \ell\}$ 以上で, 同じ長さ k の接頭辞と長さ ℓ の接尾辞をもち, 共通文脈をもつ一方で分布が異なるなら, L は (k, ℓ) -代入可能ではない. 最初の三条件から $h_{k, \ell}$ -型が等しく共通文脈をもち, 最後の条件が $\sim_{h_{k, \ell}}$ -代入可能性に反するからである.

従って固定 (k, ℓ) クラスはちょうど $RS_{h_{k, \ell}}$ であり, 第 7 節でその多項式厚み付きデータ上界を与える. $k = \ell = 0$ では $h_{0, 0}$ は λ と非空語を区別するだけで, 一元モノイドと同じ代入可能性条件を誘導する. アルファベット Γ に対し

$$KL(\Gamma) := \bigcup_{k, \ell \geq 0} \{L \subseteq \Gamma^* : L \text{ は } (k, \ell)\text{-代入可能}\}$$

とし, $KL := KL(\Sigma)$ と略記する.

3.2 主定理

定理 3.4 (固定- h 学習定理). 効率的に計算可能な有限モノイド準同型 $h : \Sigma^* \rightarrow M$ を固定する. 集合駆動型再構成作用素 $\mathcal{B}_h$ と保守的逐次学習器 $\mathcal{A}_h$ が存在し, 次を満たす.

(i) $\mathcal{B}_h$ は標本整合的で, $\mathcal{B}_h(K)$ は $\|K\|$ の多項式時間で構成できる.

(ii) すべての $L \in \mathcal{C}_h^{\text{cf}}$ は $\mathcal{B}_h$ に対する有限特徴標本をもつ.

(iii) $\mathcal{A}_h$ はすべての非空 $L \in \mathcal{C}_h^{\text{cf}}$ を *Gold* の意味で同定し, 各更新はそれまでに見たデータの多項式時間で行える.

(iv) 正の像半群 $h(\Sigma^+)$ が局所自明なら, 各非空標的について (ii) の標本は, その標的を表す任意の縮約済み CFG G_* に対し $|G_*|$ と τ_{G_*} の多項式サイズに選べる. 特に, これはすべての固定窓型付け $h_{k, \ell}$ に適用できる (定理 7.2 と命題 7.3 から直接従う).

(v) 任意の固定 h と $L \in \mathcal{C}_h^{\text{lin}}$ に対し, (ii) の標本は, L を表す任意の線形 CFG G_* について $|G_*|$ の多項式サイズに選べる.

(iv)–(v) の多項式は固定した h と Σ に依存してよいが, 選んだ標的文法 G_* には依存しない. 項目 (iv)–(v) の定量的機構と, 一般の固定型付けに対するその限界は, 第 6–8 節で扱う.

これは Gold の定理と整合する. 非空アルファベット上では, クラス $\mathcal{C}_h^{\text{cf}}$ はすべての有限言語を含むわけではない. $h(x) = h(y)$ を満たす相異なる非空語 x, y を取り, さらに $|z| > \max\{|x|, |y|\}$ を満たす $z \in \Sigma^*$ を取る. $\{x, y, zx\}$ では x, y は空文脈を共有するが, (z, λ) は x だけの文脈である.

■固定窓の代数的位置づけ. 以下の同値性は局所自明有限半群に関する古典的結果の, 正語像と核に即した再定式化であり, 新しい半群定理としては主張しない. Pin [6, Propositions XI.4.17 and XIV.1.20] を参照されたい. なお, 構文半群の局所自明性によって特徴づけられる古典的な正則言語族は, *generalized definite* (接頭辞 – 接尾辞検査可能) 言語と呼ばれる [4, Proposition 5.18]. ここでは構文半群に限らない固定準同型の正の像と核を扱い, その言語クラスの和への適用と, 系 7.4 の学習に固有な厚みの評価を記録する.

命題 3.5 (局所自明型付けと固定窓). 非空アルファベット上の有限モノイド準同型 $h : \Sigma^* \rightarrow M$ に対し, $n := |h(\Sigma^+)| + 1$ とおく. 次は同値である.

(i) $h(\Sigma^+)$ は局所自明である.

(ii) ある $k, \ell \geq 0$ が存在して $\ker h_{k, \ell}|_{\Sigma^+} \subseteq \ker h|_{\Sigma^+}$ が成り立つ.

これらが成り立つとき $(k, \ell) = (n, n)$ と取れる．さらに，各正の像半群 $h_{k, \ell}(\Sigma^+)$ は局所自明であり， 276

$$\text{KL}(\Sigma) = \bigcup_{\substack{h: \Sigma^* \rightarrow M \\ h(\Sigma^+) \text{ が局所自明}}} \text{RS}_h(\Sigma)$$

が成り立つ．両辺を CFL と交わらせても同じ等式が成り立つ． 277

Proof. まず (i) を仮定し， $S = h(\Sigma^+)$ ， $n = |S| + 1$ とおく．Pin [6, Corollary II.6.35 and Proposition XI.4.17] による一般の有限半群での事実 $S^n = SE(S)S$ と，局所自明性から従う，任意の $e, f \in E(S)$ と任意の $t \in S$ に対する恒等式 $etf = ef$ を使う．長さ n の任意の p, q について $h(p) = aeb$ ， $h(q) = cfd$ と分解できるので，すべての $r \in \Sigma^*$ に対し $h(prq) = ae(bh(r)c)fd = aefd = h(pq)$ となる．短い非空語を個別に記録する $h_{n, n}$ の定義から (ii) が従う． 278 279 280 281 282

逆に S が局所自明でなければ，冪等元 e と元 m で $eme \neq e$ を満たすものがある．これらを表す非空語を r, z とし，任意の k, ℓ に対して $j|r| \geq \max\{k, \ell\}$ を満たす $j \geq 1$ を取る． $x = r^{2j+1}$ と $y = r^j z r^j$ は同じ固定窓型を持つが， $h(x) = e \neq eme = h(y)$ なので (ii) は成立しない． 283 284 285

最後に命題 3.3 の積を使うと，正の像 $h_{k, \ell}(\Sigma^+)$ の各冪等元は $\langle p, q \rangle$ の形で^{*2}， $\langle p, q \rangle t \langle p, q \rangle = \langle p, q \rangle$ を満たす．従って正の像は局所自明である．逆向きの包含は，前半と核の精密化に関する単調性から $\text{RS}_h \subseteq \text{RS}_{h_{n, n}}$ による．言語クラスの和を取れば所望の等式が得られ，CFL に制限しても成り立つ． 286 287 288 289

4 再構成作用素と逐次学習器 290

4.1 有限標本からの再構成 291

有限標本 $K \subseteq \Sigma^*$ に対し， 292

$$\widehat{V}(K) := \{[x] : x \in \Sigma^+, \exists u, v \in \Sigma^* \text{ with } uxv \in K\}$$

とおく．したがって，標本中で観測された相異なる非空因子ごとに仮説非終端記号を一つだけ置く．角括弧は非終端記号名の一部であり，商類を表す記号ではない．観測された非空因子 x, y に対し 293 294

$$x \approx_{K, h} y \iff h(x) = h(y) \text{ かつ } \mathcal{D}_K(x) \cap \mathcal{D}_K(y) \neq \emptyset$$

と書く．文法 $\mathcal{B}_h(K)$ は非終端記号集合 $\widehat{V}(K) \cup \{\widehat{S}\}$ と開始記号 $\widehat{S}$ をもち，表示されたすべての角括弧付き非終端記号が $\widehat{V}(K)$ に属する場合に，次の規則をもつ： 295 296

- (B) $[xy] \rightarrow [x][y]$, $x, y \in \Sigma^+$,
- (U) $[x] \rightarrow [y]$, $x \approx_{K, h} y$,
- (L) $[a] \rightarrow a$, $a \in \Sigma$,
- (S) $\widehat{S} \rightarrow [w]$, $w \in K \cap \Sigma^+$.

$\lambda \in K$ のときは，規則 (S) に $\widehat{S} \rightarrow \lambda$ も含める． 297

^{*2} 正の像の短語型元 x は $0 < |x| < m_0$ を満たす．十分大きな j では $h_{k, \ell}(x^j)$ は長語型だが， x が冪等なら $h_{k, \ell}(x^j) = x$ となり矛盾する．

この文法は Yoshinaka [16, Section 4, Algorithm 1] の部分文字列添字付き構成に基づき、Clark [21, Section 4, Algorithm 1] も同じ構成を紹介している。特に $h = h_{k,\ell}$ のとき、規則 (U) の非自明な場合は Yoshinaka の単位規則と一致する。すなわち相異なる非空の観測因子が共通の標本文脈をもち、同じ $h_{k,\ell}$ -型をもつとき結ばれる。同値に、その二因子はともに長さ $\max\{1, k + \ell\}$ 以上で、同じ長さ k の接頭辞と長さ ℓ の接尾辞をもつ。冗長な恒等規則、初期規則を別の開始記号で表す点、および λ の扱いを除けば、両構成は一致する。一般の固定 h では、この接頭辞 – 接尾辞の比較を h -型の一致で置き換える。

補題 4.1 (標本整合性). 任意の有限正例標本 K に対して、 $K \subseteq L(\mathcal{B}_h(K))$ が成り立つ。

Proof. $w = a_1 \cdots a_m \in K \cap \Sigma^+$ とする。規則 (S) により $[w]$ に入る。 w の任意の二分木分解に沿って規則 (B) を繰り返すと一文字因子へ到達し、それらはすべて同じ標本語中に現れるので観測済みである。最後に規則 (L) が $a_1 \cdots a_m$ を生成する。 $\lambda \in K$ の場合は開始規則が直接生成する。 $\square$

定理 4.2 (健全性). $K \subseteq L$ かつ L が $\sim_h$ -代入可能ならば、 $L(\mathcal{B}_h(K)) \subseteq L$ である。

Proof. $[x]$ を根とする導出木の高さについて帰納法を行い、

$$[x] \Rightarrow_{\mathcal{B}_h(K)}^* w \implies x \equiv_L w \text{ かつ } h(w) = h(x) \quad (1)$$

を示す。因子非終端記号は観測された非空語を添字にもつので、規則 (U) で比較する因子は定義 2.1 の非空条件を満たす。また規則 (B)–(L) は、因子非終端記号から λ を導出しない。規則 (L) は明らかである。規則 (U) で $[x] \rightarrow [y]$ とする。定義から、ある標本文脈 (u, v) が存在して $uxv, uyv \in K \subseteq L$ かつ $h(x) = h(y)$ である。fixed- h 代入可能性により $x \equiv_L y$ であり、帰納法の仮定から $y \equiv_L w$ と $h(w) = h(y)$ が従うので (1) を得る。

規則 (B) について、 $[xy] \rightarrow [x][y]$ から得られる終端語を $w_1 w_2$ と書く。帰納法の仮定より $x \equiv_L w_1$, $y \equiv_L w_2$, $h(w_1) = h(x)$, $h(w_2) = h(y)$ である。 $\equiv_L$ はモノイド合同なので $xy \equiv_L w_1 w_2$ であり、準同型性から $h(w_1 w_2) = h(xy)$ である。

最後に開始規則 $\hat{S} \rightarrow [x]$ を用いたなら $x \in K \subseteq L$ なので $(\lambda, \lambda) \in \mathcal{D}_L(x)$ である。不変量から $\mathcal{D}_L(w) = \mathcal{D}_L(x)$ だから $w \in L$ を得る。 λ の直接規則は $\lambda \in K \subseteq L$ の場合にしか存在しない。 $\square$

4.2 逐次学習器

$\mathcal{B}_h$ を各データ到着時に再計算しても、文法表現は一般には安定しない。たとえば $L_c = \{a^n c b^n : n \geq 0\}$ では、長い正例から $[a^n c b^n]$ のような新しい因子非終端記号が生じる。そこで Clark–Eyraud の Substitution Graph Learner (SGL, Algorithm 2) および Yoshinaka の (k, ℓ) -Substitutable Grammar Learner $((k, \ell)$ -SGL, Algorithm 1) と同じ保守的ラッパーを用いる [9, 16]。集合駆動型再構成と逐次学習の区別については Eyraud–Heinz–Yoshinaka [22, Appendix] も参照されたい。固定空文法 H_0 から始め、 w_n を読んだ後

$$H_n := \begin{cases} H_{n-1}, & w_n \in L(H_{n-1}), \\ \mathcal{B}_h(K_n), & w_n \notin L(H_{n-1}), \end{cases} \quad \mathcal{A}_h(T[n]) := H_n$$

とする。再構成は常に蓄積標本全体 K_n を用いる。 $\mathcal{B}_h$ は集合駆動型だが、 $\mathcal{A}_h$ が最終的に安定する文法は提示順序に依存し得る。主張するのは、標的言語を生成する文法への最終的な構文的安定化だけ

である (系 5.5). 実際, 無限な $L \in \mathcal{C}_h^{\text{cf}}$ のテキスト T で学習器が安定するとき, 極限仮説を構成した有限標本のすべての語より長い $w \in L$ を選べる. T 上の極限文法は $[w]$ を含まないが, w を先頭に追加したテキストでは, 最初の再構成以降の全仮説がこの非終端記号を含む. 従って, 同じ標的に対して異なる極限文法が得られる. Clark [21, Section 4, Example 1] も, $L_c = \{a^n cb^n : n \geq 0\}$ について, 初期の正例列の違いによって相異なる部分文字列添字付き文法に安定することを示している.

5 有限証拠・厳密再構成・計算量

5.1 標的の精密化と有限証拠

再構成作用素と逐次学習器はすでに定義済みである. ここでは完全性の証明のためだけに標的側の精密化を導入する. 目標は, 対応する正例証拠が出現した後に, 仮説文法が有限個の型付き標的導出を模倣できることを示すことである. 次の標準形は証明上の道具としてのみ用いる.

定義 5.1 (開始記号分離二分標準形). $CFG\ G = (V, \Sigma, P, S_0)$ が 開始記号分離二分標準形 (SSBNF) にあるとは, S_0 がいかなる右辺にも現れず, すべての開始規則が $S_0 \rightarrow A$ または $S_0 \rightarrow \lambda$ の形であり, すべての非開始規則が $A \rightarrow a$ または $A \rightarrow BC$ の形であることをいう.

開始記号の分離により文全体への入口が内部非終端記号と区別され, λ は開始記号で別途扱える.

任意の非空文脈自由言語は, 標準的な開始記号分離, 無用記号除去, 開始記号以外での λ /単位規則除去, および二分化の手続きにより, 同値な縮約済み SSBNF 文法をもつ. 従って以下の精密化は非空文脈自由言語について定義する. 空標的は H_0 と $\mathcal{B}_h(\emptyset)$ により別途表す.

非空言語 L に対する縮約済み SSBNF 文法を $G = (V, \Sigma, P, S_0)$ とする. 開始記号 $\tilde{S}$ と, $A \in V \setminus \{S_0\}$, $\mu \in M$ に対する非開始記号 A_μ をもつ次の生成語型付き文法を作る. 以下, 型添字の併置は M における積を表す. すなわち $\mu\nu = \mu \cdot \nu$ とする. 規則は次である.

$$\begin{aligned} \tilde{S} &\rightarrow A_\mu & (S_0 \rightarrow A \in P, \mu \in M), \\ \tilde{S} &\rightarrow \lambda & (S_0 \rightarrow \lambda \in P), \\ A_{h(a)} &\rightarrow a & (A \rightarrow a \in P), \\ A_{\mu\nu} &\rightarrow B_\mu C_\nu & (A \rightarrow BC \in P, \mu, \nu \in M). \end{aligned}$$

この文法の縮約部分を $\tilde{G} = (\tilde{V}, \Sigma, \tilde{P}, \tilde{S})$ と書き, 型付き精密化と呼ぶ. したがって, 規約として $\tilde{G}$ のすべての記号は到達可能かつ生産的である.

Σ 上に順序を一つ固定し, それが誘導する *shortlex* 順序を用いる. すなわち短い語を先に置き, 同じ長さなら辞書式順序で比較する. $\tilde{G}$ の各非開始記号 X に対し, $\omega(X)$ をその shortlex 最小終端生成語とし, これを X の標準生成語と呼ぶ. $\tilde{G}$ は縮約済みなので $\omega(X)$ は常に定義される.

完全性のためには生成語型による分割が必要である. 親の型付き非終端記号の標準生成語と, その子の標準生成語を接続した語とが同じ h -型をもつことによって, 単位規則 (U) が適用できる (定理 5.3).

この分割が現在の完全性証明で果たす役割は, 型付け前の文法ですで見える. $h(w) = |w| \bmod 2$ とし, 開始記号を S_0 とする SSBNF 文法 G の規則を $S_0 \rightarrow A$, $A \rightarrow a \mid BC$, $B \rightarrow a$, $C \rightarrow a$ とする. A の最短生成語は a であり型は奇数である一方, B, C の最短生成語の接続 aa は偶数型である. したがって, A を生成語型で分割しなければ, 対応する単位規則の段階は許可されない. 生成語型で分割することで必要な等式が不変量となる. 一方で周囲の左文脈または右文脈には型を付けない. 再

363 構成作用素がそのような型を一度も検査しないからである。

364 **命題 5.2** (型付き持ち上げと生成語不変量). 型付き精密化は $L(\tilde{G}) = L(G)$ を満たす. さらに, $\tilde{G}$ に
365 残る任意の非開始記号 A_μ について,

$$L_{\tilde{G}}(A_\mu) = L_G(A) \cap h^{-1}(\{\mu\})$$

366 が成り立つ. 特に $A_\mu \Rightarrow_G^* w$ ならば $h(w) = \mu$ である.

367 *Proof.* 型注釈を消去すれば任意の型付き導出は G の導出となる. 逆に G の成功導出木の各非開始
368 節点に, その部分木の終端生成語の h -型を注釈する. 終端規則と二項規則は型のボトムアップ伝播則
369 そのものなので, 注釈付き木はトリム前の型付き文法での導出となる. 成功木上の記号はすべてトリ
370 ム後も残る.

371 残った非開始記号 A_μ について, 型注釈の消去から

$$L_{\tilde{G}}(A_\mu) \subseteq L_G(A) \cap h^{-1}(\{\mu\})$$

372 が従う. 逆の包含のため, $w \in L_G(A)$ かつ $h(w) = \mu$ とする. A_μ はトリム後に残っているので, そ
373 の出現を含む成功した型付き導出木が存在する. 一方, $A \Rightarrow_G^* w$ という元文法での導出木の各部分
374 木の終端生成語を h -型でボトムアップに注釈する. 得られた型付き部分木を, 先の成功木の A_μ の
375 出現箇所に接ぎ木する. 根の型が μ なので接ぎ木は正しく, 全体として成功した型付き導出木にな
376 る. したがって接ぎ木した部分木の記号と規則はすべてトリム後にも残り, $A_\mu \Rightarrow_G^* w$ を得る. 生成
377 語型の不変量も型付き導出に関する帰納法から直接従う. $\square$

378 $\tilde{G}$ の各非開始記号 X に対し, X の終端到達文脈の中から $|u_X| + |v_X|$ を最小化するものとして
379 $\chi(X) = (u_X, v_X)$ を選び, 同値な候補がある場合は u_X の shortlex 順序, 次に v_X の shortlex 順序
380 で決める. $\chi(X)$ を X の標準文脈と呼ぶ. $\tilde{G}$ は縮約済みなので, このような終端到達文脈は存在す
381 る. 実際, 到達可能性により X は到達可能な文形式中に現れ, 周囲の非終端記号の生産性により, そ
382 の左側および右側のすべての記号を終端文字列へ展開できる. 命題 5.2 から $h(\omega(A_\mu)) = \mu$ である.
383 有限証拠集合を

$$\begin{aligned} W(\tilde{G}) := & \{u_X \omega(X) v_X : X \in \tilde{V} \setminus \{\tilde{S}\}\} \\ & \cup \{u_X a v_X : X \rightarrow a \in \tilde{P}\} \\ & \cup \{u_X \omega(Y) \omega(Z) v_X : X \rightarrow YZ \in \tilde{P}\} \\ & \cup \{\lambda\} \text{ if } \lambda \in L \end{aligned} \tag{2}$$

384 により定める. ここに表示したすべての語は L に属し, 集合は有限である. 特に, 二項規則 $X \rightarrow YZ$
385 に対応する証拠語は

$$\tilde{S} \Rightarrow^* u_X X v_X \Rightarrow u_X Y Z v_X \Rightarrow^* u_X \omega(Y) \omega(Z) v_X$$

386 により正当化される. 第一族と第二族についても同様である. $W(\tilde{G})$ の要素を **標準正例証拠** と呼ぶ.
387 第一族は各型付き記号の標準的な一出現を記録し, 第二族と第三族はそれぞれ終端生成規則と二項生
388 成規則を記録する.

5.2 厳密再構成と Gold 収束

定理 5.3 (有限証拠からの完全性). 非空言語 L に対する任意の縮約済み $SSBNF$ 文法を G とし, 固定準同型 h に関するその型付き精密化を $\tilde{G}$ とする. 有限集合 K が $W(\tilde{G}) \subseteq K$ を満たすならば, $L \subseteq L(\mathcal{B}_h(K))$ である.

ここが標的型付けが登場する箇所である. 学習器とバッチ作用素は第 4 節ですでに定義されており, 以下の証明は, それらの仮説非終端記号が生成語型付き標的非終端記号を模倣できることを示す. それ以外では, この主張は純粋に組合せ論的である. 型付き文法と包含 $W(\tilde{G}) \subseteq K$ だけを用い, 代入可能性も追加仮定 $K \subseteq L$ も必要としない.

Proof. 各非開始記号 X に対し, $\hat{X} := [\omega(X)]$ と書く. 式 (2) の第一族の対応する語により $\hat{X}$ は存在する. 型付き導出 $X \Rightarrow^* w$ について帰納法を行い, $\hat{X} \Rightarrow_{\mathcal{B}_h(K)}^* w$ を示す.

最初の規則が $X \rightarrow a$ の場合, 第一族と第二族にはそれぞれ $u_X \omega(X) v_X$ と $u_X a v_X$ が含まれる. 命題 5.2 より $h(\omega(X)) = h(a)$ なので $\omega(X) \approx_{K,h} a$ である. 必要なら規則 (U) で $\hat{X}$ から $[a]$ へ移り, 規則 (L) で a を生成する.

最初の規則が $X = A_{\mu\nu} \rightarrow B_\mu C_\nu$ の場合, $Y := B_\mu, Z := C_\nu$ とおく. 第一族と第三族には $u_X \omega(X) v_X$ と $u_X \omega(Y) \omega(Z) v_X$ が含まれる. さらに

$$h(\omega(X)) = \mu\nu = h(\omega(Y))h(\omega(Z)) = h(\omega(Y)\omega(Z))$$

なので, 必要なら規則 (U) により $\hat{X}$ から $[\omega(Y)\omega(Z)]$ へ移る. 第三族の証拠により $\omega(Y)\omega(Z)$ は観測因子でもあるから, 規則 (B) で

$$[\omega(Y)\omega(Z)] \rightarrow [\omega(Y)][\omega(Z)]$$

と分解できる. 二つの部分導出は帰納法の仮定で完了する.

最後に, 任意の非空 $w \in L$ は $\tilde{S} \rightarrow X \Rightarrow^* w$ という持ち上げられた開始導出をもつ. 開始規則そのものにより (λ, λ) は X の終端到達文脈であり, 全長 0 で最小だから $\chi(X) = (\lambda, \lambda)$ である. 第一族から $\omega(X) \in K$ なので, 規則 (S) が上の導出を開始する. $w = \lambda$ の場合も式 (2) と規則 (S) から直ちに従う. $\square$

定理 5.4 (厳密有限標本再構成). $L \in \mathcal{C}_h^{\text{cf}}$ を非空とし, G を L の縮約済み $SSBNF$ 文法, $\tilde{G}$ をその型付き精密化とする. $W(\tilde{G}) \subseteq K \subseteq L$ ならば, $L(\mathcal{B}_h(K)) = L$ である.

Proof. 定理 4.2 と 5.3 を合わせればよい. $\square$

したがって, $L(G) \in \mathcal{C}_h^{\text{cf}}$ が非空となる任意の縮約済み $SSBNF$ 文法 G に対し, 集合 $W(\tilde{G})$ は第 2.1 節の意味で, $\mathcal{B}_h$ に関する $L(G)$ の特徴標本である.

定理 5.4 は $\{\lambda\}$ を含むすべての非空標的を覆う. 残る端点 $L = \emptyset$ については $C_L = \emptyset$ とおけば, $\mathcal{B}_h(\emptyset)$ は開始生成規則をもたない. これにより定理 3.4 の項目 (ii) が確立される.

系 5.5 (Gold 同定). 有限モノイド M への固定準同型 $h : \Sigma^* \rightarrow M$ に対し, 学習器 $\mathcal{A}_h$ は $\mathcal{C}_h^{\text{cf}}$ のすべての非空言語を正例データから同定する. より具体的には, 任意の縮約済み $SSBNF$ 標的文法 G とその型付き精密化 $\tilde{G}$ に対し, $W(\tilde{G}) \subseteq K_{n_0}$ となったとき, 段階 $n \geq n_0$ の範囲で生じうる仮説変更は高々一回である.

422 *Proof.* 本論文のテキスト規約の下では, Gold の主張は非空標的を対象とする. H_0 は初期空仮説で
 423 ある. L を非空とし, T を L のテキストとする. $w_1 \notin L(H_0) = \emptyset$ なので, 学習器は段階 1 で再
 424 構成する. $W(\tilde{G}) \subseteq K_{n_0}$ を満たす n_0 を選ぶ. ある段階 $n \geq n_0$ で学習器が再構成するならば, 定
 425 理 5.4 により新たな仮説はちょうど L となり, その後はいかなる正例も追加の変更を引き起こさな
 426 い. この場合はこれが最後の仮説変更となる. 一方, どの段階 $n \geq n_0$ でも再構成が起こらないと仮
 427 定する. 健全性から $L(H_{n_0}) \subseteq L$ である. さらに, すべての n について $K_n \subseteq L(H_n)$ が成り立つ.
 428 再構成時には標本整合性があり, 再構成しない段階では新たに提示されたデータがすでに変更されな
 429 い仮説によって生成されるからである. したがって真の包含 $L(H_{n_0}) \subsetneq L$ ならば, 段階 n_0 までも
 430 現れていないある $w^* \in L \setminus L(H_{n_0})$ が存在する. しかし標的のすべての語は最終的にテキストに現
 431 れるので, w^* は後の段階で現れて再構成を強制し, 矛盾する. したがって $L(H_{n_0}) = L$ である. こ
 432 の場合, 段階 n_0 以後に仮説変更は必要ない. $\square$

433 これは Eyraud–Heinz–Yoshinaka [22, Appendix] が指摘する delayed-rebuild 現象である. 特徴
 434 標本をすでに見終えた後でも, 新しい各正例が以前の誤った仮説によって生成されている限り, 保守
 435 的学習器はその仮説を保持し得る. その仮説の外にある後続の正例が現れたとき, すでに特徴データ
 436 を含む蓄積標本全体から再構成が行われる. 上の証明は $\mathcal{A}_h$ に対するこの安定化を明示している.

437 5.3 再構成ステップの計算量

438 **定理 5.6** (多項式時間再構成). h を固定すると, $\mathcal{B}_h(K)$ は $\|K\|$ に関して多項式時間で構成できる.

439 *Proof.* $n_K := \|K\|$ とおき, 観測因子出現の集合を $\mathcal{O}_K := \{(u, x, v) \in \Sigma^* \times \Sigma^+ \times \Sigma^* : uxv \in K\}$
 440 とする. $|\mathcal{O}_K| = O(n_K^2)$ なので, 因子非終端記号も高々 $O(n_K^2)$ 個である. 各標本語の各開始位置か
 441 ら因子を一文字ずつ延長して h -値を記録すれば, 固定モノイド中の $O(n_K^2)$ 回の積で全因子の h -値
 442 を計算できる.

443 規則 (B) の候補は, 観測因子出現とその分割位置を選ぶので高々 $O(n_K^3)$ 個である. 規則 (U) に
 444 ついては, 各 $(u, x, v) \in \mathcal{O}_K$ と各 $w \in K$ に対し, $w = uyv$ を満たす非空語 y が存在するか調べる.
 445 そのような y は存在すれば一意であり, $h(x) = h(y)$ ならば規則 $[x] \rightarrow [y]$ を生成する. これにより
 446 規則 (U) の候補をすべて列挙でき, その個数は高々 $|\mathcal{O}_K||K| = O(n_K^3)$ である.

447 終端規則と開始規則はこれより低次である. 各候補について, 文字列の照合と生成規則の符号化・
 448 出力は $O(n_K)$ 時間で行える. 重複する規則は生成言語に影響しないため, 列挙時に除去する必要は
 449 ない. 従って, $\mathcal{B}_h(K)$ は $O(n_K^4)$ 時間で構成できる. $\square$

450 保守的学習器 $\mathcal{A}_h$ の各更新も, それまでに見たデータの符号化サイズに関して多項式時間で処理で
 451 きる. CFG membership は文法と入力サイズに関して多項式時間であり, 現在の仮説サイズと必要
 452 な再構成の計算量はいずれも定理 5.6 によって多項式に抑えられる.

453 補題 4.1, 定理 5.4, 系 5.5 と合わせて, 主定理 3.4(i)–(iii) が得られる. 定量的な (iv)–(v) は
 454 第 7–8 節で証明する. 文法サイズだけによる上界は不可能である. Clark–Eyraud [9, Example 2]
 455 および Eyraud–Heinz–Yoshinaka [22, Example 2.3] の標準的な doubling family を開始記号分離
 456 し添字を付け替えた版は, 縮約済み SSBNF 文法 $S_0 \rightarrow D_n$, $D_0 \rightarrow a$, $D_i \rightarrow D_{i-1}D_{i-1}$ をもち, 生
 457 成規則記号数は $O(n)$ だが生成言語は $\{a^{2^n}\}$ である. de la Higuera の定理 3 [7] は, これと密接に
 458 関連する simple-deterministic な変種を用いる. 任意の singleton 言語は, 任意の h に対して $\sim_h$ -

6 一般の固定型付けに対する型付き厚み

460

任意の固定 h に対し, 生成語型付けの費用を明示的に測れば, 有限証拠構成から直接的な定
量上界が得られる. $G = (V, \Sigma, P, S_0)$ を縮約済み SSBNF 文法, $\tilde{G}$ をその型付き精密化とし,
 $N := |V \setminus \{S_0\}|$, $N_t := |\tilde{V} \setminus \{\tilde{S}\}|$ とおく. この表現の **型付き厚み**を

463

$$\tau_h^{\text{typ}}(G) := \max\left(\{|\omega(X)| : X \in \tilde{V} \setminus \{\tilde{S}\}\} \cup \{1\}\right)$$

と定める. これは完全な生成語型分割とトリミング後の最短終端生成語を測る表現依存パラメータで
あり, 学習器への追加仮定ではない.

466

補題 6.1 (型付き厚みによる証拠上界). $G, \tilde{G}$ を上の通りとし, $\tau := \tau_h^{\text{typ}}(G)$ と書く. 任意の非開始
型付き記号 X に対し $|u_X| + |v_X| \leq (N_t - 1)\tau$ であり, 任意の $w \in W(\tilde{G})$ に対し $|w| \leq (N_t + 1)\tau$
である. $P_{\text{ter}}, P_{\text{bin}}$ をそれぞれ G の非開始終端規則と二項規則の集合とすると

466

467

468

$$\|W(\tilde{G})\| \leq (N|M| + |P_{\text{ter}}| + |P_{\text{bin}}||M|^2 + 1)((N|M| + 1)\tau + 1).$$

特に固定 h の下で, この上界は $|G|$ と $\tau_h^{\text{typ}}(G)$ の多項式である.

469

Proof. $\tilde{G}$ の非開始記号を頂点とし, 二項規則で親から各子へ辺を張る依存有向グラフを作る. $\tilde{G}$ は
縮約済みなので任意の非開始記号 X は到達可能であり, ある開始子 A から X への経路がある. 最
短経路を選ぶと型付き記号を反復せず, 辺数は高々 $N_t - 1$ である.

470

471

472

経路の各辺について, その辺を実現する二項規則を選び, 経路外の子をその標準生成語へ展開す
る. $\tilde{S} \rightarrow A$ から始めれば, これらの展開は X の終端到達文脈を与える. 各経路外の標準生成語長は
高々 τ なので文脈全長は $(N_t - 1)\tau$ 以下であり, 標準文脈 (u_X, v_X) はそれより長くない.

473

474

475

第一族の語は標準文脈に標準生成語を一つ, 第二族は終端記号を一つ, 第三族は標準生成語を二つ
加える. $\tau \geq 1$ だから, 式 (2) の各語の長さは $(N_t + 1)\tau$ 以下である. さらに $N_t \leq N|M|$ であり,
元の終端規則から生じる型付き終端規則は高々一つ, 元の各二項規則からは高々 $|M|^2$ 個の型付き規
則が生じる. 従って第一因子が λ の可能な証拠も含めた証拠個数を, 第二因子が各 $|w| + 1$ を抑え
る. 積をとれば主張が従う. $\square$

476

477

478

479

480

系 6.2 (型付き厚みからの特徴データ). h を固定する. G が非空な $L(G) \in \mathcal{C}_h^{\text{cf}}$ の縮約済み SSBNF
文法なら, $W(\tilde{G})$ は B_h に対する特徴標本であり, その符号化サイズは $|G|$ と $\tau_h^{\text{typ}}(G)$ の多項式で
ある.

481

482

483

Proof. 定量上界は補題 6.1, 特徴標本性は定理 5.4 による. $\square$

484

型付き精密化による議論では, 型付き厚みを一般に元文法の通常の厚みへ置き換えられない. この
ような表現依存性自体は CFG 学習で既知の現象である. Clark–Eyraud [9, Example 2] は, 小さい文
法でも正の特徴データに指数長の語が必要となる例を与えている. Yoshinaka [16] は fixed-window
設定で通常の文法厚みを明示的なパラメータとし, Eyraud–Heinz–Yoshinaka [22] も特徴データ基
準の表現依存性を論じている. ここで必要なのはより限定された点であり, 通常の元文法厚みを記録
しても, 本論文の fixed- h 再構成で用いる型付き精密化の最短生成語は大幅に長くなり得る.

485

486

487

488

489

490

命題 6.3 (元文法と型付き厚みの指数ギャップ). 固定された二元型付け h_c と, サイズ $O(n)$, 通常
の厚み 1 の縮約済み SBNF 文法族 G_n^c が存在し, $\tau_{h_c}^{\text{typ}}(G_n^c) \geq 2^n$ となる. 従って, 一つの固定型
付けに限っても, 型付き厚みを元文法サイズと通常の厚みの多項式で一般に上から抑えることはでき
ない.

Proof. $M_c = \{1, \zeta\}$ を零元 ζ をもつ二元モノイドとし, $h_c(a) = 1, h_c(c) = \zeta$ とする. $n \geq 1$ に対
し, 文法 G_n^c を

$$\begin{aligned} S_0 &\rightarrow U, & U &\rightarrow a \mid c \mid UU \mid E_n D, & D &\rightarrow c, \\ E_0 &\rightarrow a, & E_i &\rightarrow E_{i-1} E_{i-1} \mid c \quad (1 \leq i \leq n) \end{aligned}$$

で定める. これはサイズ $O(n)$ の縮約済み SBNF 文法であり, $L(G_n^c) = \{a, c\}^+ \in \mathcal{C}_{h_c}^{\text{cf}}$ である.

まず, S_0, U, E_0 は a を, D, E_i ($i \geq 1$) は c を生成できる. つまり, すべての非終端記号が長さ 1
の語を生成できるため, 通常の厚みは $\tau_{G_n^c} = 1$ である.

一方, 型付き精密化で型 1 に制限すると, $h_c(c) = \zeta \neq 1$ なので, $E_i \rightarrow c$ は使えない. ま
た, 積が 1 になるのは $1 \cdot 1$ だけである. 従って帰納法により $L((E_i)_1) = \{a^{2^i}\}$ となる. さらに
 $\tilde{S} \rightarrow U_\zeta \rightarrow (E_n)_1 D_\zeta$ により $(E_n)_1$ はトリミング後も残る. よって型付き厚みは $\tau_{h_c}^{\text{typ}}(G_n^c) \geq 2^n$ で
ある.

□

この文法族の標的言語 $\{a, c\}^+$ 自体は n に依存しない. 従って, この命題は特徴データに対する
学習作用素非依存の下界ではない. ここでの役割は, 通常の元文法厚みでは系 6.2 に現れる型付き精
密化パラメータを制御できないことを示すことだけである. このため, 一般 fixed- h の上界は型付き
厚みによって記述する.

7 固定窓と局所自明型付けに対する厚み付きデータ

固定窓では, 有界な接頭辞と接尾辞を保存することで, 元文法の厚みから型付き厚みを制御で
きる. 一般の h についてはこの性質は成り立たない (命題 6.3). Yoshinaka [16] および Eyraud–
Heinz–Yoshinaka [22, Definition 2.12] の多項式時間・厚み付きデータ同定 (IPTtD) の意味で,
バッチ作用素の特徴データ上界を与える. これは集合ベースの基準に文法厚みをサイズパラメータと
して追加するものである. 同じ正規形や同じ多項式次数は主張しない.

$k, \ell \geq 0$ を固定する. $G = (V, \Sigma, P, S_0)$ を縮約済み SBNF 文法, $\tilde{G}$ をその縮約済み $h_{k,\ell}$ -型付き
精密化とし,

$$N := |V \setminus \{S_0\}|, \quad \theta_{k,\ell}(G) := \begin{cases} \tau_G, & k + \ell = 0, \\ (k + \ell) + (2(k + \ell) - 1)N\tau_G, & k + \ell > 0 \end{cases}$$

とおく.

補題 7.1 (固定窓型付き生成語の有界性). $\tilde{G}$ の任意の非開始型付き記号 A_μ に対し $|\omega(A_\mu)| \leq$
 $\theta_{k,\ell}(G)$ である.

Proof. 付録 付録 A を参照されたい.

□

定理 7.2 (固定窓に対する多項式厚み付きデータ). 任意に固定した組 (k, ℓ) とアルファベット Σ に対し, 多項式 $q_{k, \ell}$ が存在し, $L(G) \in \mathcal{C}_{h_{k, \ell}}^{\text{cf}}$ を満たす任意の縮約済み SSBNF 文法 G について $\|W(\tilde{G})\| \leq q_{k, \ell}(|G|, \tau_G)$ が成り立ち, $W(\tilde{G})$ は $\mathcal{B}_{h_{k, \ell}}$ に対する特徴標本である.

Proof. 補題 7.1 より $\tau_{h_{k, \ell}}^{\text{typ}}(G) \leq \theta_{k, \ell}(G)$ であり, 固定 k, ℓ, Σ の下では右辺は $|G|, \tau_G$ の多項式である. 系 6.2 を適用すればよい. $\square$

上の定理は縮約済み SSBNF 表現について述べている. 次の正規化で任意の縮約済み CFG へ移送する.

命題 7.3 (厚みを多項式的に保存する SSBNF 正規化). 固定多項式 $q_{\text{size}}, q_{\text{thick}}$ が存在し, 非空言語を生成する任意の縮約済み CFG G_* を多項式時間で同値な縮約済み SSBNF 文法 G へ変換でき, $|G| \leq q_{\text{size}}(|G_*|)$, $\tau_G \leq q_{\text{thick}}(|G_*|, \tau_{G_*} + 1)$ が成り立つ.

証明は付録 A.2 に与える. 文法サイズと最短非空生成語を多項式に保つため, 終端分離と二分化を非開始 λ -規則除去より先に行う.

系 7.4 (局所自明型付けに対する通常厚み上界). $h: \Sigma^* \rightarrow M$ を固定し, $h(\Sigma^+)$ が局所自明であるとする. このとき, 縮約済み CFG G_* で表される任意の非空 $L \in \mathcal{C}_h^{\text{cf}}$ は, $\mathcal{B}_h$ に対して $|G_*|$ と τ_{G_*} の多項式サイズの特徴データをもつ.

Proof. $n := |h(\Sigma^+)| + 1$ とおく. 命題 3.5 より $\ker h_{n, n}|_{\Sigma^+} \subseteq \ker h|_{\Sigma^+}$ である. 縮約済み SSBNF 文法 G に対し, 縮約済み h -精密化に残る任意の A_μ を取る. その記号のある出現を通る成功導出木を一つ選び, 同じ基礎導出木に $h_{n, n}$ -生成語型を付け直す. 対応するコピー A_ν は成功木上に現れるので到達可能かつ生産的であり, トリム後にも残る. 命題 5.2 によると, 両記号の生成語言語はそれぞれ $L_G(A) \cap h_{n, n}^{-1}(\{\nu\})$ および $L_G(A) \cap h^{-1}(\{\mu\})$ に等しい. 核の精密化 $\ker h_{n, n}|_{\Sigma^+} \subseteq \ker h|_{\Sigma^+}$ により, 前者は後者に含まれる. 従って

$$\tau_h^{\text{typ}}(G) \leq \tau_{h_{n, n}}^{\text{typ}}(G) \leq 2n + (4n - 1)|V \setminus \{S_0\}| \tau_G$$

が補題 7.1 から従う. h は固定されているので n は定数であり, 系 6.2 から G に対する多項式特徴データ上界を得る. 命題 7.3 を適用すれば, 元の縮約済み CFG G_* へ移送できる. $\square$

空標的は空標本によって別途扱う.

定理 7.2 と命題 7.3 から固定窓の上界を直接得られる. 多項式は固定型付けとアルファベットに依存してよい. k, ℓ が可変の場合の様な上界, 非局所自明型付けに関する逆命題, 逐次学習器に対する多項式データ保証は主張しない.

8 線形部分クラス

線形言語はちょうど 1 ターン・プッシュダウンオートマトンによって受理される [19, 23]. 以下の正規化はその文法的対応物を与える. 成功導出には一つの継続する非終端記号の経路があり, これを *spine* と呼ぶ.

命題 8.1 (linear-spine SSBNF 正規化). 固定多項式 q_{lin} が存在し, 非空言語を生成する任意の線形 CFG G を多項式時間で同値な縮約済み SSBNF 文法 $G_0 = (V_0, \Sigma, P_0, S_0)$ へ変換でき,

554 $|G_0| \leq q_{\text{lin}}(|G|)$ である．さらに各二項生成規則は， $W_a \rightarrow a$ を満たすちょうど一つの新鮮な終端
555 ラッパー子と，ちょうど一つのそれ以外の非終端子をもつ．

556 構成は付録 付録 B に与える． $\tilde{G}_0$ を型付き精密化， $N_t := |\tilde{V}_0 \setminus \{\tilde{S}\}|$ とおく．各基礎非開始記号は
557 高々 $|M|$ 個の型付きコピーをもつので $N_t \leq |V_0 \setminus \{S_0\}| |M|$ である．

558 **補題 8.2** (短い標準生成語)． $\tilde{G}_0$ の任意の型付き非開始記号 X に対し $|\omega(X)| \leq N_t$ である．従って
559 $\tau_h^{\text{typ}}(G_0) \leq N_t$ である．

560 証明は付録 付録 C に与える．

561 **定理 8.3** (線形標的に対する多項式特徴データ)． h を固定する．線形 CFG G で表される任意の
562 $L \in \mathcal{C}_h^{\text{lin}}$ は， $\mathcal{B}_h$ に対し， $|G|$ の多項式で $\|\cdot\|$ -サイズが抑えられる特徴標本をもつ．

563 *Proof.* $L = \emptyset$ と $L = \{\lambda\}$ では第 5 節の標本を用いる．それ以外では命題 8.1 の G_0 を取る．補
564 題 8.2 から $\tau_h^{\text{typ}}(G_0) \leq N_t \leq |V_0 \setminus \{S_0\}| |M|$ なので，系 6.2 により $|G_0| \leq q_{\text{lin}}(|G|)$ の多項式サイ
565 ズの特徴標本を得る． $\square$

566 定理 5.6 と合わせると，選んだ線形 CFG 表現を基準として， $\mathcal{C}_h^{\text{lin}}$ の標的には多項式時間のバッチ
567 再構成と多項式サイズの特徴データが得られる．これは de la Higuera [7, Theorem 2] の線形言語
568 全体についての否定結果とは矛盾しない．本定理は固定 h に対する代入可能な部分クラスだけを対
569 象とするからである．さらに逐次学習器 $\mathcal{A}_h$ に対する多項式データ保証は主張しない．

570 **■非正則な線形 fixed- h 例．** 直前の定理は，正則標的や既知の線形代入可能クラスに限定されない．

$$L_{\pm,e} := \{a^{2m}cb^{2m} : m \geq 0\} \cup \{a^{2m+1}db^{2m+1} : m \geq 0\} \\ \cup \{a^n eb^n : n \geq 0\}.$$

571 これは線形文法

$$S \rightarrow U_{\text{ev}} \mid U_e, \quad U_{\text{ev}} \rightarrow c \mid aU_{\text{odd}}b, \quad U_{\text{odd}} \rightarrow d \mid aU_{\text{ev}}b, \\ U_e \rightarrow e \mid aU_eb$$

572 で生成される．添字 ev と odd は，対応する非終端記号自身の生成語長の偶奇ではなく，開始点から
573 外側を包む a, b の対の個数の偶奇を表す．

574 c, d, e を**中心記号**と呼ぶ．

575 **命題 8.4.** 言語 $L_{\pm,e}$ は線形かつ非正則であり，ある有限モノイドへの準同型 h に対して $\mathcal{C}_h^{\text{lin}}$ に属
576 する．一方，Clark–Eyraud 代入可能ではなく，いかなる固定 $k, \ell \geq 0$ に対しても (k, ℓ) -代入可能で
577 はない．

578 *Proof.* 線形性は表示文法から従う．有限型付けに関する代入可能性を示すため，

$$L_{\text{all}} := \{a^n \xi b^n : n \geq 0, \xi \in \{c, d, e\}\}, \quad Q := (aa)^*c(bb)^* \cup a(aa)^*db(bb)^* \cup a^*eb^*$$

579 とおく．線形言語 L_{all} は非空因子の規約で Clark–Eyraud 代入可能である．中心記号を含まない
580 因子は共通文脈から一意に決まり，中心記号を一つ含む因子 $a^i \xi b^j$ の分布は $i - j$ のみに依存する．
581 従って自明な型付け h_0 に対し $L_{\text{all}} \in \mathcal{C}_{h_0}^{\text{lin}}$ である． Q は正規言語で $L_{\pm,e} = L_{\text{all}} \cap Q$ だから，命
582 題 3.2(ii) と線形言語の正規交差に関する閉包性により， Q を認識するある有限モノイド準同型 g に
583 ついて $L_{\pm,e} \in \mathcal{C}_{h_0 \times g}^{\text{lin}}$ が従う．

また, $L_{\pm,e} \cap a^*eb^* = \{a^n eb^n : n \geq 0\}$ から非正則性が従う. 因子 c, e は空文脈を共有するが, $(a, b) \in \mathcal{D}_{L_{\pm,e}}(e) \setminus \mathcal{D}_{L_{\pm,e}}(c)$ なので Clark–Eyraud 代入可能ではない. さらに $k, \ell \geq 0$ を固定し, $m_0 := \max\{1, k+\ell\}$, $w_e := a^k eb^\ell$, $w_c := a^k cb^\ell$ とおく. 両因子は同じ長さ k の接頭辞と長さ ℓ の接尾辞をもち, 文脈 $(a^{2m_0-k}, b^{2m_0-\ell})$ を共有する一方, $(a^{2m_0+1-k}, b^{2m_0+1-\ell}) \in \mathcal{D}_{L_{\pm,e}}(w_e) \setminus \mathcal{D}_{L_{\pm,e}}(w_c)$ である. 従って固定窓代入可能性の反例基準より $L_{\pm,e} \notin \text{KL}$ である. $\square$

■四元型付けによる具体例. 上の正規フィルタによる証明では有限型付けの存在が示されたが, 実際には四元型付けだけで十分である. $M_{\pm,e} := \{1, \kappa_{cd}, \kappa_e, 0\}$ を, 1 が単位元で, すべての $\mu, \nu \in \{\kappa_{cd}, \kappa_e, 0\}$ に対して $\mu\nu = 0$ が成り立つモノイドとし, 準同型 $h_{\pm,e} : \{a, b, c, d, e\}^* \rightarrow M_{\pm,e}$ を

$$h_{\pm,e}(a) = h_{\pm,e}(b) = 1, \quad h_{\pm,e}(c) = h_{\pm,e}(d) = \kappa_{cd}, \quad h_{\pm,e}(e) = \kappa_e \quad (3)$$

で定める. このとき $L_{\pm,e}$ は $\sim_{h_{\pm,e}}$ -代入可能である. 実際, 中心記号を含まない非空因子は共通文脈から一意に決まる. $a^i eb^j$ の分布は $i - j$ のみに依存し, $\xi \in \{c, d\}$ に対する $a^i \xi b^j$ の分布は $(i - j, \text{par}(\xi) - i \bmod 2)$ のみに依存する. ただし $\text{par}(c) = 0$, $\text{par}(d) = 1$ とする. 共通文脈はそれぞれの不変量を一致させ, 同じ $h_{\pm,e}$ -型であることは e -因子と c/d -因子を区別する. 従って, 共通文脈をもつ同型の因子の分布は一致する.

従って定理 8.3 は KL の外にある非正則線形言語にも適用される. 表示文法は even-linear なので, Takada の control-set 枠組みからの分離は主張しない.

■生成語型付けが誘導する有限状態制御. 次の標準的な有限状態の直積構成は, Takada の control-set の見方との限定的な接点を与える. 線形文法 $G = (V, \Sigma, P, S)$ の各生成規則にアルファベット Π から相異なるラベルを与え, $\alpha \in \Pi^*$ が導出の生成規則ラベル列であるとき $A \Rightarrow_G^\alpha w$ と書く. $F \subseteq M$ に対し

$$C_{h,F}(G) := \{\alpha \in \Pi^* : S \Rightarrow_G^\alpha w \text{ for some } w \in \Sigma^*, h(w) \in F\}$$

とおく. これは正則制御集合である. 実際, 状態 $V \times M \times M$ と一つの受理状態をもつ有限オートマトンを用い, $(S, 1, 1)$ から開始する. ラベル付き規則 $A \rightarrow uBv$ に対して $(A, \mu_L, \mu_R) \mapsto (B, \mu_L h(u), h(v) \mu_R)$ と遷移し, 終端規則 $A \rightarrow w$ では $\mu_L h(w) \mu_R \in F$ のときちょうど受理する. 不変量は, 文形式 uAv が $(A, h(u), h(v))$ に対応することである. 従って受理されるラベル列は, 終端生成語の h -型が F に属する成功導出のものと同じよう一致する. よって $C_{h,F}(G)$ による正則制御は $L(G) \cap h^{-1}(F)$ をちょうど生成する. 任意の非終端記号 A から開始し $F = \{\mu\}$ とすれば, 型付きコピー A_μ についても同じ解釈が得られる. これは Takada の正則制御言語 [18] への有限状態の橋を与えるが, 任意の Takada control set が終端生成語型付けから得られるとは主張しない.

9 表現力と境界

ここでは fixed-window 階層と, より広い文脈自由言語族の間で本枠組みを位置づける.

9.1 RS 内の非線形標的

$\Delta := \{a^n b^n : n \geq 0\}$ とし Δ^* を考える. $z \in \{a, b\}^*$ に対し $\beta(z) := |z|_a - |z|_b$ とし,

$$\underline{\beta}(z) := \min\{\beta(p) : p \text{ は } z \text{ の接頭辞}\}$$

と定める. ここでは空接頭辞も含める. ba の各出現の高さを, その b で終わる接頭辞の高さと呼ぶ. 次の特徴づけを用いる: $(\star) w \in \Delta^*$ であることと, $\underline{\beta}(w) \geq 0$, $\beta(w) = 0$, かつすべての ba の出現高さが 0 であることは同値である. 順方向は $a^n b^n$ 因子への分解から従い, 逆方向は高さ 0 となる位置ごとに切れば balanced な $a^* b^*$ segment が得られる.

$\text{fst}(w), \text{lst}(w) \in \{\perp, a, b\}$ を最初と最後の記号 ($\perp$ では $\perp$) とし, $\text{ba}(w)$ で w が ba を含むかを記録する.

$$h_\star(w) := (\text{fst}(w), \text{lst}(w), \text{ba}(w)).$$

連接の要約は二因子の要約だけから決まる. 端点は明らかな仕方で連接され, 新しい ba は境界 $b|a$ でのみ生じ得る. 従って有限像 $M_\star := h_\star(\{a, b\}^*)$ に $h_\star(x)h_\star(y) := h_\star(xy)$ と積を入れれば, $h_\star$ は有限モノイド準同型になる.

非空の x に対し, $\text{Occ}_{ba}(x)$ を内部での ba の出現全体とする. 各 $o \in \text{Occ}_{ba}(x)$ に対し, $\eta_x(o)$ をその出現の b で終わる接頭辞の, x の先頭を基準とした高さとする.

$$\mathcal{Q}(x) := \{q \in \mathbb{Z} : q + \underline{\beta}(x) \geq 0 \text{ かつ } q + \eta_x(o) = 0 \text{ がすべての } o \in \text{Occ}_{ba}(x) \text{ について成り立つ}\}$$

と定める.

命題 9.1 (非線形 fixed- $h_\star$ 標的). Δ^* は決定性文脈自由・非正則・非線形で, $\sim_{h_\star}$ -代入可能である. さらにどの固定 $k, \ell \geq 0$ に対しても (k, ℓ) -代入可能ではない. 従って $\Delta^* \in \text{RS}_{h_\star}(\{a, b\}) \cap \text{CFL}$ かつ $\Delta^* \in \text{RS}(\{a, b\}) \setminus \text{KL}(\{a, b\})$ である.

Proof. 文法 $S \rightarrow TS \mid \lambda, T \rightarrow aTb \mid \lambda$ は Δ^* を生成する. また決定性 PDA は, 各ブロックの a 部分でスタックに記号を積み, 続く b 部分でそれらを取り除き, スタックが底記号へ戻ったときにのみ次のブロックを開始できるようにすればよい. $\Delta^* \cap a^* b^* = \Delta$ から非正則であり, 線形言語の正則交差に対する閉包性と $\Delta^* \cap a^* b^* a^* b^* = \Delta\Delta$ および $\Delta\Delta$ の非線形性から非線形である. 後者は Autebert–Berstel–Boasson [23, Section 6.1, Theorem 6.1 の直前] に明記されている.

代入可能性を示すため, 同じ $h_\star$ -型をもつ非空因子 x, y が共通文脈 (u, v) をもつとする. $uxv, uyv \in \Delta^*$ なので全体バランスから $\beta(x) = \beta(y)$ である. 任意の文脈 (u', v') を固定する. $(\star)$ により, 中間因子 x を走査する際に課される条件はちょうど, x の内部で高さが負にならないことと, x 内部の各 ba が大域的高さ 0 で現れることであり, これらは $\beta(u') \in \mathcal{Q}(x)$ と同値である. 境界 $u'|x$ または $x|v'$ をまたいで新たに生じ得る ba は x の最初と最後の記号だけに依存し, v' に入る高さは $\beta(u') + \beta(x)$ だけに依存する. 従って u', v' を固定すれば, 残りの membership 条件が x に依存するのは $h_\star(x), \beta(x), \mathcal{Q}(x)$ を通じてのみである. よって $\mathcal{Q}(x) = \mathcal{Q}(y)$ を示せば十分である.

両者が ba を含むなら, 内部 ba は可能な進入高さを一意に強制し, 共通文脈がその高さを供給するので $\mathcal{Q}(x) = \{\beta(u)\} = \mathcal{Q}(y)$ である. どちらも ba を含まなければ $x, y \in a^* b^*$ で, $\mathcal{Q}(z) = \{q : q \geq -\min\{0, \beta(z)\}\}$ だから $\beta(x) = \beta(y)$ から等号が従う. 従って $\mathcal{D}_{\Delta^*}(x) = \mathcal{D}_{\Delta^*}(y)$ である.

固定窓からの分離として k, ℓ を固定し, $m := \max\{1, k + \ell\}$, $x := a^m b^m$, $y := a^m b^m a^m b^m$ とおく. 両者は同じ長さ k の接頭辞と長さ ℓ の接尾辞をもち, 空文脈を共有する. さらに $axb \in \Delta^*$ だが, ayb の中央の ba は高さ 1 なので $ayb \notin \Delta^*$ である. 従って固定窓代入可能性の反例基準から, Δ^* はどの (k, ℓ) にも属さない. $\square$

従って fixed- h 枠組みは, 固定窓階層の外にある第 8 節の非正則線形例 $L_{\pm, e}$ と, 非線形文脈自由言語 Δ^* の双方を含む. control-set 法一般との分離は主張しない.

9.2 上限制約つき正則カウンタ族

正則言語 $L_0 = ae^*ce^*a \cup ae^*de^*a \cup be^*ce^*b$ による固定窓階層からの分離は Yoshinaka [16, Proposition 1] によって既に示されている. 以下の族は, 第 9.3 節の無界カウンタに対する有限状態の capped 版として残す.

$\Sigma_c := \{\uparrow, \downarrow, \#\}$ とする. $w = \delta_1 \cdots \delta_n \in \Sigma_c^*$ に対し, $\text{ht}_i(w)$ を先頭 i 文字を読んだ後の高さとする. $\text{ht}_0(w) = 0$ とし, $\uparrow$ で $+1$, $\downarrow$ で -1 , $\#$ で 0 にリセットする. $\rho \geq 1$ に対し

$$\text{CTR}_\rho := \{w \in \Sigma_c^* : 0 \leq \text{ht}_i(w) \leq \rho \text{ for all } 0 \leq i \leq |w|\}$$

とおく.

任意の $\rho \geq 1$ に対し CTR_ρ は正則である. 実際, 決定性有限オートマトンが高さ $0, \dots, \rho$ を記録し, 範囲外に一つの sink を置き, $\#$ で 0 に戻ればよい. 従って命題 3.1 から $\text{CTR}_\rho \in \text{RS}(\Sigma_c)$ となる.

定理 9.2. 任意の $\rho \geq 2$ に対し CTR_ρ はどの $k, \ell \geq 0$ についても (k, ℓ) -代入可能ではない.

Proof. k, ℓ を固定し $x := (\uparrow\downarrow)^k \uparrow^{\rho-1} \#^\ell$, $y := (\uparrow\downarrow)^k \uparrow^\rho \#^\ell$ とおく. 両者は固定窓基準に十分長く, 同じ長さ k の接頭辞と長さ ℓ の接尾辞をもち, ともに CTR_ρ に属する. 一方 $\uparrow x \in \text{CTR}_\rho$ だが $\uparrow y \notin \text{CTR}_\rho$ で, 後者は高さ $\rho + 1$ に達する. 従って分布が異なり, 反例基準が適用できる. $\square$

境界 $\rho \geq 2$ は最良である. 実際, CTR_1 は $(1, 1)$ -代入可能である. その所属条件は, 先頭文字が $\downarrow$ でないこと, および長さ 2 の因子 $\uparrow\uparrow, \downarrow\downarrow, \#\downarrow$ が現れないことだけで記述できる. したがって共通文脈をもつ許容された非空因子については, 先頭文字と末尾文字が等しければ, 任意の文脈での所属可否は一致する.

任意の $\rho \geq 1$ について, 上の DFA が誘導する遷移モノイド準同型を $h_\rho : \Sigma_c^* \rightarrow M_\rho$ とする. これは CTR_ρ を認識するので, すべての $\rho \geq 1$ に対して $\text{CTR}_\rho \in \mathcal{C}_{h_\rho}^{\text{cf}}$ が成り立つ. 一方, $\text{CTR}_\rho \notin \text{KL}$ という強い結論が成り立つのは $\rho \geq 2$ の場合である. この capped family は新しい正則分離ではなく, 下の無界言語 CTR と対比するためのものである.

9.3 RS の外にある自然な決定性文脈自由言語

補題 9.3 (有限モノイド障害). $L \subseteq \Sigma^*$ とする. 無限集合 $\Xi \subseteq \Sigma^+$ が存在し, 相異なる任意の $x, y \in \Xi$ について $\mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \emptyset$ かつ $\mathcal{D}_L(x) \neq \mathcal{D}_L(y)$ が成り立つなら $L \notin \text{RS}(\Sigma)$ である.

Proof. 有限 h は Ξ の二要素を同一視する. その二語は共通文脈をもち分布が異なるので $\sim_h$ -代入可能性に反する. $\square$

上限を外すと決定性文脈自由言語

$$\text{CTR} := \{w \in \Sigma_c^* : \text{ht}_i(w) \geq 0 \text{ for all } 0 \leq i \leq |w|\}$$

を得る．これは reset 付きの明らかな決定性プッシュダウン・カウンタで受理される．

系 9.4 (上限なしカウンタの障害). $\text{CTR} \notin \text{RS}(\Sigma_c)$ である．

Proof. $\Xi = \{\uparrow^i : i \geq 1\}$ を用いる． $i < j$ なら $(\lambda, \downarrow^i)$ は共通文脈だが, $(\lambda, \downarrow^j)$ は $\uparrow^j$ だけの文脈である． $\square$

一種類の括弧の Dyck 言語

$$D_1 := \{w \in \{a, b\}^* : |w'|_a \geq |w'|_b \text{ for every prefix } w', |w|_a = |w|_b\}$$

は標準的な決定性文脈自由言語 [24] である．ここでの D_1 は Dyck 言語全体を表し, Autebert–Berstel–Boasson [23] の規約では D_1^* と書かれる．

系 9.5. $D_1 \notin \text{RS}(\{a, b\})$ である．

Proof. $\Xi = \{b^i a^i : i \geq 1\}$ を用いる． $i < j$ なら (a^j, b^j) は共通文脈だが, (a^i, b^i) は $b^i a^i$ だけの文脈である． $b^j a^j$ では接頭辞 $a^i b^j$ がアンダーフローを起こす． $\square$

従って障害は無界スタック挙動それ自体ではない．非正則 1-turn 言語 $L_{\pm, e}$ は RS に属する．障害は, 文脈的挙動が異なるにもかかわらず相互に比較可能な因子が無限族をなし, 有限 h ではそれらをすべて分離できないことである．

補題 9.6 (固定語による商). L が $\sim_h$ -代入可能で $z \in \Sigma^*$ なら, $L/z := \{w : wz \in L\}$ も $\sim_h$ -代入可能である．

Proof. L/z の共通文脈 (u, v) は L では (u, vz) になる． L で分布が等しいなら, 任意の文脈 (s, t) の右に z を付加することで L/z に分布等式を移せる． $\square$

$S \rightarrow aSS \mid b$ が生成する言語を *Lukasiewicz 言語* と呼ぶ．Yoshinaka [16, Section 3] はすでに, この言語がどの固定 k, ℓ に対しても (k, ℓ) -代入可能でないことを指摘している．本論文の記法では $L_{\text{Luk}} = D_1 b$ [23] で, これは決定性文脈自由言語でもある [24]．ここでは右商の議論により, さらに強く有限型付け全体の和の外にあることを示す．もし $L_{\text{Luk}} \in \text{RS}(\{a, b\})$ なら補題 9.6 により $D_1 = L_{\text{Luk}}/b \in \text{RS}$ となり, 系 9.5 に反する．

9.4 Clark の congruential family との比較

Clark [25] は有限初期集合 $I \subseteq V$ を許し, $L_G[I] := \bigcup_{A \in I} L_G(A)$ と書く．このような文法が *congruential* であるとは, 各 $L_G(A)$ が $L_G[I]$ の一つの構文合同類に含まれることをいう． Γ 上の congruential grammar が生成する言語全体を $\text{CONG}(\Gamma)$ と書く．Clark はすでに substitutable および (k, ℓ) -substitutable language をこの族に位置づけている．次の命題はこの包含をすべての fixed- h slice へ拡張する．

命題 9.7 (Clark の congruential family との比較). 任意の有限アルファベット Γ と有限モノイド 709
 準同型 $h : \Gamma^* \rightarrow M$ に対して $\mathcal{C}_h^{\text{cf}} \subseteq \text{CONG}(\Gamma)$ である. 従って $\text{RS}(\Gamma) \cap \text{CFL} \subseteq \text{CONG}(\Gamma)$ であり, 710
 $\Gamma = \{a, b\}$ ではこの包含は真である. 711

Proof. 非空 $L \in \mathcal{C}_h^{\text{cf}}$ の縮約済み SSBNF 文法と型付き精密化 $\tilde{G}$ を取る. 任意の非開始型付き記号 712
 $X = A_\mu$ は終端到達文脈 (u, v) をもち, 命題 5.2 より任意の $w \in L_{\tilde{G}}(X)$ は非空かつ $h(w) = \mu$ で 713
 ある. 従って $x, y \in L_{\tilde{G}}(X)$ は同じ型と共通文脈 (u, v) をもち, fixed- h 代入可能性から $x \equiv_L y$ と 714
 なる. すなわち各型付き非終端記号は一つの構文合同類の語だけを生成する. 715

分離された開始記号を削除し, その型付き後続記号を有限初期集合として用いる. $\lambda \in L$ なら λ 716
 だけを生成する新しい初期記号を一つ加える. 命題 5.2 により, これで L の congruential grammar 717
 が得られる. 空言語は生成規則をもたない初期記号で扱える. h 全体に和を取れば包含が従う. 718

$\{a, b\}$ 上で包含が真であることには, Clark [25] も論じる Dyck 例を用いる. 任意の $x \in D_1$ に 719
 対し $uxv \in D_1$ iff $uv \in D_1$ なので $x \equiv_{D_1} \lambda$ である. 従って $S \rightarrow aSbS \mid \lambda$ は congruential だが, 720
 系 9.5 より $D_1 \notin \text{RS}(\{a, b\})$ である. $\square$ 721

10 結論 722

固定した h の下で, 多項式時間の集合駆動型再構成と保守的な Gold 同定を分離して与えた. 有 723
 限個の標準正例証拠により, 型付き厚みによる特徴データ上界が得られる. 正の像が局所自明な型付 724
 けでは通常の文法厚みで十分であり, 線形標的では文法サイズによる上界が得られる. 型付き厚みの 725
 指数ギャップが制限するのは, この精密化に基づく解析であり, 一般の学習アルゴリズムそのもので 726
 はない. 727

有限型付けを精密化してよいなら, 積型付けによって正則フィルタと消去を許す任意の逆準同型像 728
 を扱える. これは単一の fixed- h slice の閉包性ではなく, 有限情報の合成可能性を表す. 局所自明性 729
 の古典的判定条件から固定窓クラスの和が回復される. 非正則線形・非線形の例は固定窓を超える表 730
 現力を示す一方, カウンタ・Dyck 言語に関する障害と, Clark の congruential family への真の包 731
 含が本枠組みの限界を示す. 未解決問題として, $\text{RS} \cap \text{CFL}$ の特徴づけ, 非正則標的に対する $\mathcal{C}_h^{\text{lin}}$ の 732
 範囲, 有用な型付けの選択方法, およびプッシュダウンオートマトンによる直接的な特徴づけが挙げ 733
 られる. 734

データ利用可能性 735

本研究では実証データを使用していない. 736

利益相反の申告 737

著者は, 本論文で報告した研究に影響を与えたと考えられる既知の競合する金銭的利益関係または 738
 個人的関係がないことを申告する. 739

研究費

本研究は、公的機関、民間企業、または非営利部門のいずれの資金配分機関からも特定の助成を受けていない。

謝辞

著者は、指導・励まし・関連文献への助力をいただいた金澤誠教授と吉仲亮教授、ならびに本論文を大幅に改善する丁寧で建設的な報告をくださった二名の匿名査読者に感謝する。特に査読者は、投稿版の学習アルゴリズムの問題点を指摘し、定理 9.2 の直接的な二語反例を促してくださった。残る誤りはすべて著者の責任である。

付録 A 固定窓証拠語上界と厚み保存正規化

A.1 補題 7.1 の証明

補題 7.1 の証明. $k + \ell = 0$ のとき、 $h_{0,0}$ は Σ^+ 上で定数なので、 $\tilde{G}$ の非開始型付き記号 A_μ は基礎となる非終端記号 A と同じ非空生成語をもち、 $|\omega(A_\mu)| \leq \tau_G$ である。

$k + \ell > 0$ とする。 μ が $M_{k,\ell}$ の短語要素なら、型 μ の語はその短語自身なので、その長さは $k + \ell$ 未満である。残る長語要約要素 $\mu = \langle p, q \rangle$ について、この型をもつ A の導出木を一つ選び、最初の k 個と最後の ℓ 個の終端葉を印付けする。印付け葉はちょうど $k + \ell$ 個であり、そのラベルは必要な順序で p と q を与える。根から印付け葉への経路の和を $\mathcal{U}$ とする。

$\mathcal{U}$ 上でちょうど一つの子だけが $\mathcal{U}$ に残る非終端ノードの極大鎖を考える。同じ基礎非終端記号が一つの鎖に二度現れたら、上側の出現を下側の部分木で置き換える。これは同じ非終端記号からの正しい導出であり、印付け葉を含まない兄弟部分木しか削除しないので、印付けられた境界終端記号とその順序は保存される。これを繰り返すと、各極大一子鎖には高々 N 個の非終端記号しか残らない。

各極大一子鎖を縮約すると、 $k + \ell$ 個の印付け葉を結ぶ根付き二分木が得られ、その頂点数は高々 $2(k + \ell) - 1$ である。したがって、最初の分岐頂点より上にあり得る初期鎖も含め、極大一子鎖は高々 $2(k + \ell) - 1$ 本である。 $\mathcal{U}$ の外側に省略された兄弟部分木が生じるのはこれらの鎖上のノードだけであり、分岐ノードでは両方の子が $\mathcal{U}$ に含まれる。従って省略された兄弟部分木は高々 $(2(k + \ell) - 1)N$ 個である。

それぞれをその根の最短終端生成語で置き換えると、一つにつき高々 τ_G 個の終端記号を寄与する。印を付けた葉は元の語の最初の k 個と最後の ℓ 個の葉なので、 $k > 0$ の場合に印付き接頭辞より前へ、 $\ell > 0$ の場合に印付き接尾辞より後へ、印を付けなかった兄弟部分木が位置することはない。SSBNF の非開始記号の終端生成語はすべて非空である。従って、鎖の短縮と兄弟部分木の置換は、その間の部分語を変更しても印付きの接頭辞と接尾辞を保存する。 $k = 0$ または $\ell = 0$ の場合、対応する境界条件は空条件である。得られる語 w' は依然として A から導出され、接頭辞 p と接尾辞 q を保つので、同じ $h_{k,\ell}$ -型 μ をもち、 $|w'| \leq (k + \ell) + (2(k + \ell) - 1)N\tau_G$ 。

命題 5.2 の持ち上げ等式より、 $w' \in L_G(A) \cap h_{k,\ell}^{-1}(\{\mu\})$ は縮約済み精密化 $\tilde{G}$ に残る A_μ の生成語である。従って shortlex 最小の型付き生成語 $\omega(A_\mu)$ も同じ長さ上界を満たす。 $\square$

A.2 厚みを多項式的に保存する SSBNF 正規化

命題 7.3 の証明. $G_* = (V, \Sigma, P, S)$ を縮約済みで非空言語を生成する文法とし, $n := |G_*|$, $\bar{\tau} := \tau_{G_*} + 1$ とおく. 文法サイズと最短終端生成語とともに多項式に保つ順序で標準正規化を行う.

まず新しい開始記号 S_0 と規則 $S_0 \rightarrow S$ を導入し, $\lambda \in L(G_*)$ なら最終的に $S_0 \rightarrow \lambda$ を残す. 長さ 2 以上の右辺に現れるすべての終端記号を新しいラッパー $W_a \rightarrow a$ で分離し, 長さ 2 を越える右辺を二分化する. 得られる文法を G_{bin} とする. 選んだ妥当な符号化の下で, これらの操作の総サイズは $O(n)$ である. 元の各非終端記号は同じ終端生成語を保持. 新たな各二分化記号は元のある右辺の連続部分を展開し, そこに含まれる元の記号数は高々 $O(n)$ である. その部分に現れる各生産的非終端記号を最短終端生成語で置き換えれば, ある定数 c_1 に対して $\tau_{G_{\text{bin}}} \leq c_1 n \bar{\tau}$ が得られる.

次に, G_{bin} の空語導出可能記号から得られる最短の **非空** 生成語を抑える. $A \Rightarrow_{G_{\text{bin}}}^* w$ を非空終端語への導出とし, 導出木の終端葉の一つ選んで根からの経路をたどる. 同じ非終端記号が二度現れれば, 上側の部分木を下側の部分木で置き換えてサイクルを削除できる. これを繰り返すと経路上の非終端記号数は高々 $|V_{G_{\text{bin}}}|$ となる. 各二項ノードで経路外の兄弟記号をその最短終端生成語へ置き換えると, 空語導出可能な兄弟記号は空語を寄与してよく, 選んだ終端葉が一文字を寄与するので, ある定数 c_2 に対して

$$\min\{|w| > 0 : A \Rightarrow_{G_{\text{bin}}}^* w\} \leq 1 + |V_{G_{\text{bin}}}| \tau_{G_{\text{bin}}} \leq c_2 n^2 \bar{\tau}$$

である.

ここで非開始 λ -規則をすべて除去する. G_{bin} は二分文法なので, 規則 $A \rightarrow BC$ から生じるのは, 空語導出可能な子に応じて高々 $A \rightarrow BC$, $A \rightarrow B$, $A \rightarrow C$ であり, 指数的な空語導出可能記号の部分集合に関する展開は起こらない. 通常の構成は各非終端記号の非空終端生成語を保存するので, 上の長さ上界も保たれる. 続いて単位閉包を計算し, 非開始単位規則を除去する. 各出発非終端記号と, そこから単位規則だけで到達可能な各非単位規則について, その規則を出発非終端記号にコピーする. この段階の前には非終端記号が $O(n)$ 個, 非単位規則も $O(n)$ 個なので, 生成される規則は高々 $O(n^2)$ 個である. 単位規則消去は各非終端記号の言語を保存するため厚み上界を増加させない. 最後に無用記号をトリムする.

得られる文法は縮約済みで開始記号が分離され, 各非開始規則は終端規則または二項規則であり, $S_0 \rightarrow \lambda$ が唯一の可能な λ -規則である. 従って SSBNF である. そのサイズは n の多項式, 厚みは高々 $c_2 n^2 (\tau_{G_*} + 1)$ であり, すべての変換は多項式時間で実行できる. $\square$

付録 B linear-spine SSBNF 正規化の証明

命題 8.1 の構成は, 標準的な開始記号分離, 無用記号・空語導出可能規則・単位規則の除去, および二分化を組み合わせ, 第 8 節で必要な単一 spine 形を保存する.

命題 8.1 の証明. $L(G) = \{\lambda\}$ なら, 単一規則 $S_0 \rightarrow \lambda$ をもつ縮約済み文法を取ればよい. 二項生成規則をもたないので, 要求される条件は自明に成り立つ. 従って以下では, $L(G)$ が空でない語を含むと仮定する.

807 S を元の開始記号とする．右辺に決して現れない新しい S_0 を導入し， $S_0 \rightarrow S$ を加え，さらに
808 $\lambda \in L(G)$ なら $S_0 \rightarrow \lambda$ も加える．以後 S は非開始記号として扱う．無用記号を除去し， λ を S_0 に
809 のみ保存しつつ非開始 λ -規則を除去し，その後で非開始単位規則を除去する．開始規則には単位規則
810 消去を適用しないので，最終トリミング後に残る各開始規則は，要求どおり $S_0 \rightarrow A$ または $S_0 \rightarrow \lambda$
811 の形になる．この順序により， λ -消去によって新たに生じた単位規則も除去される．入力文法は線形
812 なので，各右辺には空語導出可能な非終端記号が高々一つしか現れず，各生成規則から追加される代
813 替右辺は高々一つである．ここで線形性は二箇所で使われる．第一に，空語導出可能規則の展開を多
814 項式に抑える．第二に，消去後も，残る各非単位右辺には非終端記号が高々一つしか現れないことを
815 保証し，これが以下の「ラッパーでない子を持つだけ持つ」分解を可能にする．単位閉包とラッパー
816 鎖による二分化そのものは，一般 CFG に対しても多項式時間の操作である．単位規則消去では有限
817 な単位到達可能閉包を計算する．すなわち，出発非終端記号と，到達可能な非単位生成規則の各組
818 は，高々一つの複製規則を生じる．従って生成規則数も右辺長の総和も多項式に保たれる．
819 新たな単位規則を作らずに二分化するため，新鮮な終端ラッパー $W_a \rightarrow a$ を導入する．規則
820 $A \rightarrow a_1 \cdots a_m B b_1 \cdots b_n$ に対し，単位規則を消去済みなので $m + n > 0$ である．まず $R_0 := B$ と
821 おき， $n > 0$ のとき右側の鎖

$$R_j \rightarrow R_{j-1} W_{b_j} \quad (1 \leq j \leq n)$$

822 を作る．途中の R_j は新しい記号とする． $m = 0$ の場合は $R_n := A$ として，表示した最後の規則の
823 左辺を A とする． $m > 0$ の場合には $n > 0$ なら R_n は新しい記号とし， $n = 0$ なら $R_0 = B$ のま
824 まとする．次に $m > 0$ なら $L_m := R_n$ とおき，新たな $L_1, \dots, L_{m-1}$ を導入して

$$A \rightarrow W_{a_1} L_1, \quad L_i \rightarrow W_{a_{i+1}} L_{i+1} \quad (1 \leq i < m)$$

825 とする． $m = 1$ の場合には $L_1 = R_n$ である．すべての規則は二項規則で，ちょうど一つの子が新鮮
826 な終端ラッパーとなる．元の記号 B はラッパーではない．
827 終端記号のみからなる規則 $A \rightarrow a_1 \cdots a_m$ については， $m = 1$ なら $A \rightarrow a_1$ を残す． $m \geq 2$ では
828 新鮮な $\Theta_2, \dots, \Theta_m$ を導入して

$$A \rightarrow W_{a_1} \Theta_2, \quad \Theta_i \rightarrow W_{a_i} \Theta_{i+1} \quad (2 \leq i \leq m-1), \quad \Theta_m \rightarrow a_m$$

829 とする ($m = 2$ なら中間の規則族は空である)．従って新たな非開始規則は終端規則か，ちょうど一
830 つのラッパー子と別の非終端子をもつ二項規則である．ラッパーは二項規則のラッパー子位置にのみ
831 現れ，継続する非終端子にはならない．終端のみの規則の構成は，終端規則をもつ新しい非ラッパー
832 記号で終わる．最後のトリムはこの性質，分離開始形，縮約済み性を保存する．鎖への変換のサイズ
833 は，すでに多項式に抑えられた右辺長総和に対して線形なので，全体の構成は多項式時間で実行で
834 き，文法サイズも多項式に抑えられる． $\square$

835 付録 C 短い標準生成語補題の証明

836 補題 8.2 の証明．命題 8.1 の linear-spine SSBNF 形では，各二項 spine step は $A \rightarrow W_a B$ または
837 $A \rightarrow B W_a$ の形で， $W_a \Rightarrow a$ だから，継続する非終端記号の外側にちょうど一つの終端記号を放出
838 する．

X が終端ラッパーなら $|\omega(X)| = 1$ である. そうでなければ, 型付き spine 記号 X からの最短終
 端導出を取り, spine を $X = X_0, X_1, \dots, X_t$ と書く. X_t は終端規則を用い, 生成語長は $t + 1$ であ
 る. もし $X_i = X_j$ ($i < j$) なら, 二出現の間を削除して, より少ない spine step をもつ有効な導出
 を得られるので最短性に反する. 従って $t + 1$ 個の型付き spine 記号は相異なり, すべて非開始記号
 なので $t + 1 \leq N_t$ である. よって $|\omega(X)| \leq N_t$ が従う. $\square$

参考文献

- [1] M. Kanazawa. *Learnable Classes of Categorical Grammars*. CSLI Publications, 1998.
- [2] M. Kanazawa. Identification in the limit of categorical grammars. *Journal of Logic, Language and Information*, 5(2):115–155, 1996. doi:10.1007/BF00173697.
- [3] E. M. Gold. Language identification in the limit. *Information and Control*, 10(5):447–474, 1967.
- [4] J.-E. Pin. Syntactic semigroups. In G. Rozenberg and A. Salomaa (eds.), *Handbook of Formal Languages*, Vol. 1, pp. 679–746, Springer, 1997.
- [5] S. Eilenberg. *Automata, Languages, and Machines*, Vol. A. Academic Press, 1974.
- [6] J.-E. Pin. *Mathematical Foundations of Automata Theory*. Lecture notes, version of March 24, 2025. <https://www.irif.fr/~jep/PDF/MPRI/MPRI.pdf>.
- [7] C. de la Higuera. Characteristic sets for polynomial grammatical inference. *Machine Learning*, 27:125–138, 1997.
- [8] C. de la Higuera. *Grammatical Inference: Learning Automata and Grammars*. Cambridge University Press, 2010.
- [9] A. Clark and R. Eyraud. Polynomial identification in the limit of substitutable context-free languages. *Journal of Machine Learning Research*, 8:1725–1745, 2007.
- [10] M. Wakatsuki and E. Tomita. A fast algorithm for checking the inclusion for very simple deterministic pushdown automata. *IEICE Transactions on Information and Systems*, E76-D(10):1224–1233, 1993.
- [11] T. Kuriyama. *Learning Algorithm for Relation-Substitutable Context-Free Languages*. arXiv:1409.6247, originally posted in 2014 (v3: November 2014). <https://arxiv.org/abs/1409.6247>.
- [12] R. Yoshinaka. General perspective on distributionally learnable classes. In *Proceedings of the 14th Meeting on the Mathematics of Language (MoL 14)*, pp. 87–98, 2015.
- [13] A. Clark and R. Yoshinaka. Distributional learning of context-free and multiple context-free grammars. In *Topics in Grammatical Inference*, Springer, 2016.
- [14] F. Coste, G. Garet, and J. Nicolas. Locally substitutable languages for enhanced inductive leaps. In *Proceedings of the Eleventh International Conference on Grammatical Inference*, PMLR 21:97–111, 2012.
- [15] F. Coste and J. Nicolas. Learning local substitutable context-free languages from positive examples in polynomial time and data by reduction. In *Proceedings of the 14th International Conference on Grammatical Inference*, PMLR 93:155–168, 2019.

- [16] R. Yoshinaka. Identification in the limit of k, l -substitutable context-free languages. In *Grammatical Inference: Algorithms and Applications – ICGI 2008*, LNCS 5278, pp. 266–279, Springer, 2008. doi:10.1007/978-3-540-88009-7_21.
- [17] Y. Takada. Grammatical inference for even linear languages based on control sets. *Information Processing Letters*, 28(4):193–199, 1988. doi:10.1016/0020-0190(88)90208-6.
- [18] Y. Takada. Learning formal languages based on control sets. In K. P. Jantke and S. Lange (Eds.), *Algorithmic Learning for Knowledge-Based Systems*, LNAI 961, pp. 316–339, Springer, 1995. doi:10.1007/3-540-60217-8_15.
- [19] S. Ginsburg and E. H. Spanier. Finite-turn pushdown automata. *SIAM Journal on Control*, 4(3):429–453, 1966. doi:10.1137/0304034.
- [20] F. Coste, D. Fredouille, C. Kermorvant, and C. de la Higuera. Introducing domain and typing bias in automata inference. In *ICGI 2004*, LNAI 3264, pp. 115–126, Springer, 2004. doi:10.1007/978-3-540-30195-0_11.
- [21] A. Clark. Learning trees from strings: A strong learning algorithm for some context-free grammars. *Journal of Machine Learning Research*, 14:3537–3559, 2013.
- [22] R. Eyraud, J. Heinz, and R. Yoshinaka. Efficiency in the identification in the limit learning paradigm. In J. Heinz and J. M. Sempere (Eds.), *Topics in Grammatical Inference*, Springer, 2016. doi:10.1007/978-3-662-48395-4_2.
- [23] J.-M. Autebert, J. Berstel, and L. Boasson. Context-free languages and pushdown automata. In G. Rozenberg and A. Salomaa (Eds.), *Handbook of Formal Languages*, Vol. 1, pp. 111–174, Springer, 1997.
- [24] S. Ginsburg and S. A. Greibach. Deterministic context-free languages. *Information and Control*, 9:620–648, 1966.
- [25] A. Clark. Distributional learning of some context-free languages with a minimally adequate teacher. In *Proceedings of ICGI 2010*, LNCS 6339, pp. 24–37, Springer, 2010. doi:10.1007/978-3-642-15488-1_4.