固定有限半群型付けの下での文脈自由言語の分布学習

Takayuki Kuriyama
独立研究者
growup.kuriyama@gmail.com

概要

非空因子を有限半群への固定準同型 $s : \Sigma^+ \to \mathsf{S}$ で型付けした文脈自由言語について，正例学習を研究する．多項式時間の集合駆動型作用素は，代入可能な標的を有限の正例証拠から再構成し，別の保守的学習器は非空標的を Gold の意味で極限同定する．特徴データの総符号長は，文法サイズと型付き最短生成語長の多項式で抑えられる．固定接頭辞 – 接尾辞窓と有限群値で型が決まる場合は通常厚みで十分であり，線形標的では線形文法のサイズだけで足りる．一方，固定二元半束型付けの下では，文法サイズが線形で通常厚みが小さい有限標的にも指数長の特徴標本が必要となる．この下界は，当該固定型付けクラス全体に特徴標本をもつ任意の集合駆動型作用素にも及ぶ．型付けを変更したときの閉包性，固定窓を超える例，および Dyck 言語による障害により，本枠組みの範囲を明らかにする．

キーワード： 文法推論；文脈自由言語；分布学習；正例からの同定；有限半群

1 序論

1.1 背景と動機

Gold [1] は正例だけによる極限同定の限界を示した．分布学習は対象クラスを制限することで正の結果を得る．代表例は Clark–Eyraud の代入可能性 [2] と Yoshinaka の (k, ℓ)-代入可能性 [3] である．一般的な背景は de la Higuera [4]，相補的な範疇文法の正例学習は Kanazawa [5, 6] を参照されたい．

■先行研究との関係． 著者の 2014 年のプレプリント [7] は，可認識同値関係に相対化した代入可能性を導入し，Yoshinaka の一般的な多ソート signature 理論 [8] の公刊に先行する．固定半群準同型 $s : \Sigma^+ \to \mathsf{S}$ の非空語ファイバーは，型付き連接演算と語全体のソートへの昇格演算を備えた互いに素なソートとして表現できる．この特殊化により，正例からの極限同定，多項式時間の仮説更新，および型付き標的文法のサイズに関して個数が多項式の特徴証拠の存在は，Yoshinaka の一般理論 [8, Theorem 1 and Lemma 3] からすでに得られる．ただし，この具体的なソートの選択を Yoshinaka 自身の構成として帰属させるものではない．

以下の構成は固定有限半群型付けでの具体化であり，空規則・単位規則を含む直接的な完全性証明を与える．学習可能性・更新時間・証拠の個数そのものを独立の新規成果とは主張しない．本稿の中心は特徴データの**総符号長**，その多項式上界と指数下界，および有限型付けの代数的・表現力的帰結にある．局所自明半群による固定窓の特徴づけ自体は古典的である．

本論文では，この研究計画の可認識合同関係版を考える．$s : \Sigma^+ \to \mathsf{S}$ を有限半群への準同型と

し，$\sim_s := \ker s \subseteq \Sigma^+ \times \Sigma^+$ とする．$x \in \Sigma^*$ に対し $\mathcal{D}_L(x) := \{(u,v) : uxv \in L\}$ と書く．言語 L が $\sim_s$-**代入可能**であるとは，非空の x, y について $s(x) = s(y)$ かつ $\mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \emptyset$ ならば $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ が成り立つことをいう．文脈自由な $\sim_s$-代入可能言語のクラスを $\mathcal{C}_s^{\mathrm{cf}}$ と書き，これを *fixed-s slice* と呼ぶ．したがって，分布の完全な一致を要求するのは，固定された有限代数的比較の下ですでに一致する因子だけである．

例えば $\Sigma = \{a\}$，$L = \{a, aa\}$ を考える．$(\lambda, \lambda) \in \mathcal{D}_L(a) \cap \mathcal{D}_L(aa)$ であるが，$(a, \lambda) \in \mathcal{D}_L(a) \setminus \mathcal{D}_L(aa)$ である．したがって，L は Clark–Eyraud 代入可能でない．一方，長さの偶奇を記録する準同型 $s(a^n) = n \bmod 2$（値域 $\mathbb{Z}/2\mathbb{Z}$）を用いれば，a と aa は異なる型をもち，$L \in \mathcal{C}_s^{\mathrm{cf}}$ となる．

Σ^+ 上の有限指数半群合同関係，すなわち有限半群準同型の核は，有限型付けを与える．固定した s に対し，文脈自由性を仮定しないすべての $\sim_s$-代入可能言語のクラスを RS_s と書く．表現力の比較のため，$\mathsf{RS} := \bigcup_s \mathsf{RS}_s$ と定める．ここで s は Σ^+ 上の有限半群準同型全体を動く．すべての正則言語はこの和に属する．一方，本論文の学習結果は一つの s をクラス全体に固定した $\mathcal{C}_s^{\mathrm{cf}}$ だけを対象とし，RS 全体の学習可能性は主張しない．

一つの固定接頭辞 – 接尾辞窓と異なり，s は独立な有限状態の因子特徴を積によって組み合わせられる．このように有限型付けそのものを精密化してよいなら，正則フィルタとの交わりや，消去を許す任意の逆準同型像を，再び有限型付けの枠内で扱える（命題 3.2）．これは一つの fixed-s slice を同じ s のまま閉じるという主張ではない．代数的な判定条件で固定接頭辞 – 接尾辞窓が非空因子の型を決める場合を特徴づけ（命題 3.5），さらに有限群値を加えた型付けにも特徴データ上界を与える（系 7.5）．後述の非正則線形例と非線形例は固定窓を超える表現力を示し，カウンタや Dyck 言語に関する障害はその表現力の限界を示す．

s は終端因子に対する型付けバイアスであり，因子の出現位置の外側文脈は型に含めない [9]．正則制御集合との接点 [10, 11] は線形文法に限る（第 8 節）．

1.2 貢献と主要結果

本稿では，有限正例証拠からの再構成作用素 Rec_s と，別の保守的 Gold 学習器 Learn_s を与え，再構成と各更新の多項式時間性を示す．これらの定性的学習保証および多項式時間性は Yoshinaka の一般理論 [8] の具体化である．新しい特徴データの**総符号長**の評価は Rec_s に関するものであり，Learn_s の逐次的な多項式データ保証は主張しない．

主要な貢献は，有限型付けの定量的負担と表現力上の範囲にある．

(1) **特徴データの上界と下界．**任意の固定 s について，定性的な再構成と有限の特徴証拠は任意の CFG から直接得られる．一般の右辺についても，規則一つに対して標準証拠語一つで十分である（定理 5.2）．定量的な評価には，多項式サイズの二分・単位・空語標準形（BUNF）への変換を用い，型付き最短生成語長によって特徴データの総符号長を抑える（系 6.3）．正語像が局所自明有限半群と有限群の結合 $\mathbf{LI} \vee \mathbf{Grp}$ に属する型付けでは，元の CFG のサイズと通常厚みで十分である（第 7 節，系 7.5）．また，線形標的では線形文法サイズのみで足りる．他方，固定二元半束型付けでは，文法サイズと通常厚みが $O(n)$ の有限標的にも特徴標本の語長に $\Omega(2^n)$ の下界が生じる．この下界は識別対の両標的に特徴標本をもつ任意の集合駆動型作用素に及び，同じ標的の任意の縮約済み上記標準形文法の型付き厚みにも指数下界が成立する（命題 6.4，系 6.5）．

(2) **代数的・表現力上の範囲．**単一の fixed-s slice を保つのではなく，有限型付けを変更することで正則フィルタとの交わりや逆準同型像に関する閉包性を得る．固定窓型付けに関する古典的代数的特徴づけを整理し，すべての固定窓クラスの外にある非正則標的と，カウンタ・Dyck 言語による障害を示す．線形文法では型付けが正則制御集合も誘導する．

2 準備

Σ を有限アルファベットとし，Σ^* を単位元 λ をもつ自由モノイドとする．また $\Sigma^+ := \Sigma^* \setminus \{\lambda\}$ とおく．対 $(u, v) \in \Sigma^* \times \Sigma^*$ を **終端文脈** と呼ぶ．$L \subseteq \Sigma^*$ と $x \in \Sigma^*$ に対し，L における x の **分布** を $\mathcal{D}_L(x) := \{(u, v) \in \Sigma^* \times \Sigma^* : uxv \in L\}$ と定める．L の **構文合同関係** は，$x, y \in \Sigma^*$ に対して $x \equiv_L y \iff \mathcal{D}_L(x) = \mathcal{D}_L(y)$ により定める．$x \equiv_L y$ のとき，x と y は **構文合同** であるという [12, Chapter III, Proposition 10.2]．通常通り，$\equiv_L$ はモノイド合同であり，$x \equiv_L x'$ かつ $y \equiv_L y'$ ならば $xy \equiv_L x'y'$ である．

語 $w \in \Sigma^*$ と文字 $a \in \Sigma$ に対し，$|w|_a$ は w における a の出現回数を表す．

文脈自由文法（CFG）は有限非終端記号集合 V，開始記号 $S \in V$，および $A \in V$, $\alpha \in (V \cup \Sigma)^*$ に対する生成規則 $A \to \alpha$ からなる組 $G = (V, \Sigma, P, S)$ である．**文形式**とは $(V \cup \Sigma)^*$ の任意の語である．G における一段階導出を $\alpha \Rightarrow_G \beta$ と書き，その反射推移閉包を $\Rightarrow_G^*$ と書く．したがって $L(G) := \{w \in \Sigma^* : S \Rightarrow_G^* w\}$．$A \in V$ に対して $L_G(A) := \{w \in \Sigma^* : A \Rightarrow_G^* w\}$ とおく．非終端記号 $X \in V$ に対し，$S \Rightarrow_G^* uXv$ が成り立つとき，終端文脈 (u, v) を G における X の **終端到達文脈** と呼ぶ．非終端記号が S から到達可能な文形式中に現れるとき **到達可能** であるといい，終端語を導出するとき **生産的** であるという．到達可能性または生産性の少なくとも一方を欠く非終端記号を **無用** といい，λ を導出する非終端記号を **空語導出可能**（*nullable*）という．$A, B \in V$ に対する生成規則 $A \to B$ を **単位規則** という．**単位閉包**とは，単位生成規則が非終端記号上に誘導する関係の反射推移閉包である．すべての非終端記号が到達可能かつ生産的である文法を **縮約済み** という．非空言語を生成する文法について，その **トリム**（縮約部分）とは，まず生産的でない非終端記号とそれらに接続する生成規則を削除し，次に残った文法で開始記号から到達不能な非終端記号とそれらに接続する生成規則を削除して得られる部分文法をいう．各右辺に高々一つの非終端記号しか現れない CFG を **線形** という．**二分化**とは，新たな非終端記号を用いて長い右辺を同値な二項生成規則の鎖へ置き換えることをいう．CFL を文脈自由言語全体のクラスとする．任意の有限表現 $\mathcal{R}$ に対し，$|\mathcal{R}|$ は固定した妥当な符号化の長さを表すものとする．文法については，これは通常の生成規則中の記号数と多項式の範囲で同値である．ここでは Wakatsuki–Tomita [13] が用い，Yoshinaka [3] が採用した最短生成語に基づく**厚み**を用いる（Eyraud–Heinz–Yoshinaka [14, Definition 2.11] も参照）．縮約済み文法を $G = (V, \Sigma, P, S)$ として

$$\tau_G := \max_{A \in V} \min\{\, |w| : A \Rightarrow_G^* w,\ w \in \Sigma^* \,\}$$

と定める．すなわち τ_G は，各非終端記号の最短終端生成語の長さを取り，その最大値をとったものである．

2.1 正例データからの学習

Gold の explanatory model [1] を用いる．H_0 を，一つの開始記号をもち生成規則をもたない固定 CFG とし，$L(H_0) = \emptyset$ とする．以下のテキスト規約は非空の標的言語に限定する．空言語はこのテキストに基づく Gold の記述から除外し，別途 H_0 により表す．同値に，通常の pause 記号をテキストに加えることで空標的を含めることもできるが，余分な記法を避けるためにここでは非空テキスト規約を用いる．非空言語 L に対し，**テキスト**とは，L の各語が少なくとも一度は現れる L 上の無限列 $\mathcal{T} = (w_1, w_2, \ldots)$ である．$\mathcal{T}[n] = (w_1, \ldots, w_n)$ および $K_n := \{w_1, \ldots, w_n\}$ と書く．学習器 Learn が非空言語 L を **極限同定**するとは，L の任意のテキスト $\mathcal{T}$ に対して，ある n_0 と文法 H が存在し，すべての $n \geq n_0$ について $\mathsf{Learn}(\mathcal{T}[n]) = H$ かつ $L(H) = L$ が成り立つことをいう．したがって，仮説表現そのものが最終的に安定する．逐次学習器が **保守的** であるとは，新たに提示された正例データが現在の仮説によって生成されない場合にのみ，その現在の仮説を変更することをいう．

この逐次学習器とは別に，**集合駆動型再構成作用素** Rec を考える．これは有限語集合から文法への写像であり，とくにその出力は提示順序や重複回数に依存しない．任意の有限標本 K に対して $K \subseteq L(\mathsf{Rec}(K))$ が成り立つとき，Rec は **標本整合的** であるという．有限集合 $\mathcal{F} \subseteq L$ が L の Rec に対する **特徴標本** であるとは，任意の有限 K について $\mathcal{F} \subseteq K \subseteq L$ ならば $L(\mathsf{Rec}(K)) = L$ が成り立つことをいう．これは de la Higuera の多項式文法推論枠組み [15] の特徴標本に対応する．学習器に相対的な特徴標本とその符号化サイズについては [4, Section 7.3.3, Definition 7.3.3] も参照されたい．ただし同書の定義は逐次的提示に対するものであり，本論文の条件は明示的に集合駆動型である．標本サイズを $\|K\| := \sum_{w \in K} (|w| + 1)$ で測る[*1]．したがって λ も 1 を寄与する．以下では **特徴データ** という語を，特徴標本 $\mathcal{F}$ の符号化サイズ $\|\mathcal{F}\|$ の略称としてのみ用いる．定量的結果では，$\mathsf{Rec}(K)$ の多項式時間構成と，多項式に抑えられる特徴データサイズを組み合わせる．多項式更新時間と多項式特徴標本サイズは別の評価基準であり [4, Sections 7.3.2–7.3.3]，それらの一方だけから逐次的な多項式時間・データ同定は導けない．Eyraud–Heinz–Yoshinaka [14, Definitions 2.5 and 2.8] は，逐次的な多項式時間・データ同定と集合ベースの基準を区別する．前者では特徴標本を観測した時点で正しい仮説に到達し，その後は仮説が安定しなければならない．後者は，特徴標本を含む任意の有限標本から正しく再構成できることを要求する．本論文の多項式特徴データ保証は集合駆動型の Rec_s に対するものであり，逐次学習器 Learn_s の多項式データ保証ではない．後者の Gold 安定化は系 5.4 で別途示す．

2.2 固定有限半群型付け

有限半群 S と全射半群準同型 $s : \Sigma^+ \twoheadrightarrow \mathsf{S}$ を固定する．S の乗法表と各 $a \in \Sigma$ の像 $s(a)$ を入力の固定情報とする．非空語に対する $s(w)$ は左から右への積により $O(|w|)$ 時間で求まる．全射性は一般性を失わない．任意の有限半群型付けは正の像半群へ終域を制限できるからである．後で直積や逆準同型像から非全射の型付けが得られる場合も，新単位元付加の前に終域を正の像半群へ制限すると

[*1] $+1$ は，$K = \{\lambda\}$ のような非空標本のサイズが 0 になることを防ぐ．また $|K| \leq \|K\|$ となるため，正例数も同じサイズ尺度で抑えられる．

いう規約を採用する．以下，特記しない限りアルファベットは非空とする．$\Sigma = \emptyset$ の場合，標的言語は $\emptyset$ または $\{\lambda\}$ のみであり，従来の学習器が直接処理できる．

有限半群 T の冪等元を $e^2 = e$ を満たす元とし，その集合を $E(\mathsf{T})$ と書く．すべての $e \in E(\mathsf{T})$, $t \in \mathsf{T}$ について $ete = e$ が成り立つとき T を**局所自明**と呼ぶ．非空有限半群は冪等元を持つ．従って有限半群の全射準同型によって局所自明性は保存される．実際，像の冪等元の逆像部分半群は冪等元を持つからである．

定義 2.1 (固定-s 代入可能性)**.** 言語 $L \subseteq \Sigma^*$ が $\sim_s$-代入可能 であるとは，すべての $x, y \in \Sigma^+$ について，$s(x) = s(y)$ と $\mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \varnothing$ から $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ が従うことをいう．

補題 2.2 (有限半群への標準的新単位元付加)**.** 有限半群 S に，すでに単位元がある場合もそれとは異なる新単位元 $\mathbf{1}_\sharp$ を付加して $\mathsf{S}^\sharp = \mathsf{S} \sqcup \{\mathbf{1}_\sharp\}$ とおく．このとき $s : \Sigma^+ \twoheadrightarrow \mathsf{S}$ は一意の全射モノイド準同型 $\widehat{s} : \Sigma^* \twoheadrightarrow \mathsf{S}^\sharp$ へ拡張され，

$$\widehat{s}(w) = \begin{cases} \mathbf{1}_\sharp, & w = \lambda, \\ s(w), & w \in \Sigma^+ \end{cases}$$

となる．さらに $\mathsf{S}^\sharp \cong \Sigma^* / \ker \widehat{s}$ である．ここで $\ker \widehat{s}$ は

$$\ker \widehat{s} = \{(x, y) \in \Sigma^* \times \Sigma^* : \widehat{s}(x) = \widehat{s}(y)\}$$

で定義される核合同を表す．特に

$$\widehat{s}(x) = \widehat{s}(y) \quad \Longleftrightarrow \quad (x = y = \lambda) \text{ または } (x, y \in \Sigma^+ \text{ かつ } s(x) = s(y))$$

が成立する．したがって定義 *2.1* は

$$\forall x, y \in \Sigma^*, \quad \big(\widehat{s}(x) = \widehat{s}(y) \wedge \mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \emptyset\big) \Longrightarrow \mathcal{D}_L(x) = \mathcal{D}_L(y)$$

と同値である．逆に，任意の有限モノイド型付け $h : \Sigma^* \to M$ は $s = h|_{\Sigma^+} : \Sigma^+ \to h(\Sigma^+)$ という有限半群型付けを与える．h による代入可能性も定義 *2.1* と同じく非空因子のみを比較する場合には，言語クラスも非空因子に関する再構成文法も変わらない．$h(\lambda)$ 型の非空因子と λ まで比較する別条件との同値性は主張しない．

Proof. 新単位元の積により $\widehat{s}$ は準同型となる．s が全射で，λ が $\mathbf{1}_\sharp$ へ写るため，拡張も全射である．$\mathbf{1}_\sharp \notin \mathsf{S}$ なので核の特徴づけが成立し，非空因子の比較と全因子での $\widehat{s}$-型の比較は同値となる．逆方向も，非空語上の型の等式だけが定義および再構成規則に使われることから従う． □

以下，代入可能言語族・再構成作用素・型付き厚みの添字は**非空語**上の半群準同型とする．任意のアルファベットに対する一元半群への唯一の型付けを s_0 と書く．正則言語の認識や空の文脈の計算にモノイド準同型 $h : \Sigma^* \to M$ を使う場合は，その制限 $s = h|_{\Sigma^+}$ が学習バイアスである．nullable な生成語は補題 2.2 の $\widehat{s}$ で処理し，代数的条件は正語像に課す．

任意の $x \in \Sigma^*$ に対し，$\widehat{s}(x)$ をその **生成語型** と呼ぶ．非空語では $\widehat{s}(x) = s(x)$ である．文脈自由 $\sim_s$-代入可能言語のクラスを $\mathcal{C}_s^{\mathrm{cf}}$ と書き，$\mathcal{C}_s^{\mathrm{lin}} := \{L \in \mathcal{C}_s^{\mathrm{cf}} : L \text{ はある線形 CFG により生成される}\}$ と定める．したがって $\mathcal{C}_s^{\mathrm{lin}}$ は線形言語からなる部分クラスである．

3　固定可認識代入可能性

固定 s に対し $\mathsf{RS}_s := \{L \subseteq \Sigma^* : L \text{ は } \sim_s\text{-代入可能}\}$ とおく．fixed-s slice は $\mathcal{C}_s^{\mathrm{cf}} = \mathsf{RS}_s \cap \mathrm{CFL}$ であり，$\mathcal{C}_s^{\mathrm{lin}}$ はそのうち線形 CFG で生成される言語からなる．表現力の比較に限り，s を Σ^+ 上の有限半群準同型全体に動かして $\mathsf{RS} := \bigcup_s \mathsf{RS}_s$ とする．アルファベットを明示するときは $\mathsf{RS}_s(\Gamma)$, $\mathsf{RS}(\Gamma)$ と書き，以下の包含はアルファベットごとに解釈する．学習結果は常に一つの固定 s を対象とする．

命題 3.1. $L \subseteq \Sigma^*$ が正則であることと，ある有限半群型付け $s : \Sigma^+ \to \mathsf{S}$ と $\mathsf{Acc} \subseteq \mathsf{S}^\sharp$ に対して $L = \widehat{s}^{-1}(\mathsf{Acc})$ と書けることは同値である．この形で認識される言語は RS_s に属する．従ってすべての正則言語は RS に属する．

Proof. 正則言語の構文モノイド準同型 [12, Chapter III, Proposition 10.2] を非空語に制限し，終域を正の像半群へ縮小する．新単位元による拡張で，空語が L に属する場合かつその場合に限り $\mathbf{1}_\sharp$ を受理型に含めればよい．逆に有限モノイド準同型 $\widehat{s}$ で認識される言語は正則である．非空因子 x, y の s-型が等しければ，任意の文脈 u, v に対し $\widehat{s}(uxv) = \widehat{s}(uyv)$ なので $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ が成り立つ．□

非空アルファベット上では，RS も $\mathsf{RS} \cap \mathrm{CFL}$ も正例データから極限同定できない．命題 3.1 により両者はすべての有限言語と Σ^* を含むため，Gold の定理が適用されるからである．同様に Yoshinaka [3, Section 4] は，彼の設定では (k, ℓ)-代入可能な文脈自由言語クラス全体の和が正例から極限同定できないことを指摘している．その理由は，その和が λ を含まないすべての有限言語と少なくとも一つの無限言語を含むからである．以下で学習可能性を主張するのは，個別の $\mathcal{C}_s^{\mathrm{cf}}$ のみに対してである．

新単位元付加を用いると，有限半群型付け s, s', t の精緻化と直積を，モノイド合同の核として記述できる：

$$\ker \widehat{s'} \subseteq \ker \widehat{s} \iff \ker s' \subseteq \ker s, \qquad \ker \widehat{s \times t} = \ker \widehat{s} \cap \ker \widehat{t}.$$

ここで $\widehat{s \times t}$ は正の像半群 $(s \times t)(\Sigma^+)$ に新単位元を付加した拡張を表す．またその像は $\mathrm{im}(\widehat{s} \times \widehat{t})$ と同型であり，$\mathsf{S}^\sharp \times \mathsf{T}^\sharp$ の部分モノイドとなる．従って第一の包含の下で $\mathsf{RS}_s \subseteq \mathsf{RS}_{s'}$，また $\mathsf{RS}_s \cup \mathsf{RS}_t \subseteq \mathsf{RS}_{s \times t}$ が従う．ただし精緻化は定量的な型付き文法を大きくし得る．

Yoshinaka [3, Proposition 1] は，固定窓代入可能言語が正則言語との交わりや消去を許す逆準同型像について閉じないことを示した．一方，非消去準同型の逆像については閉包性が成り立つ．実際，非消去準同型 φ では，$p \in \Gamma^k$ に対して $|\varphi(p)| \geq k$ なので，$\varphi(prq)$ の先頭 k 文字は p のみに依存する．接尾辞についても同様であり，窓長の閾値より短い因子は，型が等しければ語自体が等しい．従って，固定窓代入可能性の条件を φ に沿って逆像へ引き戻せる．これに対し，次の命題は，有限型付けを変更することで，正則フィルタとの交わりや消去的準同型による逆像を扱えることを示す．

命題 3.2 (有限情報に関する閉包性)**.** $s : \Sigma^+ \to \mathsf{S}$ と $t : \Sigma^+ \to \mathsf{T}$ を有限半群型付けとする．

(i) $L \in \mathsf{RS}_s$，$J \in \mathsf{RS}_t$ ならば $L \cap J \in \mathsf{RS}_{s \times t}$ である．

(ii) $R_{\mathrm{reg}} = \widehat{t}^{-1}(\mathsf{Acc}_t)$ が正則で $L \in \mathcal{C}_s^{\mathrm{cf}}$ ならば $L \cap R_{\mathrm{reg}} \in \mathcal{C}_{s \times t}^{\mathrm{cf}}$ である．

(iii) $\varphi : \Gamma^* \to \Sigma^*$ を消去的でもよい準同型とし，$r = (\widehat{s} \circ \varphi)|_{\Gamma^+} : \Gamma^+ \to \mathsf{S}^\sharp$ とおく．$L \in \mathsf{RS}_s$ なら

ば $\varphi^{-1}(L) \in \mathsf{RS}_r$ であり，$L \in \mathcal{C}_s^{\mathrm{cf}}$ ならば $\varphi^{-1}(L) \in \mathcal{C}_r^{\mathrm{cf}}$ である．[*2]

Proof. (i) は，共通文脈を持ち $(s \times t)$-型が等しい非空因子が，L と J のそれぞれで分布一致することから従う．(ii) は (i) と CFL の正則言語との交わりに関する閉包性による．(iii) の r はモノイド準同型 $\widehat{s} \circ \varphi$ の非空語への制限なので半群準同型である．同じ r-型を持つ非空因子 x, y の像は，双方が空語か，双方が非空で同じ s-型を持つかのいずれかである．前者では逆像の分布は直ちに一致し，後者では L における代入可能性と共通文脈の逆像から同じ結論が従う．CFL の逆準同型閉包性も用いる． □

■型付けの適合性とコスト． 補題 2.2 により，$L \in \mathsf{RS}_s$ であることと，共通文脈をもち分布が異なる因子対を $\ker \widehat{s}$ が区別することは同値である．従って型付けは有限指数モノイド合同による分離問題となる．精緻化と直積はこの条件を保つが，特徴データを指数的に増大させる場合がある（命題 6.4）．補題 9.3 は有限型付けによる分離の障害を与え，第 7 節と第 8 節は厚みを制御できる場合を示す．より強い条件 $\ker \widehat{s} \subseteq \equiv_L$ は十分だが，これを課すと L は正則になる．

3.1 古典的特殊場合

Clark–Eyraud の元の定義 5 は空語を含む因子を扱っている [2]．ここでは Clark [16] に従い λ を比較から除く．この違いは $L = a^+$ でも重要である．(a, λ) は $\mathcal{D}_L(\lambda)$ と $\mathcal{D}_L(a)$ の双方に属するが，(λ, λ) は $\mathcal{D}_L(a)$ に属し $\mathcal{D}_L(\lambda)$ には属さない．よって型による分離なしに空語も比較すると a^+ は代入可能でなくなる．一方 $\widehat{s}$ は空語を独立した型にするので，この比較は要求されない．すべての $x, y \in \Sigma^+$ について $\mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \emptyset$ から $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ が従うとき，L を ***Clark–Eyraud* 代入可能**と呼ぶ．これは定義 2.1 の自明モノイドの場合，従って Yoshinaka の $(0, 0)$ の場合にちょうど一致する．

$k, \ell \geq 0$ に対し，$\mathrm{pref}_k(w)$ と $\mathrm{suf}_\ell(w)$ をそれぞれ長さ $\min\{k, |w|\}$ の接頭辞と長さ $\min\{\ell, |w|\}$ の接尾辞とする．特に $\mathrm{pref}_0(w) = \mathrm{suf}_0(w) = \lambda$ であり，短い語については語全体を返す．Yoshinaka の変数を，本稿の記法に合わせて改名する．以下では u_i, v_i を外側文脈，p, q を窓，r, s をその内側部分に用いる．L が (k, ℓ)-**代入可能** であるとは，すべての $p \in \Sigma^k$, $q \in \Sigma^\ell$ および $u_1, u_2, v_1, v_2, r_1, r_2 \in \Sigma^*$ について，$pr_1q, pr_2q \neq \lambda$ のとき

$$u_1pr_1qv_1 \in L, \quad u_1pr_2qv_1 \in L, \quad u_2pr_1qv_2 \in L \\ \Longrightarrow \quad u_2pr_2qv_2 \in L$$

が成り立つことをいう．

命題 3.3 (固定窓の有限半群による実現)**.** 任意の $k, \ell \geq 0$ に対し，全射有限半群準同型 $s_{k,\ell} : \Sigma^+ \to W_{k,\ell}$ が存在し，$L \subseteq \Sigma^*$ の (k, ℓ)-代入可能性と $\sim_{s_{k,\ell}}$-代入可能性は同値である．

Proof. $m_0 := \max\{1, k + \ell\}$ とし，非空語 w に対して

$$s_{k,\ell}(w) := \begin{cases} (\mathrm{short}, w), & 0 < |w| < m_0, \\ (\mathrm{long}, \mathrm{pref}_k(w), \mathrm{suf}_\ell(w)), & |w| \geq m_0 \end{cases}$$

[*2] $\mathsf{S}^\sharp$ の新単位元は消去フラグを代替する．自明型付け，$L = a^+$，$\varphi(a) = a$，$\varphi(b) = \lambda$ では逆像の非空因子 a, b が共通文脈を持つが分布は異なる．

と定める．この型の等値関係は Σ^+ 上の両側合同である．短語型の一致は同じ語を意味する．長語型の一致では，左右に共通の語を連接しても接頭辞と接尾辞の窓が一致する．従って有限商半群 $W_{k,\ell}$ には結合的な積が誘導され，$s_{k,\ell}$ は全射半群準同型となる．

非空 x, y の型が等しければ，$x = y$ であるか，共通の $p \in \Sigma^k$, $q \in \Sigma^\ell$ を用いて $x = pr_1 q$, $y = pr_2 q$ と書ける．後者では共通文脈と一方の任意の文脈に四語条件を適用し，対称性から分布の一致を得る．逆に Yoshinaka の条件の二つの非空因子は同じ $s_{k,\ell}$-型なので，相対的代入可能性から第四の語が従う． □

Yoshinaka [8, Example 4] は，(k,ℓ)-代入可能性をソート付き signature $\Sigma_{k,\ell}$ で既に表現している．命題 3.3 は，この窓による比較を誘導する有限半群の商型付けを明示するものであり，窓 signature の符号化そのものについて先取権を主張しない．

■固定窓代入可能性の反例基準． x, y が長さ $\max\{1, k+\ell\}$ 以上で，同じ長さ k の接頭辞と長さ ℓ の接尾辞をもち，共通文脈をもつ一方で分布が異なるなら，L は (k,ℓ)-代入可能ではない．最初の三条件から $s_{k,\ell}$-型が等しく共通文脈をもち，最後の条件が $\sim_{s_{k,\ell}}$-代入可能性に反するからである．

従って固定 (k,ℓ) クラスはちょうど $\mathsf{RS}_{s_{k,\ell}}$ であり，第 7 節でその多項式厚み付きデータ上界を与える．$k = \ell = 0$ では $s_{0,0}$ はすべての非空語を一つの型へ写し，Σ^+ 上で s_0 と一致する．アルファベット Γ に対し

$$\mathsf{KL}(\Gamma) := \bigcup_{k,\ell \geq 0} \{L \subseteq \Gamma^* : L \text{ は } (k,\ell)\text{-代入可能}\}$$

とし，$\mathsf{KL} := \mathsf{KL}(\Sigma)$ と略記する．

3.2 主定理

定理 3.4 (固定-s 学習定理)**.** 効率的に計算可能な全射有限半群準同型 $s : \Sigma^+ \twoheadrightarrow \mathsf{S}$ を固定する．集合駆動型再構成作用素 Rec_s と保守的逐次学習器 Learn_s が存在し，次を満たす．

(i) Rec_s は標本整合的で，$\mathsf{Rec}_s(K)$ は $\|K\|$ の多項式時間で構成できる．

(ii) すべての $L \in \mathcal{C}_s^{\mathrm{cf}}$ は Rec_s に対する有限特徴標本をもつ．

(iii) Learn_s はすべての非空 $L \in \mathcal{C}_s^{\mathrm{cf}}$ を *Gold* の意味で同定し，各更新はそれまでに見たデータの多項式時間で行える．

(iv) 正の像半群 $s(\Sigma^+)$ が有限な局所自明半群と有限群の直積の部分半群の準同型像なら，各非空標的について *(ii)* の標本は，その標的を表す任意の縮約済み *CFG* G_* に対し $|G_*|$ と $\tau_{G_*} + 1$ の多項式サイズに選べる．特に，固定窓型付けと有限群型付けに適用できる．

(v) 任意の固定 s と $L \in \mathcal{C}_s^{\mathrm{lin}}$ に対し，*(ii)* の標本は，L を表す任意の線形 *CFG* G_* について $|G_*|$ の多項式サイズに選べる．

(iv)–(v) の多項式は固定した s と Σ に依存してよいが，選んだ標的文法 G_* には依存しない．項目 *(iv)–(v)* の定量的機構と，一般の固定型付けに対するその限界は，第 *6–8* 節で扱う．

これは Gold の定理と整合する．非空アルファベット上では，クラス $\mathcal{C}_s^{\mathrm{cf}}$ はすべての有限言語を含むわけではない．$s(x) = s(y)$ を満たす相異なる非空語 x, y を取り，さらに $|z| > \max\{|x|, |y|\}$ を満たす $z \in \Sigma^*$ を取る．$\{x, y, zx\}$ では x, y は空文脈を共有するが，(z, λ) は x だけの文脈である．

■固定窓の代数的位置づけ． 以下の同値性の基礎となる局所自明有限半群の恒等式と，それに対応する接頭辞・接尾辞による正則言語の特徴づけは古典的である [17, Chapter 2, Proposition 3.5 and Theorem 3.6]．以下では，任意の有限半群型付けの正語像と核による定式化を明示して証明する．新しい半群定理としては主張しない．なお，構文半群の局所自明性によって特徴づけられる古典的な正則言語族は，*generalized definite*（接頭辞 – 接尾辞検査可能）言語と呼ばれる [18, Proposition 5.18]．ここでは構文半群に限らない固定準同型の正の像と核を扱い，その言語クラスの和への適用と，系 7.5 の学習に固有な厚みの評価を記録する．以下の代数的条件は $\mathsf{S}^\sharp$ ではなく，正の像半群 $\mathsf{S} = s(\Sigma^+)$ に課す．実際 $\mathsf{S} \neq \emptyset$ のとき，新単位元 $\mathbf{1}_\sharp$ と任意の $t \in \mathsf{S}$ について $\mathbf{1}_\sharp t \mathbf{1}_\sharp = t \neq \mathbf{1}_\sharp$ なので，$\mathsf{S}^\sharp$ 自体は局所自明でない．

命題 3.5 (局所自明型付けと固定窓)**.** 非空アルファベット上の全射有限半群準同型 $s : \Sigma^+ \twoheadrightarrow \mathsf{S}$ と $n := |\mathsf{S}| + 1$ に対し，次は同値である．

(i) S は局所自明である．

(ii) ある $k, \ell \geq 0$ について $\ker s_{k,\ell} \subseteq \ker s$ が成り立つ．

(ii) は $k = \ell = n$ で満たせる．各窓半群 $W_{k,\ell} = s_{k,\ell}(\Sigma^+)$ は局所自明であり，

$$\mathsf{KL}(\Sigma) = \bigcup_{\substack{s:\Sigma^+ \to \mathsf{S} \\ \mathsf{S} \text{ が有限局所自明}}} \mathsf{RS}_s(\Sigma)$$

が成り立つ．CFL と交わらせても同様である．

Proof. $W_{k,\ell}$ の短語型は冪等元でない．正語を二乗すると短語の代表が変わるか長語型になるためである．長語型 $e = s_{k,\ell}(x)$ と正語 u に対して xux は x と同じ窓をもち，任意の t について $ete = e$ となる．従って $W_{k,\ell}$ は局所自明である．

任意の有限半群 S に対し，$n = |\mathsf{S}| + 1$ ならば古典的な恒等式 $\mathsf{S}^n = \mathsf{S}E(\mathsf{S})\mathsf{S}$ が成り立つ [17, Chapter 1, Proposition 1.12]．さらに S が局所自明ならば，任意の冪等元 e, f と $t \in \mathsf{S}$ に対し $etf = ef$ が成り立つ [17, Chapter 2, Proposition 3.5]．$p, q \in \Sigma^n$ について $s(p) = aeb$, $s(q) = cfd$ と書く．$r = \lambda$ でも $b\widehat{s}(r)c \in \mathsf{S}$ なので，$s(prq) = a\,e\,(b\widehat{s}(r)c)\,f\,d = aefd = s(pq)$ が従う．長さ $2n$ 以上では長さ n の窓が型を決定し，それより短い語は $s_{n,n}$ が区別する．逆に (ii) は $W_{k,\ell} \twoheadrightarrow \mathsf{S}$ を誘導し，局所自明性は準同型像で保存される．言語族の等式は核の精密化の単調性から従う． □

4 再構成作用素と逐次学習器

4.1 有限標本からの再構成

有限標本 $K \subseteq \Sigma^*$ に対し，

$$\widehat{V}(K) := \{[\![x]\!] : x \in \Sigma^+,\ \exists u, v \in \Sigma^* \text{ with } uxv \in K\}$$

とおく．したがって，標本中で観測された相異なる非空因子ごとに仮説非終端記号を一つだけ置く．二重角括弧は非終端記号名の一部であり，商類や終端記号を表すものではない．観測された非空因子 x, y に対し

$$x \approx_{K,s} y \quad \Longleftrightarrow \quad s(x) = s(y) \text{ かつ } \mathcal{D}_K(x) \cap \mathcal{D}_K(y) \neq \emptyset$$

と書く．文法 $\mathsf{Rec}_s(K)$ は非終端記号集合 $\widehat{V}(K) \cup \{\widehat{S}\}$ と開始記号 $\widehat{S}$ をもち，表示されたすべての角括弧付き非終端記号が $\widehat{V}(K)$ に属する場合に，次の規則をもつ：

$$\begin{aligned}
&\text{(B)} \quad [\![xy]\!] \to [\![x]\!][\![y]\!], \quad x, y \in \Sigma^+,\\
&\text{(U)} \quad [\![x]\!] \to [\![y]\!], \qquad x \approx_{K,s} y,\\
&\text{(L)} \quad [\![a]\!] \to a, \qquad a \in \Sigma,\\
&\text{(S)} \quad \widehat{S} \to [\![w]\!], \qquad w \in K \cap \Sigma^+.
\end{aligned}$$

$\lambda \in K$ のときは，規則 (S) に $\widehat{S} \to \lambda$ も含める．有限標本 $K \subseteq K'$ に対して，$\mathsf{Rec}_s(K)$ のすべての非終端記号と生成規則は $\mathsf{Rec}_s(K')$ にも含まれる．従って $L(\mathsf{Rec}_s(K)) \subseteq L(\mathsf{Rec}_s(K'))$ である．ここで生成規則は集合として扱い，重複を除く．従って $\mathsf{Rec}_s(K)$ は標本 K のみに依存し，因子出現の列挙順に依存しない．

この文法は Yoshinaka [3, Section 4, Algorithm 1] の部分文字列添字付き構成に基づき，Clark [16, Section 4, Algorithm 1] も同じ構成を紹介している．特に半群型付け $s = s_{k,\ell}$ のとき，規則 (U) の非自明な場合は Yoshinaka の単位規則と一致する．すなわち相異なる非空の観測因子が共通の標本文脈をもち，同じ $s_{k,\ell}$-型をもつとき結ばれる．同値に，その二因子はともに長さ $\max\{1, k+\ell\}$ 以上で，同じ長さ k の接頭辞と長さ ℓ の接尾辞をもつ．冗長な恒等規則，初期規則を別の開始記号で表す点，および λ の扱いを除けば，両構成は一致する．一般の固定 s では，この接頭辞 – 接尾辞の比較を s-型の一致で置き換える．

補題 4.1 (標本整合性)**.** 任意の有限正例標本 K に対して，$K \subseteq L(\mathsf{Rec}_s(K))$ が成り立つ．

Proof. $w = a_1 \cdots a_m \in K \cap \Sigma^+$ とする．規則 (S) により $[\![w]\!]$ に入る．w の任意の二分木分解に沿って規則 (B) を繰り返すと一文字因子へ到達し，それらはすべて同じ標本語中に現れるので観測済みである．最後に規則 (L) が $a_1 \cdots a_m$ を生成する．$\lambda \in K$ の場合は開始規則が直接生成する． □

定理 4.2 (健全性)**.** $K \subseteq L$ かつ L が $\sim_s$-代入可能ならば，$L(\mathsf{Rec}_s(K)) \subseteq L$ である．

Proof. $[\![x]\!]$ を根とする導出木の高さについて帰納法を行い，

$$[\![x]\!] \Rightarrow^*_{\mathsf{Rec}_s(K)} w \quad \Longrightarrow \quad x \equiv_L w \text{ かつ } s(w) = s(x) \tag{1}$$

を示す．因子非終端記号は観測された非空語を添字にもつので，規則 (U) で比較する因子は定義 2.1 の非空条件を満たす．また規則 (B)–(L) は，因子非終端記号から λ を導出しない．規則 (L) は明らかである．規則 (U) で $[\![x]\!] \to [\![y]\!]$ とする．定義から，ある標本文脈 (u, v) が存在して $uxv, uyv \in K \subseteq L$ かつ $s(x) = s(y)$ である．fixed-s 代入可能性により $x \equiv_L y$ であり，帰納法の仮定から $y \equiv_L w$ と $s(w) = s(y)$ が従うので (1) を得る．

規則 (B) について，$[\![xy]\!] \to [\![x]\!][\![y]\!]$ から得られる終端語を $w_1 w_2$ と書く．帰納法の仮定より $x \equiv_L w_1$, $y \equiv_L w_2$, $s(w_1) = s(x)$, $s(w_2) = s(y)$ である．$\equiv_L$ はモノイド合同なので $xy \equiv_L w_1 w_2$ であり，準同型性から $s(w_1 w_2) = s(xy)$ である．

最後に開始規則 $\widehat{S} \to [\![x]\!]$ を用いたなら $x \in K \subseteq L$ なので $(\lambda, \lambda) \in \mathcal{D}_L(x)$ である．不変量から $\mathcal{D}_L(w) = \mathcal{D}_L(x)$ だから $w \in L$ を得る．λ の直接規則は $\lambda \in K \subseteq L$ の場合にしか存在しない． □

4.2 逐次学習器

Rec_s を各データ到着時に再計算しても，文法表現は一般には安定しない．たとえば $L_{\mathrm{c}} = \{a^n c b^n : n \geq 0\}$ では，長い正例から $[\![a^n c b^n]\!]$ のような新しい因子非終端記号が生じる．そこで Clark–Eyraud の Substitution Graph Learner (SGL, Algorithm 2) および Yoshinaka の (k,ℓ)-Substitutable Grammar Learner ((k,ℓ)-SGL, Algorithm 1) と同じ保守的ラッパーを用いる [2, 3]．集合駆動型再構成と逐次学習の区別については Eyraud–Heinz–Yoshinaka [14, Appendix] も参照されたい．固定空文法 H_0 から始め，w_n を読んだ後

$$H_n := \begin{cases} H_{n-1}, & w_n \in L(H_{n-1}), \\ \mathsf{Rec}_s(K_n), & w_n \notin L(H_{n-1}), \end{cases} \qquad \mathsf{Learn}_s(\mathcal{T}[n]) := H_n$$

とする．再構成は常に蓄積標本全体 K_n を用いる．Rec_s は集合駆動型だが，Learn_s の最終文法は提示順序に依存し得る．実際，無限標的 L のテキスト $\mathcal{T}$ を固定し，最後の再構成時点のすべての標本語より長い $w \in L$ を選ぶ．$\mathcal{T}$ に対する最終文法には $[\![w]\!]$ が存在しない一方，冒頭に w を追加したテキストでは最初の再構成に w が含まれ，その後の再構成でも $[\![w]\!]$ が残る．両方とも標的 L を生成するが，最終的な文法は異なる．主張するのは構文的な極限安定化である（系 5.4）．Clark [16, Section 4, Example 1] も参照されたい．

5 有限証拠・厳密再構成・計算量

5.1 標的の精密化と有限証拠

定性的な完全性のためには，任意の標的 CFG を $\mathsf{S}^\sharp$ 上で型付けすればよい．仮説文法 $\mathsf{Rec}_s(K)$ は変更せず，従来どおり観測された非空因子を用い，λ は開始規則から直接扱う．

非空言語 L を生成する任意の CFG $G = (V, \Sigma, P, S_0)$ を取る．その規則を $\rho : A \to u_0 B_1 u_1 \cdots B_r u_r$ と書く．ここで $u_i \in \Sigma^*$，$B_i \in V$，$r \geq 0$ である．各 $(\mu_1, \ldots, \mu_r) \in (\mathsf{S}^\sharp)^r$ に対して $\mu = \widehat{s}(u_0) \prod_{i=1}^{r} (\mu_i \widehat{s}(u_i))$ とし，次の型付き規則を加える：

$$A_\mu \to u_0 (B_1)_{\mu_1} u_1 \cdots (B_r)_{\mu_r} u_r.$$

この構成は，終端記号のみの規則，空語規則，単位規則も扱う．新しい開始記号 $\widetilde{S}$ を加え，すべての $\mu \in \mathsf{S}^\sharp$ に対して $\widetilde{S} \to (S_0)_\mu$ を置く．非到達・非生産的な記号を削除した縮約済み文法を $\widetilde{G}$ と書く．この精密化は有限であるが，サイズは指数的になり得る．学習アルゴリズムの一部ではない．

残った型付き記号はすべて到達可能かつ生産的で，その終端生成語は指定された型をもつ．とくに $A_{\mathbf{1}_\sharp}$ は λ だけを生成し，$\mu \neq \mathbf{1}_\sharp$ の A_μ は空語を生成しない．残存する各非開始記号 X に対し，その終端生成語のうち shortlex 順序で最小のものを $\omega(X)$ とする．$\omega(X) = \lambda$ も許す．型付けにより，$\omega(X)$ と X の各規則の標準右辺生成語は同じ型をもつ．外側の到達文脈には型注釈を付けない．

命題 5.1 (型付き持ち上げと生成語不変量)**.** *任意の CFG G の型付き精密化は $L(\widetilde{G}) = L(G)$ を満たす．元の開始記号 S_0 の型付きコピーも含め，残存する任意の A_μ に対して*

$$L_{\widetilde{G}}(A_\mu) = L_G(A) \cap \widehat{s}^{-1}(\{\mu\}).$$

とくに $A_\mu \Rightarrow_{\widetilde{G}}^{*} w$ ならば $\widehat{s}(w) = \mu$ である．

Proof. 型添字を消去すると G の導出を得る．逆に，G の導出木の各節点に終端生成語の型を注釈すれば，空語を生成する子も含めて型付き導出木となる．成功する型付き導出は縮約後にも残る．残存する A_μ の到達可能な出現箇所に，型が μ の任意の $w \in L_G(A)$ の注釈付き導出木を接ぎ木することで，各ファイバーについての等式と開始言語の等式が得られる． □

残存する各非開始記号 X に対し，**標準到達文脈** $\chi(X) = (u_X, v_X)$ を選ぶ．まず $|u_X| + |v_X|$ を最小化し，同点の場合は u_X，次いで v_X の shortlex 順序で選ぶ．$\widetilde{G}$ は縮約済みなので，この文脈は存在する．非開始記号を左辺にもつ型付き規則 $\rho : X \to u_0 Y_1 u_1 \cdots Y_r u_r$ に対し，その **標準右辺生成語** を

$$t_\rho := u_0 \omega(Y_1) u_1 \cdots \omega(Y_r) u_r$$

と定める．t_ρ と $\omega(X)$ はいずれも $L_{\widetilde{G}}(X)$ に属し，同じ型をもつ．有限な **標準正例証拠集合** を

$$\begin{aligned} \mathsf{Wit}(\widetilde{G}) := {} & \{u_X \omega(X) v_X : X \in \widetilde{V} \setminus \{\widetilde{S}\}\} \\ & \cup \{u_X t_\rho v_X : \rho = (X \to \alpha) \in \widetilde{P},\ X \neq \widetilde{S}\}. \end{aligned} \tag{2}$$

と定める．すべての証拠語は L に属する．空語型の規則では $t_\rho = \omega(X) = \lambda$ となり，その規則証拠は重複している．また $\lambda \in L$ なら，開始記号の型付きコピー $(S_0)_{\mathbf{1}_\sharp}$ は標準文脈 (λ, λ) と生成語 λ をもち，$\lambda \in \mathsf{Wit}(\widetilde{G})$ が従う．

5.2 厳密再構成と Gold 収束

定理 5.2 (有限証拠からの完全性)**.** G を非空言語 L を生成する任意の *CFG* とし，$\widetilde{G}$ をその $\mathsf{S}^\sharp$-型付き精密化とする．$\mathsf{Wit}(\widetilde{G}) \subseteq K$ ならば $L \subseteq L(\mathsf{Rec}_s(K))$ である．

代入可能性も $K \subseteq L$ も仮定しない．

Proof. 残存する非空型の $X = A_\mu$ に対し $\widehat{X} := [\![\omega(X)]\!]$ とおく．第一の証拠族により $\omega(X)$ は観測済みの非空因子である．型付き導出木の高さに関する帰納法で，$X \Rightarrow^*_{\widetilde{G}} w$ ならば $\widehat{X} \Rightarrow^*_{\mathsf{Rec}_s(K)} w$ を示す．

根の規則を $\rho : X \to u_0 Y_1 u_1 \cdots Y_r u_r$ とし，各子の生成語を w_i とする．$\omega(X)$ と $t_\rho = u_0 \omega(Y_1) u_1 \cdots \omega(Y_r) u_r$ は非空で，同じ s-型をもち，共通の文脈 (u_X, v_X) で K に現れる．よって規則 (U) により $\widehat{X} \to [\![t_\rho]\!]$ を得る．

列 $(u_0, \omega(Y_1), u_1, \ldots, \omega(Y_r), u_r)$ から空語成分を除き，残りを順に $z_1, \ldots, z_h$ とおく．X は非空型なので $h \geq 1$ であり，$t_\rho = z_1 \cdots z_h$ である．各成分とその連続する連接は $u_X t_\rho v_X \in K$ の非空因子なので，規則 (B) により $[\![t_\rho]\!] \Rightarrow^*_{\mathsf{Rec}_s(K)} [\![z_1]\!] \cdots [\![z_h]\!]$ を得る（$h = 1$ では零ステップ）．終端ブロックは規則 (B), (L) で生成する．非空型の子 Y_i に対応する成分では $[\![z_j]\!] = [\![\omega(Y_i)]\!] = \widehat{Y_i}$ だから，帰納法の仮定により $[\![z_j]\!] \Rightarrow^* w_i$ である．空語型の子は $w_i = \lambda$ なので省略できる．従って $\widehat{X} \Rightarrow^* u_0 w_1 u_1 \cdots w_r u_r = w$ を得る．

任意の非空な標的語 w には型付き開始コピー $(S_0)_{\widehat{s}(w)}$ があり，その標準文脈は (λ, λ) である．その標準生成語は K に属するので，開始規則 (S) と上の帰納法から $\widehat{S} \Rightarrow^* w$ を得る．また $\lambda \in L$ ならば，開始コピーの証拠により $\lambda \in K$ となり，規則 (S) がこれを直接生成する． □

定理 5.3 (厳密有限標本再構成)**.** 非空な $L \in \mathcal{C}^{\mathrm{cf}}_s$ と，これを生成する任意の *CFG* G，およびその $\mathsf{S}^\sharp$-型付き精密化 $\widetilde{G}$ に対し，$\mathsf{Wit}(\widetilde{G}) \subseteq K \subseteq L$ ならば $L(\mathsf{Rec}_s(K)) = L$ である．

Proof. G に定理 5.2 を適用して完全性を得，$K \subseteq L$ に定理 4.2 を適用して健全性を得る． □

したがって $\mathsf{Wit}(\widetilde{G})$ は $\{\lambda\}$ を含む任意の非空標的の特徴標本である．$L = \emptyset$ に対しては空標本が $L(\mathsf{Rec}_s(\emptyset)) = \emptyset$ を与える．これで定理 3.4(ii) が従う．

系 5.4 (Gold 同定)**.** 有限半群への固定全射準同型 $s : \Sigma^+ \twoheadrightarrow \mathsf{S}$ に対し，学習器 Learn_s は $\mathcal{C}_s^{\mathrm{cf}}$ の任意の非空言語を正例から極限同定する．より詳しくは，標的を表す任意の *CFG* G とその一般型付き精密化 $\widetilde{G}$ について，$\mathsf{Wit}(\widetilde{G}) \subseteq K_{n_0}$ となった後，$n \geq n_0$ で生じる仮説変更は高々一回である．

Proof. 非空な L のテキストを $\mathcal{T}$ とし，$\mathsf{Wit}(\widetilde{G}) \subseteq K_{n_0}$ を満たす n_0 を選ぶ．最初のデータ w_1 は $L(H_0) = \emptyset$ に属さないため，学習器は段階 1 で再構成する．したがって $n \geq 1$ で H_n は直近の再構成段階 $m \leq n$ における $\mathsf{Rec}_s(K_m)$ である．再構成時の標本整合性とその後の再構成条件により $K_n \subseteq L(H_n)$ であり，$K_m \subseteq L$ と健全性により $L(H_n) \subseteq L$ でもある．ある $n \geq n_0$ で再構成が起これば，定理 5.3 から $L(H_n) = L$ となり，以後は変更しない．再構成が一度も起こらなければ，$n \geq n_0$ で $H_n = H_{n_0}$ である．テキストに現れる L の各語はある K_n に含まれ，$K_n \subseteq L(H_n) = L(H_{n_0})$ なので $L(H_{n_0}) = L$ となる．いずれの場合も段階 n_0 以後の仮説変更は高々一回である． □

5.3 再構成ステップの計算量

定理 5.5 (多項式時間再構成)**.** s を固定すると，$\mathsf{Rec}_s(K)$ は $\|K\|$ に関して多項式時間で構成できる．

Proof. $n_K := \|K\|$ とおき，観測因子出現の集合を $\mathcal{O}_K := \{(u, x, v) \in \Sigma^* \times \Sigma^+ \times \Sigma^* : uxv \in K\}$ とする．$|\mathcal{O}_K| = O(n_K^2)$ なので，因子非終端記号も高々 $O(n_K^2)$ 個である．各標本語の各開始位置から因子を一文字ずつ延長して s-値を記録すれば，固定半群中の $O(n_K^2)$ 回の積で全因子の s-値を計算できる．

規則 (B) の候補は，観測因子出現とその分割位置を選ぶので高々 $O(n_K^3)$ 個である．規則 (U) については，各 $(u, x, v) \in \mathcal{O}_K$ と各 $w \in K$ に対し，$w = uyv$ を満たす非空語 y が存在するか調べる．そのような y は存在すれば一意であり，$s(x) = s(y)$ ならば規則 $[\![x]\!] \to [\![y]\!]$ を生成する．これにより規則 (U) の候補をすべて列挙でき，その個数は高々 $|\mathcal{O}_K||K| = O(n_K^3)$ である．

終端規則と開始規則はこれより低次である．各候補について，文字列の照合と生成規則の符号化・出力は $O(n_K)$ 時間で行える．生成規則を集合として扱うため，重複は除去する．明示的な規則符号列の trie を使えば，重複の判定と除去は候補の総符号長に比例する時間で実行でき，上の上界を変えない．従って，$\mathsf{Rec}_s(K)$ は $O(n_K^4)$ 時間で構成できる． □

保守的学習器 Learn_s の各更新も，それまでに見たデータの符号化サイズに関して多項式時間で処理できる．CFG membership は文法と入力サイズに関して多項式時間であり，現在の仮説サイズと必要な再構成の計算量はいずれも定理 5.5 によって多項式に抑えられる．

補題 4.1，定理 5.3，系 5.4 と合わせて，主定理 3.4(i)–(iii) が得られる．定量的な (iv)–(v) は第 7–8 節で証明する．文法サイズだけによる上界は不可能である．Clark–Eyraud [2, Example 2] および Eyraud–Heinz–Yoshinaka [14, Example 2.3] の標準的な doubling family の添字を付け替えた例は，縮約済み BUNF 文法 $S_0 \to D_n$, $D_0 \to a$, $D_i \to D_{i-1}D_{i-1}$ をもち，生成規則記号数は $O(n)$ だが生成言語は $\{a^{2^n}\}$ である．de la Higuera の定理 3 [15] は，これと密接に関連する

simple-deterministic な変種を用いる．任意の singleton 言語は，任意の s に対して $\sim_s$-代入可能である．

6　一般の固定型付けに対する型付き厚み

定義 6.1 (二分・単位・空語標準形)**.** すべての生成規則が $A \to BC$，$A \to B$，$A \to a$，$A \to \lambda$ のいずれかである *CFG* を二分・単位・空語標準形（*BUNF*）と呼ぶ．

終端記号の分離と二分化により，同値で多項式サイズの BUNF 文法を得られる．命題 7.3 は通常厚みも制御する．ここでは BUNF を規則の型付きコピー数と導出木の分岐数の評価に用いるのであって，第 5 節の学習結果を制限するものではない．

固定 s に対し，$\mathsf{S}^\sharp$-型付き精緻化の標準生成語長から証拠サイズを評価する．$G = (V, \Sigma, P, S_0)$ を縮約済み BUNF 文法，$\widetilde{G}$ をその型付き精緻化とし，$N := |V|$，$N_t := |\widetilde{V} \setminus \{\widetilde{S}\}|$ とおく．この表現の**型付き厚み**を

$$\tau_s^{\mathrm{typ}}(G) := \max\Big(\{|\omega(X)| : X \in \widetilde{V} \setminus \{\widetilde{S}\}\} \cup \{1\}\Big)$$

と定める．これは文法表示依存の量であり，学習器への追加の仮定ではない．型付き厚みには元の開始記号の型付きコピーも含む．開始記号が右辺に現れたり空語を生成したりしても同じ定義を用いる．特に任意の非空標的 $L = L(G)$ に対し

$$\tau_s^{\mathrm{typ}}(G) \geq \max_{\mu \in \widehat{s}(L)} \min\{\, |w| : w \in L,\ \widehat{s}(w) = \mu \,\} \qquad (\spadesuit)$$

が成り立つ．実際，各 $\mu \in \widehat{s}(L)$ に対して $(S_0)_\mu$ は縮約後も残り，命題 5.1 により，その最短生成語長は右辺の対応する最小値に等しい．

補題 6.2 (型付き厚みによる証拠上界)**.** $G, \widetilde{G}$ を上記の通りとし，$\tau := \tau_s^{\mathrm{typ}}(G)$ とする．任意の非開始型付き記号 X に対して $|u_X| + |v_X| \leq (N_t - 1)\tau$，任意の $w \in \mathsf{Wit}(\widetilde{G})$ に対して $|w| \leq (N_t + 1)\tau$ が成立する．P_{ter}，P_{unit}，P_{bin} を元の文法の終端・単位・二項規則の集合とすると，

$$\|\mathsf{Wit}(\widetilde{G})\| \leq \big(N|\mathsf{S}^\sharp| + |P_{\mathrm{ter}}| + |P_{\mathrm{unit}}||\mathsf{S}^\sharp| + |P_{\mathrm{bin}}||\mathsf{S}^\sharp|^2\big)\big((N|\mathsf{S}^\sharp| + 1)\tau + 1\big).$$

従って固定した s について $|G|$ と $\tau_s^{\mathrm{typ}}(G)$ の多項式上界を得る．

Proof. 残存する非開始型付き記号の依存グラフに単位規則と二項規則の親子の辺を張る．各記号は元の開始記号の型付きコピーから到達可能であり，最短路は高々 $N_t - 1$ 辺をもつ．二項規則の経路外の子を標準生成語で展開すると，一辺あたり長さ高々 τ が加わり，単位規則の辺では語が加わらない．従って標準文脈長は $(N_t - 1)\tau$ 以下である．BUNF 規則の証拠語は，標準文脈に標準生成語を高々二つ，または終端記号一つを加えるので，語長の上界が得られる．空語型の規則証拠は標準生成語の証拠と重複するため，個数を別途数える必要はない．型付き記号は高々 $N|\mathsf{S}^\sharp|$ 個，終端・単位・二項規則の型付きコピーはそれぞれ $|P_{\mathrm{ter}}|$，$|P_{\mathrm{unit}}||\mathsf{S}^\sharp|$，$|P_{\mathrm{bin}}||\mathsf{S}^\sharp|^2$ 個である．各語の符号長 $|w| + 1$ を合計すれば主張が従う． □

系 6.3 (型付き厚みからの特徴データ)**.** s を固定する．非空な $L(G_*) \in \mathcal{C}_s^{\mathrm{cf}}$ を生成する任意の縮約済み *CFG* G_* を取り，これと同値でサイズが $|G_*|$ の多項式となる縮約済み *BUNF* 正規化 G を選ぶ．（G_* がすでに *BUNF* なら $G = G_*$ としてよい．）このとき $\mathsf{Wit}(\widetilde{G})$ は Rec_s に対する特徴標本であり，その符号化サイズは $|G_*|$ と $\tau_s^{\mathrm{typ}}(G)$ の多項式である．

Proof. 定理 5.3 は元の任意の CFG G_* から特徴標本性を与える．選んだ BUNF 正規化 G に補題 6.2 を適用し，$|G|$ が $|G_*|$ の多項式であることを用いる． □

系 6.3 の型付き厚みは，元の G_* に直接付随するのではなく，選んだ BUNF 正規化 G のパラメータである．一般の固定型付けでは元文法のサイズと通常厚みだけから多項式上界を導くことはできず，再構成作用素に対しても通常厚みは型付き厚みの代用にならない．さらに次の例は，再構成作用素そのものに指数長の正例が必要となることを示す．

■括弧付き倍増言語族． $\Gamma_{\mathrm{br}} = \{\mathsf{a}, \lfloor, \rfloor, \lceil, \rceil\}$ とする．単位元 1 と吸収元 ζ をもつ二元半束 $U_1 = \{1, \zeta\}$ を取る．$1\zeta = \zeta 1 = \zeta^2 = \zeta$ である．全射半群準同型 $s_{\mathrm{U}} : \Gamma_{\mathrm{br}}^{+} \to U_1$ は $\mathsf{a}, \lfloor, \rfloor$ を 1 に，$\lceil, \rceil$ を ζ に写す．非空語 w の型が 1 であることは ceiling 括弧を含まないことと同値であり，$\widehat{s_{\mathrm{U}}}(\lambda) = \mathbf{1}_\sharp \neq 1$ である．

$n \geq 1$ に対し縮約済み CFG G_n を

$$S_0 \to E_n, \qquad E_0 \to \mathsf{a}, \qquad E_i \to \lfloor E_{i-1} E_{i-1} \rfloor \mid \lceil E_{i-1} \rceil \quad (1 \leq i \leq n)$$

で定義し，$L_n = L(G_n)$ とおく．$|G_n| = O(n)$，$\tau_{G_n} = 2n + 1$ である．$w_0^* = \mathsf{a}$，$w_i^* = \lfloor w_{i-1}^* w_{i-1}^* \rfloor$ とおく．L_n で $\lceil, \rceil$ を含まない語は w_n^* のみで，$|w_n^*| = 3 \cdot 2^n - 2$ である．これは単項節点を除けば，高さ n の完全二分木に一意に定まるからである．

命題 6.4 (精密化による特徴データの指数的増大)**.** 任意の $n \geq 1$ に対して以下が成り立つ．

(i) L_n は *Clark–Eyraud* 代入可能であり，$L_n \in \mathcal{C}_{s_0}^{\mathrm{cf}} \cap \mathcal{C}_{s_{\mathrm{U}}}^{\mathrm{cf}}$ である．

(ii) L_n は Rec_{s_0} に対し，符号化サイズが n の多項式で抑えられる特徴標本をもつ．

(iii) 有限 $K \subseteq L_n$ に対し $w_n^* \in L(\mathsf{Rec}_{s_{\mathrm{U}}}(K))$ ならば $w_n^* \in K$ である．従って $\mathsf{Rec}_{s_{\mathrm{U}}}$ に対する任意の特徴標本 $\mathcal{F}$ は $\|\mathcal{F}\| \geq 3 \cdot 2^n - 1$ を満たす．

(iv) $L_n^- := L_n \setminus \{w_n^*\}$ とおくと $L_n^- \in \mathcal{C}_{s_{\mathrm{U}}}^{\mathrm{cf}}$ である．L_n, L_n^- の両方に特徴標本をもつ任意の集合駆動型作用素 Op について，L_n の任意の特徴標本 $\mathcal{F}$ は w_n^* を含み，$\|\mathcal{F}\| \geq 3 \cdot 2^n - 1$ を満たす．特に，固定 s_{U} クラス全体に特徴標本をもつ任意の集合駆動型作用素に対して成り立つ．

特に固定型付け s_{U} では，$\mathcal{C}_{s_{\mathrm{U}}}^{\mathrm{cf}}$ の標的を表す縮約済み *CFG* に対して，$\mathsf{Rec}_{s_{\mathrm{U}}}$ の特徴データ量を元文法サイズと通常厚みの多項式で一様に上から抑えることはできない．

Proof. (i) の代入可能性は付録 付録 C で示す．(ii) については明示的な特徴標本だけで十分である．具体的に，$u_0 = \mathsf{a}$，$u_i = \lceil u_{i-1} \rceil$ とおき，

$$\mathcal{F}_n = \{u_n\} \cup \{\lceil^{n-i} \lfloor u_{i-1} u_{i-1} \rfloor \rceil^{n-i} : 1 \leq i \leq n\}$$

とする．各 i で二つの標本語は u_i と $\lfloor u_{i-1} u_{i-1} \rfloor$ に共通文脈を与える．規則 (U)，(B) は E_i の両選択肢を再現するので，$L_n \subseteq L(\mathsf{Rec}_{s_0}(\mathcal{F}_n))$ である．さらに $\mathcal{F}_n \subseteq K \subseteq L_n$ とする．$\mathcal{F}_n \subseteq K$ から単調性により $L_n \subseteq L(\mathsf{Rec}_{s_0}(K))$ が従い，$K \subseteq L_n$ から健全性（定理 4.2）により $L(\mathsf{Rec}_{s_0}(K)) \subseteq L_n$ が従う．よって $\mathcal{F}_n$ は特徴標本であり，$|\mathcal{F}_n| = n + 1$，$\|\mathcal{F}_n\| = 3n^2 + 4n + 2$ である．

(iii)–(iv) について，削除語による標的は $L_n^- = L_n \cap \widehat{s_{\mathrm{U}}}^{-1}(\{\zeta\})$ である．同じ s_{U}-型の非空因子は共通外側文脈へ入れても $\widehat{s_{\mathrm{U}}}$-型が一致する．従ってその型ファイバーの和集合との交わりは相対的代入可能性を保ち，正則フィルタとの交わりなので $L_n^- \in \mathcal{C}_{s_{\mathrm{U}}}^{\mathrm{cf}}$ が直接従う．

(iii) $K \subseteq L_n$ が w_n^* を含まなければ $K \subseteq L_n^-$ である．健全性定理 4.2 より $L(\mathsf{Rec}_{s_{\mathrm{U}}}(K)) \subseteq L_n^-$

なので，w_n^* は再構成文法から生成できない．従って任意の特徴標本 $\mathcal{F}$ は w_n^* を含み，$\|\mathcal{F}\| \geq |w_n^*| + 1 = 3 \cdot 2^n - 1$ となる．$|G_n|, \tau_{G_n} = O(n)$ と合わせて命題末尾の主張を得る．

(iv) $\mathcal{F}$ を Op に関する L_n の特徴標本とし，$w_n^* \notin \mathcal{F}$ と仮定する．L_n^- の特徴標本 $\mathcal{F}'$ を取ると，$\mathcal{F} \cup \mathcal{F}' \subseteq L_n^- \subsetneq L_n$ である．すると同じ文法 $\mathsf{Op}(\mathcal{F} \cup \mathcal{F}')$ が両方の言語を生成しなければならず，矛盾する．

なお $n \geq 2$ では $L_n^- \notin \mathcal{C}_{s_0}^{\mathrm{cf}}$ である．実際，u_{n-1} と w_{n-1}^* は L_n^- において文脈 $(\lfloor, u_{n-1}\rfloor)$ を共有するが，文脈 $(\lfloor w_{n-1}^*, \rfloor)$ を許すのは前者だけである．従って (iv) は (ii) の自明型付けでの上界と矛盾しない． □

(iv) の矛盾は，異なる二標的の対称差に含まれる語を用いる古典的な区別対の論法に沿う（[4, Theorem 15.1.4] を参照）．ここでの固定 s に対する区別対 L_n, L_n^- と指数長の証人は，本論文の構成に固有である．

系 6.5 (文法表示によらない型付き厚みの指数下界)**.** $G = (V, \Gamma_{\mathrm{br}}, P, S_0)$ を L_n の任意の縮約済み *BUNF* 文法とすると，

$$\boxed{\tau_{s_{\mathrm{U}}}^{\mathrm{typ}}(G) \geq 3 \cdot 2^n - 2}$$

が成り立つ．文法サイズに制限はない．また L_n には文法サイズ・通常厚みがともに n の多項式となる縮約済み *BUNF* 表示が存在する．

Proof. 正語型 1 のファイバーは $L_n \cap \widehat{s_{\mathrm{U}}}^{-1}(\{1\}) = \{w_n^*\}$ であり，$1 \neq \mathbf{1}_\sharp$ である．式 (♠) より，任意の G について $\tau_{s_{\mathrm{U}}}^{\mathrm{typ}}(G) \geq |w_n^*| = 3 \cdot 2^n - 2$ が従う．通常厚みが多項式となる表示は G_n に命題 7.3 を適用して得る． □

7　固定窓を超える多項式厚み付きデータ

固定 (k, ℓ)-代入可能文脈自由言語の多項式厚み付きデータ学習可能性は，Yoshinaka [3, Theorem 1] により既に示されている．そこでは (k, ℓ)-Greibach 正規形と特徴集合の評価 [3, Lemmas 2 and 7] を用いる．本節では代わりに，Rec_s で用いる型付き精密化の最短生成語長を抑える．固定窓と有限群値を併用する場合まで，同一の証明で扱える．これらのバッチ型評価は Yoshinaka [3] と Eyraud–Heinz–Yoshinaka [14, Definition 2.12] の集合駆動型の意味での「多項式時間・厚み付きデータによる同定」（identification in polynomial time and thick data; IPTtD）を与える．同文献の Definition 2.5 が要求する，より強い逐次的な構文安定化を主張するものではない．Yoshinaka の多項式次数の改善も主張しない．一般の固定 s では，通常厚みだけでは Rec_s の特徴データを多項式で抑えられない（命題 6.4）．

$k, \ell \geq 0$ と有限群 H への準同型 $g : \Sigma^* \to \mathsf{H}$ を固定する．$s_{k,\ell}$ との直積では群成分を Σ^+ に制限する．$m := k + \ell$ とおく．

補題 7.1 (固定窓と有限群による BUNF 型付き生成語上界)**.** $G = (V, \Sigma, P, S_0)$ を縮約済み *BUNF* 文法とし，$N := |V| \geq 1$, $m := k + \ell$, $q := |\mathsf{H}|$ とおく．有限型付け s が $\ker\bigl(s_{k,\ell} \times (g|_{\Sigma^+})\bigr) \subseteq \ker s$ を満たせば，

$$\tau_s^{\mathrm{typ}}(G) \leq m + 1 + [1 + 2(m+q)(m+2)Nq](\tau_G + 1).$$

開始記号が右辺に現れる場合も，空語規則・単位規則も許す．

Proof. 詳細は付録 付録 A に与える．非空性を保存する保護文字と，導出木の節点数による第二の最小化を用いる． □

定理 7.2 (固定窓と有限群の精密化による多項式厚み付きデータ)**.** s, Σ を固定し，ある固定 k, ℓ と有限群準同型 g が $\ker\bigl(s_{k,\ell} \times (g|_{\Sigma^+})\bigr) \subseteq \ker s$ を満たすとする．縮約済み *BUNF* 文法 G で表される任意の非空 $L \in \mathcal{C}_s^{\mathrm{cf}}$ は，Rec_s に対し，$|G|$ と $\tau_G + 1$ の多項式符号長の特徴標本 $\mathsf{Wit}(\widetilde{G})$ をもつ．

Proof. 補題 7.1 と系 6.3 を適用する． □

群 H を自明に取れば固定窓の場合を含む．一般の CFG 表現には終端記号の分離と二分化のみを用いる．

命題 7.3 (厚みを多項式的に保存する BUNF 正規化)**.** 固定多項式 $q_{\mathrm{size}}, q_{\mathrm{thick}}$ が存在し，非空言語を生成する任意の縮約済み *CFG* G_* は，多項式時間で同値な縮約済み *BUNF* 文法 G に変換でき，

$$|G| \le q_{\mathrm{size}}(|G_*|), \qquad \tau_G \le q_{\mathrm{thick}}(|G_*|, \tau_{G_*} + 1)$$

を満たす．空語規則・単位規則を除去する必要はない．

証明は付録 A.2 に与える．

補題 7.4 (局所自明半群・有限群の除数と窓型付け)**.** 非空アルファベット上の全射有限半群準同型 $s : \Sigma^+ \twoheadrightarrow \mathsf{S}$ に対し次は同値である．

(i) S は有限局所自明半群 T と有限群 H の直積 $\mathsf{T} \times \mathsf{H}$ の除数である．

(ii) ある $k, \ell \ge 0$ と有限群 H へのモノイド準同型 $g : \Sigma^* \to \mathsf{H}$ が存在して

$$\ker\bigl(s_{k,\ell} \times (g|_{\Sigma^+})\bigr) \subseteq \ker s$$

が成り立つ．

Proof. (i) より部分半群 $V \subseteq \mathsf{T} \times \mathsf{H}$ と全射準同型 $\pi : V \to \mathsf{S}$ を選ぶ．各 $s(a)$ を V へ持ち上げて $\pi\varphi = s$ を満たす $\varphi : \Sigma^+ \to V$ を得る．射影を $\sigma : \Sigma^+ \to \mathsf{T}$ と $g_+ : \Sigma^+ \to \mathsf{H}$ とすると，後者は $g(\lambda) = 1_{\mathsf{H}}$ によって $g : \Sigma^* \to \mathsf{H}$ に拡張できる．$\sigma(\Sigma^+)$ が局所自明だから，命題 3.5 から $\ker s_{k,\ell} \subseteq \ker \sigma$ となる k, ℓ を得る．群成分も加えると (ii) となる．逆に (ii) は全射半群準同型

$$(s_{k,\ell} \times g)(\Sigma^+) \longrightarrow \mathsf{S}, \qquad (s_{k,\ell}(w), g(w)) \longmapsto s(w)$$

を誘導する．定義域は局所自明な $W_{k,\ell}$ と H の直積の部分半群だから (i) が従う． □

系 7.5 (局所自明半群と有限群による通常厚み上界)**.** $s : \Sigma^+ \twoheadrightarrow \mathsf{S}$ を固定する．S が有限な局所自明半群と有限群の直積の部分半群の準同型像であるとする．このとき，縮約済み *CFG* G_* で表される任意の非空 $L \in \mathcal{C}_s^{\mathrm{cf}}$ は，Rec_s に対して $|G_*|$ と $\tau_{G_*} + 1$ の多項式符号長の特徴データをもつ．これには局所自明な正の像半群や有限群の型付けを含む．

Proof. 補題 7.4 により，定理 7.2 の核の精密化条件が成り立つ．同定理の上界は，補題 7.1 と系 6.3 から従う．命題 7.3 の正規化を施して定理 7.2 を適用する．

□

ここで **LI** を局所自明有限半群の擬多様体，**Grp** を有限群を半群とみなした擬多様体とする．両者は有限直積で閉じているので，その擬多様体としての結合 $\mathbf{LI} \vee \mathbf{Grp}$ は，$\mathsf{S} \in \mathbf{LI}$ と $\mathsf{G} \in \mathbf{Grp}$ の直積 $\mathsf{S} \times \mathsf{G}$ の除数（部分半群の準同型像）全体に正確に一致する．局所自明半群を含む擬多様体の結合は Costa [19, 20] らによって研究されてきた．本論文で扱うのは，そこから導く文法学習の定量的帰結である．固定型付け s に関して，補題 7.4 は，定理 7.2 の核の精密化条件と $s(\Sigma^+) \in \mathbf{LI} \vee \mathbf{Grp}$ の同値性を与える．系はこの代数的条件から定量的結果を任意の縮約済み CFG 表現へ拡張する．これは多項式特徴データ上界をもつ型付けすべてを特徴づけるものではない．

補題 7.6 (二元半束は窓・群の結合の外にある)**.** $U_1 \notin \mathbf{LI} \vee \mathbf{Grp}$.

Proof. 背理法で，$\mathsf{S} \in \mathbf{LI}$ と有限群 G の直積の部分半群 $\mathsf{T} \subseteq \mathsf{S} \times \mathsf{G}$ から U_1 への全射準同型 $\pi : \mathsf{T} \to U_1$ が存在するとする．$\pi^{-1}(1)$ と $\pi^{-1}(\zeta)$ はそれぞれ空でない有限部分半群なので，冪等元 e, f を含む．$\mathsf{S} \times \mathsf{G}$ の冪等元の群成分は 1_{G} であるから，e, f の S 成分も冪等元である．S の局所自明性から $efe = e$ だが，π を作用させると $1 \cdot \zeta \cdot 1 = 1$ となり，$\zeta \neq 1$ に矛盾する． □

備考 7.7. s_{U} の正の像は U_1 であり，補題 7.6 により $\mathbf{LI} \vee \mathbf{Grp}$ に属さない．命題 6.4 は，系 7.5 の代数的仮定を外すと Rec_s の通常厚みに関する特徴データ上界が成立しない場合を示す．これは任意の固定型付けについて条件の必要性を主張するものではない．命題 6.4(iv) は二つの標的を識別するための集合駆動型作用素に依存しない特徴標本下界を与えるが，任意の Gold 学習器の実行時間・収束時点の下界は主張しない．

この多項式上界は固定型付けとアルファベットに依存してよく，窓長や群を可変とした一様な上界は主張しない．

8 線形部分クラス

線形言語はちょうど 1 ターン・プッシュダウンオートマトンによって受理される [21, 22]．以下の正規化はその文法的対応物を与える．成功導出には一つの継続する非終端記号の経路があり，これを *spine* と呼ぶ．

命題 8.1 (linear-spine BUNF 正規化)**.** 固定多項式 q_{lin} が存在し，非空言語を生成する任意の線形 *CFG* G を多項式時間で同値な縮約済み *BUNF* 文法 $G_0 = (V_0, \Sigma, P_0, S_0)$ へ変換でき，$|G_0| \leq q_{\mathrm{lin}}(|G|)$ である．さらに各二項生成規則は，$W_a \to a$ を満たすちょうど一つの新鮮な終端ラッパー子と，ちょうど一つのそれ以外の非終端子をもつ．

構成は付録 付録 B に与える．$\widetilde{G}_0$ を型付き精密化，$N_t := |\widetilde{V}_0 \setminus \{\widetilde{S}\}|$ とおく．元の開始記号の型付きコピーも数えるため $N_t \leq |V_0|\,|\mathsf{S}^\sharp|$ である．

補題 8.2 (短い標準生成語)**.** $\widetilde{G}_0$ の任意の型付き非開始記号 X に対し $|\omega(X)| \leq N_t$ である．従って $\tau_s^{\mathrm{typ}}(G_0) \leq N_t$ である．

Proof. **継続** *spine* は各二項規則のラッパーでない方の子をたどる．ラッパー子はちょうど一文字を生成し，継続 spine には入らない．単位規則は文字を寄与せず，終端・空語規則は spine を終了する．$\omega(X)$ を与える導出のうち非終端節点数最少のものを選ぶ．同じ**型付き** spine 記号が繰り返せば，下

側の部分導出を上側へ移植しても型付き導出は保たれる．その区間に二項規則があれば生成語長が真に減り，単位規則のみなら節点数が減る．いずれも選んだ導出の最小性に反する．従って spine 上の型付き記号は重複せず，終端規則の最後の一文字も含めて生成語長は高々 N_t である．ラッパー記号にも同じ上界が成立する． □

定理 8.3 (線形標的に対する多項式特徴データ)**.** s を固定する．線形 *CFG* G で表される任意の $L \in \mathcal{C}_s^{\mathrm{lin}}$ は，Rec_s に対し，$|G|$ の多項式で $\|\cdot\|$-サイズが抑えられる特徴標本をもつ．

Proof. $L = \emptyset$ と $L = \{\lambda\}$ では第 5 節の標本を用いる．それ以外では命題 8.1 の G_0 を取る．補題 8.2 から $\tau_s^{\mathrm{typ}}(G_0) \le N_t \le |V_0|\,|\mathsf{S}^\sharp|$ なので，系 6.3 により $|G_0| \le q_{\mathrm{lin}}(|G|)$ の多項式サイズの特徴標本を得る．より具体的には，補題 6.2 から $\|\mathsf{Wit}(\widetilde{G}_0)\| = O(|G_0|^3|\mathsf{S}^\sharp|^4)$ である．元の $|G|$ に関する多項式評価には正規化の q_{lin} も使う． □

定理 5.5 と合わせると，選んだ線形 CFG 表現を基準として，$\mathcal{C}_s^{\mathrm{lin}}$ の標的には多項式時間のバッチ再構成と多項式サイズの特徴データが得られる．これは de la Higuera [15, Theorem 2] の線形言語全体についての否定結果とは矛盾しない．本定理は固定 s に対する代入可能な部分クラスだけを対象とするからである．さらに逐次学習器 Learn_s に対する多項式データ保証は主張しない．

■非正則な線形 fixed-s 例． 直前の定理は，正則標的や既知の線形代入可能クラスに限定されない．

$$L_{\pm,e} := \{a^{2m}cb^{2m} : m \ge 0\} \cup \{a^{2m+1}db^{2m+1} : m \ge 0\} \\ \cup \{a^n eb^n : n \ge 0\}.$$

これは線形文法

$$S \to U_{\mathrm{ev}} \mid U_e, \quad U_{\mathrm{ev}} \to c \mid aU_{\mathrm{odd}}b, \quad U_{\mathrm{odd}} \to d \mid aU_{\mathrm{ev}}b, \\ U_e \to e \mid aU_eb$$

で生成される．添字 ev と odd は，対応する非終端記号自身の生成語長の偶奇ではなく，開始点から外側を包む a, b の対の個数の偶奇を表す．

c, d, e を**中心記号**と呼ぶ．

命題 8.4. 言語 $L_{\pm,e}$ は線形かつ非正則であり，ある有限半群への準同型 s に対して $\mathcal{C}_s^{\mathrm{lin}}$ に属する．一方，*Clark–Eyraud* 代入可能ではなく，いかなる固定 $k, \ell \ge 0$ に対しても (k,ℓ)-代入可能ではない．

Proof. 線形性は表示文法から従う．有限型付けに関する代入可能性を示すため，

$$L_{\mathrm{all}} := \{a^n \xi b^n : n \ge 0,\ \xi \in \{c,d,e\}\}, \qquad R_{\mathrm{reg}} := (aa)^*c(bb)^* \cup a(aa)^*d\,b(bb)^* \cup a^*eb^*$$

とおく．線形言語 L_{all} は非空因子の規約で Clark–Eyraud 代入可能である．中心記号を含まない因子は共通文脈から一意に決まり，中心記号を一つ含む因子 $a^i\xi b^j$ の分布は $i-j$ のみに依存する．従って自明な型付け s_0 に対し $L_{\mathrm{all}} \in \mathcal{C}_{s_0}^{\mathrm{lin}}$ である．R_{reg} は正則言語で $L_{\pm,e} = L_{\mathrm{all}} \cap R_{\mathrm{reg}}$ だから，命題 3.2(ii) と線形言語の正規交差に関する閉包性により，R_{reg} を認識するある有限モノイド準同型 $g : \Sigma^* \to M$ に対して $L_{\pm,e} \in \mathcal{C}^{\mathrm{lin}}_{s_0 \times (g|_{\Sigma^+})}$ が従う．

また，$L_{\pm,e} \cap a^*eb^* = \{a^neb^n : n \ge 0\}$ から非正則性が従う．因子 c, e は空文脈を共有するが，$(a,b) \in \mathcal{D}_{L_{\pm,e}}(e) \setminus \mathcal{D}_{L_{\pm,e}}(c)$ なので Clark–Eyraud 代入可能ではない．さらに $k, \ell \ge 0$ を固定し，$m_0 := \max\{1, k+\ell\}$, $w_e := a^keb^\ell$, $w_c := a^kcb^\ell$ とおく．両因子は同じ長さ k の接頭辞と長さ ℓ の接尾

辞をもち，文脈 $(a^{2m_0-k}, b^{2m_0-\ell})$ を共有する一方，$(a^{2m_0+1-k}, b^{2m_0+1-\ell}) \in \mathcal{D}_{L_{\pm,e}}(w_e) \setminus \mathcal{D}_{L_{\pm,e}}(w_c)$ である．従って固定窓代入可能性の反例基準より $L_{\pm,e} \notin \mathsf{KL}$ である． □

■四元型付けによる具体例． 上の正規フィルタによる証明では有限型付けの存在が示されたが，実際には四元型付けだけで十分である．$M_{\pm,e} := \{1, \kappa_{cd}, \kappa_e, 0\}$ を，1 が単位元で，すべての $\mu, \nu \in \{\kappa_{cd}, \kappa_e, 0\}$ に対して $\mu\nu = 0$ が成り立つモノイドとし，準同型 $s_{\pm,e} : \{a, b, c, d, e\}^+ \to M_{\pm,e}$ を

$$s_{\pm,e}(a) = s_{\pm,e}(b) = 1, \qquad s_{\pm,e}(c) = s_{\pm,e}(d) = \kappa_{cd}, \qquad s_{\pm,e}(e) = \kappa_e \tag{3}$$

で定める．このとき $L_{\pm,e}$ は $\sim_{s_{\pm,e}}$-代入可能である．実際，中心記号を含まない非空因子は共通文脈から一意に決まる．$a^i e b^j$ の分布は $i - j$ のみに依存し，$\xi \in \{c, d\}$ に対する $a^i \xi b^j$ の分布は $(i - j, \mathrm{par}(\xi) - i \bmod 2)$ のみに依存する．ただし $\mathrm{par}(c) = 0$，$\mathrm{par}(d) = 1$ とする．共通文脈はそれぞれの不変量を一致させ，同じ $s_{\pm,e}$-型であることは e-因子と c/d-因子を区別する．従って，共通文脈をもつ同型の因子の分布は一致する．

従って定理 8.3 は KL の外にある非正則線形言語にも適用される．表示文法は even-linear なので，Takada の control-set 枠組みからの分離は主張しない．

■生成語型付けが誘導する有限状態制御． 元の型付け s とその新単位元付加 $\widehat{s}$ は，同じ有限状態構成で扱える．$t : \Sigma^* \to T$ を任意の有限モノイド準同型とし，線形文法 $G = (V, \Sigma, P, S)$ の各生成規則に $\mathsf{ProdLab}$ の相異なるラベルを付ける．規則ラベル列 α をもつ導出を $A \Rightarrow_G^{\alpha} w$ と書く．$\mathsf{Acc}_{\mathrm{ctrl}} \subseteq T$ に対し

$$\mathsf{Ctrl}_{t,\mathsf{Acc}_{\mathrm{ctrl}}}(G) := \{\alpha \in \mathsf{ProdLab}^* : S \Rightarrow_G^{\alpha} w \text{ for some } w \in \Sigma^*,\ t(w) \in \mathsf{Acc}_{\mathrm{ctrl}}\}$$

とおく．これは正則である．状態 $V \times T \times T$ と一つの受理状態をもち，$(S, 1_T, 1_T)$ から開始するオートマトンで，$A \to uBv$ に対し $(A, \mu_L, \mu_R) \mapsto (B, \mu_L t(u), t(v)\mu_R)$ と遷移し，終端規則 $A \to w$ では $\mu_L t(w) \mu_R \in \mathsf{Acc}_{\mathrm{ctrl}}$ のとき受理すればよい．文形式 uAv の不変量は $(A, t(u), t(v))$ であり，制御される言語は $L(G) \cap t^{-1}(\mathsf{Acc}_{\mathrm{ctrl}})$ に等しい．

半群型付け s の制御では，モノイド拡張を用いる．$t = \widehat{s}$，開始非終端記号を A，$\mathsf{Acc}_{\mathrm{ctrl}} = \{\mu\}$ とすれば，命題 5.1 の $L_G(A) \cap \widehat{s}^{-1}(\{\mu\})$ を空語型 $\mathbf{1}_\sharp$ も含めて得る．これは Takada の正則制御言語 [11] との有限状態的な接点であるが，任意の Takada control set が生成語型付けから得られるとは主張しない．

9 表現力と境界

ここでは fixed-window 階層と，より広い文脈自由言語族の間で本枠組みを位置づける．

9.1 RS 内の非線形標的

$\Delta := \{a^n b^n : n \geq 0\}$ とし Δ^* を考える．$z \in \{a, b\}^*$ に対し $\beta(z) := |z|_a - |z|_b$ と定め，接頭辞 p を読み終えた時点の**高さ**を $\beta(p)$ と呼ぶ．語 x の**許容進入高さ集合**を

$$\mathcal{Q}(x) := \{q \in \mathbb{Z}_{\geq 0} : q + \beta(x) \geq 0, \quad a^q x b^{q+\beta(x)} \in \Delta^*\}$$

と定める．ここで $w \in \Delta^*$ であるための必要十分条件は，すべての接頭辞の高さが非負であり，$\beta(w) = 0$ で，さらに ba の各出現において b の直後の高さが 0 となることである．実際，ba を境界として w を分けると各ブロックは $a^i b^j$ の形をもち，上の条件から各ブロックの始点と終点の高さは 0 となり，$i = j$ が従う．逆に，このようなブロックの連接は条件を満たす．標準補完 $a^q x b^{q+\beta(x)}$ は x との境界で新たな ba を作らないので，この局所特徴づけから，$\mathcal{Q}(x)$ は Δ^* の語中に x が現れる直前の高さの集合に一致する．逆向きについては，$uxv \in \Delta^*$ のとき，進入高さ $\beta(u)$ から x を読んでも内部の高さの非負性と ba 境界条件は保たれるため，標準補完 $a^{\beta(u)} x b^{\beta(u)+\beta(x)}$ も Δ^* に属する．

例えば，$\mathcal{Q}(ab) = \mathbb{Z}_{\geq 0}$, $\mathcal{Q}(aa) = \mathbb{Z}_{\geq 0}$, $\mathcal{Q}(\lambda) = \mathbb{Z}_{\geq 0}$, $\mathcal{Q}(bb) = \mathbb{Z}_{\geq 2}$, $\mathcal{Q}(ba) = \{1\}$, $\mathcal{Q}(bbaa) = \{2\}$, $\mathcal{Q}(baaba) = \varnothing$ である．

この標準補完から，次の所属条件を得る：

$$w \in \Delta^* \iff \beta(w) = 0 \text{ かつ } 0 \in \mathcal{Q}(w). \tag{$\star$}$$

$\mathrm{fst}(w), \mathrm{lst}(w) \in \{\bot, a, b\}$ を最初と最後の記号（λ では $\bot$）とし，$\mathrm{ba}(w)$ で w が ba を含むかを二値で記録する．$h_\star(w) := (\mathrm{fst}(w), \mathrm{lst}(w), \mathrm{ba}(w))$．連接の要約は二因子の要約だけから決まる．端点は明らかな仕方で連接され，新しい ba は境界 $b|a$ でのみ生じ得る．従って有限像 $M_\star := h_\star(\{a,b\}^*)$ に $h_\star(x)h_\star(y) := h_\star(xy)$ と積を入れれば，$h_\star$ は有限モノイド準同型になる．学習型付けにはその正語への制限 $s_\star := h_\star|_{\{a,b\}^+}$ を用いる．

許容進入高さ集合は，右側に語を連接しても広がらず，次の連接公式が成り立つ：[*3]

$$\mathcal{Q}(st) = \mathcal{Q}(s) \cap \{q \in \mathbb{Z} : q + \beta(s) \in \mathcal{Q}(t)\} \cap \begin{cases} \{-\beta(s)\}, & (\mathrm{lst}(s), \mathrm{fst}(t)) = (b, a), \\ \mathbb{Z}, & \text{それ以外.} \end{cases} \tag{$\star\star$}$$

命題 9.1 (非線形 fixed-$s_\star$ 標的)**.** Δ^* は決定性文脈自由・非正則・非線形で，$\sim_{s_\star}$-代入可能である．さらにどの固定 $k, \ell \geq 0$ に対しても (k,ℓ)-代入可能ではない．従って $\Delta^* \in \mathsf{RS}_{s_\star}(\{a,b\}) \cap \mathrm{CFL}$ かつ $\Delta^* \in \mathsf{RS}(\{a,b\}) \setminus \mathsf{KL}(\{a,b\})$ である．

Proof. 文法 $S \to TS \mid \lambda, T \to aTb \mid \lambda$ は Δ^* を生成する．また決定性 PDA は，各ブロックの a 部分でスタックに記号を積み，続く b 部分でそれらを取り除き，スタックが底記号へ戻ったときにのみ次のブロックを開始できるようにすればよい．$\Delta^* \cap a^*b^* = \Delta$ から非正則であり，線形言語の正則交差に対する閉包性と $\Delta^* \cap a^*b^*a^*b^* = \Delta\Delta$ および $\Delta\Delta$ の非線形性から非線形である．後者は Autebert–Berstel–Boasson [22, Section 6.1, Theorem 6.1 の直前] に明記されている．

代入可能性を示す．同じ $s_\star$-型をもつ非空語 x, y が共通文脈 (u, v) をもつとする．直前の $\mathcal{Q}$ の特徴づけと β の加法性より，$uxv, uyv \in \Delta^*$ から $\beta(x) = \beta(y)$ および $\beta(u) \in \mathcal{Q}(x) \cap \mathcal{Q}(y)$ が従う．$s_\star(x) = s_\star(y)$ だから，x, y はともに ba を含むか，ともに含まない．

前者では，$x = rbat$ $(r, t \in \{a,b\}^*)$ と分解する．Δ^* の語では，ba が現れるたびに b の直後の高さが 0 になるため，任意の $q \in \mathcal{Q}(x)$ は $q + \beta(rb) = 0$ を満たす．従って $\mathcal{Q}(x)$ は高々一元集合であり，y についても同様である．一方，$\beta(u) \in \mathcal{Q}(x) \cap \mathcal{Q}(y)$ だから，$\mathcal{Q}(x) = \{\beta(u)\} = \mathcal{Q}(y)$ を得る．

[*3] 実際，st を高さ q から読む際の条件は，s 内の条件 $q \in \mathcal{Q}(s)$，t 内の条件 $q + \beta(s) \in \mathcal{Q}(t)$，および境界 $s|t$ の条件に分かれる．境界が $b|a$ のときに限り，Δ^* の語では b の直後の高さが 0 でなければならないため，$q + \beta(s) = 0$ が必要となる．これらの条件は十分でもあるから，公式が従う．

後者では $x, y \in a^*b^*$ であり，各 $z \in \{x, y\}$ について $\mathcal{Q}(z) = \{q \in \mathbb{Z} : q \geq -\min\{0, \beta(z)\}\}$ である．既に示した $\beta(x) = \beta(y)$ から，直ちに $\mathcal{Q}(x) = \mathcal{Q}(y)$ が従う．

従って $\beta(x) = \beta(y)$ および $\mathcal{Q}(x) = \mathcal{Q}(y)$ が成り立つ．また，$s_\star$-型が一致するから $\mathrm{fst}(x) = \mathrm{fst}(y)$ および $\mathrm{lst}(x) = \mathrm{lst}(y)$ である．$(\star\star)$ を二度適用すると，任意の文脈 (u', v') に対して $\beta(u'xv') = \beta(u'yv')$ および $\mathcal{Q}(u'xv') = \mathcal{Q}(u'yv')$ を得る．ゆえに $(\star)$ より $u'xv' \in \Delta^*$ と $u'yv' \in \Delta^*$ は同値である．すなわち $\mathcal{D}_{\Delta^*}(x) = \mathcal{D}_{\Delta^*}(y)$ である．

固定窓からの分離として k, ℓ を固定し，$m := \max\{1, k + \ell\}$，$x := a^m b^m$，$y := a^m b^m a^m b^m$ とおく．両者は同じ長さ k の接頭辞と長さ ℓ の接尾辞をもち，空文脈を共有する．さらに $axb \in \Delta^*$ だが，ayb の中央の ba は高さ 1 なので $ayb \notin \Delta^*$ である．従って固定窓代入可能性の反例基準から，Δ^* はどの (k, ℓ) にも属さない． □

従って fixed-s 枠組みは，固定窓階層の外にある第 8 節の非正則線形例 $L_{\pm,e}$ と，非線形文脈自由言語 Δ^* の双方を含む．control-set 法一般との分離は主張しない．

9.2 上限制約つき正則カウンタ族

正則言語 $L_{\mathrm{Yreg}} = ae^*ce^*a \cup ae^*de^*a \cup be^*ce^*b$ による固定窓階層からの分離は Yoshinaka [3, Proposition 1] によって既に示されている．以下の族は，第 9.3 節の無界カウンタに対する有限状態の capped 版として残す．

$\Sigma_c := \{\uparrow, \downarrow, \#\}$ とする．$w = \delta_1 \cdots \delta_n \in \Sigma_c^*$ に対し，$\mathrm{ht}_i(w)$ を先頭 i 文字を読んだ後の高さとする．$\mathrm{ht}_0(w) = 0$ とし，$\uparrow$ で $+1$，$\downarrow$ で -1，$\#$ で 0 にリセットする．$\rho \geq 1$ に対し

$$\mathrm{CTR}_\rho := \{w \in \Sigma_c^* : 0 \leq \mathrm{ht}_i(w) \leq \rho \text{ for all } 0 \leq i \leq |w|\}$$

とおく．

任意の $\rho \geq 1$ に対し CTR_ρ は正則である．実際，決定性有限オートマトンが高さ $0, \ldots, \rho$ を記録し，範囲外に一つの sink を置き，$\#$ で 0 に戻ればよい．従って命題 3.1 から $\mathrm{CTR}_\rho \in \mathsf{RS}(\Sigma_c)$ となる．

定理 9.2. 任意の $\rho \geq 2$ に対し CTR_ρ はどの $k, \ell \geq 0$ についても (k, ℓ)-代入可能ではない．

Proof. k, ℓ を固定し $x := (\uparrow\downarrow)^k \uparrow^{\rho-1} \#^\ell$，$y := (\uparrow\downarrow)^k \uparrow^\rho \#^\ell$ とおく．両者は固定窓基準に十分長く，同じ長さ k の接頭辞と長さ ℓ の接尾辞をもち，ともに CTR_ρ に属するため空文脈を共有する．一方 $\uparrow x \in \mathrm{CTR}_\rho$ だが $\uparrow y \notin \mathrm{CTR}_\rho$ で，後者は高さ $\rho + 1$ に達する．従って分布が異なり，反例基準が適用できる． □

境界 $\rho \geq 2$ は最良である[*4]．

任意の $\rho \geq 1$ について，上の DFA が誘導する遷移モノイド準同型を $h_\rho : \Sigma_c^* \to M_\rho$ とする．学習にはその正語への制限 $s_\rho := h_\rho|_{\Sigma_c^+}$ を用いる．これは CTR_ρ を認識するので，すべての $\rho \geq 1$ に対して $\mathrm{CTR}_\rho \in \mathcal{C}^{\mathrm{cf}}_{s_\rho}$ が成り立つ．一方，$\mathrm{CTR}_\rho \notin \mathsf{KL}$ という強い結論が成り立つのは $\rho \geq 2$ の場合

[*4] 実際，CTR_1 は $(1, 1)$-代入可能である．その所属条件は，先頭文字が $\downarrow$ でないこと，および長さ 2 の因子 $\uparrow\uparrow, \downarrow\downarrow, \#\downarrow$ が現れないことだけで記述できる．したがって共通文脈をもつ許容された非空因子については，先頭文字と末尾文字が等しければ，任意の文脈での所属可否は一致する．

である．この capped family は新しい正則分離ではなく，下の無界言語 CTR と対比するためのものである．

9.3 RS の外にある自然な決定性文脈自由言語

補題 9.3 (有限半群障害)**.** $L \subseteq \Sigma^*$ とする．無限集合 $\Xi \subseteq \Sigma^+$ が存在し，相異なる任意の $x, y \in \Xi$ について $\mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \emptyset$ かつ $\mathcal{D}_L(x) \neq \mathcal{D}_L(y)$ が成り立つなら $L \notin \mathsf{RS}(\Sigma)$ である．

Proof. 有限 s は Ξ の二要素を同一視する．その二語は共通文脈をもち分布が異なるので $\sim_s$-代入可能性に反する． □

上限を外すと決定性文脈自由言語

$$\mathrm{CTR} := \{w \in \Sigma_c^* : \mathrm{ht}_i(w) \geq 0 \text{ for all } 0 \leq i \leq |w|\}$$

を得る．これは reset 付きの明らかな決定性プッシュダウン・カウンタで受理される．

系 9.4 (上限なしカウンタの障害)**.** $\mathrm{CTR} \notin \mathsf{RS}(\Sigma_c)$ である．

Proof. $\Xi = \{\uparrow^i : i \geq 1\}$ を用いる．$i < j$ なら $(\lambda, \downarrow^i)$ は共通文脈だが，$(\lambda, \downarrow^j)$ は $\uparrow^j$ だけの文脈である． □

一種類の括弧の Dyck 言語

$$D_1 := \{w \in \{a, b\}^* : |w'|_a \geq |w'|_b \text{ for every prefix } w',\ |w|_a = |w|_b\}$$

は標準的な決定性文脈自由言語 [24] である．ここでの D_1 は Dyck 言語全体を表し，Autebert–Berstel–Boasson [22] の規約では D_1^* と書かれる．

系 9.5. $D_1 \notin \mathsf{RS}(\{a, b\})$ である．

Proof. $\Xi = \{b^i a^i : i \geq 1\}$ を用いる．$i < j$ なら (a^j, b^j) は共通文脈だが，(a^i, b^i) は $b^i a^i$ だけの文脈である．$b^j a^j$ では接頭辞 $a^i b^j$ がアンダーフローを起こす． □

従って障害は無界スタック挙動それ自体ではない．非正則 1-turn 言語 $L_{\pm,e}$ は RS に属する．障害は，文脈的挙動が異なるにもかかわらず相互に比較可能な因子が無限族をなし，有限 s ではそれらをすべて分離できないことである．

補題 9.6 (固定語による商)**.** L が $\sim_s$-代入可能で $z \in \Sigma^*$ なら，$L/z := \{w : wz \in L\}$ も $\sim_s$-代入可能である．

Proof. L/z の共通文脈 (u, v) は L では (u, vz) になる．L で分布が等しいなら，任意の文脈 (s, t) の右に z を付加することで L/z に分布等式を移せる． □

$S \to aSS \mid b$ が生成する言語を *Łukasiewicz* **言語**と呼ぶ．Yoshinaka [3, Section 3] はすでに，この言語がどの固定 k, ℓ に対しても (k, ℓ)-代入可能でないことを指摘している．本論文の記法では $L_{\mathrm{Luk}} = D_1 b$ [22] で，これは決定性文脈自由言語でもある [24]．ここでは右商の議論により，さらに強く有限型付け全体の和の外にあることを示す．もし $L_{\mathrm{Luk}} \in \mathsf{RS}(\{a, b\})$ なら補題 9.6 により $D_1 = L_{\mathrm{Luk}}/b \in \mathsf{RS}$ となり，系 9.5 に反する．

9.4　Clark の congruential family との比較

Clark [25] は有限初期集合 $I \subseteq V$ を許し，$L_G[I] := \bigcup_{A \in I} L_G(A)$ と書く．このような文法が *congruential* であるとは，各 $L_G(A)$ が $L_G[I]$ の一つの構文合同類に含まれることをいう．Γ 上の congruential grammar が生成する言語全体を $\mathsf{CONG}(\Gamma)$ と書く．Clark はすでに substitutable および (k,ℓ)-substitutable language をこの族に位置づけている．次の命題はこの包含をすべての fixed-s slice へ拡張する．

命題 9.7 (Clark の congruential family との比較)**.** 任意の有限アルファベット Γ と有限半群型付け $s : \Gamma^+ \to \mathsf{S}$ に対して $\mathcal{C}_s^{\mathrm{cf}} \subseteq \mathsf{CONG}(\Gamma)$ である．従って $\mathsf{RS}(\Gamma) \cap \mathrm{CFL} \subseteq \mathsf{CONG}(\Gamma)$ であり，$\Gamma = \{a, b\}$ ではこの包含は真である．

Proof. 非空 $L \in \mathcal{C}_s^{\mathrm{cf}}$ の任意の CFG と，その $\mathsf{S}^\sharp$-型付き精緻化をトリムした $\widetilde{G}$ を取る．各残存型付き記号 A_μ の生成語は等しい $\widehat{s}$-型と共通の終端到達文脈をもつので，補題 2.2 により同じ構文合同類に属する．この議論は空語生成記号にも適用できる．

補助開始記号 $\widetilde{S}$ を除き，その型付き後続記号 $(S_0)_\mu$ 全体を有限初期集合とする．$\lambda \in L$ の場合も型 $\mathbf{1}_\sharp$ によって扱われるので，空語専用の初期記号は不要である．空言語は生成規則をもたない初期記号で扱える．全ての有限型付けについて和を取れば包含が従う．

$\{a, b\}$ 上で包含が真であることには，Clark [25] も論じる Dyck 例を用いる．任意の $x \in D_1$ に対し $uxv \in D_1$ と $uv \in D_1$ は同値なので $x \equiv_{D_1} \lambda$ である．従って $S \to aSbS \mid \lambda$ は congruential だが，系 9.5 より $D_1 \notin \mathsf{RS}(\{a, b\})$ である． □

10　結論

定性的な学習可能性は文法の正規形に依存しない一方，定量的なデータ上界には型付けの代数的構造が現れる．指数的な隔たりは，さまざまな BUNF 表示の下での型付き厚み，および集合駆動型作用素の特徴標本に関するものであり，任意の Gold 学習器の収束速度に関するものではない．窓・有限群に関する仮定は十分条件であって，必要条件であるとは主張しない．$\mathsf{RS} \cap \mathrm{CFL}$ の特徴づけは未解決である．

データ利用可能性

本論文で述べた研究には実証データを使用していない．

利益相反の申告

著者は，本論文で報告した研究に影響を与えた可能性のある，既知の競合する金銭的利害関係または個人的関係が存在しないことを申告する．

研究費

本研究は，公的機関，民間企業，非営利部門のいずれの資金配分機関からも，特定の助成を受けていない．

謝辞

著者は，指導，励まし，関連文献についての助力をいただいた Makoto Kanazawa（金澤誠）氏と Ryo Yoshinaka（吉仲亮）氏，および本論文を大きく改善する慎重かつ建設的な査読報告をくださった二名の匿名査読者に感謝する．とりわけ，査読者は初回投稿版の学習アルゴリズムに含まれていた問題を指摘し，定理 9.2 における直接的な二語による証拠の提示を促した．また，本研究の初期段階にあたる ICGI 2014 において有益な助言をくださった Alexander Clark 氏にも感謝する．なお，残る誤りについてはすべて著者が責任を負う．

原稿作成過程における生成 AI および AI 支援技術の利用申告

本原稿の作成および改訂にあたり，著者は OpenAI の ChatGPT と Anthropic の Claude を，文章の編集，原稿の構成整理，および数学的議論の検討の補助に使用した．著者は AI による支援を受けた内容を自ら確認・編集しており，本論文に提示する結果および証明について全面的に責任を負う．

付録 A　固定窓証拠語上界と厚み保存正規化

A.1　補題 7.1 の証明

補題 *7.1* の証明. $m = k + \ell$, $q = |\mathsf{H}|$, $N = |V|$, $\bar{\tau} := \tau_G + 1$, $D_{\mathrm{dep}} := (m+2)Nq$, $W_{\mathrm{ess}} := m + q$ とおく．縮約後に残る任意の型付き記号 A_μ を考える．A が元の開始記号であってもよい．$\mu = \mathbf{1}_\sharp$ なら生成語は λ のみである．以下 $\mu \neq \mathbf{1}_\sharp$ とする．このとき正語 $w_0 \in L_G(A)$ で $\widehat{s}(w_0) = \mu$ となるものが存在する．$\eta := (s_{k,\ell}(w_0), g(w_0))$ とおき，$L_G(A)$ のうち $(s_{k,\ell} \times g)$-型が η と等しい**非空語**の最短語を w とする．さらに w の導出木のうち非終端節点数が最少のものを選ぶ．核の包含から $\widehat{s}(w) = \mu$ であり，$|\omega(A_\mu)| \le |w|$ となる．$|w| < m$ なら主張する上界は明らかである．

$|w| \ge m = k + \ell$ なので，最初の k 文字と最後の ℓ 文字の位置は交わらない（空の窓区間も許す）．これらと，任意の**非空性のための一文字**を保護する．その一文字が窓の保護位置に含まれていてもよい．保護位置の集合を Prot とおけば $1 \le d := |\mathrm{Prot}| \le m + 1$ である．$m = 0$ でも保護文字があるため短縮後に空語とならない．保護文字の順序と群値を保存する部分木置換では，非空性・接頭辞と接尾辞の窓が保たれ，$(s_{k,\ell} \times g)$-値も不変である．

BUNF 導出木の非終端記号の出現を節点とする．単位規則・空語規則の節点も含める．節点 z のラベルを $\mathrm{nt}(z)$, 生成語（空語も可）を $y(z)$, 部分木が含む保護位置を $\mathrm{Mark}(z)$ とする．祖先から子孫へ進むとマーク集合は包含で単調となり，高々 $d+1$ 種類の値を取る．三つ組 $(\mathrm{Mark}(z), \mathrm{nt}(z), g(y(z)))$ は同じ祖先鎖上で二度現れない．ラベルが同じなら下側の導出木を上側へ移植できる．$g(y(z))$ の一致と準同型性から全文字列の群値を保存し，マーク集合の一致により保護文字の順序も保存する．新

しい語は元と同じ非空ファイバーにあり，語長は増えない．非終端節点数は真に減るため，語長が減れば最短性，等しければ節点数最小性に反する．この議論は空語を生成する子や単位規則の巡回があっても成立する．従って深さは高々 $(d+1)Nq \le D_{\mathrm{dep}}$ である．

節点の生成語が保護位置を含むか，その長さが $\bar{\tau}$ を超えるとき**重要節点**と呼ぶ．同じ深さで保護位置を含む節点は高々 d 個である．重要節点が $d+q$ 個以上あれば，保護位置を含まない生成語長が $\bar{\tau}$ より大きい節点を左から q 個選ぶ．その生成語を $a_1, \dots, a_q$ とする．各節点と同じ非終端記号が生成する長さ τ_G 以下の語 b_i を選ぶ（空語でもよい）．$w = c_0 a_1 c_1 \cdots a_q c_q$ と書き，

$$r_j = g(a_1 c_1 \cdots a_j c_j), \quad t_j = g(b_1 c_1 \cdots b_j c_j), \quad x_j = t_j r_j^{-1}, \qquad x_0 = 1_{\mathsf{H}}.$$

この $q+1$ 個の群元 x_j のうち $x_i = x_j$ $(i < j)$ となる二つが存在する．順序を保った区間群積を $r_{i:j}, t_{i:j}$ と書けば，$r_j = r_i r_{i:j}$，$t_j = t_i t_{i:j}$ である．$t_i r_i^{-1} = t_i t_{i:j} r_{i:j}^{-1} r_i^{-1}$ の両側で消去して $t_{i:j} = r_{i:j}$，すなわち

$$g(b_{i+1} c_{i+1} \cdots b_j c_j) = g(a_{i+1} c_{i+1} \cdots a_j c_j)$$

が従う．該当する互いに交わらない部分木を置換すると，順序を保った群積，保護文字，非空性を変えずに語長が真に短くなり，最短性に矛盾する．群の可換性は使わない．従って各深さの重要節点数は高々 $W_{\mathrm{ess}} = m + q$ 個である．

重要節点の集合は祖先閉であり，その総数は高々 $W_{\mathrm{ess}} D_{\mathrm{dep}}$ 個である．極大な非重要部分木は BUNF の二分性により高々 $1 + 2W_{\mathrm{ess}} D_{\mathrm{dep}}$ 個，それぞれの生成語長は高々 $\bar{\tau}$ である．その外側に残る終端位置はすべて保護位置であり高々 d 個だから，

$$|w| \le d + (1 + 2W_{\mathrm{ess}} D_{\mathrm{dep}})\bar{\tau} \le m + 1 + [1 + 2(m+q)(m+2)Nq](\tau_G + 1).$$

元の開始記号の型付きコピーも同様であり，空語型コピーは λ のみを生成する．全コピーについて最大を取ればよい． □

A.2 厚みを多項式的に保存する BUNF 正規化

命題 *7.3* の証明. G_* を縮約済み CFG とし，$n := |G_*|$, $\bar{\tau} := \tau_{G_*} + 1$ とおく．元の単位規則と空語規則を保持したまま，まず長い右辺の終端記号を $W_a \to a$ というラッパーで分離し，次に右辺を二分化する．この古典的操作は元の各非終端記号の生成言語を保つ [22, Section 3.1] [23, Sections 7.1 and 7.4.2]．二分化の補助記号は元の生成規則ごとに新鮮に取る．それは右辺の高々 $O(n)$ 個の元の記号からなる連続部分に対応するため，各記号の最短生成語を代入して長さ $O(n(\tau_{G_*} + 1))$ 以下の語が得られる．元の非終端記号の生成言語・最短生成語長は変わらない．最後に非到達・非生産的な記号を除去する．得られる縮約済み BUNF 文法は元の言語を生成し，サイズは n の多項式で，厚みは $O(n(\tau_{G_*} + 1))$ である． □

付録 B linear-spine BUNF 正規化の証明

命題 *8.1* の証明. 線形 CFG の生成規則は $A \to uBv$ または $A \to w$ $(u, v, w \in \Sigma^*)$ と書ける．単位規則 $A \to B$ と空語規則 $A \to \lambda$ は残す．新しいラッパー $W_a \to a$ を各 $a \in \Sigma$ に導入し，他の補助

非終端記号は規則ごとに新たに取る．規則 $A \to a_1 \cdots a_m B b_1 \cdots b_n$（$m+n>0$）には，右鎖と左鎖

$$
\begin{aligned}
&C_0^{\mathrm{R}} := B, \quad C_j^{\mathrm{R}} \to C_{j-1}^{\mathrm{R}} W_{b_j} \qquad (1 \le j \le n),\\
&C_0^{\mathrm{L}} := C_n^{\mathrm{R}}, \quad C_i^{\mathrm{L}} \to W_{a_{m-i+1}} C_{i-1}^{\mathrm{L}} \quad (1 \le i \le m)
\end{aligned}
$$

を作る．$m=0$ なら $C_n^{\mathrm{R}} = A$，それ以外なら $C_m^{\mathrm{L}} = A$ と同一視する．$m=n=0$ なら $A \to B$ をそのまま残す．終端のみの規則 $A \to a_1 \cdots a_k$ は $k=0,1$ なら残す．$k \ge 2$ なら $C_1^{\mathrm{T}} := A$ と新しい $C_2^{\mathrm{T}}, \ldots, C_k^{\mathrm{T}}$ により

$$
C_i^{\mathrm{T}} \to W_{a_i} C_{i+1}^{\mathrm{T}} \quad (1 \le i < k), \qquad C_k^{\mathrm{T}} \to a_k
$$

とする．各二項規則はちょうど一つの終端ラッパー子と一つの spine 子を持つ．最後に非到達・非生産的記号を除去すれば，同値な縮約済み BUNF 文法となり，符号化サイズは元の文法サイズの多項式である． □

付録 C　括弧付き倍増言語族の代入可能性

$L_0 = \{\mathtt{a}\}$ とおく．命題 6.4 の $L_n = L(G_n)$ は $n \ge 1$ について $L_n = \lceil L_{n-1} \rceil \cup \lfloor L_{n-1} L_{n-1} \rfloor$ を満たし，$L_{G_n}(E_i) = L_i$（$0 \le i \le n$）である．高さ i の帰納法により，L_i の任意の語は，ちょうど i 個の開き括弧に続いて $\mathtt{a}$ が現れる形で始まる．以下では可逆な決定的トップダウン解析器を用いて，代入可能性を直接証明する．

■解析器とスタックの性質． $n \ge 1$ を固定する．スタックは $E_0, \ldots, E_n$ と閉じ記号 $\rceil$, $\rfloor$ 上の語で，左端が頂点であり，空スタックを λ とする．任意のスタック ψ と $1 \le i \le n$ について，遷移は次のものに限る．

$$
\begin{aligned}
&E_0\psi \xrightarrow{\mathtt{a}} \psi, \quad E_i\psi \xrightarrow{\lceil} E_{i-1}\rceil\psi, \quad E_i\psi \xrightarrow{\lfloor} E_{i-1}E_{i-1}\rfloor\psi,\\
&\rceil\psi \xrightarrow{\rceil} \psi, \qquad \rfloor\psi \xrightarrow{\rfloor} \psi.
\end{aligned}
$$

$\sigma \xrightarrow{w} \theta$ は σ から w を読んで θ に至る計算を表す．遷移は決定的であり，各入力文字について単射でもある．実際，開き括弧の遷移の出力から展開前の E_i と残りのスタックが一意に復元でき，他の遷移では入力文字が決める頂記号だけが削除される．よって任意の語 v の作用は部分単射であり，$\sigma \xrightarrow{v} \theta_{\mathrm{out}}$ と $\theta \xrightarrow{v} \theta_{\mathrm{out}}$ から $\sigma = \theta$ が従う．

E_i の重みを 4^i，閉じ記号の重みを 1 とし，スタック全体の重みをその総和とする．文字 $\mathtt{a}$ の遷移と二つの閉じ記号の pop は重みを 1 減らし，$i \ge 1$ に対して $4^i > 2 \cdot 4^{i-1} + 1 > 4^{i-1} + 1$ が成立するから，すべての遷移で重みが厳密に減少する．特に $\sigma \xrightarrow{w} \sigma$ なら $w = \lambda$ である．次の二つの基本事実を使う．第一に，$v \ne \lambda$ とし，$v\vartheta$ から始まる計算が初めて ϑ に到達するまでは，スタックは $v'\vartheta$（$v' \ne \lambda$）の形を保ち，遷移は v' にのみ作用する．ϑ に到達すれば，入力は $w = w_1 w_2$ と分解され，$v \xrightarrow{w_1} \lambda$ の後に $\vartheta \xrightarrow{w_2} \theta$ が続く．到達しなければ，最後は $v'\vartheta$（$v' \ne \lambda$）となる．重みの厳密減少性から，ϑ への到達は高々一度である．第二に，遷移は頂記号のみを書き換えるので，最後の記号が $\rceil$（それぞれ $\rfloor$）の非空スタックは，空になるまで同じ末尾記号を保つ．

補題 付録 C.1. $0 \le i \le n$，任意のスタック ψ と $w \in \Gamma_{\mathrm{br}}^*$ について，$E_i\psi \xrightarrow{w} \psi$ と $w \in L_i$ は同値である．さらに $\sigma \xrightarrow{w} \theta$ かつ $w \in L_i$ なら，あるスタック ψ について $\sigma = E_i\psi$，$\theta = \psi$ となる．

Proof. $E_i\psi \xrightarrow{w} \psi$ とする．前述の接尾部保存性より，計算は必ず ψ に初めて到達する．到達しなければ終状態は $v'\psi$（$v' \neq \lambda$）となるからである．厳密な重み減少性により，その後の入力は空でなければならない．従ってこの計算は，$E_i \xrightarrow{w} \lambda$ に接尾部 ψ を保持したものに等しい．逆方向の持ち上げも可能である．

$E_i \xrightarrow{w} \lambda$ と $w \in L_i$ の同値性を i に関する帰納法で示す．$i = 0$ では唯一の遷移が a を読んで空スタックに至る．$i \geq 1$ では，最初の文字は $\lceil$ または $\lfloor$ に限られる．単項の場合，遷移後のスタックは $E_{i-1}\rceil$ であり，接尾部保存性により，最後の $\rceil$ を読む前に E_{i-1} を完全に処理する必要がある．従って $w = \lceil z \rceil$ で $E_{i-1} \xrightarrow{z} \lambda$，すなわち帰納法から $z \in L_{i-1}$ である．二分の場合，遷移後は $E_{i-1}E_{i-1}\rfloor$ である．二つの E_{i-1} に順に同じ接尾部保存性を適用すれば，$w = \lfloor z_1 z_2 \rfloor$，$z_1, z_2 \in L_{i-1}$ を得る．逆に，これらの形の任意の語は対応する遷移で読み終えられる．

最後の主張を示す．w の先頭の i 文字は開き括弧で，次が a である．最初の文字（$i = 0$ なら a）を読むには $\sigma = E_k\psi$ が必要である．開き括弧を読むたびに頂点の添字は 1 ずつ減り，次の a が読めるのは $k = i$ の場合だけである．前半の同値性と決定性から $\theta = \psi$ が従う． □

補題 付録 C.2. $0 \leq i \leq n$，$w, w' \in L_i$ なら $w \equiv_{L_n} w'$ である．

Proof. 任意の受理計算 $E_n \xrightarrow{p} \sigma \xrightarrow{w} \theta \xrightarrow{q} \lambda$ を考える．補題 付録 C.1 より $\sigma = E_i\psi$，$\theta = \psi$ である．同じ補題より $E_i\psi \xrightarrow{w'} \psi$ も成立する．従って $(p, q) \in \mathcal{D}_{L_n}(w)$ なら $(p, q) \in \mathcal{D}_{L_n}(w')$ である．対称性から両分布は等しい． □

補題 付録 C.3 (分岐同期)**.** 非空語 x, y の先頭文字が異なり，$\sigma \xrightarrow{x} \theta$，$\sigma \xrightarrow{y} \theta$ なら，ある $1 \leq i \leq n$ とスタック ψ について $\sigma = E_i\psi$ であり，$x = wx'$，$y = w'y'$，$w, w' \in L_i$ と分解でき，$\psi \xrightarrow{x'} \theta$，$\psi \xrightarrow{y'} \theta$ が成り立つ．

Proof. 初手が二通りあるのは $E_i\psi$ の場合だけで，読む文字は $\lceil$ と $\lfloor$ である．x が前者，y が後者とすると，最初の遷移後の状態は $E_{i-1}\rceil\psi$ と $E_{i-1}E_{i-1}\rfloor\psi$ になる．初めて ψ に到達するまでは，接尾部保存性と末尾記号保存性から，それぞれ $A\rceil\psi$，$B\rfloor\psi$ の形を保つ．その重みは $\mathrm{wt}(\psi)$ より大きい．ψ に到達した時の重みは等しく，その後の遷移では小さくなる．従って両計算が同じ θ で終わるなら，双方とも ψ に到達するか，双方とも到達しないかのいずれかである．後者では $A\rceil\psi = B\rfloor\psi$ となるが，自由モノイドの右消去律より $A\rceil = B\rfloor$ が従い，末尾記号が異なるので矛盾する．よって双方とも ψ に到達する．その時点までに読んだ接頭語 w, w' は補題 付録 C.1 より L_i に属し，残りの語はともに ψ から θ に至る． □

命題 付録 C.4. 任意のスタック σ, θ と $x, y \in \Gamma_{\mathrm{br}}^*$ について，$\sigma \xrightarrow{x} \theta$ かつ $\sigma \xrightarrow{y} \theta$ なら $x \equiv_{L_n} y$ である．

Proof. $|x| + |y|$ に関する帰納法を用いる．$x = \lambda$ なら $\sigma = \theta$ なので，重みの厳密減少性により $y = \lambda$ である．$y = \lambda$ の場合も同様．$x = cx'$，$y = cy'$ と先頭文字が等しければ，決定性により一文字読んだ後の状態は共通であり，帰納法から $x' \equiv_{L_n} y'$，従って $x \equiv_{L_n} y$ となる．先頭文字が異なるときは補題 付録 C.3 によって $x = wx'$，$y = w'y'$（$w, w' \in L_i$）と分解され，$\psi \xrightarrow{x'} \theta$，$\psi \xrightarrow{y'} \theta$ となる．取り除いた接頭語は非空だから，帰納法で $x' \equiv_{L_n} y'$ を得る．補題 付録 C.2 により $w \equiv_{L_n} w'$ である．構文合同のモノイド合同性から $wx' \equiv_{L_n} w'y'$ が従う． □

命題 *6.4(i)* の証明. $x, y \in \Gamma^+_{\mathrm{br}}$ および $(u, v) \in \mathcal{D}_{L_n}(x) \cap \mathcal{D}_{L_n}(y)$ とする．E_n から空スタックへの二つの受理計算は，決定性により共通接頭語 u の直後で同じ状態 σ に至る．共通接尾語 v の直前の状態を θ_x, θ_y とすれば，$\theta_x \xrightarrow{v} \lambda$，$\theta_y \xrightarrow{v} \lambda$ である．語作用の部分単射性から $\theta_x = \theta_y =: \theta$ となる．従って $\sigma \xrightarrow{x} \theta$，$\sigma \xrightarrow{y} \theta$ であり，命題 付録 C.4 より $\mathcal{D}_{L_n}(x) = \mathcal{D}_{L_n}(y)$ である．L_n は有限ゆえ文脈自由であり，Clark–Eyraud の意味で代入可能だから $L_n \in \mathcal{C}^{\mathrm{cf}}_{s_0} \cap \mathcal{C}^{\mathrm{cf}}_{s_{\mathrm{U}}}$ が従う． □

参考文献

[1] E. M. Gold. Language identification in the limit. *Information and Control*, 10(5):447–474, 1967.

[2] A. Clark and R. Eyraud. Polynomial identification in the limit of substitutable context-free languages. *Journal of Machine Learning Research*, 8:1725–1745, 2007.

[3] R. Yoshinaka. Identification in the limit of k, l-substitutable context-free languages. In *Grammatical Inference: Algorithms and Applications – ICGI 2008*, LNCS 5278, pp. 266–279, Springer, 2008. doi:10.1007/978-3-540-88009-7_21.

[4] C. de la Higuera. *Grammatical Inference: Learning Automata and Grammars*. Cambridge University Press, 2010.

[5] M. Kanazawa. Identification in the limit of categorial grammars. *Journal of Logic, Language and Information*, 5(2):115–155, 1996. doi:10.1007/BF00173697.

[6] M. Kanazawa. *Learnable Classes of Categorial Grammars*. CSLI Publications, 1998.

[7] T. Kuriyama. *Learning Algorithm for Relation-Substitutable Context-Free Languages*. arXiv:1409.6247v3, November 2014 (historical version). `https://arxiv.org/abs/1409.6247v3`.

[8] R. Yoshinaka. General perspective on distributionally learnable classes. In *Proceedings of the 14th Meeting on the Mathematics of Language (MoL 14)*, pp. 87–98, 2015.

[9] F. Coste, D. Fredouille, C. Kermorvant, and C. de la Higuera. Introducing domain and typing bias in automata inference. In *ICGI 2004*, LNCS 3264, pp. 115–126, Springer, 2004. doi:10.1007/978-3-540-30195-0_11.

[10] Y. Takada. Grammatical inference for even linear languages based on control sets. *Information Processing Letters*, 28(4):193–199, 1988. doi:10.1016/0020-0190(88)90208-6.

[11] Y. Takada. Learning formal languages based on control sets. In K. P. Jantke and S. Lange (Eds.), *Algorithmic Learning for Knowledge-Based Systems*, LNAI 961, pp. 316–339, Springer, 1995. doi:10.1007/3-540-60217-8_15.

[12] S. Eilenberg. *Automata, Languages, and Machines*, Vol. A. Academic Press, 1974.

[13] M. Wakatsuki and E. Tomita. A fast algorithm for checking the inclusion for very simple deterministic pushdown automata. *IEICE Transactions on Information and Systems*, E76-D(10):1224–1233, 1993.

[14] R. Eyraud, J. Heinz, and R. Yoshinaka. Efficiency in the identification in the limit learning paradigm. In J. Heinz and J. M. Sempere (Eds.), *Topics in Grammatical Inference*, pp. 25–46, Springer, 2016. doi:10.1007/978-3-662-48395-4_2.

[15] C. de la Higuera. Characteristic sets for polynomial grammatical inference. *Machine Learning*, 27:125–138, 1997.

[16] A. Clark. Learning trees from strings: A strong learning algorithm for some context-free grammars. *Journal of Machine Learning Research*, 14:3537–3559, 2013.

[17] J.-E. Pin. *Varieties of Formal Languages*. Translated by A. Howie. Plenum Press, New York, 1986. ISBN 0-306-42294-8.

[18] J.-E. Pin. Syntactic semigroups. In G. Rozenberg and A. Salomaa (eds.), *Handbook of Formal Languages*, Vol. 1, pp. 679–746, Springer, 1997.

[19] J. C. Costa. Some pseudovariety joins involving locally trivial semigroups. *Semigroup Forum*, 64(1):12–28, 2002. doi:10.1007/s002330010060.

[20] J. C. Costa. Some pseudovariety joins involving groups and locally trivial semigroups. In *Semigroups, Algorithms, Automata and Languages*, pp. 341–348, World Scientific, 2002. doi:10.1142/9789812776884_0013.

[21] S. Ginsburg and E. H. Spanier. Finite-turn pushdown automata. *SIAM Journal on Control*, 4(3):429–453, 1966. doi:10.1137/0304034.

[22] J.-M. Autebert, J. Berstel, and L. Boasson. Context-free languages and pushdown automata. In G. Rozenberg and A. Salomaa (Eds.), *Handbook of Formal Languages*, Vol. 1, pp. 111–174, Springer, 1997.

[23] J. E. Hopcroft, R. Motwani, and J. D. Ullman. *Introduction to Automata Theory, Languages, and Computation*. 3rd ed., Pearson/Addison-Wesley, 2007.

[24] S. Ginsburg and S. A. Greibach. Deterministic context-free languages. *Information and Control*, 9:620–648, 1966.

[25] A. Clark. Distributional learning of some context-free languages with a minimally adequate teacher. In *Proceedings of ICGI 2010*, LNCS 6339, pp. 24–37, Springer, 2010. doi:10.1007/978-3-642-15488-1_4.