

# 固定有限モノイド型付けの下での文脈自由言語の分布学習

Takayuki Kuriyama  
独立研究者  
growup.kuriyama@gmail.com

## 概要

本論文では、有限モノイドへの準同型  $h: \Sigma^* \rightarrow M$  の核として与えられる固定可認識合同関係  $\sim_h$  の下で、文脈自由言語の分布学習を研究する。生成語型付き精密化では、各非終端記号の生成語の  $h$ -型を記録する。任意の有限正例標本に対して集合駆動型の文法再構成作用素を定義し、有限個の標準的な正例証拠語だけで、任意の文脈自由  $\sim_h$ -代入可能標的を厳密に再構成できることを示す。Gold の極限同定は、新たな正例が現在の文法によって生成されない場合にのみ仮説を変更する保守的逐次学習器によって別途得られる。 $h$  を固定すると、再構成および各学習更新はいずれも蓄積標本サイズに関して多項式時間である。

任意の固定された接頭辞 – 接尾辞窓  $(k, \ell)$  ( $(0, 0)$  を含む) について、対応する有限モノイド型付けは Yoshinaka の  $(k, \ell)$ -代入可能性クラスをちょうど表す。この特殊場合に対し、本論文の再構成作用素が、Yoshinaka により確立された文法サイズと厚みに関する特徴データと同じ尺度を回収することを、start-separated binary normal form への厚みを多項式的に保存する一般正規化を用いて示す。一方、任意の固定  $h$  に対する線形標的では、single-spine 構造から標準生成語と標準文脈の長さを線形 CFG 表現サイズの多項式で直接抑え、定理の記述に独立な厚みパラメータを必要とせず多項式サイズの特徴データを得る。固定窓の場合の多項式は、固定された窓とアルファベットに依存し、 $k, \ell$  を可変とした一様多項式上界は主張しない。さらに、固定有限モノイドによる比較が任意の固定窓を越えることを示す非正則線形標的および非線形標的を与え、同時に二文字アルファベット上ですでにいくつかの決定性文脈自由言語がこの枠組みの外にあることを示す。

**キーワード:** 文法推論, 分布学習, 文脈自由言語, 可認識合同関係, 有限モノイド準同型, 極限同定, 厳密再構成

## 1 序論

### 1.1 背景と動機

Gold [2] は、すべての有限言語と少なくとも一つの無限言語を含む言語クラスは、正例データのみから極限同定できないことを示した。この否定的結果は、文法推論における広範な研究の流れを生み出した。一般的背景については、たとえば de la Higuera [5] を参照されたい。文脈自由言語について正例学習可能性を回復する標準的な方法の一つが、**分布的**アプローチである。そこでは、異なる文脈間で比較してよい部分文字列を制限することで学習可能性を得る。古典的な例として、Clark–Eyraud の代入可能性 [6] および Yoshinaka の  $(k, \ell)$ -代入可能性 [7] がある。より一般には、適切な有限制御の仮定の下で、他の文法クラスに対しても正例データからの学習可能性が示されている。たとえば制限付き範疇文法については Kanazawa [1] を参照されたい。

本論文では、この分布的研究計画の可認識合同関係版を研究する。 $h: \Sigma^* \rightarrow M$  を有限モノイドへ

の準同型とし、 $\sim_h := \ker h$  つまり  $x \sim_h y$  iff  $h(x) = h(y)$  とおく． $x \in \Sigma^*$  に対し、

$$\mathcal{D}_L(x) := \{(u, v) \in \Sigma^* \times \Sigma^* : uxv \in L\}$$

を  $L$  における  $x$  の分布とする．言語  $L \subseteq \Sigma^*$  が  $\sim_h$ -**代入可能** であるとは、すべての  $x, y \in \Sigma^+$  について<sup>\*1</sup>

ここで、可認識合同関係は自然な比較機構を与える．ある有限モノイド準同型  $h : \Sigma^* \rightarrow M$  と  $\text{Acc} \subseteq M$  に対して  $L = h^{-1}(\text{Acc})$  であるならば、同じ  $h$ -値をもつ任意の二つの文字列は自動的に同じ継続挙動をもち、したがって同じ分布をもつ．特に、すべての正則言語は、ある有限モノイド準同型に対して  $\sim_h$ -代入可能な言語からなる、より広いクラス RS (Section 3 で形式的に定義する) に属する．この観察は、有限モノイド型付けが有界文脈の場合当たりの一般化ではなく、有限な比較バイアスを与える標準的な代数的源であることを示している．

本論文の焦点は **固定**- $h$  の状況である．同じ有限モノイド準同型  $h : \Sigma^* \rightarrow M$  が、文脈自由  $\sim_h$ -代入可能言語のクラス  $\mathcal{C}_h^{\text{cf}}$  全体にわたって一様に固定され、各標的についてデータ観測後に別々に選ばれるのではない．したがって固定  $h$  は、Yoshinaka の階層における固定された組  $(k, \ell)$  と同じクラスレベルの役割を果たす．有用な型付けを選ぶ問題と、型付けがすでに指定された後に学習する問題とを分離する点で、この観点はオートマトン推論における型付けまたは領域バイアス [12] に近い．

制御集合アプローチとの対比もある．Takada の even-linear 枠組みでは、固定された普遍文法の導出を規則ラベル列の正則言語によって制御する [8, 9]．これに対し、本論文の準同型は終端生成語に作用し、有限な **比較バイアス** を与える．すなわち、 $h$  を固定しても標的一言語が決まるのではなく、どの部分文字列を同一視してよいか制限されるだけである．制御集合に関する正例学習では追加の制限も用いられる [10]．ここでは位置づけのためにこの対比を用いるだけであり、control-set 枠組み全体からのクラス分離は主張しない．

## 1.2 貢献と主要結果

本論文の主要な貢献は三つである．

- (1) 固定有限モノイド準同型  $h$  に対して集合駆動型再構成作用素を定義し、有限個の標準正例証拠語からの厳密再構成を証明する．さらに、別に定義した保守的逐次学習器により、すべての非空  $L \in \mathcal{C}_h^{\text{cf}}$  の Gold 同定を得る．再構成と各更新はいずれも多項式時間である．
- (2) 任意の固定接頭辞 – 接尾辞窓  $(k, \ell)$  に対して、対応する有限モノイド型付けが Yoshinaka の  $(k, \ell)$ -代入可能性条件とちょうど同値であることを示し、厚みを多項式的に保存する SSBNF 正規化を通じて、本論文の再構成が Yoshinaka により確立された文法サイズと厚みに関する特徴データと同じ尺度を回収することを示す．一方、任意の固定  $h$  に対する線形部分クラスでは、標準生成語と標準文脈に直接多項式上界を与え、線形 CFG 表現のサイズに関して多項式の特徴データを得る．
- (3) 枠組みの構造的位置づけを与える．固定窓階層は正則レベルですでに可認識合同関係代入可能性に真に含まれ、この分離は非正則線形言語および非線形な文脈自由言語でも持続する．逆に、一種類括弧の Dyck 言語のような自然な決定性文脈自由言語は RS の外にある．さらに

<sup>\*1</sup> Clark–Eyraud では  $a^+$  が代入可能として扱われるが、 $\lambda$  自身を比較対象に含めると  $a^+$  は代入可能でなくなる．この点については Clark [13] も参照されたい．

RS  $\cap$  CFL は Clark の congruential family に含まれ、二文字アルファベット  $\{a, b\}$  上です  
にこの包含は真である。

### 1.3 論文の構成

Section 2 では記法と学習モデルを固定し、Section 3 では固定可認識代入可能性と古典的クラスと  
の関係を述べる。Section 4 では再構成作用素と保守的逐次学習器を定義し、Section 5 では標的文法  
を生成語型付けすることで厳密再構成と Gold 収束を証明する。Section 6 では多項式構成上界を与  
える。Section 7 では、厚みを多項式的に保存する SSBNF 正規化を用いて、本再構成が Yoshinaka  
の固定窓に対する文法サイズと厚みに関する尺度を回収することを確認し、Section 8 では任意の固  
定- $h$  線形標的について型付き証拠語に直接多項式上界を与える。Section 9 では主要な表現力・境界  
結果を記録する。正規化および短い証拠語に関する技術的証明は付録へ回す。

## 2 準備

$\Sigma$  を有限アルファベットとし、 $\Sigma^*$  を単位元  $\lambda$  をもつ自由モノイドとする。また  $\Sigma^+ := \Sigma^* \setminus \{\lambda\}$   
とおく。対  $(u, v) \in \Sigma^* \times \Sigma^*$  を **終端文脈** と呼ぶ。 $L \subseteq \Sigma^*$  と  $x \in \Sigma^*$  に対し、 $L$  における  $x$  の **分**  
**布** を

$$\mathcal{D}_L(x) := \{(u, v) \in \Sigma^* \times \Sigma^* : uxv \in L\}$$

と定める。 $L$  の **構文合同関係** は、 $x, y \in \Sigma^*$  に対して  $x \equiv_L y$  iff  $\mathcal{D}_L(x) = \mathcal{D}_L(y)$  により定める。  
 $x \equiv_L y$  のとき、 $x$  と  $y$  は **構文合同** であるといい、 $x$  の  $\equiv_L$ -同値類を  $[x]_{\equiv_L}$  と書く。

文脈自由文法 (CFG) は有限非終端記号集合  $V$ 、開始記号  $S \in V$ 、および  $A \in V, \alpha \in (V \cup \Sigma)^*$   
に対する生成規則  $A \rightarrow \alpha$  からなる組  $G = (V, \Sigma, P, S)$  である。**文形式**とは  $(V \cup \Sigma)^*$  の任意の語で  
ある。 $G$  における一段階導出を  $\alpha \Rightarrow_G \beta$  と書き、その反射推移閉包を  $\Rightarrow_G^*$  と書く。したがって

$$L(G) := \{w \in \Sigma^* : S \Rightarrow_G^* w\}.$$

$A \in V$  に対して

$$L_G(A) := \{w \in \Sigma^* : A \Rightarrow_G^* w\}$$

とおく。非終端記号  $X \in V$  に対し、 $S \Rightarrow_G^* uXv$  が成り立つとき、終端文脈  $(u, v)$  を  $G$  における  
 $X$  の **終端到達文脈** と呼ぶ。非終端記号が  $S$  から到達可能な文形式中に現れるとき **到達可能** である  
といい、終端語を導出するとき **生産的** であるという。到達可能かつ生産的でない非終端記号を **無用**  
といい、 $\lambda$  を導出する非終端記号を **nullable** という。 $A, B \in V$  に対する生成規則  $A \rightarrow B$  を **単位**  
**規則** という。**単位閉包**とは、単位生成規則が非終端記号上に誘導する関係の反射推移閉包である。す  
べての非終端記号が到達可能かつ生産的である文法を **縮約済み** という。非空言語を生成する文法に  
ついて、その **トリム**とは、すべての無用な非終端記号と、それらに接続する生成規則を削除して得  
られる部分文法をいう。各右辺に高々一つの非終端記号しか現れない CFG を **線形** という。**二分化**  
とは、新たな非終端記号を用いて長い右辺を同値な二項生成規則の鎖へ置き換えることをいう。CFL  
を文脈自由言語全体のクラスとする。任意の有限表現  $r$  に対し、 $|r|$  は固定した妥当な符号化の長さ  
を表すものとする。文法については、これは通常の生成規則中の記号数と多項式の範囲で同値であ

る. Yoshinaka の固定窓解析 [7] に従い, 縮約済み文法  $G = (V, \Sigma, P, S)$  について**厚み**パラメータを

$$\tau_G := \max_{A \in V} \min \{ |w| : A \Rightarrow_G^* w, w \in \Sigma^* \}$$

と定める. すなわち  $\tau_G$  は, 各非終端記号の最短終端生成語の長さを取り, その最大値をとったものである.

## 2.1 正例データからの学習

Gold の explanatory model [2] を用いる.  $H_0$  を, 一つの開始記号をもち生成規則をもたない固定 CFG とし,  $L(H_0) = \emptyset$  とする. 以下のテキスト規約は非空の標的言語に限定する. 空言語はこのテキストに基づく Gold の記述から除外し, 別途  $H_0$  により表す. 同値に, 通常の pause 記号をテキストに加えることで空標的を含めることもできるが, 余分な記法を避けるためにここでは非空テキスト規約を用いる. 非空言語  $L$  に対し, **テキスト**とは,  $L$  の各語が少なくとも一度は現れる  $L$  上の無限列  $T = (w_1, w_2, \dots)$  である.  $T[n] = (w_1, \dots, w_n)$  および  $K_n := \{w_1, \dots, w_n\}$  と書く. 学習器  $\mathcal{A}$  が非空言語  $L$  を **極限同定**するとは,  $L$  の任意のテキスト  $T$  に対して, ある  $n_0$  と文法  $H$  が存在し, すべての  $n \geq n_0$  について  $\mathcal{A}(T[n]) = H$  かつ  $L(H) = L$  が成り立つことをいう. したがって, 仮説表現そのものが最終的に安定する. 逐次学習器が **保守的** であるとは, 新たに提示された正例データが現在の仮説によって生成されない場合にのみ, その現在の仮説を変更することをいう.

この逐次学習器とは別に, 集合駆動型の有限標本作用素  $B$  を考える. ここで  $B(K)$  は有限集合  $K$  のみに依存し, 提示順序や重複回数には依存しない. 任意の有限標本  $K$  に対して  $K \subseteq L(B(K))$  が成り立つとき,  $B$  は **標本整合的** であるという. 有限集合  $C \subseteq L$  が  $B$  に対する **特徴標本** であるとは, 任意の有限  $K$  について  $C \subseteq K \subseteq L$  ならば  $L(B(K)) = L$  が成り立つことをいう. これは de la Higuera の多項式文法推論枠組み [4] における有限標本部分である. 標本サイズを

$$\|K\| := \sum_{w \in K} (|w| + 1)$$

で測る<sup>\*2</sup>. したがって  $\lambda$  も 1 を寄与する. 以下の定量的結果では,  $B(K)$  の多項式時間構成と, 多項式サイズの特徴データを組み合わせる.

## 2.2 固定有限モノイド型付け

有限モノイド  $M$  と準同型  $h : \Sigma^* \rightarrow M$  を固定する. これらは  $M$  の乗法表および各  $a \in \Sigma$  に対する文字像  $h(a)$  によって表現される. したがって  $h(w)$  は左から右への積によって  $O(|w|)$  時間で計算できる. 以下で固定準同型が **効率的に計算可能** であるというのはこの意味である.

**定義 2.1** (固定- $h$  代入可能性). 言語  $L \subseteq \Sigma^*$  が  $\sim_h$ -代入可能 であるとは, すべての  $x, y \in \Sigma^+$  について,  $h(x) = h(y)$  と  $\mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \emptyset$  から  $\mathcal{D}_L(x) = \mathcal{D}_L(y)$  が従うことをいう.

空語は内部の代入可能因子としては用いない.  $\lambda \in L$  の場合には, 再構成において開始記号を通じて別途処理する.

<sup>\*2</sup> 各正例が少なくとも 1 を寄与するようにするためである. たとえば  $K = \{\lambda\}$  に対し  $\sum_{w \in K} |w| = 0$  となるのを避け,  $\|K\| = 1$  とする. また常に  $|K| \leq \|K\|$  となるため, 正例数も同じサイズ尺度で抑えられる.

非空内部因子  $x$  に対して,  $h(x)$  をその **生成語型** と呼ぶ. 文脈自由  $\sim_h$ -代入可能言語のクラスを  $\mathcal{C}_h^{\text{cf}}$  と書き,

$$\mathcal{C}_h^{\text{lin}} := \{L \in \mathcal{C}_h^{\text{cf}} : L \text{ はある線形 CFG により生成される}\}$$

と定める. したがって  $\mathcal{C}_h^{\text{lin}}$  は線形言語からなる部分クラスである. 以下の多項式データ上界は, 標的について選ばれた線形 CFG 表現を基準に測る. 後で構成される再構成仮説自体は線形文法である必要はない.

### 3 固定可認識代入可能性

固定準同型  $h$  に対し,

$$\text{RS}_h := \{L \subseteq \Sigma^* : L \text{ は } \sim_h\text{-代入可能}\}$$

とおく. したがって  $\mathcal{C}_h^{\text{cf}} = \text{RS}_h \cap \text{CFL}$  であり,  $\mathcal{C}_h^{\text{lin}}$  は  $\text{RS}_h \cap \text{CFL}$  に属し, かつある線形 CFG により生成される言語からなる. 表現力の比較のためだけに,  $h$  が定義域  $\Sigma^*$  をもつ有限モノイド準同型全体を動くものとして,

$$\text{RS} := \bigcup_h \text{RS}_h$$

とする. このようなクラス記法はすべて周囲のアルファベットに相対的である. アルファベットを明示する必要があるときは,  $\Gamma^*$  上の対応するクラスを  $\text{RS}_h(\Gamma)$  および  $\text{RS}(\Gamma)$  と書く. クラス包含は常にアルファベットごとに理解する. 本論文の学習結果は一つの固定  $h$  を対象とする. 非空アルファベット上では,  $\text{RS}$  も  $\text{RS} \cap \text{CFL}$  も正例データから極限同定できない.\*<sup>3</sup>ただし, 型付けバイアスの精密化について単純な単調性がある.  $h' : \Sigma^* \rightarrow M'$  が  $\ker h' \subseteq \ker h$  という意味で  $h$  を精密化するとき,  $\text{RS}_h \subseteq \text{RS}_{h'}$  が成り立つ. 実際,  $h'$  の下で等しいことは  $h$  の下で等しいことを意味するので,  $h'$  が要求するすべての比較はすでに  $h$ -代入可能性によって覆われている. したがって, より細かい型付けは比較すべき因子対を減らすことにより, より大きな固定- $h$  クラスを許す. ただし, この利得は以下の量的上界において無償ではない. 型付けを精密化すると, 後述する型付き非終端記号数が増え, その結果, 証拠集合サイズも増える可能性がある. 特に, 二つの有限型付け  $h, g$  に対して積準同型  $h \times g$  は  $\ker(h \times g) = \ker h \cap \ker g$  をもち, 両者を精密化する. したがって  $\text{RS}_h \cup \text{RS}_g \subseteq \text{RS}_{h \times g}$  であり, 窓情報と独立な有限の領域固有特徴を一つの固定型付けに合成できる.

型付けに関するもう一つの有用な観察として, 単純な十分条件が得られる.  $\ker h$  を  $\Sigma^+$  に制限した関係が  $\equiv_L$  を精密化するならば\*<sup>4</sup>,  $L \in \text{RS}_h$  である. なぜなら,  $h$ -型が等しい語はすでに構文合同だからである. しかしこれは必要条件ではない. 後の Proposition 8.4 は, 四元の固定- $h$  に属しながら構文合同関係が無限指数をもつ例を与える. 任意の有限モノイド核の指数は有限なので, 固定- $h$  代入可能性は,  $\ker h$  が完全な構文合同関係を精密化することよりも真に弱い.

**命題 3.1.** 言語が正則であることと, ある有限モノイド  $M$  への準同型  $h : \Sigma^* \rightarrow M$  およびある  $\text{Acc} \subseteq M$  に対して  $h^{-1}(\text{Acc})$  の形に書けることは同値である. さらに, 任意の固定  $h$  と  $\text{Acc} \subseteq M$  に対し, 言語  $h^{-1}(\text{Acc})$  は  $\sim_h$ -代入可能である. したがって, すべての正則言語は  $\text{RS}$  に属する.

\*<sup>3</sup> Proposition 3.1 で示すように, すべての正則言語は  $\text{RS}$  に属する. したがって, 非空アルファベット  $\Sigma$  上では,  $\text{RS}$  も  $\text{RS} \cap \text{CFL}$  もすべての有限言語を含み, さらに無限正則言語  $\Sigma^*$  も含む. ゆえに両クラスは superfinite であり, Gold の定理 [2] により正例データから極限同定できない.

\*<sup>4</sup> もし  $\ker h \subseteq \equiv_L$  を  $\Sigma^*$  全体で要求してしまうと, 例えば自明モノイドでは  $\lambda$  とすべての非空語が同じ型になるため, 通常は代入可能とされる  $a^+$  も  $\lambda \not\equiv_{a^+} a$  により除外されてしまう.

159 *Proof.* 最初の主張は、有限モノイドによる正則言語の標準的特徴づけである [3]。具体的には、DFA  
 160 から有限遷移モノイドを得て、各語をその語が誘導する状態変換へ写す準同型を考えればよい。逆  
 161 に、 $L = h^{-1}(\text{Acc})$  ならば、状態集合  $M$ 、初期状態  $1_M$ 、遷移  $m \xrightarrow{a} mh(a)$ 、受理集合  $\text{Acc}$  をもつ  
 162 有限オートマトンが  $L$  を認識する。  $h(x) = h(y)$  なら、任意の  $u, v$  に対して  $h(uxv) = h(uyv)$  で  
 163 あるから、 $uxv \in h^{-1}(\text{Acc})$  iff  $uyv \in h^{-1}(\text{Acc})$  である。 よって  $\mathcal{D}_{h^{-1}(\text{Acc})}(x) = \mathcal{D}_{h^{-1}(\text{Acc})}(y)$ .  $\square$

### 164 3.1 古典的特殊場合

165 言語  $L \subseteq \Sigma^*$  が *Clark–Eyraud 代入可能* であるとは、すべての  $x, y \in \Sigma^+$  について、 $\mathcal{D}_L(x) \cap$   
 166  $\mathcal{D}_L(y) \neq \emptyset$  ならば  $\mathcal{D}_L(x) = \mathcal{D}_L(y)$  が成り立つことをいう。 Definition 2.1 の非空因子規約の下で  
 167 は、これはちょうど自明モノイドの場合である。 特に、Yoshinaka の  $(0, 0)$  の場合に一致する。 同じ  
 168 運用上の規約については Clark [13] も参照されたい。

169 **命題 3.2** (Clark–Eyraud の特殊場合). すべての *Clark–Eyraud 代入可能* 言語は RS に属する。

170 *Proof.* 一元モノイドをとる。すると型条件は自明となり、Definition 2.1 は通常の代入可能性そのも  
 171 のになる。  $\square$

172  $k, \ell \geq 0$  に対し、 $\text{pref}_k(w)$  および  $\text{suf}_\ell(w)$  を、それぞれ存在するときの指定長 prefix と suffix と  
 173 し、 $\text{pref}_0(w) = \text{suf}_0(w) = \lambda$  とする。

174 Yoshinaka の元の定義 [7] では、長さ  $k$  の左窓を  $v \in \Sigma^k$ 、長さ  $\ell$  の右窓を  $u \in \Sigma^\ell$  と書く。以下で  
 175 は一般の文脈記法  $(u, v)$  との衝突を避けるため、この二つの窓変数だけを  $p, q$  と改名する。したがっ  
 176 て、言語  $L$  が  $(k, \ell)$ -代入可能 であるとは、すべての  $p \in \Sigma^k, q \in \Sigma^\ell$  および  $x_1, x_2, y_1, y_2, z_1, z_2 \in \Sigma^*$   
 177 について、 $py_1q, py_2q \neq \lambda$  かつ

$$\begin{aligned} x_1py_1qz_1 \in L, \quad x_1py_2qz_1 \in L, \quad x_2py_1qz_2 \in L \\ \implies x_2py_2qz_2 \in L \end{aligned}$$

178 が成り立つことをいう。

179 **命題 3.3.** 任意の固定  $k, \ell \geq 0$  に対して有限モノイド準同型  $h_{k, \ell}$  が存在し、任意の言語  $L \subseteq \Sigma^*$  に  
 180 ついて、 $L$  が  $(k, \ell)$ -代入可能であることと、 $L$  が  $\sim_{h_{k, \ell}}$ -代入可能であることは同値である。

181 *Proof.*  $m_0 := \max\{1, k + \ell\}$  とおく。  $|w| < m_0$  のとき  $h_{k, \ell}(w) = w$  とし、それ以外では

$$h_{k, \ell}(w) = \langle \text{pref}_k(w), \text{suf}_\ell(w) \rangle$$

182 とする。1 ビットのタグを用いて、短い語を表す要素と長い語を表す要素とを互いに素に区別する。  
 183 さらに  $M_{k, \ell} := h_{k, \ell}(\Sigma^*)$  とおく。短い語  $x, y$  と像中のタグ付き要素に対し、積を

$$\begin{aligned} x \cdot y &:= h_{k, \ell}(xy), & x \cdot \langle p, q \rangle &:= \langle \text{pref}_k(xp), q \rangle, \\ \langle p, q \rangle \cdot y &:= \langle p, \text{suf}_\ell(qy) \rangle, & \langle p, q \rangle \cdot \langle p', q' \rangle &:= \langle p, q' \rangle \end{aligned}$$

184 と定める。四つの場合を直接確認すれば  $h_{k, \ell}(xy) = h_{k, \ell}(x) \cdot h_{k, \ell}(y)$  が得られる。  $h_{k, \ell}$  は全射なの  
 185 で、結合律は連接の結合律から従い、 $h_{k, \ell}(\lambda)$  が単位元である。したがって  $M_{k, \ell}$  は有限モノイドで  
 186 あり、 $h_{k, \ell}$  は準同型である。

$s, t \in \Sigma^+$  かつ  $h_{k,\ell}(s) = h_{k,\ell}(t)$  かつ  $\mathcal{D}_L(s) \cap \mathcal{D}_L(t) \neq \emptyset$  と仮定する.  $|s| < m_0$  ならば  $s = t$  である. そうでなければ  $s, t$  はともに長く, 同じ長さ  $k$  の prefix  $p$  と長さ  $\ell$  の suffix  $q$  をもつので,  $s = py_1q, t = py_2q$  と書ける.  $(u_0, v_0)$  を  $s, t$  の共通文脈とし,  $(u', v')$  を  $s$  の任意の文脈とする. 三つの語

$$u_0py_1qv_0, \quad u_0py_2qv_0, \quad u'py_1qv'$$

は  $L$  に属する.  $(k, \ell)$ -代入可能性を適用すると  $u'py_2qv' \in L$  を得る. よって  $\mathcal{D}_L(s) \subseteq \mathcal{D}_L(t)$  であり, 対称性から等号が成り立つ.

逆に,  $L$  が  $\sim_{h_{k,\ell}}$ -代入可能であるとし,  $(k, \ell)$ -代入可能性の前提を満たす文字列をとる.  $s := py_1q, t := py_2q$  とおくと, 定義により両者は非空である.  $k + \ell > 0$  なら  $|s|, |t| \geq k + \ell = m_0$  であり, 両者の型はともに  $\langle p, q \rangle$  である.  $k = \ell = 0$  なら, 非空性から  $|s|, |t| \geq 1 = m_0$  であり, 両者は唯一の非空語型  $\langle \lambda, \lambda \rangle$  をもつ. 従って  $h_{k,\ell}(s) = h_{k,\ell}(t)$  である. 最初の二つの前提語から  $s, t$  は文脈  $(x_1, z_1)$  を共有し, 第三の前提語から  $(x_2, z_2) \in \mathcal{D}_L(s)$  である. 固定- $h_{k,\ell}$  代入可能性により  $(x_2, z_2) \in \mathcal{D}_L(t)$  が従い, これは必要な第四の語そのものである.  $\square$

**■固定窓代入可能性の反例基準.**  $k, \ell \geq 0$  とし,  $m_0 := \max\{1, k + \ell\}$  とおく.  $s, t \in \Sigma^*$  が  $|s|, |t| \geq m_0$ ,  $\text{pref}_k(s) = \text{pref}_k(t)$ ,  $\text{suf}_\ell(s) = \text{suf}_\ell(t)$ ,  $\mathcal{D}_L(s) \cap \mathcal{D}_L(t) \neq \emptyset$  を満たし, かつ  $\mathcal{D}_L(s) \neq \mathcal{D}_L(t)$  であるならば,  $L$  は  $(k, \ell)$ -代入可能ではない. 実際, 長さの仮定と prefix-suffix の一致から  $h_{k,\ell}(s) = h_{k,\ell}(t)$  である一方,  $s, t$  は共通文脈をもちながら分布が異なるので,  $L$  は  $\sim_{h_{k,\ell}}$ -代入可能ではない. Proposition 3.3 より結論が従う.

したがって, 固定  $(k, \ell)$  クラスはちょうど  $\text{RS}_{h_{k,\ell}}$  である. Section 7 では, この特殊場合に本論文の再構成作用素が Yoshinaka の文法サイズと厚みに関する有限標本尺度を回収することを確認する. ここで  $k, \ell$  は固定されており, 窓パラメータを可変とした一様な多項式上界は主張しない. また, 厚み付きデータの主張は集合駆動型作用素  $\mathcal{B}_{h_{k,\ell}}$  による一括再構成に関するものであり, 保守的逐次学習器の最終的安定化は別に Gold の極限同定として示す.  $k = \ell = 0$  のとき, 準同型  $h_{0,0}$  は  $\lambda$  と非空語を区別し, 非空内部因子だけを比較する Definition 2.1 の下では一元自明モノイドと同じ代入可能性条件を誘導する. 現在のアルファベット上で固定されたすべての  $k, \ell$  にわたる和集合を  $\text{KL}$  と書き, アルファベット  $\Gamma$  を明示するときは  $\text{KL}(\Gamma)$  と書く.

## 3.2 主定理

**定理 3.4** (固定- $h$  学習定理). 有限モノイドへの効率的に計算可能な準同型  $h : \Sigma^* \rightarrow M$  を固定する. このとき, 集合駆動型再構成作用素  $\mathcal{B}_h$  と保守的逐次学習器  $\mathcal{A}_h$  が存在し, 次を満たす.

- (i)  $\mathcal{B}_h$  は標本整合的であり, 任意の有限正例標本  $K$  に対して  $\mathcal{B}_h(K)$  は  $\|K\|$  に関して多項式時間で構成可能である.
- (ii) すべての  $L \in \mathcal{C}_h^{\text{cf}}$  は,  $\mathcal{B}_h$  に対する有限特徴標本  $C_L \subseteq L$  をもつ.
- (iii)  $\mathcal{A}_h$  はすべての非空  $L \in \mathcal{C}_h^{\text{cf}}$  を Gold の意味で同定し, 各更新はその時点までの正例集合  $K_n$  のサイズ  $\|K_n\|$  に関して多項式時間で処理できる.

さらに, 任意の固定  $(k, \ell)$  について,  $\mathcal{C}_{h_{k,\ell}}^{\text{cf}}$  の標的, すなわち同値に文脈自由な  $(k, \ell)$ -代入可能標的の特徴データを, 縮約済み標的 CFG のサイズと厚みに関して多項式の符号化サイズに選べる. 任意の固定  $h$  に対する線形部分クラス  $\mathcal{C}_h^{\text{lin}}$  では, 特徴標本を標的の線形文法サイズに関して多項式に選

223 べる.

224 Sections 4–6 で定性的定理を証明し, Sections 7 および 8 で二つの定量的評価を与える. 線形の  
225 場合には, Section 8 で証拠構成に用いる標準生成語と標準文脈に直接多項式上界を与える.

226 Gold の標準的な superfinite obstruction, すなわちすべての有限言語と少なくとも一つの無  
227 限言語を含むクラスは正例データから同定できないという障害, との矛盾はない. 非空アルファ  
228 ベットと任意の固定有限  $h$  に対し,  $h(x) = h(y)$  を満たす相異なる非空語  $x, y$  を選び, さらに  
229  $|r| > \max\{|x|, |y|\}$  を満たす  $r$  を選ぶ. すると  $rx \notin \{x, y\}$  かつ  $ry \notin \{x, y, rx\}$  である. 前者の  
230  $\{x, y\}$  からの除外は長さから従い,  $rx \neq ry$  は左消去律と  $x \neq y$  から従う. 有限言語  $\{x, y, rx\}$  は  
231  $\sim_h$ -代入可能ではない. 実際,  $x$  と  $y$  は空文脈を共有する一方,  $(r, \lambda)$  は  $x$  の文脈だが  $y$  の文脈では  
232 ない. したがって  $RS_h$ , および  $C_h^{cf} = RS_h \cap CFL$  はすべての有限言語を含まない.

## 233 4 再構成作用素と逐次学習器

### 234 4.1 有限標本からの再構成

235 有限標本  $K \subseteq \Sigma^*$  に対し,

$$\hat{V}(K) := \{[x : u, v] : uxv \in K, x \in \Sigma^+\}$$

236 とおく. これらは構文的三つ組である. すなわち規約として,  $[x : u, v] = [x' : u', v']$  iff  $x = x'$ ,  
237  $u = u', v = v'$  とする. 特に, 同じ標本語から生じる場合であっても, 因子文字列または文脈文字列  
238 が異なる二つの出現は, 異なる仮説非終端記号である. 文法  $B_h(K) = \hat{G}(K)$  は, 非終端記号集合  
239  $\hat{V}(K) \cup \{\hat{S}\}$  と開始記号  $\hat{S}$  をもつ. 表示されるすべての角括弧付き非終端記号が  $\hat{V}(K)$  に属する場合  
240 に, 次の生成規則をもつ.

$$\begin{aligned} (R1) \quad & [xy : u, v] \rightarrow [x : u, yv][y : ux, v], & x, y \in \Sigma^+, \\ (R2) \quad & [x : u, v] \rightarrow [x : u', v'], & uxv, u'xv' \in K, \\ (R3) \quad & [x : u, v] \rightarrow [x' : u, v], & h(x) = h(x'), \\ (R4) \quad & [a : u, v] \rightarrow a, & a \in \Sigma, \\ (R5) \quad & \hat{S} \rightarrow [w : \lambda, \lambda], & w \in K \cap \Sigma^+. \end{aligned}$$

241  $\lambda \in K$  のときは, Rule (R5) に  $\hat{S} \rightarrow \lambda$  も含める. 直観的には,  $[x : u, v]$  は観測された因子  $x$  を文脈  
242  $(u, v)$  の中で置き換える候補を表す.  $\sim_h$ -代入可能な標的に対しては, 以下の健全性不変量により, 導  
243 出されるすべての語が  $x$  と同じ  $h$ -型をもち, 分布的に交換可能であることが保証される. Rule (R2)  
244 は文脈輸送規則である. 同じ観測因子は, その因子自身が観測された任意の文脈で表現できる. 二つ  
245 の周囲文脈の  $h$ -型に関する条件は不要である. Rule (R3) は, 一つの固定生成語型の内部で代表元  
246 を変更する. その条件  $h(x) = h(x')$  は, 健全性不変量の生成語型部分を保存するためにまさに用い  
247 られる. その不変量はその後 Rules (R1) および (R2) で代入可能性を適用するときに用いられる.

248 **補題 4.1** (標本整合性). 任意の有限正例標本  $K$  に対して,  $K \subseteq L(B_h(K))$  が成り立つ.

249 *Proof.*  $w = a_1 \cdots a_m \in K \cap \Sigma^+$  とする. Rule (R5) により  $[w : \lambda, \lambda]$  に入る. この  $w$  の出現を任意  
250 に二分木分解し, それに沿って Rule (R1) を繰り返し適用すると, 一文字因子へ到達する. 中間で  
251 必要となる観測非終端記号はすべて, 同じ標本語の因子と, それによって誘導される文脈から生じる

ため存在する．最後に Rule (R4) が  $a_1 \cdots a_m$  を出力する． $\lambda \in K$  の場合は，開始規則がこれを直接出力する． □

また  $K \subseteq K'$  ならば， $K$  から作られたすべての観測非終端記号と Rules (R1)–(R5) のすべてのインスタンスは  $K'$  に対しても残る．したがって  $\widehat{G}(K)$  は  $\widehat{G}(K')$  の部分文法であり，

$$L(\mathcal{B}_h(K)) \subseteq L(\mathcal{B}_h(K')).$$

ゆえに保守的学習器が再構成を行うとき，仮説言語は拡大することしかない．

**定理 4.2 (健全性).**  $K \subseteq L$  かつ  $L$  が  $\sim_h$ -代入可能ならば， $L(\widehat{G}(K)) \subseteq L$  である．

*Proof.*  $[x : u, v]$  を根とする導出木の高さについて帰納法を行い，次を同時に証明する．

$$[x : u, v] \Rightarrow_{\widehat{G}(K)}^* w \implies uvw \in L \text{ かつ } h(w) = h(x). \quad (1)$$

Rules (R1)–(R4) は消去生成規則を含まず，すべての語彙規則は一つの終端記号を出力する．したがって，開始記号以外の仮説非終端記号から導出されるすべての終端語は非空である．特に，以下で Definition 2.1 を適用する語  $w, w_1, w_2$  は  $\Sigma^+$  に属する．Rule (R4) の場合は明らかである．Rule (R3) については，帰納法の仮定から  $h(w) = h(x') = h(x)$  が得られ，またすでに  $uvw \in L$  が得られる．Rule (R2) については，帰納法の仮定から  $u'wv' \in L$  および  $h(w) = h(x)$  が得られる．さらに  $[x : u', v']$  と  $[x : u, v]$  は  $\widehat{V}(K)$  に属するので，その定義から  $u'xv', u'xv \in K \subseteq L$  である．したがって  $x$  と  $w$  は文脈  $(u', v')$  を共有し，代入可能性により  $\mathcal{D}_L(x) = \mathcal{D}_L(w)$  を得る．よって  $uvw \in L$  である．

Rule (R1) について，導出語を  $w_1w_2$  と書く．二つの帰納法の仮定から

$$uw_1yv \in L, \quad uxw_2v \in L, \quad h(w_1) = h(x), \quad h(w_2) = h(y)$$

が得られる． $uxyv \in K$  なので， $x$  と  $w_1$  は文脈  $(u, yv)$  を共有し，同じ型をもつ．したがって両者の分布は一致する．第二の帰納法の仮定により  $(u, w_2v) \in \mathcal{D}_L(x)$  である．この文脈に分布の等しさを適用すると  $uw_1w_2v \in L$  を得る．さらに帰納法の仮定から  $h(w_1w_2) = h(xy)$  である．これで (1) が証明された．開始規則を用いれば  $L(\widehat{G}(K))$  に対する主張が従う． $\lambda$  は  $\lambda \in K \subseteq L$  の場合にのみ存在する． □

## 4.2 逐次学習器

バッチ作用素自体は，各正例が追加されるたびに再計算すると，文法表現としては安定しない場合が一般的である．\*5 そこで，Section 2.1 で定義した固定空文法  $H_0$  から始め，標準的な保守的ラッパーを用いる． $w_n$  を読んだ後，

$$H_n := \begin{cases} H_{n-1}, & w_n \in L(H_{n-1}), \\ \mathcal{B}_h(K_n), & w_n \notin L(H_{n-1}), \end{cases} \quad \mathcal{A}_h(T[n]) := H_n$$

とおく．有限標本と特徴標本という見方は古典的な代入可能性研究に従う．Clark–Eyraud [6] を参照されたい．本論文では，バッチ構成器を保守的な逐次ラッパーの中に置く．すなわち，再構成のた

\*5 たとえば  $L = \{a^n cb^n : n \geq 0\}$  に対し，次第に長い正例が蓄積標本に加わると，各新語は  $[a^n cb^n : \lambda, \lambda]$  のような新たな因子／文脈三つ組を追加する．

279 びに蓄積集合全体  $K_n$  を用い、現在の仮説が次の正例を生成しない場合にのみ再構成する。したがっ  
 280 て、 $\mathcal{B}_h$  に対する特徴標本が  $K_n$  に含まれた後の任意の再構成は、Theorem 5.4 を直接適用できる。  
 281 収束性の証明は、Section 5 で標的側の完全性構成を与えた後に行う。学習器自体の定義はここで  
 282 完全に終わっている。

## 283 5 生成語型付き精密化と有限証拠による完全性

### 284 5.1 標的の精密化と有限証拠

285 再構成作用素と逐次学習器はすでに定義済みである。ここでは完全性の証明のためだけに標的側の  
 286 精密化を導入する。目標は、対応する正例証拠が出現した後に、仮説文法が有限個の型付き標的導出  
 287 を模倣できることを示すことである。次の標準形は証明上の道具としてのみ用いる。

288 **定義 5.1** (開始記号分離二分標準形). CFG  $G = (V, \Sigma, P, S_0)$  が 開始記号分離二分標準形 (SSBNF)  
 289 にあるとは、 $S_0$  がいかなる右辺にも現れず<sup>\*6</sup>、すべての開始規則が  $S_0 \rightarrow A$  または  $S_0 \rightarrow \lambda$  の形で  
 290 あり、すべての非開始規則が  $A \rightarrow a$  または  $A \rightarrow BC$  の形であることをいう。

291 任意の非空文脈自由言語は、標準的な開始記号分離、無用記号除去、開始記号以外での  $\lambda$ /単位規  
 292 則除去、および二分化の手続きにより、同値な縮約済み SSBNF 文法をもつ。標的言語が空集合の場  
 293 合は自明である。

294  $L \in \mathcal{C}_h^{\text{cf}}$  に対する縮約済み SSBNF 文法を  $G = (V, \Sigma, P, S_0)$  とする。その **完全生成語型付き精密**  
 295 **化** は、開始記号  $\tilde{S}$  と、 $A \in V \setminus \{S_0\}$ 、 $\mu \in M$  に対する非開始記号  $A_\mu$  をもつ。以下、型添字の併置  
 296 は  $M$  における積を表す。すなわち  $\mu\nu = \mu \cdot \nu$  とする。規則は次である。

$$\begin{aligned} \tilde{S} &\rightarrow A_\mu & (S_0 \rightarrow A \in P, \mu \in M), \\ \tilde{S} &\rightarrow \lambda & (S_0 \rightarrow \lambda \in P), \\ A_{h(a)} &\rightarrow a & (A \rightarrow a \in P), \\ A_{\mu\nu} &\rightarrow B_\mu C_\nu & (A \rightarrow BC \in P, \mu, \nu \in M). \end{aligned}$$

297 **型付き精密化**  $\tilde{G} = (\tilde{V}, \Sigma, \tilde{P}, \tilde{S})$  は、この文法の縮約部分とする。したがって、規約として  $\tilde{G}$  のす  
 298 べての記号は到達可能かつ生産的である。生成語型の添字は完全性証明の Rule (R3) に必要である。  
 299 型付けがなければ、標的規則  $A \rightarrow BC$  に対して、 $A$  の標準生成語  $\omega(A)$  と  $B, C$  の標準生成語の連  
 300 接  $\omega(B)\omega(C)$  が同じ  $h$ -値をもつとは限らず、必要な Rule (R3) の遷移を保証できない。生成語型で  
 301 分割することにより、この等式が不変量となる。一方で周囲の左文脈または右文脈には型を付けな  
 302 い。再構成作用素がそのような型を一度も検査しないからである。

303 **命題 5.2** (型付き持ち上げと生成語不変量). 型付き精密化は  $L(\tilde{G}) = L(G)$  を満たす。さらに、  
 304  $X = A_\mu$  が  $\tilde{G}$  の非開始記号であるとき、 $X \Rightarrow_G^* w$  ならば  $h(w) = \mu$  である。

305 *Proof.* 型注釈を消去すれば、任意の型付き導出は  $G$  の導出へ写る。逆に、 $G$  の成功した導出木の各  
 306 非開始節点に、その終端生成語の  $h$ -型を注釈する。上で定めた終端規則と二項規則は、それらの型の  
 307 ボトムアップ伝播則そのものである。したがって注釈付き木は完全精密化の導出であり、成功した導  
 308 出木に現れるすべての記号は trim 後も残る。不変量は型付き導出についての帰納法から従う。□

<sup>\*6</sup> 開始記号を文全体の生成入口として内部の非終端から分離し、型付き精密化と  $\lambda$  の特別扱いを単純に保つためである。

$\Sigma$  上に順序を一つ固定し、それが誘導する *shortlex* 順序を用いる。すなわち短い語を先に置き、同じ長さなら辞書式順序で比較する。 $\tilde{G}$  の各非開始記号  $X$  に対し、 $\omega(X)$  をその *shortlex* 最小終端生成語とし、これを  $X$  の**標準生成語**と呼ぶ。さらに  $X$  の終端到達文脈の中から、 $|u_X| + |v_X|$  を最小化するものとして  $\chi(X) = (u_X, v_X)$  を選び、同値な候補がある場合は  $u_X$  の *shortlex* 順序、次に  $v_X$  の *shortlex* 順序で決める。 $\chi(X)$  を  $X$  の**標準文脈**と呼ぶ。 $\tilde{G}$  は縮約済みなので、このような終端到達文脈は存在する。実際、到達可能性により  $X$  は到達可能な文形式中に現れ、周囲の非終端記号の生産性により、その左側および右側のすべての記号を終端文字列へ展開できる。Proposition 5.2 から  $h(\omega(A_\mu)) = \mu$  である。したがって、任意の型付き二項規則  $X = A_{\mu\nu} \rightarrow Y = B_\mu Z = C_\nu$  に対し、

$$h(\omega(X)) = \mu\nu = h(\omega(Y))h(\omega(Z)) = h(\omega(Y)\omega(Z))$$

が成り立つ。これこそが完全性証明で Rule (R3) により用いられる等式である。

有限証拠集合を

$$\begin{aligned} W(\tilde{G}) := & \{u_X\omega(X)v_X : X \in \tilde{V} \setminus \{\tilde{S}\}\} \\ & \cup \{u_Xav_X : X \rightarrow a \in \tilde{P}\} \\ & \cup \{u_X\omega(Y)\omega(Z)v_X : X \rightarrow YZ \in \tilde{P}\} \\ & \cup \{\lambda\} \text{ if } \lambda \in L \end{aligned} \quad (2)$$

により定める。ここに表示したすべての語は  $L$  に属し、集合は有限である。特に、二項規則  $X \rightarrow YZ$  に対応する証拠語は

$$\tilde{S} \Rightarrow^* u_X X v_X \Rightarrow u_X Y Z v_X \Rightarrow^* u_X \omega(Y) \omega(Z) v_X$$

により正当化される。anchor と終端規則証拠についても同様である。 $W(\tilde{G})$  の要素を **標準正例証拠**と呼ぶ。要素  $u_X\omega(X)v_X$  は  $X$  の一つの標準出現を証拠づける  $X$  の *anchor* であり、他の語は終端または二項の **規則証拠** という別役割がある。

## 5.2 厳密再構成と Gold 収束

**定理 5.3** (有限証拠からの完全性). 非空言語  $L$  に対する任意の縮約済み *SSBNF* 文法を  $G$  とし、固定準同型  $h$  に関するその型付き精密化を  $\tilde{G}$  とする。有限集合  $K$  が  $W(\tilde{G}) \subseteq K$  を満たすならば、 $L \subseteq L(\hat{G}(K))$  である。

ここが標的型付けが登場する箇所である。学習器とバッチ作用素は Section 4 ですでに定義されており、以下の証明は、それらの仮説非終端記号が生成語型付き標的非終端記号を模倣できることを示す。それ以外では、この主張は純粋に組合せ論的である。型付き文法と包含  $W(\tilde{G}) \subseteq K$  だけを用い、代入可能性も追加仮定  $K \subseteq L$  も必要としない。

*Proof.* 各非開始記号  $X$  に対し、 $\hat{X} := [\omega(X) : u_X, v_X]$  と書く。(2) の anchor 語により、 $\hat{X}$  は存在する。型付き導出  $X \Rightarrow^* w$  について帰納法を行い、 $\hat{X} \Rightarrow_{\hat{G}(K)}^* w$  を証明する。

最初の規則が  $X \rightarrow a$  であるとする。証拠  $u_Xav_X \in K$  により  $[a : u_X, v_X]$  が存在する。 $\omega(X) \neq a$  なら、 $h(\omega(X)) = h(a)$  なので Rule (R3) が  $\hat{X}$  を  $[a : u_X, v_X]$  に変更する。 $\omega(X) = a$  ならこの段階は不要である。その後 Rule (R4) が  $a$  を生成する。

338 最初の規則が  $X = A_{\mu\nu} \rightarrow B_\mu C_\nu$  であるとする.  $Y := B_\mu$  および  $Z := C_\nu$  とおく. (2) の規則証  
 339 拠により三つの観測非終端記号が得られ, Rule (R1) を適用して次を得る.

$$[\omega(Y)\omega(Z) : u_X, v_X] \rightarrow [\omega(Y) : u_X, \omega(Z)v_X][\omega(Z) : u_X\omega(Y), v_X]. \quad (3)$$

340  $h(\omega(X)) = \mu\nu = h(\omega(Y)\omega(Z))$  なので, 必要なら Rule (R3) により  $\hat{X}$  を (3) の左辺へ変更する.  
 341 すでに  $\omega(X) = \omega(Y)\omega(Z)$  であるならば, この段階は不要である. 次に Rule (R2) により二つの子  
 342 を  $\hat{Y}$  および  $\hat{Z}$  へ輸送する. これらはそれぞれ  $Y, Z$  の標準文脈によって定まる. 二つの部分導出は  
 343 帰納法の仮定により完了する.

344 最後に, 任意の非空  $w \in L$  は  $\tilde{S} \rightarrow X \Rightarrow^* w$  という持ち上げられた開始導出をもつ. 開始規則  
 345 そのものにより  $(\lambda, \lambda)$  は  $X$  の終端到達文脈である. その全長は 0 であり最小なので, 標準選択は  
 346  $\chi(X) = (\lambda, \lambda)$  となる. その anchor  $\omega(X)$  は  $K$  に属するため, Rule (R5) が上記の導出を開始す  
 347 る.  $w = \lambda$  の場合は (2) と Rule (R5) から直ちに従う.  $\square$

348 **定理 5.4** (厳密有限標本再構成).  $L \in \mathcal{C}_h^{\text{cf}}$  を非空とし,  $G$  を  $L$  の縮約済み *SSBNF* 文法,  $\tilde{G}$  をその  
 349 型付き精密化とする.  $W(\tilde{G}) \subseteq K \subseteq L$  ならば,  $L(\mathcal{B}_h(K)) = L$  である.

350 *Proof.* Theorems 4.2 と 5.3 を合わせればよい.  $\square$

351 したがって, 任意の非空標的表現  $\tilde{G}$  について, 集合  $W(\tilde{G})$  は Section 2.1 の意味で,  $\mathcal{B}_h$  に関す  
 352 る  $L(G)$  の特徴標本である.

353 Theorem 5.4 は  $\{\lambda\}$  を含むすべての非空標的を覆う. 残る端点  $L = \emptyset$  については  $C_L = \emptyset$  とお  
 354 けば,  $\mathcal{B}_h(\emptyset)$  は開始生成規則をもたない. これにより Theorem 3.4 の item (ii) が確立される.

355 **系 5.5** (Gold 同定). 有限モノイド  $M$  への固定準同型  $h : \Sigma^* \rightarrow M$  に対し, 学習器  $\mathcal{A}_h$  は  $\mathcal{C}_h^{\text{cf}}$  のす  
 356 べての非空言語を正例データから同定する. より具体的には, 任意の縮約済み *SSBNF* 標的文法  $G$   
 357 とその型付き精密化  $\tilde{G}$  に対し,  $W(\tilde{G}) \subseteq K_{n_0}$  となったとき,  $\text{stage } n \geq n_0$  の範囲で生じうる仮説  
 358 変更は高々一回である.

359 *Proof.* 本論文のテキスト規約の下では, Gold の主張は非空標的を対象とする.  $H_0$  は初期空仮説で  
 360 ある.  $L$  を非空とし,  $T$  を  $L$  のテキストとする.  $w_1 \notin L(H_0) = \emptyset$  なので, 学習器は stage 1 で  
 361 再構成する.  $W(\tilde{G}) \subseteq K_{n_0}$  を満たす  $n_0$  を選ぶ. ある stage  $n \geq n_0$  で学習器が再構成するならば,  
 362 Theorem 5.4 により新たな仮説はちょうど  $L$  となり, その後はいかなる正例も追加の変更を引き起  
 363 こさない. この場合はこれが最後の仮説変更となる. 一方, どの stage  $n \geq n_0$  でも再構成が起こら  
 364 ないと仮定する. 健全性から  $L(H_{n_0}) \subseteq L$  である. さらに, すべての  $n$  について  $K_n \subseteq L(H_n)$  が  
 365 成り立つ. 再構成時には標本整合性があり, 再構成しない段階では新たに提示されたデータがすでに  
 366 変更されない仮説によって生成されるからである. したがって真の包含  $L(H_{n_0}) \subsetneq L$  ならば, stage  
 367  $n_0$  までまだ現れていないある  $w^* \in L \setminus L(H_{n_0})$  が存在する. しかし標的のすべての語は最終的にテ  
 368 キストに現れるので,  $w^*$  は後の段階で現れて再構成を強制し, 矛盾する. この場合は 0 回の仮説変  
 369 更で十分となる.  $\square$

## 370 6 再構成ステップの計算量

371 **定理 6.1.**  $h$  を固定する. このとき  $\mathcal{B}_h(K)$  は  $\|K\|$  に関して多項式時間で構成できる.

*Proof.*  $n_K := \|K\|$  とおく．全標本語にわたる非空分解  $uxv$  は  $O(n_K^2)$  個であるから， $|\widehat{V}(K)| = O(n_K^2)$  である．また，すべての部分文字列の  $h$ -値は， $O(n_K^2)$  回のモノイド積によってあらかじめ計算し，キャッシュできる．

Rule (R1) の候補は  $O(n_K^3)$  個であり，Rules (R2),(R3) の候補は観測非終端記号の組から高々  $O(n_K^4)$  個である．固定  $h$  の下では型検査は定数時間で行える．したがって，生成される規則の総数は高々  $O(n_K^4)$  個である．

各規則に現れる非終端記号は標本語の因子と文脈を明示的に保持するため，各規則の符号化長は  $O(n_K)$  である．よって，出力文法全体の総符号化長は  $O(n_K^4) \cdot O(n_K) = O(n_K^5)$  である．因子と文脈をあらかじめ出現 ID で表現すれば，候補走査中の等値判定は定数時間で行える．また，長さ  $O(n_K)$  の符号化を直接比較する場合でも，高々  $O(n_K^4)$  個の候補の走査と条件確認には  $O(n_K^5)$  時間で十分である．出力文法の明示的な書き出しにも高々  $O(n_K^5)$  時間しかかからない．したがって， $\mathcal{B}_h(K)$  は  $O(n_K^5)$  時間で明示的に構成できる．  $\square$

**系 6.2.** 各段階で，保守的学習器  $\mathcal{A}_h$  は次の正例を，それまでに観測されたデータの符号化サイズに関して多項式時間で処理できる．

*Proof.* CFG membership は文法サイズと入力長に関して多項式時間であり，現在の仮説サイズは Theorem 6.1 により多項式である．再構成が必要な場合も，同じ定理により多項式時間である．  $\square$

Lemma 4.1, Theorems 5.4 および 6.1 と，Corollaries 5.5 および 6.2 により Theorem 3.4 の定性的部分が従う．一方，任意の CFG 表現について文法サイズだけからデータ量を多項式に抑えることはできない．実際，SSBNF 文法族  $S_0 \rightarrow A_n$ ,  $A_0 \rightarrow a$ ,  $A_i \rightarrow A_{i-1}A_{i-1}$  は生成規則中の記号数が  $O(n)$  であり，本論文の符号化規約では符号化サイズも  $n$  の多項式である一方，singleton  $\{a^{2^n}\}$  を生成する．一般に任意の singleton 言語は任意の  $h$  に対して  $\sim_h$ -代入可能である．実際，その唯一の語の内部で二つの非空因子が同じ文脈を共有すれば，自由モノイドの消去律により二因子は一致する．したがってこの障害は任意の固定- $h$  標的クラスの内部ですでに生じる．任意の特徴標本は長さ  $2^n$  の語を含み，これは符号化された文法サイズに対して超多項式である．そこで次節では Yoshinaka の固定窓解析で用いられる厚みパラメータを用い，Section 8 では任意の固定  $h$  の線形標的に対して文法サイズだけの上界を得る．

## 7 固定窓に対する厚み付きデータ

Proposition 3.3 により，固定窓の場合は特定の有限モノイド型付けとちょうど一致する．したがって本節の役割は互換性の確認である．Yoshinaka の Theorem 1 は，Lemmas 6, 7 により特徴集合の個数上界と記述サイズ上界を分けて与え，文法サイズと厚みに関する特徴データ尺度を確立している [7]．本節では，新しい固定窓学習結果を主張するのではなく，本論文の再構成作用素がその同じ尺度を保つことを示す． $h_{k,\ell}$  の型付き非終端記号  $A_\mu$  が保存すべきなのは有界な接頭辞と接尾辞だけなので，型付けによる追加の証拠語コストを制御できる．

$k, \ell \geq 0$  を固定し， $r := k + \ell$  とおき，Proposition 3.3 の準同型を  $h_{k,\ell}$  とする． $G = (V, \Sigma, P, S_0)$

406 を縮約済み SSBNF 文法とし,  $\tilde{G}$  を  $h_{k,\ell}$  に関するその縮約済み生成語型付き精密化とする.

$$N := |V \setminus \{S_0\}|, \quad N_t := |\tilde{V} \setminus \{\tilde{S}\}|, \quad B_{k,\ell}(G) := \begin{cases} \tau_G, & r = 0, \\ r + (2r - 1)N\tau_G, & r > 0 \end{cases}$$

407 と書く.

408 **補題 7.1** (固定窓型付き生成語の有界性).  $\tilde{G}$  の任意の非開始型付き記号  $A_\mu$  に対して,  $|\omega(A_\mu)| \leq$   
409  $B_{k,\ell}(G)$  である.

410 *Proof.* 付録 A を参照されたい. □

411 **補題 7.2** (固定窓文脈と証拠語の有界性).  $\tilde{G}$  の任意の非開始型付き記号  $X$  は

$$|u_X| + |v_X| \leq N_t B_{k,\ell}(G)$$

412 を満たす終端到達文脈をもち,  $W(\tilde{G})$  の任意の語の長さは高々  $(N_t + 2)B_{k,\ell}(G) + 1$  である.

413 *Proof.* 付録 A を参照されたい. □

414 **定理 7.3** (固定窓に対する多項式厚み付きデータ). 任意に固定した組  $(k, \ell)$  とアルファベット  $\Sigma$  に  
415 対し, 多項式  $Q_{k,\ell}$  が存在して次が成り立つ.  $G$  を  $L(G) \in \mathcal{C}_{h_{k,\ell}}^{\text{cf}}$  を満たす縮約済み SSBNF 文法と  
416 し,  $\tilde{G}$  をその生成語型付き精密化とする. このとき

$$\|W(\tilde{G})\| \leq Q_{k,\ell}(|G|, \tau_G).$$

417 したがって  $W(\tilde{G})$  は  $B_{h_{k,\ell}}$  に対する特徴標本であり, その  $\|\cdot\|$ -サイズは  $|G|$  と  $\tau_G$  の多項式で抑  
418 えられる.

419 *Proof.* 固定された  $k, \ell, \Sigma$  に対して  $M_{k,\ell}$  のサイズは定数であり,  $N_t \leq N|M_{k,\ell}|$  である. 各終端規  
420 則は高々一つの生産的型付き終端規則を, 各二項規則は高々  $|M_{k,\ell}|^2$  個の型付きコピーを生むので,  
421  $|\tilde{V}| + |\tilde{P}| = O_{k,\ell}(|G|)$  である. 証拠集合には型付き非終端記号ごとに高々一つのアンカー, 型付き終  
422 端または二項規則ごとに一つの証拠語, 必要なら  $\lambda$  が含まれる. Lemma 7.2 により各証拠語長は  $|G|$   
423 と  $\tau_G$  の多項式で抑えられるから, 主張が従う. 特徴標本であることは Theorem 5.4 による. □

424 上の定理は縮約済み SSBNF 表現について述べたものである. 次の正規化命題により, これを任意  
425 の縮約済み CFG 表現へ移送できる.

426 **命題 7.4** (厚みを多項式的に保存する SSBNF 正規化). 固定多項式  $P_1, P_2$  が存在し, 非空言語を生  
427 成する任意の縮約済み CFG  $R$  を, 多項式時間で, 同値な縮約済み SSBNF 文法  $G$  へ変換でき,

$$|G| \leq P_1(|R|), \quad \tau_G \leq P_2(|R|, \tau_R + 1)$$

428 が成り立つ.

429 証明は A.2 に与える. 終端記号の分離と二分化を非開始  $\lambda$ -規則除去より先に行うことで, 文法サ  
430 イズと最短非空生成語の双方を多項式に保つ.

431 **系 7.5** (固定窓計算量の移送). 任意の固定  $k, \ell \geq 0$  と有限アルファベット  $\Sigma$  に対し, 縮約済み CFG  
432  $R$  によって表現される任意の  $L \in \mathcal{C}_{h_{k,\ell}}^{\text{cf}}$ , すなわち同値に文脈自由な  $(k, \ell)$ -代入可能標的は,  $B_{h_{k,\ell}}$   
433 に対し,  $|R|$  と  $\tau_R$  の多項式で符号化サイズが抑えられる特徴データをもつ.

*Proof.* Proposition 7.4 を適用し、続いて Theorem 7.3 を適用する．同値性は Proposition 3.3 による． □

したがって、ちょうど対応する固定窓クラス上で、本論文のバッチ再構成は Yoshinaka の Theorem 1 および Lemmas 6–7 により確立された文法サイズと厚みに関する有限標本尺度と同じ尺度を回収する [7]．これは一般再構成枠組みの互換性確認であり、新しい固定窓学習可能性の主張ではない．多項式は固定された窓とアルファベットに依存し、 $k, \ell$  を可変とした一様上界は主張しない．Gold 安定化は Corollary 5.5 として別途与えられる．

## 8 線形部分クラス

線形言語は、ちょうど 1 ターンプッシュダウンオートマトンによって受理される言語である [11]．以下の正規化は、この single-turn 構造の文法的対応物を与え、すべての成功導出に一つの継続する非終端記号の道をもたせる．

**命題 8.1** (linear-spine SBNF 標準化)．固定多項式  $P_{\text{lin}}$  が存在し、非空言語を生成する任意の線形 CFG  $G$  を、多項式時間で、 $|G_0| \leq P_{\text{lin}}(|G|)$  を満たす同値な縮約済み SBNF 文法  $G_0 = (V_0, \Sigma, P_0, S_0)$  へ変換できる．さらに  $G_0$  の各二項生成規則は、 $W_a \rightarrow a$  を満たすちょうど一つの新鮮な終端ラッパー子  $W_a$  と、ちょうど一つのそれ以外の非終端子をもつ．

完全な構成と証明は 付録 B に与える．得られる文法を *linear-spine SBNF* と呼ぶ．その型付き精密化を  $\tilde{G}_0$  とし、 $n_t := |\tilde{V}_0 \setminus \{\tilde{S}\}|$  とおく．基礎となる各非開始記号は高々  $|M|$  個の型付きコピーをもつので、 $n_t \leq |V_0 \setminus \{S_0\}| |M|$  であり、固定  $h$  の下では  $|G|$  の多項式である．短い証拠補題で用いる spine と reaching-spine の用語は 付録 C にまとめる．

**補題 8.2** (短い標準証拠)． $\tilde{G}_0$  の任意の型付き非開始記号  $X$  に対し、

$$|\omega(X)| \leq n_t, \quad |u_X| + |v_X| \leq 2n_t$$

が成り立つ．したがって  $W(\tilde{G}_0)$  の各語の長さは  $O(n_t)$  である．

証明は 付録 C に回す．本文では、そこから得られる線形上界だけを用いる．

(2) は、各型付き記号につき高々一つの anchor、各型付き生成規則につき一つの証拠、および必要なら  $\lambda$  からなるので、その濃度は  $O(|\tilde{V}_0| + |\tilde{P}_0| + 1)$  である．Lemma 8.2 により、その  $\|\cdot\|$ -サイズは、 $h$  を固定したとき  $|G_0|$ 、したがって  $|G|$  の多項式で抑えられる．ここで一般の厳密再構成定理をそのまま再利用でき、健全性・完全性の証明を二度行う必要はない．したがって線形の場合の議論は、標本整合的バッチ作用素  $B_h$  に対して、多項式で抑えられた特徴標本を与える．保守的学習器  $A_h$  の Gold 安定化は別の主張である．Theorem 6.1 と合わせれば、任意の有限標本からのバッチ再構成は多項式時間であり、選んだ線形 CFG 表現に関して特徴データも多項式で抑えられる．ただしこの結論は表現に依存するので、保守的逐次学習器  $A_h$  自身を de la Higuera の意味での polynomial time-and-data learner と呼ぶことは避ける．特に、 $B_h$  の出力が線形表現であるとは限らない．

**定理 8.3** (線形標的に対する多項式特徴データ)． $h$  を固定する．線形 CFG によって表現される  $\mathcal{C}_h^{\text{lin}}$  の任意の言語は、 $B_h$  に対し、標的表現サイズの多項式で  $\|\cdot\|$ -サイズが抑えられる特徴標本をもつ．

467 *Proof.*  $L = \emptyset$  および  $L = \{\lambda\}$  については Section 5 の特徴標本を用いる．それ以外では Proposi-  
 468 tion 8.1 と Lemma 8.2 を適用する．標準証拠は  $O(|\tilde{V}_0| + |\tilde{P}_0| + 1)$  個で、各長さは  $O(n_t)$  である．  
 469 固定  $h$  の下で  $n_t, |\tilde{V}_0|, |\tilde{P}_0|$  はいずれも線形標的表現の多項式なので、特徴データ量も多項式であ  
 470 る．特徴標本であることは Theorem 5.4 から従う．  $\square$

## 471 8.1 非正則な線形 fixed- $h$ 例

472 直前の定理は、正則標的や既知の線形代入可能クラスに限定されない．次を定める．

$$L_{\pm,e} := \{a^{2m}cb^{2m} : m \geq 0\} \cup \{a^{2m+1}db^{2m+1} : m \geq 0\} \\ \cup \{a^neb^n : n \geq 0\}.$$

473 これは次の線形文法によって生成される．

$$S \rightarrow U_{\text{ev}} \mid U_e, \quad U_{\text{ev}} \rightarrow c \mid aU_{\text{odd}}b, \quad U_{\text{odd}} \rightarrow d \mid aU_{\text{ev}}b, \\ U_e \rightarrow e \mid aU_eb.$$

474  $c, d, e$  を**中心記号**と呼ぶ．  $M_{\pm,e} := \{1, \kappa_{cd}, \kappa_e, 0\}$  を、1 が単位元であり、 $\alpha\beta = 0$  がすべての  
 475  $\alpha, \beta \in \{\kappa_{cd}, \kappa_e, 0\}$  に対して成り立つ四元モノイドとする．すなわち  $M_{\pm,e}$  は三元 null semigroup  
 476 に単位元を付加したものである．準同型  $h : \{a, b, c, d, e\}^* \rightarrow M_{\pm,e}$  を

$$h(a) = h(b) = 1, \quad h(c) = h(d) = \kappa_{cd}, \quad h(e) = \kappa_e \quad (4)$$

477 により定める．従って  $h(w)$  は、 $w$  が中心記号を含まなければ 1、ちょうど一つ含めそれが  $c$  または  
 478  $d$  なら  $\kappa_{cd}$ 、それが  $e$  なら  $\kappa_e$ 、二つ以上含めば 0 である．

479 また  $\text{par}(c) := 0, \text{par}(d) := 1$  とおく．このとき  $m, n \geq 0$  と  $\zeta \in \{c, d, e\}$  に対して

$$a^m\zeta b^n \in L_{\pm,e} \iff m = n \text{ かつ } [\zeta = e \text{ または } (\zeta \in \{c, d\} \text{ かつ } m \equiv \text{par}(\zeta) \pmod{2})]. \quad (5)$$

480 **命題 8.4.** 言語  $L_{\pm,e}$  は線形かつ非正則であり、(4) の準同型に対して  $\sim_h$ -代入可能である．一方、  
 481 *Clark–Eyraud* 代入可能ではなく、いかなる固定  $k, \ell \geq 0$  に対しても  $(k, \ell)$ -代入可能ではない．

482 *Proof.* 線形性は上の文法から従う．また  $L_{\pm,e} \cap a^*eb^* = \{a^neb^n : n \geq 0\}$  であり、右辺は非正則で  
 483 あるから、 $L_{\pm,e}$  も非正則である．以下  $L := L_{\pm,e}$  と書く．

484  $\sim_h$ -**代入可能性**．非空語  $x, y$  が  $h(x) = h(y)$  かつ  $\mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \emptyset$  を満たすとし、共通文脈を  
 485  $(u, v)$  とする．すると  $uxv, uyv \in L$  である． $L$  の各語は中心記号をちょうど一つ含むので、 $x, y$  が  
 486 中心記号を二つ以上含むことはない．従って共通の  $h$ -値は  $1, \kappa_{cd}, \kappa_e$  のいずれかである．

487 語  $w$  に対して  $\text{bal}(w) := |w|_a - |w|_b$  とおく．まず  $h(x) = h(y) = 1$  とする． $L$  の各語は  $a^m\zeta b^m$   
 488 の形をもつので、中心を含まない非空因子  $x, y$  は  $a^+ \cup b^+$  に属する．一方  $uxv, uyv \in L$  なので  
 489  $\text{bal}(uxv) = \text{bal}(uyv) = 0$  であり、従って  $\text{bal}(x) = -\text{bal}(uv) = \text{bal}(y)$  である． $a^+ \cup b^+$  の語はそ  
 490 の balance によって一意に決まるから、 $x = y$  である．よって  $\mathcal{D}_L(x) = \mathcal{D}_L(y)$  が従う．

491 次に  $h(x) = h(y) \in \{\kappa_{cd}, \kappa_e\}$  とする．このとき  $x, y$  はそれぞれ中心記号をちょうど一つ含むの  
 492 で、ある  $i, j, i', j' \geq 0$  と  $\zeta, \zeta' \in \{c, d, e\}$  に対して  $x = a^i\zeta b^j, y = a^{i'}\zeta' b^{j'}$  と書ける．

493 中心を含む因子  $a^i\zeta b^j$  を  $L$  の語に埋め込む文脈は、必ず  $(a^m, b^n)$  の形である．(5) より、 $\zeta = e$  の  
 494 場合は  $(a^m, b^n) \in \mathcal{D}_L(a^i e b^j)$  iff  $n - m = i - j$  であり、 $\zeta \in \{c, d\}$  の場合は  $(a^m, b^n) \in \mathcal{D}_L(a^i \zeta b^j)$

iff  $n - m = i - j$  かつ  $m \equiv \text{par}(\zeta) - i \pmod{2}$  である。従って中心を含む因子の分布は、 $e$ -branch  
では  $i - j$  によって、 $c/d$ -branch では  $i - j$  と  $\text{par}(\zeta) - i \pmod{2}$  によって完全に決まる。

共通文脈  $(u, v)$  自身は中心記号を含まないので、ある  $r, s \geq 0$  に対して  $u = a^r, v = b^s$  と書ける。  
 $(a^r, b^s) \in \mathcal{D}_L(x) \cap \mathcal{D}_L(y)$  から  $i - j = s - r = i' - j'$  を得る。

共通の型が  $\kappa_e$  なら  $\zeta = \zeta' = e$  であるから、分布を決める量  $i - j$  が一致し、 $\mathcal{D}_L(x) = \mathcal{D}_L(y)$   
である。共通の型が  $\kappa_{cd}$  なら  $\zeta, \zeta' \in \{c, d\}$  であり、さらに共通文脈の membership から  $r \equiv$   
 $\text{par}(\zeta) - i \equiv \text{par}(\zeta') - i' \pmod{2}$  を得る。従ってこの場合も、分布を決める二つの量がともに一致  
し、 $\mathcal{D}_L(x) = \mathcal{D}_L(y)$  である。以上により  $L_{\pm, e}$  は  $\sim_h$ -代入可能である。

**Clark-Eyraud 代入可能でないこと。**  $c, e \in L$  なので  $c$  と  $e$  は空文脈を共有するが、 $(a, b) \in \mathcal{D}_L(e)$   
である一方、 $(a, b) \notin \mathcal{D}_L(c)$  である。従って  $L_{\pm, e}$  は Clark-Eyraud 代入可能ではない。

**$(k, \ell)$ -代入可能でないこと。**  $k, \ell \geq 0$  を任意に固定し、 $N := 2 \max\{1, k + \ell\}$  とおく。 $w_e := a^k e b^\ell$ ,  
 $w_c := a^k c b^\ell$  とする。両語は長さ  $\max\{1, k + \ell\}$  以上であり、同じ長さ  $k$  の prefix と長さ  $\ell$  の suffix  
をもつ。文脈  $(a^{N-k}, b^{N-\ell})$  は両語に共通である。実際、 $N$  は偶数なので  $a^N e b^N, a^N c b^N \in L$  であ  
る。一方、 $(a^{N+1-k}, b^{N+1-\ell}) \in \mathcal{D}_L(w_e)$  であるが、 $N+1$  は奇数なので  $(a^{N+1-k}, b^{N+1-\ell}) \notin \mathcal{D}_L(w_c)$   
である。従って 固定窓代入可能性の反例基準より  $L_{\pm, e}$  は  $(k, \ell)$ -代入可能ではない。 $k, \ell$  は任意で  
あったから  $L_{\pm, e} \notin \text{KL}$  である。 □

したがって Theorem 8.3 は、Clark-Eyraud クラスおよび KL 階層全体の外にある非正則線形言  
語にも適用される。なお、上の文法は even-linear であり、各再帰規則  $A \rightarrow uBv$  は  $|u| = |v|$  を満た  
す。従ってこの例は固定窓代入可能性からの分離を示すが、Takada のより広い control-set 枠組み  
からの分離を主張するものではない。

## 9 表現力と境界

以上の主要な学習結果は、固定された可認識合同関係を対象としていた。ここでは、この枠組みの  
位置づけに必要な構造的比較だけを記録する。要点は四つある。第一に、可認識合同関係による制御  
は、正則言語の段階ですでに、任意の固定された接頭辞 – 接尾辞窓よりも真に表現力が高い。第二  
に、Section 8 で示したように、この真の包含は、非正則な線形言語に対しても成立する。第三に、  
一般の文脈自由言語に対する定理は、その線形部分クラスだけでは尽くされない。すなわち、ある  
fixed- $h$  クラスは、固定窓階層全体の外にも位置する非線形な文脈自由言語を含む。第四に、それ  
でもなおクラス RS は、自然な決定性文脈自由言語のいくつかを含まない。

### 9.1 RS 内の非線形な標的

$\Delta := \{a^n b^n : n \geq 0\}$  とおき、その Kleene 閉包  $\Delta^*$  を考える。語  $z \in \{a, b\}^*$  に対して  
 $\beta(z) := |z|_a - |z|_b$  とし、 $\beta(z)$  を  $z$  の全接頭辞 ( $\lambda$  と  $z$  自身を含む) における  $\beta$  の最小値とする。  
また、 $z_i z_{i+1} = ba$  となる位置  $i$  を  $ba$  の出現と呼び、その高さを  $\beta(z[1..i])$  とする。

以下の特徴づけを用いる。(\*)  $w \in \Delta^*$  であることと、 $\beta(w) \geq 0$ ,  $\beta(w) = 0$ , かつ  $w$  におけるす  
べての  $ba$  の出現が高さ 0 にあることは同値である。実際、 $w = a^{n_1} b^{n_1} \dots a^{n_r} b^{n_r}$  ならば右辺は明  
らかである。逆に右辺を仮定し、 $w \neq \lambda$  とする。高さが 0 となる連続する位置で  $w$  を切断すると、  
各ブロックの内部では高さが正である。従って各ブロックの内部に  $ba$  があれば (\*) の高さ 0 条件に

反するので、そのような  $ba$  は存在しない。各ブロックはしたがって  $a^*b^*$  に属し、全体 balance が 0 なので  $a^n b^n$  の形である。  $w = \lambda$  の場合は自明である。

語  $w$  の先頭記号と末尾記号を  $\text{fst}(w), \text{lst}(w) \in \{\perp, a, b\}$  とし、  $w = \lambda$  のときはいずれも  $\perp$  とする。また  $\text{ba}(w) \in \{0, 1\}$  を、  $w$  が  $ba$  を含むかどうかを表すフラグとする。  $h_*(w) := (\text{fst}(w), \text{lst}(w), \text{ba}(w))$  とおく。

連結  $xy$  の先頭記号は  $x \neq \lambda$  なら  $\text{fst}(x)$ 、そうでなければ  $\text{fst}(y)$  であり、末尾記号についても対称的である。また  $xy$  が  $ba$  を含むのは、  $x$  が  $ba$  を含むか、  $y$  が  $ba$  を含むか、または  $\text{lst}(x) = b$  かつ  $\text{fst}(y) = a$  の場合に限る。従って  $h_*(xy)$  は  $h_*(x)$  と  $h_*(y)$  だけから決まる。ゆえに有限像  $M_* := h_*(\{a, b\}^*)$  上で  $h_*(x) \cdot h_*(y) := h_*(xy)$  と定めることができる。この積は well-defined であり、全射性と連接の結合律から結合的である。また  $h_*(\lambda)$  が単位元なので、  $M_*$  は有限モノイドであり、  $h_* : \{a, b\}^* \rightarrow M_*$  は準同型である。

非空語  $x$  と  $d \in \mathbb{Z}$  に対し、  $d + \underline{\beta}(x) \geq 0$  であり、かつ  $x$  内の各  $ba$  の高さ  $\eta$  について  $d + \eta = 0$  であるとき、  $d$  を  $x$  の許容入口高さと呼ぶ。その集合を  $\mathcal{E}(x)$  と書く。

**命題 9.1** (非線形な fixed- $h_*$  標的). 言語  $\Delta^*$  は文脈自由、非正則、かつ非線形であり、上の有限準同型に対して  $\sim_{h_*}$ -代入可能である。さらに、どの固定  $k, \ell \geq 0$  に対しても  $(k, \ell)$ -代入可能ではない。特に、  $\Delta^* \in \text{RS}_{h_*}(\{a, b\}) \cap \text{CFL}$  かつ  $\Delta^* \in \text{RS}(\{a, b\}) \setminus \text{KL}(\{a, b\})$  である。

*Proof.* 文法  $S \rightarrow TS \mid \lambda, T \rightarrow aTb \mid \lambda$  は  $\Delta^*$  を生成するので、  $\Delta^*$  は文脈自由である。また  $\Delta^* \cap a^*b^* = \Delta$  であり、  $\Delta$  は非正則なので  $\Delta^*$  も非正則である。さらに、線形言語は正則言語との共通部分について閉じている一方、  $\Delta^* \cap a^*b^*a^*b^* = \Delta\Delta$  は線形でない [14]。従って  $\Delta^*$  は非線形である。

$\sim_{h_*}$ -代入可能性. 非空語  $x, y$  が  $h_*(x) = h_*(y)$  を満たし、共通文脈  $(u, v)$  をもつとする。  $uxv, uyv \in \Delta^*$  なので全体 balance を比較すれば  $\beta(x) = \beta(y)$  である。

ここで  $(*)$  を  $sxt$  に適用すると、固定した文脈  $(s, t)$  に対する membership のうち  $x$  に依存する情報は、  $\text{fst}(x), \text{lst}(x), \beta(x)$ 、および  $\beta(s) \in \mathcal{E}(x)$  であるかどうかだけである。実際、  $x$  内部の接頭辞非負性と  $ba$  の高さ条件は  $\beta(s) \in \mathcal{E}(x)$  にちょうど含まれる。境界  $s|x$  の  $ba$  条件は  $\text{fst}(x)$  と  $\beta(s)$  で決まり、  $x|t$  の条件および  $t$  内部のすべての高さ条件は、出口高さ  $\beta(s) + \beta(x)$  と  $\text{lst}(x)$  によって決まる。従って  $\mathcal{E}(x) = \mathcal{E}(y)$  を示せば  $\mathcal{D}_{\Delta^*}(x) = \mathcal{D}_{\Delta^*}(y)$  が従う。

まず  $\text{ba}(x) = \text{ba}(y) = 1$  とする。内部に一つでも  $ba$  があれば、その高さ  $\eta$  に対して許容入口高さは  $d = -\eta$  に固定されるので、  $\mathcal{E}(x)$  と  $\mathcal{E}(y)$  はいずれも高々一元集合である。共通文脈  $(u, v)$  が存在するため  $\beta(u) \in \mathcal{E}(x) \cap \mathcal{E}(y)$  であり、従って  $\mathcal{E}(x) = \{\beta(u)\} = \mathcal{E}(y)$  である。

次に  $\text{ba}(x) = \text{ba}(y) = 0$  とする。このとき  $x, y \in a^*b^*$  である。任意の  $z \in a^*b^*$  について  $\underline{\beta}(z) = \min\{0, \beta(z)\}$  なので、  $\mathcal{E}(z) = \{d \in \mathbb{Z} : d \geq -\min\{0, \beta(z)\}\}$  である。  $\beta(x) = \beta(y)$  から  $\mathcal{E}(x) = \mathcal{E}(y)$  が従う。以上により  $\Delta^*$  は  $\sim_{h_*}$ -代入可能である。

**固定窓の排除.**  $k, \ell \geq 0$  を任意に固定し、  $N := \max\{1, k + \ell\}$  とおく。  $s := a^N b^N, t := a^N b^N a^N b^N$  とする。両語は長さ  $\max\{1, k + \ell\}$  以上で、長さ  $k$  の prefix  $a^k$  と長さ  $\ell$  の suffix  $b^\ell$  を共有し、しかも  $s, t \in \Delta^*$  なので空文脈を共有する。一方  $asb = a^{N+1}b^{N+1} \in \Delta^*$  であるが、  $atb = a^{N+1}b^N a^N b^{N+1}$  では中央の  $ba$  が高さ 1 に現れるため、  $(*)$  より  $atb \notin \Delta^*$  である。従って  $(a, b) \in \mathcal{D}_{\Delta^*}(s) \setminus \mathcal{D}_{\Delta^*}(t)$  であり、固定窓代入可能性の反例基準より  $\Delta^*$  は  $(k, \ell)$ -代入可能ではない。  $k, \ell$  は任意であったから  $\Delta^* \notin \text{KL}(\{a, b\})$  である。  $\square$

Proposition 8.4 とこの例は、異なる範囲で fixed- $h$  枠組みの広がりを示す。前者は、線形部分クラスに対する多項式特徴データ定理が、固定窓階層の外にある非正則線形言語にも適用されることを示す。これに対し  $\Delta^*$  は、一般の文脈自由 fixed- $h$  定理が、固定窓階層の外にある非線形文脈自由言語にも及ぶことを示す。特に  $\Delta^*$  は線形でないため even-linear でもない。ただし、ここから control-set 法一般とのクラス分離を主張するものではない。

## 9.2 固定窓階層からの正則分離

カウンタ alphabet を  $\Sigma_c := \{\uparrow, \downarrow, \#\}$  とする。この小節では  $RS := RS(\Sigma_c)$ ,  $KL := KL(\Sigma_c)$  と略記する。  $w = \delta_1 \cdots \delta_n \in \Sigma_c^*$  に対し,  $ht_0(w) := 0$  とし, 左から一文字読むごとに  $\uparrow$  なら高さを 1 増やし,  $\downarrow$  なら 1 減らし,  $\#$  なら 0 にリセットすることで  $ht_i(w)$  を定める。  $\rho \geq 1$  に対して  $CTR_\rho := \{w \in \Sigma_c^* : 0 \leq ht_i(w) \leq \rho \text{ for all } 0 \leq i \leq |w|\}$  とおく。

**命題 9.2.** 任意の  $\rho \geq 1$  に対して  $CTR_\rho$  は正則であり, 従って  $RS$  に属する。

*Proof.* 状態  $0, 1, \dots, \rho$  で現在の高さを記録し, 範囲外に出た後の sink 状態を一つ加えればよい。  $\#$  はすべての非 sink 状態を 0 に戻す。従って  $CTR_\rho$  は正則であり, Proposition 3.1 より  $RS$  に属する。  $\square$

**定理 9.3.** 任意の  $\rho \geq 2$  に対して,  $CTR_\rho$  はどの  $k, \ell \geq 0$  に対しても  $(k, \ell)$ -代入可能ではない。

*Proof.*  $k, \ell \geq 0$  を固定し,  $s := (\uparrow\downarrow)^k \uparrow^{\rho-1} \#^\ell$ ,  $t := (\uparrow\downarrow)^k \uparrow^\rho \#^\ell$  とおく。  $\rho \geq 2$  より  $|s|, |t| \geq \max\{1, k + \ell\}$  であり, 両語は同じ長さ  $k$  の prefix と同じ長さ  $\ell$  の suffix  $\#^\ell$  をもつ。

$s, t$  はともに  $CTR_\rho$  に属するので, 空文脈を共有する。さらに  $\uparrow s$  では, 最初の  $\uparrow$  の後,  $(\uparrow\downarrow)^k$  を高さ 1 から走るため高さは 1 と 2 の間を往復し, その後の  $\uparrow^{\rho-1}$  によってちょうど高さ  $\rho$  に達する。従って  $\rho \geq 2$  より  $\uparrow s \in CTR_\rho$  である。一方  $\uparrow t$  は最初の reset より前に高さ  $\rho + 1$  に達するので  $\uparrow t \notin CTR_\rho$  である。従って  $(\uparrow, \lambda) \in \mathcal{D}_{CTR_\rho}(s) \setminus \mathcal{D}_{CTR_\rho}(t)$  であり, 固定窓代入可能性の反例基準より結論が従う。  $\square$

**系 9.4** (正則言語による分離).  $KL \subsetneq RS$  であり, この真の包含は正則言語の範囲ですでに生じる。

*Proof.* 各固定  $(k, \ell)$  クラスは Proposition 3.3 により  $RS$  に含まれる。一方, 任意の  $\rho \geq 2$  について Proposition 9.2 と Theorem 9.3 から  $CTR_\rho \in RS \setminus KL$  である。  $\square$

## 9.3 $RS$ の外にある自然な決定性文脈自由言語

次の単純な障害は, 以下のカウンタ言語と Dyck 言語が, あらゆる有限モノイド準同型が誘導するクラスの外に落ちる共通理由を切り出すものである。

**補題 9.5** (有限モノイド障害).  $L \subseteq \Sigma^*$  とする。無限集合  $\Xi \subseteq \Sigma^+$  が存在し, 互いに異なるすべての  $x, y \in \Xi$  に対して  $\mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \emptyset$  かつ  $\mathcal{D}_L(x) \neq \mathcal{D}_L(y)$  が成り立つとする。このとき  $L \notin RS(\Sigma)$  である。

*Proof.*  $h : \Sigma^* \rightarrow M$  を有限モノイドへの任意の準同型とする。  $\Xi$  は無限で  $M$  は有限だから, 互い

異なる  $x, y \in \Xi$  で  $h(x) = h(y)$  を満たすものが存在する. その分布は交わるが等しくないので,  $\sim_h$ -代入可能性に反する. 従って任意の有限  $h$  に対して  $L \notin \text{RS}_h(\Sigma)$  である.  $\square$

上限 cap を取り除くと,

$$\text{CTR} := \{w \in \Sigma_c^* : \text{ht}_i(w) \geq 0 \text{ がすべての } 0 \leq i \leq |w| \text{ について成り立つ}\}$$

を得る. これは決定性文脈自由言語である. 決定性プッシュダウンオートマトンは,  $\uparrow$  でスタック記号を一つ push し,  $\downarrow$  で一つ pop し (underflow なら reject),  $\#$  では入力走査を再開する前に bottom marker まで pop する決定的な clearing 状態へ移ればよい.

**系 9.6** (上限なしカウンタの障害).  $\text{CTR} \notin \text{RS}(\Sigma_c)$  である.

*Proof.* Lemma 9.5 を  $\Xi = \{\uparrow^i : i \geq 1\}$  に適用する.  $i < j$  なら,  $(\lambda, \downarrow^i)$  は  $\uparrow^i$  と  $\uparrow^j$  の双方の文脈である一方,  $(\lambda, \downarrow^j)$  は  $\uparrow^j$  の文脈だが  $\uparrow^i$  の文脈ではない.  $\square$

同じ障害は一種類括弧の Dyck 言語

$$D_1 := \{w \in \{a, b\}^* : |w'|_a \geq |w'|_b \text{ が } w \text{ のすべての接頭辞 } w' \text{ について成り立つ, } |w|_a = |w|_b\}$$

にも現れる. ここで  $|t|_a$  と  $|t|_b$  は語  $t$  に現れる  $a, b$  の個数を表す. これは標準的な決定性文脈自由言語である [15].

**系 9.7.**  $D_1 \notin \text{RS}(\{a, b\})$  である.

*Proof.* Lemma 9.5 を  $\Xi = \{b^i a^i : i \geq 1\}$  に適用する.  $i < j$  のとき, 文脈  $(a^j, b^j)$  は  $b^i a^i$  と  $b^j a^j$  に共通する一方,  $(a^i, b^i)$  は  $b^i a^i$  の文脈だが  $b^j a^j$  の文脈ではない. 実際, 接頭辞  $a^i b^j$  が underflow する.  $\square$

この障害は, プッシュダウンの観点から有用な解釈をもつ. 興味深い点は, 無限に大きくなりうるスタック挙動それ自体が RS と両立しないわけではない.  $L_{\pm, e}$  はすでに  $\text{RS}(\{a, b, c, d, e\})$  に属する非正則 one-turn 言語である. CTR と  $D_1$  で失敗するのは, より具体的な性質である. すなわち, 無限個の因子族が, 共通文脈によって互いに比較可能なまま, 二つずつ異なる文脈的挙動を担うため, 有限な  $h$  ではすべての互換でない因子を分離できない. ここではこれを障害としてのみ用い,  $\text{RS} \cap \text{CFL}$  の完全なプッシュダウン特徴づけとしては主張しない.

最後の例のために, 初等的な閉包性を一つ用いる.

**補題 9.8** (固定語による商).  $L$  が  $\sim_h$ -代入可能で  $z \in \Sigma^*$  なら, 右商  $L/z := \{w : wz \in L\}$  も  $\sim_h$ -代入可能である.

*Proof.* 同じ  $h$ -型をもつ空でない  $x, y$  が  $L/z$  において共通文脈  $(u, v)$  をもつなら,  $(u, vz)$  は  $L$  における共通文脈であるから  $\mathcal{D}_L(x) = \mathcal{D}_L(y)$  である. 任意の  $(s, t)$  に対して,

$$(s, t) \in \mathcal{D}_{L/z}(x) \iff (s, tz) \in \mathcal{D}_L(x) \iff (s, tz) \in \mathcal{D}_L(y) \iff (s, t) \in \mathcal{D}_{L/z}(y).$$

$\square$

$S \rightarrow aSS \mid b$  が生成する言語は通常 *Lukasiewicz 言語* と呼ばれる. 本論文での  $D_1$  の符号化では  $L_{\text{Luk}} = D_1 b$  を満たす [14]. これは標準的な決定性文脈自由言語でもある [15]. もし  $L_{\text{Luk}} \in \text{RS}(\{a, b\})$  なら, Lemma 9.8 により  $D_1 = L_{\text{Luk}}/b \in \text{RS}(\{a, b\})$  となり, Corollary 9.7 に反する.

## 9.4 Clark の congruential family との比較

Clark [16] の規約では, CFG の開始側に単一の開始記号ではなく有限初期集合を許す. 有限初期集合  $I \subseteq V$  に対して  $L_G[I] := \bigcup_{A \in I} L_G(A)$  と書く. 初期集合  $I$  をもつ CFG  $G$  が *congruential* であるとは, 各非終端記号  $A$  について  $L_G(A)$  が  $L_G[I]$  の単一の構文合同類に含まれることをいう.  $L_G(A) = \emptyset$  の場合はこの条件を自明に満たす. 有限 alphabet  $\Gamma$  に対し, congruential CFG によって生成される  $\Gamma$  上の言語全体を  $\text{CONG}(\Gamma)$  と書く.

**命題 9.9** (Clark の congruential family との比較). 任意の有限 alphabet  $\Gamma$  と有限モノイド準同型  $h : \Gamma^* \rightarrow M$  に対して  $\mathcal{C}_h^{\text{cf}} \subseteq \text{CONG}(\Gamma)$  である. 従って  $\text{RS}(\Gamma) \cap \text{CFL} \subseteq \text{CONG}(\Gamma)$  であり,  $\Gamma = \{a, b\}$  ではこの包含は真である.

*Proof.*  $L \in \mathcal{C}_h^{\text{cf}}$  とする.  $L = \emptyset$  なら, 生成規則をもたない一つの非終端記号を初期集合とすればよい. 以下  $L \neq \emptyset$  とする.

$L$  の縮約済み SSBNF 文法を取り, Section 5 の型付き精密化  $\tilde{G} = (\tilde{V}, \Gamma, \tilde{P}, \tilde{S})$  を施す. 非開始型付き非終端記号  $X = A_\mu$  を任意に固定する.  $\tilde{G}$  は縮約済みなので,  $X$  にはある終端到達文脈  $(u, v)$  が存在する. 従ってすべての  $w \in L_{\tilde{G}}(X)$  について  $uwv \in L$  である. 一方 Proposition 5.2 より  $h(w) = \mu$  であり, SSBNF には非開始  $\lambda$ -生成規則がないため  $w \neq \lambda$  である.

そこで  $x, y \in L_{\tilde{G}}(X)$  を任意にとると,  $x, y$  は同じ  $h$ -値をもち, かつ共通文脈  $(u, v)$  をもつ非空語である.  $L$  の  $\sim_h$ -代入可能性から  $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ , すなわち  $x \equiv_L y$  が従う. 従って, 各非開始型付き非終端記号  $X$  について  $L_{\tilde{G}}(X)$  は単一の  $\equiv_L$ -同値類に含まれる.

次に  $\tilde{S}$  とその生成規則を除き,  $I := \{X : \tilde{S} \rightarrow X \in \tilde{P}\}$  を初期集合とする.  $\lambda \in L$  なら, 新しい非終端記号  $X_\lambda$  と規則  $X_\lambda \rightarrow \lambda$  を加え,  $X_\lambda$  も  $I$  に含める.  $\tilde{S}$  はいかなる右辺にも現れないので, 各非開始記号  $X$  の生成語言語はこの操作で変わらない. また Proposition 5.2 より  $L(\tilde{G}) = L$  であるから, 得られた文法  $G'$  は  $L_{G'}[I] = L$  を満たす. 各旧非開始記号の生成語言語は上で示したように一つの  $\equiv_L$ -同値類に含まれ,  $L_{G'}(X_\lambda) = \{\lambda\} \subseteq [\lambda]_{\equiv_L}$  でもある. 従って  $G'$  は congruential であり,  $L \in \text{CONG}(\Gamma)$  である. これにより  $\mathcal{C}_h^{\text{cf}} \subseteq \text{CONG}(\Gamma)$ , 従って  $\text{RS}(\Gamma) \cap \text{CFL} \subseteq \text{CONG}(\Gamma)$  が従う.

包含が真であることを示すため,  $\Gamma = \{a, b\}$  上の一種類括弧 Dyck 言語  $D_1$  を考える. 任意の  $x \in D_1$  と  $u, v \in \{a, b\}^*$  に対して  $uxv \in D_1$  iff  $uv \in D_1$  である. 実際,  $x$  は全体 balance が 0 で, 各接頭辞の相対 balance が非負である. 従って  $x$  を  $u$  と  $v$  の間に挿入しても, 挿入後の高さは変化せず,  $x$  の内部でも挿入位置の高さを下回らない. 逆に  $x$  を削除しても同じ高さ条件は保存される. ゆえに  $x \equiv_{D_1} \lambda$  である.

従って文法  $S \rightarrow aSbS \mid \lambda$  は  $L_G(S) = D_1 \subseteq [\lambda]_{\equiv_{D_1}}$  を満たす congruential grammar であり,  $D_1 \in \text{CONG}(\{a, b\})$  である. 一方 Corollary 9.7 より  $D_1 \notin \text{RS}(\{a, b\})$  である. 従って  $\text{RS}(\{a, b\}) \cap \text{CFL} \subsetneq \text{CONG}(\{a, b\})$  である.  $\square$

## 10 結論

固定有限モノイド合同関係の下で, 有限証拠による厳密再構成と保守的学習器による Gold 同定を確立し, 各更新が多項式時間で行えることを示した. 任意の固定された接頭辞 – 接尾辞窓について,

本再構成は縮約済み CFG のサイズと厚みに関して多項式の特徴データ尺度を回収する．任意の固定  $h$  の線形標的については，標準生成語と標準文脈への直接上界から，線形文法サイズに関して多項式の特徴データが得られる．

構造的には，可認識合同関係による代入可能性は，正則・非正則線形・非線形な文脈自由言語の各水準で固定窓階層を真に拡張する一方，一種類括弧の Dyck 言語  $D_1$  のような自然な決定性文脈自由言語をなお除外する．さらに，任意の有限アルファベット  $\Gamma$  に対して  $RS(\Gamma) \cap CFL \subseteq CONG(\Gamma)$  が成り立ち， $\Gamma = \{a, b\}$  ではこの包含は真である． $RS \cap CFL$  の完全な特徴づけ，有用な有限型付けの条件，unknown- $h$  設定，およびより豊かな文法形式への拡張は未解決である．また，任意の固定  $h$  と一般 CFG 表現に対して，文法サイズと上で用いた厚みパラメータ  $\tau_G$  の多項式で特徴データを抑えられるかどうか未解決である．

## データ利用可能性

本論文で記述した研究ではデータを使用していない．本論文に付随する Lean 4 による形式化は，Zenodo に DOI 10.5281/zenodo.22939434 として公開・保存されている．

## 利益相反の申告

著者は，本論文で報告した研究に影響を与えたと考えられる既知の競合する金銭的利益関係または個人的関係がないことを申告する．

## 研究費

本研究は，公的機関，民間企業，または非営利部門のいずれの資金配分機関からも特定の助成を受けていない．

## 謝辞

著者は，本研究に対する長年にわたる指導，励まし，有益な助言，ならびに関連文献の入手に際して助力いただいた金澤誠教授（法政大学）に感謝する．また，本研究に関連する重要な文献をご提供いただき，さらに励ましをいただいた吉仲亮教授に感謝する．著者はさらに，きわめて丁寧で洞察に富み，建設的な査読を行ってくださった 2 名の匿名査読者に深く感謝する．両査読者の指摘は，投稿稿に残っていた重要な弱点を明らかにし，本論文の正確性，定式化，射程，提示の仕方を大幅に改善する契機となった．とりわけ，問題点を精密に説明するとともに，研究をより強固にするための具体的な改善方向を示していただいたことに，心より感謝する．なお，本論文に残る誤りはすべて著者自身の責任である．

## 付録 A 固定窓証拠語上界と厚み保存正規化

696

### A.1 Lemmas 7.1 と 7.2 の証明

697

*Lemma 7.1* の証明.  $r = 0$  のとき,  $h_{0,0}$  は  $\Sigma^+$  上で定数なので, 生産的な型付き非終端記号  $A_\mu$  は基礎となる非終端記号  $A$  と同じ非空生成語をもち,  $|\omega(A_\mu)| \leq \tau_G$  である.

698

699

$r > 0$  とし,  $A_\mu$  が生産的であるとする.  $\mu$  が  $M_{k,\ell}$  の短語要素なら, 型  $\mu$  の語はその短語自身なので, その長さは  $r$  未満である. 残る長語要約要素  $\mu = \langle p, q \rangle$  について, この型をもつ  $A$  の導出木を一つ選び, 最初の  $k$  個と最後の  $\ell$  個の終端葉を印付けする. 根から印付け葉への経路の和を  $T_0$  とする.

700

701

702

703

$T_0$  上でちょうど一つの子だけが  $T_0$  に残る非終端ノードの極大鎖を考える. 同じ基礎非終端記号が一つの鎖に二度現れたら, 上側の出現を下側の部分木で置き換える. これは同じ非終端記号からの正しい導出であり, 印付け葉を含まない sibling 部分木しか削除しないので, 印付けられた境界終端記号とその順序は保存される. これを繰り返すと, 各極大一子鎖には高々  $N$  個の非終端記号しか残らない.

704

705

706

707

708

各極大一子鎖を縮約すると,  $r$  個の印付け葉を結ぶ分岐骨格が得られ, その頂点数は高々  $2r - 1$  である. したがって, 最初の分岐頂点より上にあり得る初期鎖も含め, 極大一子鎖は高々  $2r - 1$  本である.  $T_0$  の外側に省略された sibling 部分木が生じるのはこれらの鎖上のノードだけであり, 分岐ノードでは両方の子が  $T_0$  に含まれる. 従って省略 sibling 部分木は高々  $(2r - 1)N$  個である.

709

710

711

712

それぞれをその根の最短終端生成語で置き換えると, 一つにつき高々  $\tau_G$  個の終端記号を寄与する. 得られる語  $w'$  は依然として  $A$  から導出され, 接頭辞  $p$  と接尾辞  $q$  を保つので, 同じ  $h_{k,\ell}$ -型  $\mu$  をもち,

713

714

715

$$|w'| \leq r + (2r - 1)N\tau_G.$$

Proposition 5.2 と同じ生成語型注釈により, この導出は  $A_\mu \Rightarrow_{\tilde{G}}^* w'$  に持ち上がる.  $A_\mu$  は到達可能であり, この導出木は成功しているので, 木上のすべての型付き記号は trim 後も残る. したがって  $w'$  は  $A_\mu$  の型付き生成語であり, shortlex 最小の型付き生成語  $\omega(A_\mu)$  も同じ長さ上界を満たす. □

716

717

718

719

*Lemma 7.2* の証明.  $\tilde{G}$  は縮約済みなので  $X$  は到達可能である. 非開始型付き記号を頂点とし, 二項生成規則  $Y \rightarrow ZZ'$  ごとに辺  $Y \rightarrow Z$  と  $Y \rightarrow Z'$  を張る有向子依存グラフを考える.  $X$  は到達可能なので,  $X$  がある非開始記号  $A$  から到達可能となる開始規則  $\tilde{S} \rightarrow A$  を選び, この依存グラフ上で  $A$  から  $X$  への最短経路を選ぶ. 最短経路は型付き記号を繰り返さないので二項ステップは高々  $N_t - 1$  個である. 各ステップで経路外の sibling を標準生成語へ展開すれば, Lemma 7.1 により総長高々  $N_t B_{k,\ell}(G)$  の終端到達文脈が得られる. 標準文脈  $\chi(X)$  はこれより長くない. アンカーは標準生成語を一つ, 終端規則証拠は終端記号を一つ, 二項規則証拠は標準生成語を二つ加えるので, 表示した共通上界が従う. □

720

721

722

723

724

725

726

727

## A.2 厚みを多項式的に保存する SSBNF 正規化

*Proposition 7.4* の証明.  $R = (V, \Sigma, P, S)$  を縮約済みで非空言語を生成する文法とし,  $n := |R|$ ,  $\bar{\tau} := \tau_R + 1$  とおく. 文法サイズと最短終端生成語をともに多項式に保つ順序で標準正規化を行う.

まず新しい開始記号  $S_0$  と規則  $S_0 \rightarrow S$  を導入し,  $\lambda \in L(R)$  なら最終的に  $S_0 \rightarrow \lambda$  を残す. 長さ 2 以上の右辺に現れるすべての終端記号を新しい wrapper  $W_a \rightarrow a$  で分離し, 長さ 2 を越える右辺を二分化する. 得られる文法を  $G_{\text{bin}}$  とする. これらの操作によるサイズ増加は多項式であり, 元の非終端記号の終端生成語言語は保たれる. 新たな二分化記号は元の右辺の連続部分を展開するだけなので, 各生産的非終端記号をその最短生成語で置き換えれば, ある定数  $c_1$  に対して

$$\tau_{G_{\text{bin}}} \leq c_1 n \bar{\tau}$$

が得られる.

次に,  $G_{\text{bin}}$  の nullable 記号から得られる最短の **非空** 生成語を抑える.  $A \Rightarrow_{G_{\text{bin}}}^* w$  を非空終端語への導出とし, 導出木の終端葉を一つ選んで根からの経路をたどる. 同じ非終端記号が二度現れれば, 上側の部分木を下側の部分木で置き換えて cycle を削除できる. これを繰り返すと経路上の非終端記号数は高々  $|V_{G_{\text{bin}}}|$  となる. 各二項ノードで経路外の sibling をその最短終端生成語へ置き換えると, nullable sibling は空語を寄与してよく, 選んだ終端葉が一文字を寄与するので, ある定数  $c_2$  に対して

$$\min\{|w| > 0 : A \Rightarrow_{G_{\text{bin}}}^* w\} \leq 1 + |V_{G_{\text{bin}}}| \tau_{G_{\text{bin}}} \leq c_2 n^2 \bar{\tau}$$

である.

ここで非開始  $\lambda$ -規則をすべて除去する.  $G_{\text{bin}}$  は二分文法なので, 規則  $A \rightarrow BC$  から生じるのは, nullable な子に応じて高々  $A \rightarrow BC, A \rightarrow B, A \rightarrow C$  であり, 指数的な nullable-subset 展開は起こらない. 通常の構成は各非終端記号の非空終端生成語言語を保存するので, 上の長さ上界も保たれる. 続いて unit closure を計算して非開始 unit 規則を除去し, 最後に無用記号を trim する. unit 消去は非終端記号言語を保存するため thickness 上界を増加させない.

得られる文法は縮約済みで開始記号が分離され, 各非開始規則は終端規則または二項規則であり,  $S_0 \rightarrow \lambda$  が唯一の可能な  $\lambda$ -規則である. 従って SSBNF である. そのサイズは  $n$  の多項式, 厚みは高々  $c_2 n^2 (\tau_R + 1)$  であり, すべての変換は多項式時間で実行できる.  $\square$

## 付録 B linear-spine SSBNF 正規化の証明

*Proposition 8.1* の構成は, 標準的な開始記号分離, 不要記号・nullable 規則・unit 規則の除去, および二分化を組み合わせて, Section 8 で必要な単一 spine 形を保存する.

*Proposition 8.1* の証明.  $L(G) = \{\lambda\}$  なら, 単一規則  $S_0 \rightarrow \lambda$  をもつ reduced grammar を取ればよい. 二項生成規則をもたないので, 要求される条件は自明に成り立つ. 従って以下では,  $L(G)$  が空でない語を含むと仮定する.

$S$  を元の開始記号とする. 右辺に決して現れない新しい  $S_0$  を導入し,  $S_0 \rightarrow S$  を加え, さらに  $\lambda \in L(G)$  なら  $S_0 \rightarrow \lambda$  も加える. 以後  $S$  は非開始記号として扱う. 不要記号を除去し,  $\lambda$  を  $S_0$  のみ保存しつつ非開始  $\lambda$ -規則を除去し, その後で非開始 unit 規則を除去する. 開始規則には unit

消去を適用しないので、最終 trimming 後に残る各開始規則は、要求どおり  $S_0 \rightarrow A$  または  $S_0 \rightarrow \lambda$  の形になる。この順序により、 $\lambda$ -消去によって新たに生じた unit 規則も除去される。入力文法は線形なので、各右辺には nullable な非終端記号が高々一つしか現れず、各生成規則から追加される代替右辺は高々一つである。ここで線形性は二箇所で行われる。第一に、nullable 規則の展開を多項式に抑える。第二に、消去後も、残る各非 unit 右辺には非終端記号が高々一つしか現れないことを保証し、これが以下の「wrapper でない子を一つだけ持つ」分解を可能にする。unit closure と wrapper-chain による二分化そのものは、一般 CFG に対しても多項式時間の操作である。unit 消去では有限な unit-reachability closure を計算する。すなわち、出発非終端記号と、到達可能な非 unit 生成規則の各組は、高々一つの複製規則を生じる。従って生成規則数も右辺長の総和も多項式に保たれる。

残るのは、新たな unit 規則を作らずに二分化することである。以下の二項生成規則の子として現れる各終端記号  $a$  に対して、新しい wrapper  $W_a \rightarrow a$  を一つ導入する。同様に、すべての  $a \in \Sigma$  に対してそのような wrapper を導入してもよい。規則  $A \rightarrow uBv$  に対して、 $u = a_1 \cdots a_m$ ,  $v = b_1 \cdots b_n$  と書く。非開始 unit 規則はすでに消去されているので、 $m = n = 0$  の場合（これは unit 規則  $A \rightarrow B$  になる）は起こらない。従って  $m + n > 0$  である。以下、場合分けを明示する。 $m = 0$  ならば必ず  $n > 0$  である。 $n = 1$  なら  $A \rightarrow BW_{b_1}$  を用いる。 $n \geq 2$  なら、新しい  $R_1, \dots, R_{n-1}$  を導入し、

$$R_1 \rightarrow BW_{b_1}, \quad R_j \rightarrow R_{j-1}W_{b_j} \quad (2 \leq j \leq n-1), \quad A \rightarrow R_{n-1}W_{b_n}$$

とする。次に  $m > 0$  とする。 $n = 0$  なら  $U := B$  と定める。ここで  $B$  は wrapper 導入前の文法の非終端記号なので、この二分化で導入した新しい terminal wrapper の一つではない。 $n > 0$  なら新しい  $R_1, \dots, R_n$  を導入して

$$R_1 \rightarrow BW_{b_1}, \quad R_j \rightarrow R_{j-1}W_{b_j} \quad (2 \leq j \leq n)$$

とし、 $U := R_n$  とおく。 $m = 1$  なら単一の二項規則  $A \rightarrow W_{a_1}U$  を用いる。 $m \geq 2$  なら、新しい  $J_1, \dots, J_{m-1}$  を導入して

$$A \rightarrow W_{a_1}J_1, \quad J_i \rightarrow W_{a_{i+1}}J_{i+1} \quad (1 \leq i \leq m-2), \quad J_{m-1} \rightarrow W_{a_m}U$$

とする。したがって、 $m + n > 0$  の下で、 $m = 0$  または  $m \geq 1$ ,  $n = 0$  または  $n \geq 1$  のすべての場合が覆われる。また最も内側の二項規則は、新しい unit 規則ではなく  $B$  自身を含む。

終端記号のみからなる規則  $A \rightarrow a_1 \cdots a_m$  について、 $m = 1$  なら  $A \rightarrow a_1$  をそのまま残す。 $m \geq 2$  なら、新しい  $\Theta_2, \dots, \Theta_m$  を導入し、

$$A \rightarrow W_{a_1}\Theta_2, \quad \Theta_i \rightarrow W_{a_i}\Theta_{i+1} \quad (2 \leq i \leq m-1), \quad \Theta_m \rightarrow a_m$$

とする。（ $m = 2$  のとき、中間の規則族は空である。）従って新たに得られる非開始規則は、終端規則か、あるいはちょうど一つの wrapper child と一つの別の非終端 child をもつ二項規則のいずれかである。構成上、wrapper  $W_a$  は二項規則の wrapper-child 位置にのみ現れ、継続する非終端 child としては決して現れない。一方、終端記号のみの構成は、終端規則をもつ新しい非 wrapper chain 記号で終わる。最終 trimming は、この性質、分離開始形、および reducedness を保存する。wrapper と chain による分解は、すでに多項式に抑えられた右辺長総和に対して線形であるため、全構成のサイズは多項式であり、多項式時間で実行できる。□

## 付録 C 短い標準証拠補題の証明

Lemma 8.2 で用いた cycle-deletion 議論を与える.

*Lemma 8.2 の証明.* Proposition 8.1 の linear-spine SSBNF 形における導出は、一意な spine をもつ. 各 spine step は  $A \rightarrow W_a B$  または  $A \rightarrow B W_a$  の形で、 $W_a \Rightarrow a$  であるから、次の spine 記号の外側にちょうど一つの終端記号を放出する. 従って任意の reaching spine に沿って、完了済み wrapper sibling が寄与する終端記号数は、通過した spine step 数とちょうど等しい (最初の規則  $\tilde{S} \rightarrow A_\mu$  は終端記号を寄与しない).

最短生成語について、まず  $X$  が terminal-wrapper 記号だとする. このとき  $X$  は productive rule  $X \rightarrow a$  をもつので、 $|\omega(X)| = 1 \leq n_t$  である. 次に  $X$  が spine 記号だとする.  $X$  からの終端導出のうち生成語長が最小のものを取り、その spine を  $X = X_0, X_1, \dots, X_t$  と書く. ここで  $X_t$  が終端規則を用いる. shortlex order はまず長さを最小化するので、この導出の生成語長は  $\omega(X)$  と同じである. spine step はちょうど  $t$  個で、従って wrapper sibling もちょうど  $t$  個あり、最後の終端規則がさらに一つの終端記号を寄与する. 従って  $|\omega(X)| = t + 1$  である. もしある  $i < j$  で  $X_i = X_j$  なら、二回目の出現  $X_j$  から始まる suffix derivation を、一回目の出現  $X_i$  からそのまま開始できる. この二つの間の区間を削除すると、 $X$  からの別の有効な導出が得られ、しかも  $j - i \geq 1$  個の spine step と、それらが放出する wrapper terminal をちょうど削除するので、最小性に反する. 従って  $t + 1$  個の型付き spine 記号は二つずつ異なる. これらは非開始記号なので  $t + 1 \leq n_t$  であり、従って  $|\omega(X)| = t + 1 \leq n_t$  である.

標準文脈については、前段の用語により場合分けを尽くせる. 各 spine step が完了済み wrapper sibling からちょうど一つの終端記号を寄与し、最初の規則  $\tilde{S} \rightarrow A_\mu$  は終端記号を寄与しないことを思い出そう. まず distinguished symbol  $X$  が spine 記号であるとする. その終端文脈が標準文脈  $\chi(X) = (u_X, v_X)$  となる reaching derivation を選ぶ.  $X$  に到達する前に型付き spine 記号が重複して現れたとすると、その二つの出現に挟まれた空でない区間を削除しても後の  $X$  の出現は保たれる一方、少なくとも一つの放出終端記号が除かれる. すると、 $\chi(X)$  の定義上の最小性に反して、より短い終端文脈が得られる. 従って reaching spine は repetition-free である.  $X$  を含めて  $r + 1$  個の型付き spine 記号を訪れるなら、spine step は  $r$  個である.  $r + 1 \leq n_t$  なので  $r \leq n_t - 1$  である. unique-spine 性質により、reaching context に寄与する別の非終端 branch はなく、 $r$  個の wrapper sibling がそれぞれちょうど一つの終端記号を寄与する. ゆえに  $|u_X| + |v_X| = r \leq n_t - 1$  である.

一方  $X$  が新しい terminal wrapper, たとえば  $W_a$  の型付きコピーであるとする.  $\tilde{G}_0$  は reduced なので  $X$  は reachable である. wrapper は wrapper child としてのみ現れるから、ある reachable binary production が  $X$  をその位置にもつ. その生成規則まで到達する spine のうち長さ最小のものを選ぶ. この reaching spine も repetition-free である. 型付き spine 記号の重複出現の間を削除すれば、同じ後方の生成規則に、より少ない spine step で到達できるからである. その生成規則の parent を含めて  $r + 1$  個の型付き spine 記号を訪れるなら、 $r + 1 \leq n_t$ , 従って  $r \leq n_t - 1$  である. それ以前の  $r$  個の spine step は、文脈にちょうど  $r$  個の終端記号を寄与する. 最後の二項規則における spine child は、証明前半より長さ高々  $n_t$  の最短生成語で完了できる. これにより、 $X$  への終端 reaching context で、全長が  $(n_t - 1) + n_t < 2n_t$  のものが構成される. 標準文脈  $\chi(X)$  は、この構成した文脈より長くない. 従ってすべての場合に  $|u_X| + |v_X| \leq 2n_t$  である. 最後に、式 (2) の各

rule witness は, このような文脈を一つと, 高々二つの最短生成語を含むので, その長さは  $O(n_t)$  で  
ある. □

## 参考文献

- [1] M. Kanazawa. *Learnable Classes of Categorical Grammars*. CSLI Publications, Stanford, CA, 1998.
- [2] E. M. Gold. Language identification in the limit. *Information and Control*, 10(5):447–474, 1967.
- [3] S. Eilenberg. *Automata, Languages, and Machines*, volume A. Academic Press, 1974.
- [4] C. de la Higuera. Characteristic sets for polynomial grammatical inference. *Machine Learning*, 27:125–138, 1997.
- [5] C. de la Higuera. *Grammatical Inference: Learning Automata and Grammars*. Cambridge University Press, 2010.
- [6] A. Clark and R. Eyraud. Polynomial identification in the limit of substitutable context-free languages. *Journal of Machine Learning Research*, 8:1725–1745, 2007.
- [7] R. Yoshinaka. Identification in the limit of  $k, l$ -substitutable context-free languages. In *Grammatical Inference: Algorithms and Applications – ICGI 2008*, LNCS 5278, pp. 266–279, Springer, 2008. doi:10.1007/978-3-540-88009-7\_21.
- [8] Y. Takada. Grammatical inference for even linear languages based on control sets. *Information Processing Letters*, 28(4):193–199, 1988. doi:10.1016/0020-0190(88)90208-6.
- [9] Y. Takada. Learning formal languages based on control sets. In K. P. Jantke and S. Lange (Eds.), *Algorithmic Learning for Knowledge-Based Systems*, LNCS 961, pp. 316–339, Springer, 1995.
- [10] T. Koshiba, E. Mäkinen, and Y. Takada. Learning deterministic even linear languages from positive examples. *Theoretical Computer Science*, 185(1):63–79, 1997. doi:10.1016/S0304-3975(97)00016-9.
- [11] S. Ginsburg and E. H. Spanier. Finite-turn pushdown automata. *SIAM Journal on Control*, 4(3):429–453, 1966. doi:10.1137/0304034.
- [12] F. Coste, D. Fredouille, C. Kermorvant, and C. de la Higuera. Introducing domain and typing bias in automata inference. In *ICGI 2004*, LNCS 3264, pp. 115–126, Springer, 2004.
- [13] A. Clark. Learning trees from strings: A strong learning algorithm for some context-free grammars. *Journal of Machine Learning Research*, 14:3537–3559, 2013.
- [14] J.-M. Autebert, J. Berstel, and L. Boasson. Context-free languages and pushdown automata. In G. Rozenberg and A. Salomaa (Eds.), *Handbook of Formal Languages*, Vol. 1, pp. 111–174, Springer, 1997.
- [15] S. Ginsburg and S. A. Greibach. Deterministic context-free languages. *Information and Control*, 9:620–648, 1966.
- [16] A. Clark. Distributional learning of some context-free languages with a minimally adequate teacher. In *Proceedings of ICGI 2010*, LNCS 6339, pp. 24–37, Springer, 2010. doi:10.1007/978-3-642-15488-1\_4.