固定有限モノイド型付けの下での文脈自由言語の分布学習

Takayuki Kuriyama
独立研究者
growup.kuriyama@gmail.com

概要

本論文では，有限モノイドへの準同型 $h : \Sigma^* \to M$ の核 $\sim_h$ の下で文脈自由言語の分布学習を研究する．同じ h-値をもち，一つの文脈を共有する非空因子は，すべての文脈を共有することを要求する．この h に対し，集合駆動型再構成作用素 $\mathcal{B}_h$ は文脈自由 $\sim_h$-代入可能標的を有限個の正例証拠から厳密に再構成し，別の保守的逐次学習器はすべての非空標的を Gold の意味で極限同定する．再構成と各更新は多項式時間である．標準証拠の大きさは，標的非終端記号を有限な h-値で分割した後に得られる最短生成語によって制御され，その長さは通常の文法厚みより指数的に大きくなり得る．従って一般の h では，特徴データ上界は通常の文法厚みだけでなく，この型付き厚みによって自然に記述される．局所自明有限半群についての古典的特徴づけから，h の非空因子上の型が固定接頭辞 – 接尾辞窓で決定されることと，正の像半群 $h(\Sigma^+)$ が局所自明であることが同値である．この場合，さらに正の像半群が局所自明有限半群と有限群の直積の部分半群の準同型像である場合も，通常の文法厚みで十分である．局所自明な fixed-h 体制の言語クラスの和は Yoshinaka の固定窓階層とちょうど一致する．任意の固定 h の線形標的では，線形 CFG サイズに関して多項式の特徴データを得る．さらに，Yoshinaka による既知の正則分離を踏まえ，適切な固定準同型に対し，どの固定窓クラスにも属さない非正則線形・非線形文脈自由の標的を与え，一種類の括弧の Dyck 言語がどの固定型付けクラスにも属さないことを示す．

キーワード： 文法推論；文脈自由言語；分布学習；正例からの同定；有限モノイド

1 序論

1.1 背景と動機

Gold [3] は，すべての有限言語と少なくとも一つの無限言語を含む言語クラスは，正例データのみから極限同定できないことを示した．文脈自由言語では，比較してよい部分文字列を文脈間で制限する分布学習により正の結果が回復される．古典的な例として Clark–Eyraud の代入可能性 [9] と Yoshinaka の (k, ℓ)-代入可能性 [16] がある．一般的背景は de la Higuera [8] を，範疇文法の正例学習可能性に関する結果は Kanazawa [2, 1] を参照されたい．特に Kanazawa の著書は，rigid grammar の特徴標本および k-valued 範疇文法の文字列言語族についての有限弾力性による議論を扱う [1, Chapters 5 and 8]．これは相補的な研究系列であり，本論文では代わりに終端因子の有限モノイド型付けを固定して分布的代入可能性を要求する．

■2014 年の先行研究と一般 signature による学習． 本稿は，著者の 2014 年公開プレプリント [11] を証明と学習器の面で大幅に修正・拡張したものである．その初期稿にはすでに，可認識同値関係に相対化した代入可能性と正例による学習法が提案されていた．その公開は Yoshinaka [12] の一

般的な多ソート signature の枠組みの公刊より早いが，この時系列は初期稿の全証明や量的主張の正当性を意味するものではない．Yoshinaka の枠組みでは，本論文で用いる有限モノイド準同型 $h : \Sigma^* \to M$ によって定まる $h^{-1}(m) \cap \Sigma^+$ の非空な型ごとのコピーを相異なるソートとし，型付き連接と全文字列ソートへの昇格演算を備えることで，非空因子について本稿と同じ代入可能性条件が得られる．したがって，固定 h に対する正例学習器の**存在**という質的結論は Yoshinaka [12, Theorem 1] の一般理論からも導かれる．一方，本稿の特定の再構成・保守的逐次学習器はここで直接解析する．有限モノイドに固有の寄与は，固定窓の代数的判定条件，型付け変更に伴う閉包性，証人の個数だけでなく**総符号長**を評価する特徴データ境界，線形クラスの保証，言語クラスの分離である．分布学習の広い背景は Clark–Yoshinaka [13]，局所的代入可能性は Coste–Garet–Nicolas [14] および Coste–Nicolas [15] を参照されたい．

本論文では，この研究計画の可認識合同関係版を考える．$h : \Sigma^* \to M$ を有限モノイドへの準同型とし，$\sim_h := \ker h$ とする．$x \in \Sigma^*$ に対し $\mathcal{D}_L(x) := \{(u, v) : uxv \in L\}$ と書く．言語 L が $\sim_h$-**代入可能**であるとは，非空の x, y について $h(x) = h(y)$ かつ $\mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \emptyset$ ならば $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ が成り立つことをいう．文脈自由な $\sim_h$-代入可能言語のクラスを $\mathcal{C}_h^{\mathrm{cf}}$ と書き，これを *fixed-h slice* と呼ぶ．したがって，分布の完全な一致を要求するのは，固定された有限代数的比較の下ですでに一致する因子だけである．

例えば $\Sigma = \{a\}$，$L = \{a, aa\}$ を考える．$(\lambda, \lambda) \in \mathcal{D}_L(a) \cap \mathcal{D}_L(aa)$ であるが，$(a, \lambda) \in \mathcal{D}_L(a) \setminus \mathcal{D}_L(aa)$ である．したがって，自明な型付けでは L は代入可能でない．一方，長さの偶奇を記録する準同型 $h(a^n) = n \bmod 2$（値域 $\mathbb{Z}/2\mathbb{Z}$）を用いれば，a と aa は異なる型をもち，$L \in \mathcal{C}_h^{\mathrm{cf}}$ となる．

有限指数のモノイド合同関係，すなわち有限モノイドへの準同型の核は，有限型付けを与える．固定した h に対し，文脈自由性を仮定しないすべての $\sim_h$-代入可能言語のクラスを RS_h と書く．表現力の比較のため，

$$\mathsf{RS} := \bigcup_h \mathsf{RS}_h$$

と定める．ここで h は Σ^* 上の有限モノイド準同型全体を動く．すべての正則言語はこの和に属する．一方，本論文の学習結果は一つの h をクラス全体に固定した $\mathcal{C}_h^{\mathrm{cf}}$ だけを対象とし，RS 全体の学習可能性は主張しない．

一つの固定接頭辞 – 接尾辞窓と異なり，h は独立な有限状態の因子特徴を積によって組み合わせられる．このように有限型付けそのものを精密化してよいなら，正則フィルタとの交わりや，消去を許す任意の逆準同型像を，再び有限型付けの枠内で扱える（命題 3.2）．これは一つの fixed-h slice を同じ h のまま閉じるという主張ではない．代数的な判定条件で固定接頭辞 – 接尾辞窓が非空因子の型を決める場合を特徴づけ（命題 3.5），さらに有限群値を加えた型付けにも特徴データ上界を与える（系 7.4）．後述の非正則線形例と非線形例は固定窓を超える表現力を示し，カウンタや Dyck 言語に関する障害はその表現力の限界を示す．

h の指定は事前に与えるバイアスの選択であり，オートマトン推論における型付けまたは領域バイアス [20] と関連する．ただし本論文では文字の出現とその外側文脈ではなく，終端因子全体を型付けする．線形文法の場合，生成語型付けは生成規則ラベル列上に正則制御集合も誘導する．これは Takada の正則 control-set 法 [17, 18] との限定的だが具体的な接点である（第 8 節）．両学習枠組みの同値性は主張しない．

1.2 貢献と主要結果

本論文の主要な貢献は三つである．

(1) **固定 h に対する学習．** 集合駆動型作用素 $\mathcal{B}_h$ は，$\mathcal{C}_h^{\mathrm{cf}}$ の任意の標的を有限個の標準正例証拠から厳密に再構成する．別の保守的逐次学習器 $\mathcal{A}_h$ はすべての非空標的を Gold の意味で同定し，再構成と各更新は蓄積標本に関して多項式時間である．

(2) **定量的保証．** 任意の固定 h に対し，特徴データの大きさを，文法サイズと，標的非終端記号を h-値で分割した後の最短終端生成語の長さによって上から抑える．有限型付けが固定接頭辞 – 接尾辞窓と有限群値で細分化される場合にも，元文法の通常の最短生成語パラメータで上界を表せる．線形 fixed-h 標的では，線形 CFG のサイズに関する多項式特徴データ上界が得られる．また，分割後の最短生成語が元文法のものより指数的に長くなり得ることも示す．

(3) **構造上・表現力上の位置．** 単一の fixed-h slice の閉包性ではなく，有限型付けの精密化と積によって得られる閉包性を示し，固定接頭辞 – 接尾辞窓によって決まる有限型付けを特徴づけ，線形の生成語型付けと正則制御集合とを関連づける．固定窓の外にある非正則線形・非線形の具体例に加え，カウンタ・Dyck 言語の障害と Clark の congruential family との比較により枠組みの範囲を明らかにする．

1.3 論文の構成

第 2–3 節で枠組みを準備し，第 4–5 節で学習可能性を証明する．第 6–8 節で定量的結果を与え，第 9 節で表現力を比較する．長い正規化証明は付録に置く．

2 準備

Σ を有限アルファベットとし，Σ^* を単位元 λ をもつ自由モノイドとする．また $\Sigma^+ := \Sigma^* \setminus \{\lambda\}$ とおく．対 $(u, v) \in \Sigma^* \times \Sigma^*$ を **終端文脈** と呼ぶ．$L \subseteq \Sigma^*$ と $x \in \Sigma^*$ に対し，L における x の **分布** を $\mathcal{D}_L(x) := \{(u, v) \in \Sigma^* \times \Sigma^* : uxv \in L\}$ と定める．L の **構文合同関係** は，$x, y \in \Sigma^*$ に対して $x \equiv_L y \iff \mathcal{D}_L(x) = \mathcal{D}_L(y)$ により定める．$x \equiv_L y$ のとき，x と y は **構文合同** であるという [5, Chapter III, Proposition 10.2]．通常通り，$\equiv_L$ はモノイド合同であり，$x \equiv_L x'$ かつ $y \equiv_L y'$ ならば $xy \equiv_L x'y'$ である．

語 $w \in \Sigma^*$ と文字 $a \in \Sigma$ に対し，$|w|_a$ は w における a の出現回数を表す．

文脈自由文法（CFG）は有限非終端記号集合 V，開始記号 $S \in V$，および $A \in V$, $\alpha \in (V \cup \Sigma)^*$ に対する生成規則 $A \to \alpha$ からなる組 $G = (V, \Sigma, P, S)$ である．**文形式**とは $(V \cup \Sigma)^*$ の任意の語である．G における一段階導出を $\alpha \Rightarrow_G \beta$ と書き，その反射推移閉包を $\Rightarrow_G^*$ と書く．したがって $L(G) := \{w \in \Sigma^* : S \Rightarrow_G^* w\}$．$A \in V$ に対して $L_G(A) := \{w \in \Sigma^* : A \Rightarrow_G^* w\}$ とおく．非終端記号 $X \in V$ に対し，$S \Rightarrow_G^* uXv$ が成り立つとき，終端文脈 (u, v) を G における X の **終端到達文脈** と呼ぶ．非終端記号が S から到達可能な文形式中に現れるとき **到達可能** であるといい，終端語を導出するとき **生産的** であるという．到達可能性または生産性の少なくとも一方を欠く非終端記号を **無用** といい，λ を導出する非終端記号を **空語導出可能**（*nullable*）という．$A, B \in V$ に対する生成規

則 $A \to B$ を **単位規則** という．**単位閉包**とは，単位生成規則が非終端記号上に誘導する関係の反射推移閉包である．すべての非終端記号が到達可能かつ生産的である文法を **縮約済み** という．非空言語を生成する文法について，その **トリム**（縮約部分）とは，まず生産的でない非終端記号とそれらに接続する生成規則を削除し，次に残った文法で開始記号から到達不能な非終端記号とそれらに接続する生成規則を削除して得られる部分文法をいう．各右辺に高々一つの非終端記号しか現れない CFG を **線形** という．**二分化**とは，新たな非終端記号を用いて長い右辺を同値な二項生成規則の鎖へ置き換えることをいう．CFL を文脈自由言語全体のクラスとする．任意の有限表現 $\mathcal{R}$ に対し，$|\mathcal{R}|$ は固定した妥当な符号化の長さを表すものとする．文法については，これは通常の生成規則中の記号数と多項式の範囲で同値である．ここでは Wakatsuki–Tomita [10] が用い，Yoshinaka [16] が採用した最短生成語に基づく**厚み**を用いる（Eyraud–Heinz–Yoshinaka [22, Definition 2.11] も参照）．縮約済み文法を $G = (V, \Sigma, P, S)$ として

$$\tau_G := \max_{A \in V} \min\{\, |w| : A \Rightarrow_G^* w,\ w \in \Sigma^* \,\}$$

と定める．すなわち τ_G は，各非終端記号の最短終端生成語の長さを取り，その最大値をとったものである．

2.1 正例データからの学習

Gold の explanatory model [3] を用いる．H_0 を，一つの開始記号をもち生成規則をもたない固定 CFG とし，$L(H_0) = \emptyset$ とする．以下のテキスト規約は非空の標的言語に限定する．空言語はこのテキストに基づく Gold の記述から除外し，別途 H_0 により表す．同値に，通常の pause 記号をテキストに加えることで空標的を含めることもできるが，余分な記法を避けるためにここでは非空テキスト規約を用いる．非空言語 L に対し，**テキスト**とは，L の各語が少なくとも一度は現れる L 上の無限列 $T = (w_1, w_2, \ldots)$ である．$T[n] = (w_1, \ldots, w_n)$ および $K_n := \{w_1, \ldots, w_n\}$ と書く．学習器 $\mathcal{A}$ が非空言語 L を **極限同定**するとは，L の任意のテキスト T に対して，ある n_0 と文法 H が存在し，すべての $n \geq n_0$ について $\mathcal{A}(T[n]) = H$ かつ $L(H) = L$ が成り立つことをいう．したがって，仮説表現そのものが最終的に安定する．逐次学習器が **保守的** であるとは，新たに提示された正例データが現在の仮説によって生成されない場合にのみ，その現在の仮説を変更することをいう．

この逐次学習器とは別に，**集合駆動型再構成作用素** $\mathcal{B}$ を考える．これは有限語集合から文法への写像であり，とくにその出力は提示順序や重複回数に依存しない．任意の有限標本 K に対して $K \subseteq L(\mathcal{B}(K))$ が成り立つとき，$\mathcal{B}$ は **標本整合的** であるという．有限集合 $C \subseteq L$ が L の $\mathcal{B}$ に対する **特徴標本** であるとは，任意の有限 K について $C \subseteq K \subseteq L$ ならば $L(\mathcal{B}(K)) = L$ が成り立つことをいう．これは de la Higuera の多項式文法推論枠組み [7] の特徴標本に対応する．学習器に相対的な特徴標本とその符号化サイズについては [8, Section 7.3.3, Definition 7.3.3] も参照されたい．ただし同書の定義は逐次的提示に対するものであり，本論文の条件は明示的に集合駆動型である．標本サイズを $\|K\| := \sum_{w \in K} (|w| + 1)$ で測る[*1]．したがって λ も 1 を寄与する．以下では **特徴データ** という語を，特徴標本 C の符号化サイズ $\|C\|$ の略称としてのみ用いる．定量的結果では，$\mathcal{B}(K)$ の多項式時間構成と，多項式に抑えられる特徴データサイズを組み合わせる．多項式更新時間と多

[*1] $+1$ は，$K = \{\lambda\}$ のような非空標本のサイズが 0 になることを防ぐ．また $|K| \leq \|K\|$ となるため，正例数も同じサイズ尺度で抑えられる．

項式特徴標本サイズは別の評価基準であり [8, Sections 7.3.2–7.3.3]，それらの一方だけから逐次的な多項式時間・データ同定は導けない．Eyraud–Heinz–Yoshinaka [22, Definitions 2.5 and 2.8] は，逐次的な多項式時間・データ同定と集合ベースの基準を区別する．前者では特徴標本を観測した時点で正しい仮説に到達し，その後は仮説が安定しなければならない．後者は，特徴標本を含む任意の有限標本から正しく再構成できることを要求する．本論文の多項式特徴データ保証は集合駆動型の $\mathcal{B}_h$ に対するものであり，逐次学習器 $\mathcal{A}_h$ の多項式データ保証ではない．後者の Gold 安定化は系 5.5 で別途示す．

2.2 固定有限モノイド型付け

有限モノイド M と準同型 $h : \Sigma^* \to M$ を固定する．これらは M の乗法表および各 $a \in \Sigma$ に対する文字像 $h(a)$ によって表現される．したがって $h(w)$ は左から右への積によって $O(|w|)$ 時間で計算できる．以下で固定準同型が **効率的に計算可能** であるというのはこの意味である．

有限半群 S の冪等元全体を $E(S)$ と書く．$e \in E(S)$ と $t \in S$ のすべてについて $ete = e$ が成り立つとき，S は **局所自明** であるという．h の**正の像半群**は $h(\Sigma^+)$ であり，これは M の単位元を含むとは限らない．

定義 2.1 (固定-h 代入可能性)**.** 言語 $L \subseteq \Sigma^*$ が **$\sim_h$-代入可能** であるとは，すべての $x, y \in \Sigma^+$ について，$h(x) = h(y)$ と $\mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \varnothing$ から $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ が従うことをいう．

空語は内部の代入可能因子としては用いない．$\lambda \in L$ の場合には，再構成において開始記号を通じて別途処理する．

非空内部因子 x に対して，$h(x)$ をその **生成語型** と呼ぶ．文脈自由 $\sim_h$-代入可能言語のクラスを $\mathcal{C}_h^{\mathrm{cf}}$ と書き，

$$\mathcal{C}_h^{\mathrm{lin}} := \{L \in \mathcal{C}_h^{\mathrm{cf}} : L \text{ はある線形 CFG により生成される}\}$$

と定める．したがって $\mathcal{C}_h^{\mathrm{lin}}$ は線形言語からなる部分クラスである．

3 固定可認識代入可能性

固定 h に対し $\mathsf{RS}_h := \{L \subseteq \Sigma^* : L \text{ は } \sim_h\text{-代入可能}\}$ とおく．fixed-h slice は $\mathcal{C}_h^{\mathrm{cf}} = \mathsf{RS}_h \cap \mathrm{CFL}$ であり，$\mathcal{C}_h^{\mathrm{lin}}$ はそのうち線形 CFG で生成される言語からなる．表現力の比較に限り，h を Σ^* 上の有限モノイド準同型全体に動かして $\mathsf{RS} := \bigcup_h \mathsf{RS}_h$ とする．アルファベットを明示するときは $\mathsf{RS}_h(\Gamma)$，$\mathsf{RS}(\Gamma)$ と書き，以下の包含はアルファベットごとに解釈する．学習結果は常に一つの固定 h を対象とする．

命題 3.1. 言語が正則であることと，ある有限モノイド M への準同型 $h : \Sigma^* \to M$ と $\mathsf{Acc} \subseteq M$ に対して $h^{-1}(\mathsf{Acc})$ の形に書けることは同値である．正則言語 L については h として構文準同型を取ることができ，その核は $\equiv_L$ である．さらに任意の固定 h と $\mathsf{Acc} \subseteq M$ に対し，$h^{-1}(\mathsf{Acc})$ は $\sim_h$-代入可能である．従ってすべての正則言語は RS に属する．

Proof. 最初の二つの主張は古典的な構文モノイドによる特徴づけから従う [5, Chapter III, Propositions 10.1–10.2]．$L = h^{-1}(\mathsf{Acc})$ かつ $h(x) = h(y)$ なら，すべての u, v に対し $h(uxv) = h(uyv)$

なので $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ である．□

非空アルファベット上では，RS も $\mathsf{RS} \cap \mathrm{CFL}$ も正例データから極限同定できない．命題 3.1 により両者はすべての有限言語と Σ^* を含むため，Gold の定理が適用されるからである．同様に Yoshinaka [16, Section 4] は，彼の設定では (k, ℓ)-代入可能な文脈自由言語クラス全体の和が正例から極限同定できないことを指摘している．その理由は，その和が λ を含まないすべての有限言語と少なくとも一つの無限言語を含むからである．以下で学習可能性を主張するのは，個別の $\mathcal{C}_h^{\mathrm{cf}}$ のみに対してである．

型付けの精密化には，定義 2.1 で比較される非空因子上で単調性がある．$\ker h'|_{\Sigma^+} \subseteq \ker h|_{\Sigma^+}$ ならば，h' は比較を要求する因子対を減らすので $\mathsf{RS}_h \subseteq \mathsf{RS}_{h'}$ である．ただし精密化は，後の定量解析で使う型付き文法を大きくし得る．二つの有限型付け h, g に対し $\ker(h \times g)|_{\Sigma^+} = \ker h|_{\Sigma^+} \cap \ker g|_{\Sigma^+}$ だから $\mathsf{RS}_h \cup \mathsf{RS}_g \subseteq \mathsf{RS}_{h \times g}$ であり，窓情報と別の有限特徴を標的ごとに型付けを変えずに合成できる．

Yoshinaka [16, Proposition 1] は，固定窓代入可能言語が正則言語との交わりや消去を許す逆準同型像について閉じないことを示した．一方，非消去準同型の逆像については閉包性が成り立つ．これに対し，次の命題は，有限型付けを変更することで，正則フィルタとの交わりや消去的準同型による逆像を扱えることを示す．

命題 3.2 (有限情報に関する閉包性)**.** $h : \Sigma^* \to M$ と $g : \Sigma^* \to N$ を有限モノイド準同型とする．

(i) $L \in \mathsf{RS}_h$ かつ $J \in \mathsf{RS}_g$ ならば $L \cap J \in \mathsf{RS}_{h \times g}$ である．

(ii) $Q = g^{-1}(F)$ が正規言語で $L \in \mathcal{C}_h^{\mathrm{cf}}$ ならば $L \cap Q \in \mathcal{C}_{h \times g}^{\mathrm{cf}}$ である．

(iii) $\varphi : \Gamma^* \to \Sigma^*$ を，消去的でもよい任意の準同型とする．$B_\varphi = \{1, \zeta\}$ を零元 ζ をもつ二元モノイドとし，$\varphi(w) = \lambda$ のときかつそのときに限り $e_\varphi(w) = 1$，それ以外では $e_\varphi(w) = \zeta$ と定め，$\widehat{h} = (h \circ \varphi) \times e_\varphi$ とおく．$L \in \mathsf{RS}_h$ ならば $\varphi^{-1}(L) \in \mathsf{RS}_{\widehat{h}}$ であり，さらに $L \in \mathcal{C}_h^{\mathrm{cf}}$ ならば $\varphi^{-1}(L) \in \mathcal{C}_{\widehat{h}}^{\mathrm{cf}}$ である．

Proof. (i) について，非空因子 x, y が同じ $(h \times g)$-型をもち，$L \cap J$ で文脈を共有するとする．すると L では同じ h-型で文脈を共有し，J では同じ g-型で文脈を共有する．従って $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ かつ $\mathcal{D}_J(x) = \mathcal{D}_J(y)$ なので，$\mathcal{D}_{L \cap J}(x) = \mathcal{D}_{L \cap J}(y)$ である．(ii) は (i)，命題 3.1，および CFL の正規言語との交わりに関する閉包性から従う．

(iii) では，$\varphi(uv) = \lambda$ であることと $\varphi(u) = \varphi(v) = \lambda$ であることが同値なので，e_φ は準同型である．同じ $\widehat{h}$-型をもつ非空因子 x, y が $\varphi^{-1}(L)$ で文脈を共有するとする．$e_\varphi(x) = e_\varphi(y) = 1$ ならば $\varphi(x) = \varphi(y) = \lambda$ なので，逆像言語での分布は自明に一致する．そうでなければ両像は非空で，同じ h-型をもち，共有文脈の像が L における共通文脈になる．従って fixed-h 代入可能性から L での分布が一致し，文脈を φ で引き戻せば $\mathcal{D}_{\varphi^{-1}(L)}(x) = \mathcal{D}_{\varphi^{-1}(L)}(y)$ を得る．context-free の主張は CFL の逆準同型に関する閉包性による．□

■型付けはいつ有用か． 標的 L に対する正しさという観点では，定義 2.1 より，h は，共通文脈をもつのに分布が異なる任意の二つの非空因子を分離しなければならない．同値に，有用な型付けを選ぶ問題は有限指数モノイド合同による分離問題であり，そのような分布上の衝突を $\ker h$ が潰してはならない．従って型付けの精密化は安全であり，積型付けでは，衝突する因子対を少なくとも一方の成分が分離すればよいので，独立な有限特徴を組み合わせられる．後の補題 9.3 は，そのような

衝突因子の無限な pairwise family があれば有限型付け自体が存在しないという対応する障害を与える．一方，定量的効率は別問題である．精密化は再構成上界で用いる型付き文法を大きくし得る．命題 6.3 は元文法厚みから型付き厚みへの指数ギャップを示し，第 7 節と第 8 節は，そのコストを制御できる十分な場合を与える．

$\ker h$ を Σ^+ に制限した関係が構文合同 $\equiv_L$ を精密化するなら $L \in \mathsf{RS}_h$ である．逆は通常の代入可能性ですでに成り立たない．$L_{\mathrm{c}} := \{a^n c b^n : n \geq 0\}$ を考える．定義 2.1 の非空因子規約の下で L_{c} は Clark–Eyraud 代入可能だが，$\equiv_{L_{\mathrm{c}}}$ は無限指数である．実際 $1 \leq i < j$ に対して文脈 (a, cb^{i+1}) は a^i と a^j を区別する．

3.1 古典的特殊場合

Clark–Eyraud の元の定義 5 は空語を含む因子を扱っている [9]．ここでは Clark [21] に従い λ を比較から除く．この違いは $L = a^+$ でも重要である．(a, λ) は $\mathcal{D}_L(\lambda)$ と $\mathcal{D}_L(a)$ の双方に属するが，(λ, λ) は $\mathcal{D}_L(a)$ に属し $\mathcal{D}_L(\lambda)$ には属さない．よって空語も比較すると a^+ は代入可能ではなくなる．すべての $x, y \in \Sigma^+$ について $\mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \emptyset$ から $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ が従うとき，L を *Clark–Eyraud* **代入可能**と呼ぶ．これは定義 2.1 の自明モノイドの場合，従って Yoshinaka の $(0, 0)$ の場合にちょうど一致する．

$k, \ell \geq 0$ に対し，$\mathrm{pref}_k(w)$ と $\mathrm{suf}_\ell(w)$ をそれぞれ長さ $\min\{k, |w|\}$ の接頭辞と長さ $\min\{\ell, |w|\}$ の接尾辞とする．特に $\mathrm{pref}_0(w) = \mathrm{suf}_0(w) = \lambda$ であり，短い語については語全体を返す．Yoshinaka の変数を，本稿の記法に合わせて改名する．以下では u_i, v_i を外側文脈，p, q を窓，r, s をその内側部分に用いる．L が (k, ℓ)-**代入可能** であるとは，すべての $p \in \Sigma^k$, $q \in \Sigma^\ell$ および $u_1, u_2, v_1, v_2, r, s \in \Sigma^*$ について，$prq, psq \neq \lambda$ のとき

$$u_1 prq v_1 \in L, \quad u_1 psq v_1 \in L, \quad u_2 prq v_2 \in L \quad \Longrightarrow \quad u_2 psq v_2 \in L$$

が成り立つことをいう．

命題 3.3. 任意の固定 $k, \ell \geq 0$ に対して有限モノイド準同型 $h_{k,\ell}$ が存在し，任意の $L \subseteq \Sigma^*$ について，L が (k, ℓ)-代入可能であることと $\sim_{h_{k,\ell}}$-代入可能であることは同値である．

Proof. $m_0 := \max\{1, k + \ell\}$ とし，$|w| < m_0$ なら $h_{k,\ell}(w) := w$，それ以外では，二つの場合を区別するタグを付けて $h_{k,\ell}(w) := \langle \mathrm{pref}_k(w), \mathrm{suf}_\ell(w) \rangle$ とする．有限像を $M_{k,\ell} := h_{k,\ell}(\Sigma^*)$ と書く．長さがともに m_0 未満の語 x, y について

$$x \cdot y := h_{k,\ell}(xy), \qquad x \cdot \langle p, q \rangle := \langle \mathrm{pref}_k(xp), q \rangle,$$
$$\langle p, q \rangle \cdot y := \langle p, \mathrm{suf}_\ell(qy) \rangle, \quad \langle p, q \rangle \cdot \langle p', q' \rangle := \langle p, q' \rangle$$

と積を定める．すると $h_{k,\ell}(xy) = h_{k,\ell}(x) \cdot h_{k,\ell}(y)$ であり，全射性から結合律が従い，$h_{k,\ell}(\lambda)$ が単位元になる．

非空 x, y の型が等しいことは，$x = y$ であるか，共通の長さ k の接頭辞 p と長さ ℓ の接尾辞 q を用いて $x = prq$, $y = psq$ と書けることを意味する（$k = \ell = 0$ も含む）．L が (k, ℓ)-代入可能なら，共通文脈と片方の任意の文脈から Yoshinaka の四語条件を適用し，対称性により分布が一致する．逆に Yoshinaka の前提では $x := prq$, $y := psq$ は非空で，長語側の符号化に属するため同じ $h_{k,\ell}$-型をもつ．固定-$h_{k,\ell}$ 代入可能性が第三の文脈を移送し，第四の語を与える． □

■固定窓代入可能性の反例基準． x, y が長さ $\max\{1, k+\ell\}$ 以上で，同じ長さ k の接頭辞と長さ ℓ の接尾辞をもち，共通文脈をもつ一方で分布が異なるなら，L は (k,ℓ)-代入可能ではない．最初の三条件から $h_{k,\ell}$-型が等しく共通文脈をもち，最後の条件が $\sim_{h_{k,\ell}}$-代入可能性に反するからである．

従って固定 (k,ℓ) クラスはちょうど $\mathsf{RS}_{h_{k,\ell}}$ であり，第 7 節でその多項式厚み付きデータ上界を与える．$k=\ell=0$ では $h_{0,0}$ は λ と非空語を区別するだけで，一元モノイドと同じ代入可能性条件を誘導する．アルファベット Γ に対し

$$\mathsf{KL}(\Gamma) := \bigcup_{k,\ell\geq 0} \{L \subseteq \Gamma^* : L \text{ は } (k,\ell)\text{-代入可能}\}$$

とし，$\mathsf{KL} := \mathsf{KL}(\Sigma)$ と略記する．

3.2 主定理

定理 3.4 (固定-h 学習定理)**.** 効率的に計算可能な有限モノイド準同型 $h : \Sigma^* \to M$ を固定する．集合駆動型再構成作用素 $\mathcal{B}_h$ と保守的逐次学習器 $\mathcal{A}_h$ が存在し，次を満たす．

(i) $\mathcal{B}_h$ は標本整合的で，$\mathcal{B}_h(K)$ は $\|K\|$ の多項式時間で構成できる．

(ii) すべての $L \in \mathcal{C}_h^{\mathrm{cf}}$ は $\mathcal{B}_h$ に対する有限特徴標本をもつ．

(iii) $\mathcal{A}_h$ はすべての非空 $L \in \mathcal{C}_h^{\mathrm{cf}}$ を *Gold* の意味で同定し，各更新はそれまでに見たデータの多項式時間で行える．

(iv) 正の像半群 $h(\Sigma^+)$ が有限な局所自明半群と有限群の直積の *divisor*（すなわち，その直積の部分半群の準同型像）なら，各非空標的について *(ii)* の標本は，その標的を表す任意の縮約済み *CFG* G_* に対し $|G_*|$ と τ_{G_*} の多項式サイズに選べる．特に，固定窓型付けと有限群型付けに適用できる．

(v) 任意の固定 h と $L \in \mathcal{C}_h^{\mathrm{lin}}$ に対し，*(ii)* の標本は，L を表す任意の線形 *CFG* G_* について $|G_*|$ の多項式サイズに選べる．

(iv)–(v) の多項式は固定した h と Σ に依存してよいが，選んだ標的文法 G_* には依存しない．項目 *(iv)–(v)* の定量的機構と，一般の固定型付けに対するその限界は，第 *6–8* 節で扱う．

これは Gold の定理と整合する．非空アルファベット上では，クラス $\mathcal{C}_h^{\mathrm{cf}}$ はすべての有限言語を含むわけではない．$h(x) = h(y)$ を満たす相異なる非空語 x, y を取り，さらに $|z| > \max\{|x|, |y|\}$ を満たす $z \in \Sigma^*$ を取る．$\{x, y, zx\}$ では x, y は空文脈を共有するが，(z, λ) は x だけの文脈である．

■固定窓の代数的位置づけ． 以下の同値性は局所自明有限半群に関する古典的結果の，正語像と核に即した再定式化であり，新しい半群定理としては主張しない．Pin [6, Propositions XI.4.17 and XIV.1.20] を参照されたい．なお，構文半群の局所自明性によって特徴づけられる古典的な正則言語族は，*generalized definite*（接頭辞 – 接尾辞検査可能）言語と呼ばれる [4, Proposition 5.18]．ここでは構文半群に限らない固定準同型の正の像と核を扱い，その言語クラスの和への適用と，系 7.4 の学習に固有な厚みの評価を記録する．

命題 3.5 (局所自明型付けと固定窓)**.** 非空アルファベット上の有限モノイド準同型 $h : \Sigma^* \to M$ に対し，$n := |h(\Sigma^+)| + 1$ とおく．次は同値である．

(i) $h(\Sigma^+)$ は局所自明である．

(ii) ある $k,\ell \geq 0$ が存在して $\ker h_{k,\ell}|_{\Sigma^+} \subseteq \ker h|_{\Sigma^+}$ が成り立つ．

これらが成り立つとき $(k,\ell) = (n,n)$ と取れる．さらに，各正の像半群 $h_{k,\ell}(\Sigma^+)$ は局所自明であり，

$$\mathsf{KL}(\Sigma) = \bigcup_{\substack{h:\Sigma^* \to M \\ h(\Sigma^+)\text{ が局所自明}}} \mathsf{RS}_h(\Sigma)$$

が成り立つ．両辺を CFL と交わらせても同じ等式が成り立つ．

Proof. まず (i) を仮定し，$S = h(\Sigma^+)$，$n = |S| + 1$ とおく．Pin [6, Corollary II.6.35 and Proposition XI.4.17] による一般の有限半群での事実 $S^n = SE(S)S$ と，局所自明性から従う，任意の $e, f \in E(S)$ と任意の $t \in S$ に対する恒等式 $etf = ef$ を使う．長さ n の任意の p, q について $h(p) = aeb$, $h(q) = cfd$ と分解できるので，すべての $r \in \Sigma^*$ に対し $h(prq) = a\,e\,(b\,h(r)\,c)\,f\,d = aefd = h(pq)$ となる．短い非空語を個別に記録する $h_{n,n}$ の定義から (ii) が従う．

逆に S が局所自明でなければ，冪等元 e と元 m で $eme \neq e$ を満たすものがある．これらを表す非空語を r, z とし，任意の k,ℓ に対して $j|r| \geq \max\{k,\ell\}$ を満たす $j \geq 1$ を取る．$x = r^{2j+1}$ と $y = r^j z r^j$ は同じ固定窓型を持つが，$h(x) = e \neq eme = h(y)$ なので (ii) は成立しない．

最後に命題 3.3 の積を使うと，正の像 $h_{k,\ell}(\Sigma^+)$ の各冪等元は $\langle p, q\rangle$ の形で[*2]，$\langle p,q\rangle t \langle p,q\rangle = \langle p,q\rangle$ を満たす．従って正の像は局所自明である．逆向きの包含は，前半と核の精密化に関する単調性から $\mathsf{RS}_h \subseteq \mathsf{RS}_{h_{n,n}}$ による．言語クラスの和を取れば所望の等式が得られ，CFL に制限しても成り立つ． □

4 再構成作用素と逐次学習器

4.1 有限標本からの再構成

有限標本 $K \subseteq \Sigma^*$ に対し，

$$\widehat{V}(K) := \{[x] : x \in \Sigma^+,\ \exists u, v \in \Sigma^* \text{ with } uxv \in K\}$$

とおく．したがって，標本中で観測された相異なる非空因子ごとに仮説非終端記号を一つだけ置く．角括弧は非終端記号名の一部であり，商類を表す記号ではない．観測された非空因子 x, y に対し

$$x \approx_{K,h} y \quad\Longleftrightarrow\quad h(x) = h(y) \text{ かつ } \mathcal{D}_K(x) \cap \mathcal{D}_K(y) \neq \emptyset$$

と書く．文法 $\mathcal{B}_h(K)$ は非終端記号集合 $\widehat{V}(K) \cup \{\widehat{S}\}$ と開始記号 $\widehat{S}$ をもち，表示されたすべての角括弧付き非終端記号が $\widehat{V}(K)$ に属する場合に，次の規則をもつ：

$$\begin{array}{lll} \text{(B)} & [xy] \to [x][y], & x, y \in \Sigma^+, \\ \text{(U)} & [x] \to [y], & x \approx_{K,h} y, \\ \text{(L)} & [a] \to a, & a \in \Sigma, \\ \text{(S)} & \widehat{S} \to [w], & w \in K \cap \Sigma^+. \end{array}$$

$\lambda \in K$ のときは，規則 (S) に $\widehat{S} \to \lambda$ も含める．

[*2] 正の像の短語型元 x は $0 < |x| < m_0$ を満たす．十分大きな j では $h_{k,\ell}(x^j)$ は長語型だが，x が冪等なら $h_{k,\ell}(x^j) = x$ となり矛盾する．

この文法は Yoshinaka [16, Section 4, Algorithm 1] の部分文字列添字付き構成に基づき，Clark [21, Section 4, Algorithm 1] も同じ構成を紹介している．特に $h = h_{k,\ell}$ のとき，規則 (U) の非自明な場合は Yoshinaka の単位規則と一致する．すなわち相異なる非空の観測因子が共通の標本文脈をもち，同じ $h_{k,\ell}$-型をもつとき結ばれる．同値に，その二因子はともに長さ $\max\{1, k+\ell\}$ 以上で，同じ長さ k の接頭辞と長さ ℓ の接尾辞をもつ．冗長な恒等規則，初期規則を別の開始記号で表す点，および λ の扱いを除けば，両構成は一致する．一般の固定 h では，この接頭辞 – 接尾辞の比較を h-型の一致で置き換える．

補題 4.1 (標本整合性)**.** 任意の有限正例標本 K に対して，$K \subseteq L(\mathcal{B}_h(K))$ が成り立つ．

Proof. $w = a_1 \cdots a_m \in K \cap \Sigma^+$ とする．規則 (S) により $[w]$ に入る．w の任意の二分木分解に沿って規則 (B) を繰り返すと一文字因子へ到達し，それらはすべて同じ標本語中に現れるので観測済みである．最後に規則 (L) が $a_1 \cdots a_m$ を生成する．$\lambda \in K$ の場合は開始規則が直接生成する． □

定理 4.2 (健全性)**.** $K \subseteq L$ かつ L が $\sim_h$-代入可能ならば，$L(\mathcal{B}_h(K)) \subseteq L$ である．

Proof. $[x]$ を根とする導出木の高さについて帰納法を行い，

$$[x] \Rightarrow^*_{\mathcal{B}_h(K)} w \quad \Longrightarrow \quad x \equiv_L w \text{ かつ } h(w) = h(x) \tag{1}$$

を示す．因子非終端記号は観測された非空語を添字にもつので，規則 (U) で比較する因子は定義 2.1 の非空条件を満たす．また規則 (B)–(L) は，因子非終端記号から λ を導出しない．規則 (L) は明らかである．規則 (U) で $[x] \to [y]$ とする．定義から，ある標本文脈 (u, v) が存在して $uxv, uyv \in K \subseteq L$ かつ $h(x) = h(y)$ である．fixed-h 代入可能性により $x \equiv_L y$ であり，帰納法の仮定から $y \equiv_L w$ と $h(w) = h(y)$ が従うので (1) を得る．

規則 (B) について，$[xy] \to [x][y]$ から得られる終端語を $w_1 w_2$ と書く．帰納法の仮定より $x \equiv_L w_1$, $y \equiv_L w_2$, $h(w_1) = h(x)$, $h(w_2) = h(y)$ である． $\equiv_L$ はモノイド合同なので $xy \equiv_L w_1 w_2$ であり，準同型性から $h(w_1 w_2) = h(xy)$ である．

最後に開始規則 $\widehat{S} \to [x]$ を用いたなら $x \in K \subseteq L$ なので $(\lambda, \lambda) \in \mathcal{D}_L(x)$ である．不変量から $\mathcal{D}_L(w) = \mathcal{D}_L(x)$ だから $w \in L$ を得る．λ の直接規則は $\lambda \in K \subseteq L$ の場合にしか存在しない． □

4.2 逐次学習器

$\mathcal{B}_h$ を各データ到着時に再計算しても，文法表現は一般には安定しない．たとえば $L_{\mathrm{c}} = \{a^n c b^n : n \geq 0\}$ では，長い正例から $[a^n c b^n]$ のような新しい因子非終端記号が生じる．そこで Clark–Eyraud の Substitution Graph Learner (SGL, Algorithm 2) および Yoshinaka の (k, ℓ)-Substitutable Grammar Learner ((k, ℓ)-SGL, Algorithm 1) と同じ保守的ラッパーを用いる [9, 16]．集合駆動型再構成と逐次学習の区別については Eyraud–Heinz–Yoshinaka [22, Appendix] も参照されたい．固定空文法 H_0 から始め，w_n を読んだ後

$$H_n := \begin{cases} H_{n-1}, & w_n \in L(H_{n-1}), \\ \mathcal{B}_h(K_n), & w_n \notin L(H_{n-1}), \end{cases} \qquad \mathcal{A}_h(T[n]) := H_n$$

とする．再構成は常に蓄積標本全体 K_n を用いる．$\mathcal{B}_h$ は集合駆動型だが，$\mathcal{A}_h$ が最終的に安定する文法は提示順序に依存し得る．主張するのは，標的言語を生成する文法への最終的な構文的安定化だけ

である（系 5.5）．実際，無限な $L \in \mathcal{C}_h^{\mathrm{cf}}$ のテキスト T で学習器が安定するとき，極限仮説を構成した有限標本のすべての語より長い $w \in L$ を選べる．T 上の極限文法は $[w]$ を含まないが，w を先頭に追加したテキストでは，最初の再構成以降の全仮説がこの非終端記号を含む．従って，同じ標的に対して異なる極限文法が得られる．Clark [21, Section 4, Example 1] も，$L_{\mathrm{c}} = \{a^n c b^n : n \geq 0\}$ について，初期の正例列の違いによって相異なる部分文字列添字付き文法に安定することを示している．

5　有限証拠・厳密再構成・計算量

5.1　標的の精密化と有限証拠

再構成作用素と逐次学習器はすでに定義済みである．ここでは完全性の証明のためだけに標的側の精密化を導入する．目標は，対応する正例証拠が出現した後に，仮説文法が有限個の型付き標的導出を模倣できることを示すことである．次の標準形は証明上の道具としてのみ用いる．

定義 5.1 (開始記号分離二分標準形)．*CFG* $G = (V, \Sigma, P, S_0)$ が 開始記号分離二分標準形（*SSBNF*）にあるとは，S_0 がいかなる右辺にも現れず，すべての開始規則が $S_0 \to A$ または $S_0 \to \lambda$ の形であり，すべての非開始規則が $A \to a$ または $A \to BC$ の形であることをいう．

開始記号の分離により文全体への入口が内部非終端記号と区別され，λ は開始記号で別途扱える．

任意の非空文脈自由言語は，標準的な開始記号分離，無用記号除去，開始記号以外での λ/単位規則除去，および二分化の手続きにより，同値な縮約済み SSBNF 文法をもつ．従って以下の精密化は非空文脈自由言語について定義する．空標的は H_0 と $\mathcal{B}_h(\emptyset)$ により別途表す．

非空言語 L に対する縮約済み SSBNF 文法を $G = (V, \Sigma, P, S_0)$ とする．開始記号 $\widetilde{S}$ と，$A \in V \setminus \{S_0\}$, $\mu \in M$ に対する非開始記号 A_μ をもつ次の生成語型付き文法を作る．以下，型添字の併置は M における積を表す．すなわち $\mu\nu = \mu \cdot \nu$ とする．規則は次である．

$$
\begin{array}{ll}
\widetilde{S} \to A_\mu & (S_0 \to A \in P,\ \mu \in M), \\
\widetilde{S} \to \lambda & (S_0 \to \lambda \in P), \\
A_{h(a)} \to a & (A \to a \in P), \\
A_{\mu\nu} \to B_\mu C_\nu & (A \to BC \in P,\ \mu, \nu \in M).
\end{array}
$$

この文法の縮約部分を $\widetilde{G} = (\widetilde{V}, \Sigma, \widetilde{P}, \widetilde{S})$ と書き，**型付き精密化**と呼ぶ．したがって，規約として $\widetilde{G}$ のすべての記号は到達可能かつ生産的である．

Σ 上に順序を一つ固定し，それが誘導する *shortlex* 順序を用いる．すなわち短い語を先に置き，同じ長さなら辞書式順序で比較する．$\widetilde{G}$ の各非開始記号 X に対し，$\omega(X)$ をその shortlex 最小終端生成語とし，これを X の**標準生成語**と呼ぶ．$\widetilde{G}$ は縮約済みなので $\omega(X)$ は常に定義される．

完全性のためには生成語型による分割が必要である．親の型付き非終端記号の標準生成語と，その子の標準生成語を連接した語とが同じ h-型をもつことによって，単位規則 (U) が適用できる（定理 5.3）．

この分割が現在の完全性証明で果たす役割は，型付け前の文法ですでに見える．$h(w) = |w| \bmod 2$ とし，開始記号を S_0 とする SSBNF 文法 G の規則を $S_0 \to A$, $A \to a \mid BC$, $B \to a$, $C \to a$ とする．A の最短生成語は a であり型は奇数である一方，B, C の最短生成語の連接 aa は偶数型である．したがって，A を生成語型で分割しなければ，対応する単位規則の段階は許可されない．生成語型で分割することで必要な等式が不変量となる．一方で周囲の左文脈または右文脈には型を付けない．再

構成作用素がそのような型を一度も検査しないからである．

命題 5.2 (型付き持ち上げと生成語不変量)**.** 型付き精密化は $L(\widetilde{G}) = L(G)$ を満たす．さらに，$\widetilde{G}$ に残る任意の非開始記号 A_μ について，

$$L_{\widetilde{G}}(A_\mu) = L_G(A) \cap h^{-1}(\{\mu\})$$

が成り立つ．特に $A_\mu \Rightarrow_{\widetilde{G}}^{*} w$ ならば $h(w) = \mu$ である．

Proof. 型注釈を消去すれば任意の型付き導出は G の導出となる．逆に G の成功導出木の各非開始節点に，その部分木の終端生成語の h-型を注釈する．終端規則と二項規則は型のボトムアップ伝播則そのものなので，注釈付き木はトリム前の型付き文法での導出となる．成功木上の記号はすべてトリム後も残る．

残った非開始記号 A_μ について，型注釈の消去から

$$L_{\widetilde{G}}(A_\mu) \subseteq L_G(A) \cap h^{-1}(\{\mu\})$$

が従う．逆の包含のため，$w \in L_G(A)$ かつ $h(w) = \mu$ とする．A_μ はトリム後に残っているので，その出現を含む成功した型付き導出木が存在する．一方，$A \Rightarrow_G^{*} w$ という元文法での導出木の各部分木の終端生成語を h-型でボトムアップに注釈する．得られた型付き部分木を，先の成功木の A_μ の出現箇所に接ぎ木する．根の型が μ なので接ぎ木は正しく，全体として成功した型付き導出木になる．したがって接ぎ木した部分木の記号と規則はすべてトリム後にも残り，$A_\mu \Rightarrow_{\widetilde{G}}^{*} w$ を得る．生成語型の不変量も型付き導出に関する帰納法から直接従う． □

$\widetilde{G}$ の各非開始記号 X に対し，X の終端到達文脈の中から $|u_X| + |v_X|$ を最小化するものとして $\chi(X) = (u_X, v_X)$ を選び，同値な候補がある場合は u_X の shortlex 順序，次に v_X の shortlex 順序で決める．$\chi(X)$ を X の**標準文脈**と呼ぶ．$\widetilde{G}$ は縮約済みなので，このような終端到達文脈は存在する．実際，到達可能性により X は到達可能な文形式中に現れ，周囲の非終端記号の生産性により，その左側および右側のすべての記号を終端文字列へ展開できる．命題 5.2 から $h(\omega(A_\mu)) = \mu$ である．

有限証拠集合を

$$\begin{aligned} \mathsf{W}(\widetilde{G}) := \{&u_X \omega(X) v_X : X \in \widetilde{V} \setminus \{\widetilde{S}\}\} \\ &\cup \{u_X a v_X : X \to a \in \widetilde{P}\} \\ &\cup \{u_X \omega(Y)\omega(Z) v_X : X \to YZ \in \widetilde{P}\} \\ &\cup \big(\{\lambda\} \text{ if } \lambda \in L\big) \end{aligned} \tag{2}$$

により定める．ここに表示したすべての語は L に属し，集合は有限である．特に，二項規則 $X \to YZ$ に対応する証拠語は

$$\widetilde{S} \Rightarrow^{*} u_X X v_X \Rightarrow u_X Y Z v_X \Rightarrow^{*} u_X \omega(Y)\omega(Z) v_X$$

により正当化される．第一族と第二族についても同様である．$\mathsf{W}(\widetilde{G})$ の要素を **標準正例証拠** と呼ぶ．第一族は各型付き記号の標準的な一出現を記録し，第二族と第三族はそれぞれ終端生成規則と二項生成規則を記録する．

5.2 厳密再構成と Gold 収束

定理 5.3 (有限証拠からの完全性)**.** 非空言語 L に対する任意の縮約済み *SSBNF* 文法を G とし，固定準同型 h に関するその型付き精密化を $\widetilde{G}$ とする．有限集合 K が $\mathsf{W}(\widetilde{G}) \subseteq K$ を満たすならば，$L \subseteq L(\mathcal{B}_h(K))$ である．

ここが標的型付けが登場する箇所である．学習器とバッチ作用素は第 4 節ですでに定義されており，以下の証明は，それらの仮説非終端記号が生成語型付き標的非終端記号を模倣できることを示す．それ以外では，この主張は純粋に組合せ論的である．型付き文法と包含 $\mathsf{W}(\widetilde{G}) \subseteq K$ だけを用い，代入可能性も追加仮定 $K \subseteq L$ も必要としない．

Proof. 各非開始記号 X に対し，$\widehat{X} := [\omega(X)]$ と書く．式 (2) の第一族の対応する語により $\widehat{X}$ は存在する．型付き導出 $X \Rightarrow^* w$ について帰納法を行い，$\widehat{X} \Rightarrow^*_{\mathcal{B}_h(K)} w$ を示す．

最初の規則が $X \to a$ の場合，第一族と第二族にはそれぞれ $u_X\omega(X)v_X$ と $u_X a v_X$ が含まれる．命題 5.2 より $h(\omega(X)) = h(a)$ なので $\omega(X) \approx_{K,h} a$ である．必要なら規則 (U) で $\widehat{X}$ から $[a]$ へ移り，規則 (L) で a を生成する．

最初の規則が $X = A_{\mu\nu} \to B_\mu C_\nu$ の場合，$Y := B_\mu$, $Z := C_\nu$ とおく．第一族と第三族には $u_X\omega(X)v_X$ と $u_X\omega(Y)\omega(Z)v_X$ が含まれる．さらに

$$h(\omega(X)) = \mu\nu = h(\omega(Y))h(\omega(Z)) = h(\omega(Y)\omega(Z))$$

なので，必要なら規則 (U) により $\widehat{X}$ から $[\omega(Y)\omega(Z)]$ へ移る．第三族の証拠により $\omega(Y)\omega(Z)$ は観測因子でもあるから，規則 (B) で

$$[\omega(Y)\omega(Z)] \to [\omega(Y)][\omega(Z)]$$

と分解できる．二つの部分導出は帰納法の仮定で完了する．

最後に，任意の非空 $w \in L$ は $\widetilde{S} \to X \Rightarrow^* w$ という持ち上げられた開始導出をもつ．開始規則そのものにより (λ, λ) は X の終端到達文脈であり，全長 0 で最小だから $\chi(X) = (\lambda, \lambda)$ である．第一族から $\omega(X) \in K$ なので，規則 (S) が上の導出を開始する．$w = \lambda$ の場合も式 (2) と規則 (S) から直ちに従う． □

定理 5.4 (厳密有限標本再構成)**.** $L \in \mathcal{C}_h^{\mathrm{cf}}$ を非空とし，G を L の縮約済み *SSBNF* 文法，$\widetilde{G}$ をその型付き精密化とする．$\mathsf{W}(\widetilde{G}) \subseteq K \subseteq L$ ならば，$L(\mathcal{B}_h(K)) = L$ である．

Proof. 定理 4.2 と 5.3 を合わせればよい． □

したがって，$L(G) \in \mathcal{C}_h^{\mathrm{cf}}$ が非空となる任意の縮約済み SSBNF 文法 G に対し，集合 $\mathsf{W}(\widetilde{G})$ は第 2.1 節の意味で，$\mathcal{B}_h$ に関する $L(G)$ の特徴標本である．

定理 5.4 は $\{\lambda\}$ を含むすべての非空標的を覆う．残る端点 $L = \emptyset$ については $C_L = \emptyset$ とおけば，$\mathcal{B}_h(\emptyset)$ は開始生成規則をもたない．これにより定理 3.4 の項目 (ii) が確立される．

系 5.5 (Gold 同定)**.** 有限モノイド M への固定準同型 $h : \Sigma^* \to M$ に対し，学習器 $\mathcal{A}_h$ は $\mathcal{C}_h^{\mathrm{cf}}$ のすべての非空言語を正例データから同定する．より具体的には，任意の縮約済み *SSBNF* 標的文法 G とその型付き精密化 $\widetilde{G}$ に対し，$\mathsf{W}(\widetilde{G}) \subseteq K_{n_0}$ となったとき，段階 $n \geq n_0$ の範囲で生じうる仮説変更は高々一回である．

Proof. 本論文のテキスト規約の下では，Gold の主張は非空標的を対象とする．H_0 は初期空仮説である．L を非空とし，T を L のテキストとする．$w_1 \notin L(H_0) = \emptyset$ なので，学習器は段階 1 で再構成する．$\mathsf{W}(\widetilde{G}) \subseteq K_{n_0}$ を満たす n_0 を選ぶ．ある段階 $n \geq n_0$ で学習器が再構成するならば，定理 5.4 により新たな仮説はちょうど L となり，その後はいかなる正例も追加の変更を引き起こさない．この場合はこれが最後の仮説変更となる．一方，どの段階 $n \geq n_0$ でも再構成が起こらないと仮定する．健全性から $L(H_{n_0}) \subseteq L$ である．さらに，すべての n について $K_n \subseteq L(H_n)$ が成り立つ．再構成時には標本整合性があり，再構成しない段階では新たに提示されたデータがすでに変更されない仮説によって生成されるからである．したがって真の包含 $L(H_{n_0}) \subsetneq L$ ならば，段階 n_0 までまだ現れていないある $w^\star \in L \setminus L(H_{n_0})$ が存在する．しかし標的のすべての語は最終的にテキストに現れるので，$w^\star$ は後の段階で現れて再構成を強制し，矛盾する．したがって $L(H_{n_0}) = L$ である．この場合，段階 n_0 以後に仮説変更は必要ない． □

これは Eyraud–Heinz–Yoshinaka [22, Appendix] が指摘する delayed-rebuild 現象である．特徴標本をすでに見終えた後でも，新しい各正例が以前の誤った仮説によって生成されている限り，保守的学習器はその仮説を保持し得る．その仮説の外にある後続の正例が現れたとき，すでに特徴データを含む蓄積標本全体から再構成が行われる．上の証明は $\mathcal{A}_h$ に対するこの安定化を明示している．

5.3 再構成ステップの計算量

定理 5.6 (多項式時間再構成)**.** h を固定すると，$\mathcal{B}_h(K)$ は $\|K\|$ に関して多項式時間で構成できる．

Proof. $n_K := \|K\|$ とおき，観測因子出現の集合を $\mathcal{O}_K := \{(u, x, v) \in \Sigma^* \times \Sigma^+ \times \Sigma^* : uxv \in K\}$ とする．$|\mathcal{O}_K| = O(n_K^2)$ なので，因子非終端記号も高々 $O(n_K^2)$ 個である．各標本語の各開始位置から因子を一文字ずつ延長して h-値を記録すれば，固定モノイド中の $O(n_K^2)$ 回の積で全因子の h-値を計算できる．

規則 (B) の候補は，観測因子出現とその分割位置を選ぶので高々 $O(n_K^3)$ 個である．規則 (U) については，各 $(u, x, v) \in \mathcal{O}_K$ と各 $w \in K$ に対し，$w = uyv$ を満たす非空語 y が存在するか調べる．そのような y は存在すれば一意であり，$h(x) = h(y)$ ならば規則 $[x] \to [y]$ を生成する．これにより規則 (U) の候補をすべて列挙でき，その個数は高々 $|\mathcal{O}_K||K| = O(n_K^3)$ である．

終端規則と開始規則はこれより低次である．各候補について，文字列の照合と生成規則の符号化・出力は $O(n_K)$ 時間で行える．重複する規則は生成言語に影響しないため，列挙時に除去する必要はない．従って，$\mathcal{B}_h(K)$ は $O(n_K^4)$ 時間で構成できる． □

保守的学習器 $\mathcal{A}_h$ の各更新も，それまでに見たデータの符号化サイズに関して多項式時間で処理できる．CFG membership は文法と入力サイズに関して多項式時間であり，現在の仮説サイズと必要な再構成の計算量はいずれも定理 5.6 によって多項式に抑えられる．

補題 4.1，定理 5.4，系 5.5 と合わせて，主定理 3.4(i)–(iii) が得られる．定量的な (iv)–(v) は第 7–8 節で証明する．文法サイズだけによる上界は不可能である．Clark–Eyraud [9, Example 2] および Eyraud–Heinz–Yoshinaka [22, Example 2.3] の標準的な doubling family を開始記号分離し添字を付け替えた版は，縮約済み SSBNF 文法 $S_0 \to D_n$, $D_0 \to a$, $D_i \to D_{i-1}D_{i-1}$ をもち，生成規則記号数は $O(n)$ だが生成言語は $\{a^{2^n}\}$ である．de la Higuera の定理 3 [7] は，これと密接に関連する simple-deterministic な変種を用いる．任意の singleton 言語は，任意の h に対して $\sim_h$-

代入可能である．

6　一般の固定型付けに対する型付き厚み

任意の固定 h に対し，生成語型付けの費用を明示的に測れば，有限証拠構成から直接的な定量上界が得られる．$G = (V, \Sigma, P, S_0)$ を縮約済み SSBNF 文法，$\widetilde{G}$ をその型付き精密化とし，$N := |V \setminus \{S_0\}|$, $N_t := |\widetilde{V} \setminus \{\widetilde{S}\}|$ とおく．この表現の **型付き厚み**を

$$\tau_h^{\mathrm{typ}}(G) := \max\Big(\{\, |\omega(X)| : X \in \widetilde{V} \setminus \{\widetilde{S}\}\,\} \cup \{1\}\Big)$$

と定める．これは完全な生成語型分割とトリミング後の最短終端生成語を測る表現依存パラメータであり，学習器への追加仮定ではない．

補題 6.1 (型付き厚みによる証拠上界)**.** $G, \widetilde{G}$ を上の通りとし，$\tau := \tau_h^{\mathrm{typ}}(G)$ と書く．任意の非開始型付き記号 X に対し $|u_X| + |v_X| \le (N_t - 1)\tau$ であり，任意の $w \in \mathsf{W}(\widetilde{G})$ に対し $|w| \le (N_t + 1)\tau$ である．$P_{\mathrm{ter}}, P_{\mathrm{bin}}$ をそれぞれ G の非開始終端規則と二項規則の集合とすると

$$\|\mathsf{W}(\widetilde{G})\| \le \big(N|M| + |P_{\mathrm{ter}}| + |P_{\mathrm{bin}}||M|^2 + 1\big)\big((N|M| + 1)\tau + 1\big).$$

特に固定 h の下で，この上界は $|G|$ と $\tau_h^{\mathrm{typ}}(G)$ の多項式である．

Proof. $\widetilde{G}$ の非開始記号を頂点とし，二項規則で親から各子へ辺を張る依存有向グラフを作る．$\widetilde{G}$ は縮約済みなので任意の非開始記号 X は到達可能であり，ある開始子 A から X への経路がある．最短経路を選ぶと型付き記号を反復せず，辺数は高々 $N_t - 1$ である．

経路の各辺について，その辺を実現する二項規則を選び，経路外の子をその標準生成語へ展開する．$\widetilde{S} \to A$ から始めれば，これらの展開は X の終端到達文脈を与える．各経路外の標準生成語長は高々 τ なので文脈全長は $(N_t - 1)\tau$ 以下であり，標準文脈 (u_X, v_X) はそれより長くない．

第一族の語は標準文脈に標準生成語を一つ，第二族は終端記号を一つ，第三族は標準生成語を二つ加える．$\tau \ge 1$ だから，式 (2) の各語の長さは $(N_t + 1)\tau$ 以下である．さらに $N_t \le N|M|$ であり，元の終端規則から生じる型付き終端規則は高々一つ，元の各二項規則からは高々 $|M|^2$ 個の型付き規則が生じる．従って第一因子が λ の可能な証拠も含めた証拠個数を，第二因子が各 $|w| + 1$ を抑える．積をとれば主張が従う． □

系 6.2 (型付き厚みからの特徴データ)**.** h を固定する．G が非空な $L(G) \in \mathcal{C}_h^{\mathrm{cf}}$ の縮約済み *SSBNF* 文法なら，$\mathsf{W}(\widetilde{G})$ は $\mathcal{B}_h$ に対する特徴標本であり，その符号化サイズは $|G|$ と $\tau_h^{\mathrm{typ}}(G)$ の多項式である．

Proof. 定量上界は補題 6.1，特徴標本性は定理 5.4 による． □

型付き精密化による議論では，型付き厚みを一般に元文法の通常の厚みへ置き換えられない．このような表現依存性自体は CFG 学習で既知の現象である．Clark–Eyraud [9, Example 2] は，小さい文法でも正の特徴データに指数長の語が必要となる例を与えている．Yoshinaka [16] は fixed-window 設定で通常の文法厚みを明示的なパラメータとし，Eyraud–Heinz–Yoshinaka [22] も特徴データ基準の表現依存性を論じている．ここで必要なのはより限定された点であり，通常の元文法厚みを記録しても，本論文の fixed-h 再構成で用いる型付き精密化の最短生成語は大幅に長くなり得る．

命題 6.3 (元文法と型付き厚みの指数ギャップ)**.** 固定された二元型付け h_{c} と，サイズ $O(n)$，通常の厚み 1 の縮約済み *SSBNF* 文法族 G_n^{c} が存在し，$\tau_{h_{\mathsf{c}}}^{\mathrm{typ}}(G_n^{\mathsf{c}}) \geq 2^n$ となる．従って，一つの固定型付けに限っても，型付き厚みを元文法サイズと通常の厚みの多項式で一般に上から抑えることはできない．

Proof. $M_{\mathsf{c}} = \{1, \zeta\}$ を零元 ζ をもつ二元モノイドとし，$h_{\mathsf{c}}(\mathsf{a}) = 1$, $h_{\mathsf{c}}(\mathsf{c}) = \zeta$ とする．$n \geq 1$ に対し，文法 G_n^{c} を

$$S_0 \to U, \quad U \to \mathsf{a} \mid \mathsf{c} \mid UU \mid E_n D, \qquad\qquad D \to \mathsf{c},$$
$$E_0 \to \mathsf{a}, \quad E_i \to E_{i-1}E_{i-1} \mid \mathsf{c} \quad (1 \leq i \leq n)$$

で定める．これはサイズ $O(n)$ の縮約済み SSBNF 文法であり，$L(G_n^{\mathsf{c}}) = \{\mathsf{a}, \mathsf{c}\}^+ \in \mathcal{C}_{h_{\mathsf{c}}}^{\mathrm{cf}}$ である．

まず，S_0, U, E_0 は a を，D, E_i $(i \geq 1)$ は c を生成できる．つまり，すべての非終端記号が長さ 1 の語を生成できるため，通常の厚みは $\tau_{G_n^{\mathsf{c}}} = 1$ である．

一方，型付き精密化で型 1 に制限すると，$h_{\mathsf{c}}(\mathsf{c}) = \zeta \neq 1$ なので，$E_i \to \mathsf{c}$ は使えない．また，積が 1 になるのは $1 \cdot 1$ だけである．従って帰納法により $L((E_i)_1) = \{\mathsf{a}^{2^i}\}$ となる．さらに $\widetilde{S} \to U_\zeta \to (E_n)_1 D_\zeta$ により $(E_n)_1$ はトリミング後も残る．よって型付き厚みは $\tau_{h_{\mathsf{c}}}^{\mathrm{typ}}(G_n^{\mathsf{c}}) \geq 2^n$ である．

□

この文法族の標的言語 $\{\mathsf{a}, \mathsf{c}\}^+$ 自体は n に依存しない．従って，この命題は特徴データに対する学習作用素非依存の下界ではない．ここでの役割は，通常の元文法厚みでは系 6.2 に現れる型付き精密化パラメータを制御できないことを示すことだけである．このため，一般 fixed-h の上界は型付き厚みによって記述する．

7　固定窓を超える多項式厚み付きデータ

固定 (k, ℓ)-代入可能文脈自由言語の多項式厚み付きデータ学習可能性は，Yoshinaka [16, Theorem 1] により既に示されている．そこでは (k, ℓ)-Greibach 正規形と特徴集合の評価 [16, Lemmas 2 and 7] を用いる．本節では代わりに，$\mathcal{B}_h$ で用いる型付き精密化の最短生成語長を抑える．固定窓と有限群値を併用する場合まで，同一の証明で扱える．特徴データの符号長評価は Yoshinaka [16] と Eyraud–Heinz–Yoshinaka [22, Definition 2.12] の多項式時間・厚み付きデータ同定（IPTtD）の意味であり，Yoshinaka の多項式次数の改善は主張しない．一般の h についてはこの制御が成り立たない（命題 6.3）．

$k, \ell \geq 0$ と有限群 Q への準同型 $g : \Sigma^* \to Q$ を固定し，$m := k + \ell$，$q := |Q|$，$t := h_{k,\ell} \times g$ とおく．

補題 7.1 (固定窓と有限群による型付き生成語の評価)**.** $G = (V, \Sigma, P, S_0)$ を縮約済み *SSBNF* 文法とし，$N := |V \setminus \{S_0\}| \geq 1$ とする．有限型付け h が $\ker t|_{\Sigma^+} \subseteq \ker h|_{\Sigma^+}$ を満たすなら，

$$\tau_h^{\mathrm{typ}}(G) \leq m + \big[1 + 2(m + q - 1)(m + 1)Nq\big]\tau_G.$$

Proof. 付録 付録 A を参照されたい． □

定理 7.2 (固定窓と有限群の精密化による多項式厚み付きデータ)**.** h, Σ を固定し，ある固定 k, ℓ と有限群準同型 g が $\ker(h_{k,\ell} \times g)|_{\Sigma^+} \subseteq \ker h|_{\Sigma^+}$ を満たすとする．非開始記号をもつ縮約済み *SSBNF*

文法 G で表される任意の非空 $L \in \mathcal{C}_h^{\mathrm{cf}}$ は，$\mathcal{B}_h$ に対し，$|G|$ と τ_G の多項式符号長の特徴標本 $\mathsf{W}(\widetilde{G})$ をもつ．

Proof. 補題 7.1 と系 6.2 を適用する．$\{\lambda\}$ だけの標的は別途扱う． □

Q を自明群とすれば固定窓の場合を含む．次の正規化で任意の縮約済み CFG 表現へ移す．

命題 7.3 (厚みを多項式的に保存する SSBNF 正規化)**.** 固定多項式 $q_{\mathrm{size}}, q_{\mathrm{thick}}$ が存在し，非空言語を生成する任意の縮約済み *CFG* G_* を多項式時間で同値な縮約済み *SSBNF* 文法 G へ変換でき，$|G| \le q_{\mathrm{size}}(|G_*|)$, $\tau_G \le q_{\mathrm{thick}}(|G_*|, \tau_{G_*} + 1)$ が成り立つ．

証明は付録 A.2 に与える．文法サイズと最短非空生成語を多項式に保つため，終端分離と二分化を非開始 λ-規則除去より先に行う．

系 7.4 (局所自明半群と有限群による通常厚み上界)**.** $h : \Sigma^* \to M$ を固定する．$h(\Sigma^+)$ が有限な局所自明半群と有限群の直積の *divisor*（部分半群の準同型像）であるとする．このとき，縮約済み *CFG* G_* で表される任意の非空 $L \in \mathcal{C}_h^{\mathrm{cf}}$ は，$\mathcal{B}_h$ に対して $|G_*|$ と τ_{G_*} の多項式符号長の特徴データをもつ．これには局所自明な正の像半群や有限群の型付けを含む．

Proof. 有限な局所自明半群 S，有限群 Q と，部分半群 $T \le S \times Q$，全射準同型 $\pi : T \twoheadrightarrow h(\Sigma^+)$ を取る．各文字 $a \in \Sigma$ に対して $t_a \in \pi^{-1}(h(a))$ を選び，$\varphi(a) = t_a$ から半群準同型 $\varphi : \Sigma^+ \to T$ を定める．すると $\pi \circ \varphi = h|_{\Sigma^+}$ である．φ と二つの射影を合成し，空語 λ をそれぞれの単位元に送るように拡張すると，モノイド準同型 $s : \Sigma^* \to S^1$ と $g : \Sigma^* \to Q$ が定まり，非空語 w に対し $h(w) = \pi(s(w), g(w))$ となる．正の像 $s(\Sigma^+)$ は局所自明なので，命題 3.5 からある固定 k, ℓ に対し $\ker h_{k,\ell}|_{\Sigma^+} \subseteq \ker s|_{\Sigma^+}$ が従う．よって $\ker(h_{k,\ell} \times g)|_{\Sigma^+} \subseteq \ker h|_{\Sigma^+}$．定理 7.2 と命題 7.3 を適用する． □

空標的は空特徴標本で扱う．多項式は固定型付けとアルファベットに依存してよい．divisor 条件の逆，可変の窓長や群に一様な上界，保守的逐次学習器の多項式データ保証は主張しない．

8 線形部分クラス

線形言語はちょうど 1 ターン・プッシュダウンオートマトンによって受理される [19, 23]．以下の正規化はその文法的対応物を与える．成功導出には一つの継続する非終端記号の経路があり，これを *spine* と呼ぶ．

命題 8.1 (linear-spine SSBNF 正規化)**.** 固定多項式 q_{lin} が存在し，非空言語を生成する任意の線形 *CFG* G を多項式時間で同値な縮約済み *SSBNF* 文法 $G_0 = (V_0, \Sigma, P_0, S_0)$ へ変換でき，$|G_0| \le q_{\mathrm{lin}}(|G|)$ である．さらに各二項生成規則は，$W_a \to a$ を満たすちょうど一つの新鮮な終端ラッパー子と，ちょうど一つのそれ以外の非終端子をもつ．

構成は付録 付録 B に与える．$\widetilde{G}_0$ を型付き精密化，$N_t := |\widetilde{V}_0 \setminus \{\widetilde{S}\}|$ とおく．各基礎非開始記号は高々 $|M|$ 個の型付きコピーをもつので $N_t \le |V_0 \setminus \{S_0\}|\,|M|$ である．

補題 8.2 (短い標準生成語)**.** $\widetilde{G}_0$ の任意の型付き非開始記号 X に対し $|\omega(X)| \le N_t$ である．従って

$\tau_h^{\mathrm{typ}}(G_0) \le N_t$ である．

証明は付録 付録 C に与える．

定理 8.3 (線形標的に対する多項式特徴データ)**.** h を固定する．線形 *CFG* G で表される任意の $L \in \mathcal{C}_h^{\mathrm{lin}}$ は，$\mathcal{B}_h$ に対し，$|G|$ の多項式で $\|\cdot\|$-サイズが抑えられる特徴標本をもつ．

Proof. $L = \emptyset$ と $L = \{\lambda\}$ では第 5 節の標本を用いる．それ以外では命題 8.1 の G_0 を取る．補題 8.2 から $\tau_h^{\mathrm{typ}}(G_0) \le N_t \le |V_0 \setminus \{S_0\}|\,|M|$ なので，系 6.2 により $|G_0| \le q_{\mathrm{lin}}(|G|)$ の多項式サイズの特徴標本を得る． □

定理 5.6 と合わせると，選んだ線形 CFG 表現を基準として，$\mathcal{C}_h^{\mathrm{lin}}$ の標的には多項式時間のバッチ再構成と多項式サイズの特徴データが得られる．これは de la Higuera [7, Theorem 2] の線形言語全体についての否定結果とは矛盾しない．本定理は固定 h に対する代入可能な部分クラスだけを対象とするからである．さらに逐次学習器 $\mathcal{A}_h$ に対する多項式データ保証は主張しない．

■非正則な線形 fixed-h 例． 直前の定理は，正則標的や既知の線形代入可能クラスに限定されない．

$$L_{\pm,e} := \{a^{2m} c b^{2m} : m \ge 0\} \cup \{a^{2m+1} d b^{2m+1} : m \ge 0\} \cup \{a^n e b^n : n \ge 0\}.$$

これは線形文法

$$S \to U_{\mathrm{ev}} \mid U_e, \quad U_{\mathrm{ev}} \to c \mid a U_{\mathrm{odd}} b, \quad U_{\mathrm{odd}} \to d \mid a U_{\mathrm{ev}} b, \quad U_e \to e \mid a U_e b$$

で生成される．添字 ev と odd は，対応する非終端記号自身の生成語長の偶奇ではなく，開始点から外側を包む a, b の対の個数の偶奇を表す．

c, d, e を**中心記号**と呼ぶ．

命題 8.4. 言語 $L_{\pm,e}$ は線形かつ非正則であり，ある有限モノイドへの準同型 h に対して $\mathcal{C}_h^{\mathrm{lin}}$ に属する．一方，*Clark–Eyraud* 代入可能ではなく，いかなる固定 $k, \ell \ge 0$ に対しても (k,ℓ)-代入可能ではない．

Proof. 線形性は表示文法から従う．有限型付けに関する代入可能性を示すため，

$$L_{\mathrm{all}} := \{a^n \xi b^n : n \ge 0,\ \xi \in \{c, d, e\}\}, \qquad Q := (aa)^* c (bb)^* \cup a(aa)^* d\, b(bb)^* \cup a^* e b^*$$

とおく．線形言語 L_{all} は非空因子の規約で Clark–Eyraud 代入可能である．中心記号を含まない因子は共通文脈から一意に決まり，中心記号を一つ含む因子 $a^i \xi b^j$ の分布は $i - j$ のみに依存する．従って自明な型付け h_0 に対し $L_{\mathrm{all}} \in \mathcal{C}_{h_0}^{\mathrm{lin}}$ である．Q は正規言語で $L_{\pm,e} = L_{\mathrm{all}} \cap Q$ だから，命題 3.2(ii) と線形言語の正規交差に関する閉包性により，Q を認識するある有限モノイド準同型 g について $L_{\pm,e} \in \mathcal{C}_{h_0 \times g}^{\mathrm{lin}}$ が従う．

また，$L_{\pm,e} \cap a^* e b^* = \{a^n e b^n : n \ge 0\}$ から非正則性が従う．因子 c, e は空文脈を共有するが，$(a,b) \in \mathcal{D}_{L_{\pm,e}}(e) \setminus \mathcal{D}_{L_{\pm,e}}(c)$ なので Clark–Eyraud 代入可能ではない．さらに $k, \ell \ge 0$ を固定し，$m_0 := \max\{1, k+\ell\}$, $w_e := a^k e b^\ell$, $w_c := a^k c b^\ell$ とおく．両因子は同じ長さ k の接頭辞と長さ ℓ の接尾辞をもち，文脈 $(a^{2m_0-k}, b^{2m_0-\ell})$ を共有する一方，$(a^{2m_0+1-k}, b^{2m_0+1-\ell}) \in \mathcal{D}_{L_{\pm,e}}(w_e) \setminus \mathcal{D}_{L_{\pm,e}}(w_c)$ である．従って固定窓代入可能性の反例基準より $L_{\pm,e} \notin \mathsf{KL}$ である． □

■四元型付けによる具体例． 上の正規フィルタによる証明では有限型付けの存在が示されたが，実際には四元型付けだけで十分である．$M_{\pm,e} := \{1, \kappa_{cd}, \kappa_e, 0\}$ を，1 が単位元で，すべての $\mu, \nu \in \{\kappa_{cd}, \kappa_e, 0\}$ に対して $\mu\nu = 0$ が成り立つモノイドとし，準同型 $h_{\pm,e} : \{a, b, c, d, e\}^* \to M_{\pm,e}$ を

$$h_{\pm,e}(a) = h_{\pm,e}(b) = 1, \qquad h_{\pm,e}(c) = h_{\pm,e}(d) = \kappa_{cd}, \qquad h_{\pm,e}(e) = \kappa_e \tag{3}$$

で定める．このとき $L_{\pm,e}$ は $\sim_{h_{\pm,e}}$-代入可能である．実際，中心記号を含まない非空因子は共通文脈から一意に決まる．$a^i e b^j$ の分布は $i - j$ のみに依存し，$\xi \in \{c, d\}$ に対する $a^i \xi b^j$ の分布は $(i - j, \mathrm{par}(\xi) - i \bmod 2)$ のみに依存する．ただし $\mathrm{par}(c) = 0$，$\mathrm{par}(d) = 1$ とする．共通文脈はそれぞれの不変量を一致させ，同じ $h_{\pm,e}$-型であることは e-因子と c/d-因子を区別する．従って，共通文脈をもつ同型の因子の分布は一致する．

従って定理 8.3 は KL の外にある非正則線形言語にも適用される．表示文法は even-linear なので，Takada の control-set 枠組みからの分離は主張しない．

■生成語型付けが誘導する有限状態制御． 次の標準的な有限状態の直積構成は，Takada の control-set の見方との限定的な接点を与える．線形文法 $G = (V, \Sigma, P, S)$ の各生成規則にアルファベット Π から相異なるラベルを与え，$\alpha \in \Pi^*$ が導出の生成規則ラベル列であるとき $A \Rightarrow_G^{\alpha} w$ と書く．$F \subseteq M$ に対し

$$C_{h,F}(G) := \{\alpha \in \Pi^* : S \Rightarrow_G^{\alpha} w \text{ for some } w \in \Sigma^*,\ h(w) \in F\}$$

とおく．これは正則制御集合である．実際，状態 $V \times M \times M$ と一つの受理状態をもつ有限オートマトンを用い，$(S, 1, 1)$ から開始する．ラベル付き規則 $A \to uBv$ に対して $(A, \mu_L, \mu_R) \mapsto (B, \mu_L h(u), h(v)\mu_R)$ と遷移し，終端規則 $A \to w$ では $\mu_L h(w) \mu_R \in F$ のときちょうど受理する．不変量は，文形式 uAv が $(A, h(u), h(v))$ に対応することである．従って受理されるラベル列は，終端生成語の h-型が F に属する成功導出のものとちょうど一致する．よって $C_{h,F}(G)$ による正則制御は $L(G) \cap h^{-1}(F)$ をちょうど生成する．任意の非終端記号 A から開始し $F = \{\mu\}$ とすれば，型付きコピー A_μ についても同じ解釈が得られる．これは Takada の正則制御言語 [18] への有限状態の橋を与えるが，任意の Takada control set が終端生成語型付けから得られるとは主張しない．

9　表現力と境界

ここでは fixed-window 階層と，より広い文脈自由言語族の間で本枠組みを位置づける．

9.1　RS 内の非線形標的

$\Delta := \{a^n b^n : n \geq 0\}$ とし Δ^* を考える．$z \in \{a, b\}^*$ に対し $\beta(z) := |z|_a - |z|_b$ と定め，接頭辞 p を読み終えた時点の**高さ**を $\beta(p)$ と呼ぶ．語 x の**許容進入高さ集合**を

$$\mathcal{Q}(x) := \{q \in \mathbb{Z}_{\geq 0} : q + \beta(x) \geq 0, \quad a^q x b^{q+\beta(x)} \in \Delta^*\}$$

と定める．これは Δ^* の語中に x が現れる際の直前の高さの集合に一致する．

例えば，$\mathcal{Q}(ab) = \mathbb{Z}_{\geq 0}$，$\mathcal{Q}(aa) = \mathbb{Z}_{\geq 0}$，$\mathcal{Q}(\lambda) = \mathbb{Z}_{\geq 0}$，$\mathcal{Q}(bb) = \mathbb{Z}_{\geq 2}$，$\mathcal{Q}(ba) = \{1\}$，$\mathcal{Q}(bbaa) = \{2\}$，$\mathcal{Q}(baaba) = \varnothing$ である．

この標準補完から，次の所属条件を得る：

$$w \in \Delta^* \iff \beta(w) = 0 \text{ かつ } 0 \in \mathcal{Q}(w). \tag{$\star$}$$

$\mathrm{fst}(w), \mathrm{lst}(w) \in \{\bot, a, b\}$ を最初と最後の記号（λ では $\bot$）とし，$\mathrm{ba}(w)$ で w が ba を含むかを二値で記録する．

$$h_\star(w) := (\mathrm{fst}(w), \mathrm{lst}(w), \mathrm{ba}(w)).$$

連接の要約は二因子の要約だけから決まる．端点は明らかな仕方で連接され，新しい ba は境界 $b|a$ でのみ生じ得る．従って有限像 $M_\star := h_\star(\{a,b\}^*)$ に $h_\star(x)h_\star(y) := h_\star(xy)$ と積を入れれば，$h_\star$ は有限モノイド準同型になる．

許容進入高さ集合は，右側に語を連接しても広がらず，次の連接公式が成り立つ：[*3]

$$\begin{aligned}\mathcal{Q}(st) = \mathcal{Q}(s) &\cap \{q \in \mathbb{Z} : q + \beta(s) \in \mathcal{Q}(t)\} \\ &\cap \begin{cases} \{-\beta(s)\}, & (\mathrm{lst}(s), \mathrm{fst}(t)) = (b, a), \\ \mathbb{Z}, & \text{それ以外.} \end{cases}\end{aligned} \tag{$\star\star$}$$

命題 9.1 (非線形 fixed-$h_\star$ 標的)**.** Δ^* は決定性文脈自由・非正則・非線形で，$\sim_{h_\star}$-代入可能である．さらにどの固定 $k, \ell \geq 0$ に対しても (k,ℓ)-代入可能ではない．従って $\Delta^* \in \mathsf{RS}_{h_\star}(\{a,b\}) \cap \mathrm{CFL}$ かつ $\Delta^* \in \mathsf{RS}(\{a,b\}) \setminus \mathsf{KL}(\{a,b\})$ である．

Proof. 文法 $S \to TS \mid \lambda,\ T \to aTb \mid \lambda$ は Δ^* を生成する．また決定性 PDA は，各ブロックの a 部分でスタックに記号を積み，続く b 部分でそれらを取り除き，スタックが底記号へ戻ったときにのみ次のブロックを開始できるようにすればよい．$\Delta^* \cap a^*b^* = \Delta$ から非正則であり，線形言語の正則交差に対する閉包性と $\Delta^* \cap a^*b^*a^*b^* = \Delta\Delta$ および $\Delta\Delta$ の非線形性から非線形である．後者は Autebert–Berstel–Boasson [23, Section 6.1, Theorem 6.1 の直前] に明記されている．

代入可能性を示す．同じ $h_\star$-型をもつ非空語 x, y が共通文脈 (u, v) をもつとする．直前の $\mathcal{Q}$ の特徴づけと β の加法性より，$uxv, uyv \in \Delta^*$ から $\beta(x) = \beta(y)$ および $\beta(u) \in \mathcal{Q}(x) \cap \mathcal{Q}(y)$ が従う．$h_\star(x) = h_\star(y)$ だから，x, y はともに ba を含むか，ともに含まない．

前者では，$x = rbat$ $(r, t \in \{a,b\}^*)$ と分解する．Δ^* の語では，ba が現れるたびに b の直後の高さが 0 になるため，任意の $q \in \mathcal{Q}(x)$ は $q + \beta(rb) = 0$ を満たす．従って $\mathcal{Q}(x)$ は高々一元集合であり，y についても同様である．一方，$\beta(u) \in \mathcal{Q}(x) \cap \mathcal{Q}(y)$ だから，$\mathcal{Q}(x) = \{\beta(u)\} = \mathcal{Q}(y)$ を得る．

後者では $x, y \in a^*b^*$ であり，各 $z \in \{x, y\}$ について $\mathcal{Q}(z) = \{q \in \mathbb{Z} : q \geq -\min\{0, \beta(z)\}\}$ である．既に示した $\beta(x) = \beta(y)$ から，直ちに $\mathcal{Q}(x) = \mathcal{Q}(y)$ が従う．

従って $\beta(x) = \beta(y)$ および $\mathcal{Q}(x) = \mathcal{Q}(y)$ が成り立つ．また，$h_\star$-型が一致するから $\mathrm{fst}(x) = \mathrm{fst}(y)$ および $\mathrm{lst}(x) = \mathrm{lst}(y)$ である．$(\star\star)$ を二度適用すると，任意の文脈 (u', v') に対して $\beta(u'xv') = \beta(u'yv')$ および $\mathcal{Q}(u'xv') = \mathcal{Q}(u'yv')$ を得る．ゆえに $(\star)$ より $u'xv' \in \Delta^*$ と $u'yv' \in \Delta^*$ は同値である．すなわち $\mathcal{D}_{\Delta^*}(x) = \mathcal{D}_{\Delta^*}(y)$ である．

固定窓からの分離として k, ℓ を固定し，$m := \max\{1, k+\ell\}$，$x := a^m b^m$，$y := a^m b^m a^m b^m$ とおく．両者は同じ長さ k の接頭辞と長さ ℓ の接尾辞をもち，空文脈を共有する．さらに $axb \in \Delta^*$ だ

[*3] 実際，st を高さ q から読む際の条件は，s 内の条件 $q \in \mathcal{Q}(s)$，t 内の条件 $q + \beta(s) \in \mathcal{Q}(t)$，および境界 $s|t$ の条件に分かれる．境界が $b|a$ のときに限り，Δ^* の語では b の直後の高さが 0 でなければならないため，$q + \beta(s) = 0$ が必要となる．これらの条件は十分でもあるから，公式が従う．

が，ayb の中央の ba は高さ 1 なので $ayb \notin \Delta^*$ である．従って固定窓代入可能性の反例基準から，Δ^* はどの (k,ℓ) にも属さない． □

従って fixed-h 枠組みは，固定窓階層の外にある第 8 節の非正則線形例 $L_{\pm,e}$ と，非線形文脈自由言語 Δ^* の双方を含む．control-set 法一般との分離は主張しない．

9.2 上限制約つき正則カウンタ族

正則言語 $L_0 = ae^*ce^*a \cup ae^*de^*a \cup be^*ce^*b$ による固定窓階層からの分離は Yoshinaka [16, Proposition 1] によって既に示されている．以下の族は，第 9.3 節の無界カウンタに対する有限状態の capped 版として残す．

$\Sigma_c := \{\uparrow, \downarrow, \#\}$ とする．$w = \delta_1 \cdots \delta_n \in \Sigma_c^*$ に対し，$\mathrm{ht}_i(w)$ を先頭 i 文字を読んだ後の高さとする．$\mathrm{ht}_0(w) = 0$ とし，$\uparrow$ で $+1$，$\downarrow$ で -1，$\#$ で 0 にリセットする．$\rho \geq 1$ に対し

$$\mathrm{CTR}_\rho := \{w \in \Sigma_c^* : 0 \leq \mathrm{ht}_i(w) \leq \rho \text{ for all } 0 \leq i \leq |w|\}$$

とおく．

任意の $\rho \geq 1$ に対し CTR_ρ は正則である．実際，決定性有限オートマトンが高さ $0, \ldots, \rho$ を記録し，範囲外に一つの sink を置き，$\#$ で 0 に戻ればよい．従って命題 3.1 から $\mathrm{CTR}_\rho \in \mathsf{RS}(\Sigma_c)$ となる．

定理 9.2. 任意の $\rho \geq 2$ に対し CTR_ρ はどの $k, \ell \geq 0$ についても (k,ℓ)-代入可能ではない．

Proof. k, ℓ を固定し $x := (\uparrow\downarrow)^k \uparrow^{\rho-1} \#^\ell$，$y := (\uparrow\downarrow)^k \uparrow^\rho \#^\ell$ とおく．両者は固定窓基準に十分長く，同じ長さ k の接頭辞と長さ ℓ の接尾辞をもち，ともに CTR_ρ に属する．一方 $\uparrow x \in \mathrm{CTR}_\rho$ だが $\uparrow y \notin \mathrm{CTR}_\rho$ で，後者は高さ $\rho + 1$ に達する．従って分布が異なり，反例基準が適用できる． □

境界 $\rho \geq 2$ は最良である[*4]．

任意の $\rho \geq 1$ について，上の DFA が誘導する遷移モノイド準同型を $h_\rho : \Sigma_c^* \to M_\rho$ とする．これは CTR_ρ を認識するので，すべての $\rho \geq 1$ に対して $\mathrm{CTR}_\rho \in \mathcal{C}^{\mathrm{cf}}_{h_\rho}$ が成り立つ．一方，$\mathrm{CTR}_\rho \notin \mathsf{KL}$ という強い結論が成り立つのは $\rho \geq 2$ の場合である．この capped family は新しい正則分離ではなく，下の無界言語 CTR と対比するためのものである．

9.3 RS の外にある自然な決定性文脈自由言語

補題 9.3 (有限モノイド障害)**.** $L \subseteq \Sigma^*$ とする．無限集合 $\Xi \subseteq \Sigma^+$ が存在し，相異なる任意の $x, y \in \Xi$ について $\mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \emptyset$ かつ $\mathcal{D}_L(x) \neq \mathcal{D}_L(y)$ が成り立つなら $L \notin \mathsf{RS}(\Sigma)$ である．

Proof. 有限 h は Ξ の二要素を同一視する．その二語は共通文脈をもち分布が異なるので $\sim_h$-代入可能性に反する． □

上限を外すと決定性文脈自由言語

$$\mathrm{CTR} := \{w \in \Sigma_c^* : \mathrm{ht}_i(w) \geq 0 \text{ for all } 0 \leq i \leq |w|\}$$

[*4] 実際，CTR_1 は $(1,1)$-代入可能である．その所属条件は，先頭文字が $\downarrow$ でないこと，および長さ 2 の因子 $\uparrow\uparrow, \downarrow\downarrow, \#\downarrow$ が現れないことだけで記述できる．したがって共通文脈をもつ許容された非空因子については，先頭文字と末尾文字が等しければ，任意の文脈での所属可否は一致する．

を得る．これは reset 付きの明らかな決定性プッシュダウン・カウンタで受理される．

系 9.4 (上限なしカウンタの障害)**.** $\mathrm{CTR} \notin \mathsf{RS}(\Sigma_c)$ である．

Proof. $\Xi = \{\uparrow^i : i \geq 1\}$ を用いる．$i < j$ なら $(\lambda, \downarrow^i)$ は共通文脈だが，$(\lambda, \downarrow^j)$ は $\uparrow^j$ だけの文脈である． □

一種類の括弧の Dyck 言語

$$D_1 := \{w \in \{a,b\}^* : |w'|_a \geq |w'|_b \text{ for every prefix } w',\ |w|_a = |w|_b\}$$

は標準的な決定性文脈自由言語 [24] である．ここでの D_1 は Dyck 言語全体を表し，Autebert–Berstel–Boasson [23] の規約では D_1^* と書かれる．

系 9.5. $D_1 \notin \mathsf{RS}(\{a,b\})$ である．

Proof. $\Xi = \{b^i a^i : i \geq 1\}$ を用いる．$i < j$ なら (a^j, b^j) は共通文脈だが，(a^i, b^i) は $b^i a^i$ だけの文脈である．$b^j a^j$ では接頭辞 $a^i b^j$ がアンダーフローを起こす． □

従って障害は無界スタック挙動それ自体ではない．非正則 1-turn 言語 $L_{\pm,e}$ は RS に属する．障害は，文脈的挙動が異なるにもかかわらず相互に比較可能な因子が無限族をなし，有限 h ではそれらをすべて分離できないことである．

補題 9.6 (固定語による商)**.** L が $\sim_h$-代入可能で $z \in \Sigma^*$ なら，$L/z := \{w : wz \in L\}$ も $\sim_h$-代入可能である．

Proof. L/z の共通文脈 (u, v) は L では (u, vz) になる．L で分布が等しいなら，任意の文脈 (s, t) の右に z を付加することで L/z に分布等式を移せる． □

$S \to aSS \mid b$ が生成する言語を *Łukasiewicz* **言語**と呼ぶ．Yoshinaka [16, Section 3] はすでに，この言語がどの固定 k, ℓ に対しても (k,ℓ)-代入可能でないことを指摘している．本論文の記法では $L_{\mathrm{Luk}} = D_1 b$ [23] で，これは決定性文脈自由言語でもある [24]．ここでは右商の議論により，さらに強く有限型付け全体の和の外にあることを示す．もし $L_{\mathrm{Luk}} \in \mathsf{RS}(\{a,b\})$ なら補題 9.6 により $D_1 = L_{\mathrm{Luk}}/b \in \mathsf{RS}$ となり，系 9.5 に反する．

9.4 Clark の congruential family との比較

Clark [25] は有限初期集合 $I \subseteq V$ を許し，$L_G[I] := \bigcup_{A \in I} L_G(A)$ と書く．このような文法が *congruential* であるとは，各 $L_G(A)$ が $L_G[I]$ の一つの構文合同類に含まれることをいう．Γ 上の congruential grammar が生成する言語全体を $\mathsf{CONG}(\Gamma)$ と書く．Clark はすでに substitutable および (k,ℓ)-substitutable language をこの族に位置づけている．次の命題はこの包含をすべての fixed-h slice へ拡張する．

命題 9.7 (Clark の congruential family との比較)**.** 任意の有限アルファベット Γ と有限モノイド準同型 $h : \Gamma^* \to M$ に対して $\mathcal{C}_h^{\mathrm{cf}} \subseteq \mathsf{CONG}(\Gamma)$ である．従って $\mathsf{RS}(\Gamma) \cap \mathrm{CFL} \subseteq \mathsf{CONG}(\Gamma)$ であり，$\Gamma = \{a,b\}$ ではこの包含は真である．

Proof. 非空 $L \in \mathcal{C}_h^{\mathrm{cf}}$ の縮約済み SSBNF 文法と型付き精密化 $\widetilde{G}$ を取る．任意の非開始型付き記号 $X = A_\mu$ は終端到達文脈 (u, v) をもち，命題 5.2 より任意の $w \in L_{\widetilde{G}}(X)$ は非空かつ $h(w) = \mu$ である．従って $x, y \in L_{\widetilde{G}}(X)$ は同じ型と共通文脈 (u, v) をもち，fixed-h 代入可能性から $x \equiv_L y$ となる．すなわち各型付き非終端記号は一つの構文合同類の語だけを生成する．

分離された開始記号を削除し，その型付き後続記号を有限初期集合として用いる．$\lambda \in L$ なら λ だけを生成する新しい初期記号を一つ加える．命題 5.2 により，これで L の congruential grammar が得られる．空言語は生成規則をもたない初期記号で扱える．h 全体に和を取れば包含が従う．

$\{a, b\}$ 上で包含が真であることには，Clark [25] も論じる Dyck 例を用いる．任意の $x \in D_1$ に対し $uxv \in D_1$ iff $uv \in D_1$ なので $x \equiv_{D_1} \lambda$ である．従って $S \to aSbS \mid \lambda$ は congruential だが，系 9.5 より $D_1 \notin \mathsf{RS}(\{a, b\})$ である． □

10　結論

固定した h の下で，多項式時間の集合駆動型再構成と保守的な Gold 同定を分離して与えた．有限個の標準正例証拠により，型付き厚みによる特徴データ上界が得られる．正の像半群が局所自明有限半群と有限群の直積の divisor（その直積の部分半群の準同型像）である場合は通常の文法厚みで十分であり，線形標的では文法サイズによる上界が得られる．型付き厚みの指数ギャップが制限するのは，この精密化に基づく解析であり，一般の学習アルゴリズムそのものではない．

有限型付けを精密化してよいなら，積型付けによって正則フィルタと消去を許す任意の逆準同型像を扱える．これは単一の fixed-h slice の閉包性ではなく，有限情報の合成可能性を表す．局所自明性の古典的判定条件から固定窓クラスの和が回復される．非正則線形・非線形の例は固定窓を超える表現力を示す一方，カウンタ・Dyck 言語に関する障害と，Clark の congruential family への真の包含が本枠組みの限界を示す．未解決問題として，$\mathsf{RS} \cap \mathrm{CFL}$ の特徴づけ，非正則標的に対する $\mathcal{C}_h^{\mathrm{lin}}$ の範囲，有用な型付けの選択方法，およびプッシュダウンオートマトンによる直接的な特徴づけが挙げられる．

データ利用可能性

本研究では実証データを使用していない．

利益相反の申告

著者は，本論文で報告した研究に影響を与えたと考えられる既知の競合する金銭的利害関係または個人的関係がないことを申告する．

研究費

本研究は，公的機関，民間企業，または非営利部門のいずれの資金配分機関からも特定の助成を受けていない．

謝辞

著者は，指導・励まし・関連文献への助力をいただいた金澤誠教授と吉仲亮教授，ならびに本論文を大幅に改善する丁寧で建設的な報告をくださった二名の匿名査読者に感謝する．特に査読者は，投稿版の学習アルゴリズムの問題点を指摘し，定理 9.2 の直接的な二語反例を促してくださった．残る誤りはすべて著者の責任である．

付録 A　固定窓証拠語上界と厚み保存正規化

A.1　補題 7.1 の証明

補題 *7.1* の証明. $m = k + \ell$，$q = |Q|$，$N = |V \setminus \{S_0\}|$ とおく．まず非開始記号 A と非空な $L_G(A) \cap t^{-1}(\{\eta\})$ の各組について最短語 w を評価する．A からの導出木の節点は非終端記号の出現とし，終端規則 $B \to a$ を使う非終端節点を葉とする．各節点は非開始記号をもち，生成語は非空である．$m > 0$ で η の窓成分が短語型なら $|w| < m$ である．以下では $|w| \geq m$ とする（$m = 0$ も含む）．w の二分導出木 T を固定する．最初の k 位置と最後の ℓ 位置を保護し，その和集合を P とする．一方が空でもよく，$|P| = m$ である．各節点 z の生成語の位置区間を $I(z)$，生成語を $y(z)$，非終端ラベルを $B(z)$，保護位置集合を $M(z) := I(z) \cap P$ と書く．$M(z) \neq \varnothing$ または $|y(z)| > \tau_G$ である節点を**重要節点**と呼び，その集合を E とする．親へ向かうと印集合と生成語長は減少しないため，E 自体が祖先閉である．

高さ．一つの祖先鎖上の $M(z)$ は包含関係で減少し，高々 $m + 1$ 種類の値しか取らない．異なる祖先・子孫の重要節点で $(M(z), B(z), g(y(z)))$ が一致するとき，上側の部分木を下側の部分木で置換できる．生成語長は真に短くなり，等しい印集合は保護位置を，等しい群値は $g(w)$ を保存する．これは t-型についての最短性に反する．従って重要節点の祖先鎖は高々

$$H := (m + 1)Nq$$

個の節点を含む.

幅．E の反鎖 F を取る．P と交わる節点は高々 m 個である．その他に q 個あるとして左から右へ $z_1, \dots, z_q$ と並べる．これらは保護位置を含まず，生成語 $a_i := y(z_i)$ はすべて $|a_i| > \tau_G$ である．$B(z_i)$ から長さ τ_G 以下の生成語 b_i を選ぶ．$g(a_i) = g(b_i)$ ならその節点だけを短縮でき，矛盾する．そうでなければ

$$d_i := g(p_i)\, g(b_i) g(a_i)^{-1} g(p_i)^{-1} \neq 1_Q$$

とおく．ただし p_i は**元の語** w での a_i に先行する接頭辞である．添字集合 $J = \{i_1 < \cdots < i_r\}$ に属する部分木を同時に置換すると，昇順の積 $\prod_{i \in J}^{\rightarrow} d_i := d_{i_1} \cdots d_{i_r}$ を用いて，群値は $\big(\prod_{i \in J}^{\rightarrow} d_i\big) g(w)$ に変わる．右側から展開すれば置換時の元の接頭辞 p_i が保存されているためで，群の可換性は不要である．$q + 1$ 個の群元 $1_Q, d_1, d_1 d_2, \dots, d_1 \cdots d_q$ の二つが一致するので，空でない連続添字区間 J に対して $\prod_{i \in J}^{\rightarrow} d_i = 1_Q$ を得る．対応する部分木を置換すると t-型を保って語長を短くでき，最短性に反する．よって反鎖の幅は高々

$$W := m + q - 1$$

である.

個数． E が占める深さの段数は高々 H であり，各段は反鎖なので $|E| \le WH$ となる．$E \neq \varnothing$ なら，保護位置以外の位置は極大な非重要部分木の生成語に分割され，その長さは各々 τ_G 以下である．これらは重要節点の子を根とするので高々 $2|E|$ 個である．保護位置以外の各位置には，保護位置を含まず長さ $1 \le \tau_G$ の非重要な終端規則の葉が対応する．保護位置 m 個は別に数える．$E = \varnothing$ の場合は根全体の生成語長が τ_G 以下である．従っていずれも

$$|w| \le m + (1 + 2|E|)\tau_G \le m + \big[1 + 2(m + q - 1)(m + 1)Nq\big]\tau_G.$$

これで精密化に残る非開始 t-型付き記号の上界を得る．非開始 h-型付き記号 A_μ に対し，命題 5.2 により存在する $w_0 \in L_G(A) \cap h^{-1}(\{\mu\})$ を選び，$\eta := t(w_0)$ とする．核の細分化条件から

$$L_G(A) \cap t^{-1}(\{\eta\}) \subseteq L_G(A) \cap h^{-1}(\{\mu\})$$

が従う．右辺の最短語は左辺のものより長くない．最大を取れば補題が従う． □

A.2 厚みを多項式的に保存する SSBNF 正規化

命題 *7.3* の証明. $G_* = (V, \Sigma, P, S)$ を縮約済みで非空言語を生成する文法とし，$n := |G_*|$, $\bar\tau := \tau_{G_*} + 1$ とおく．文法サイズと最短終端生成語をともに多項式に保つ順序で標準正規化を行う．

まず新しい開始記号 S_0 と規則 $S_0 \to S$ を導入し，$\lambda \in L(G_*)$ なら最終的に $S_0 \to \lambda$ を残す．長さ 2 以上の右辺に現れるすべての終端記号を新しいラッパー $W_a \to a$ で分離し，長さ 2 を越える右辺を二分化する．得られる文法を G_{bin} とする．選んだ妥当な符号化の下で，これらの操作の総サイズは $O(n)$ である．元の各非終端記号は同じ終端生成語言語を保つ．新たな各二分化記号は元のある右辺の連続部分を展開し，そこに含まれる元の記号数は高々 $O(n)$ である．その部分に現れる各生産的非終端記号を最短終端生成語で置き換えれば，ある定数 c_1 に対して $\tau_{G_{\mathrm{bin}}} \le c_1 n \bar\tau$ が得られる．

次に，G_{bin} の空語導出可能記号から得られる最短の **非空** 生成語を抑える．$A \Rightarrow^*_{G_{\mathrm{bin}}} w$ を非空終端語への導出とし，導出木の終端葉を一つ選んで根からの経路をたどる．同じ非終端記号が二度現れれば，上側の部分木を下側の部分木で置き換えてサイクルを削除できる．これを繰り返すと経路上の非終端記号数は高々 $|V_{G_{\mathrm{bin}}}|$ となる．各二項ノードで経路外の兄弟記号をその最短終端生成語へ置き換えると，空語導出可能な兄弟記号は空語を寄与してよく，選んだ終端葉が一文字を寄与するので，ある定数 c_2 に対して

$$\min\{\, |w| > 0 : A \Rightarrow^*_{G_{\mathrm{bin}}} w \,\} \le 1 + |V_{G_{\mathrm{bin}}}|\tau_{G_{\mathrm{bin}}} \le c_2 n^2 \bar\tau$$

である．

ここで非開始 λ-規則をすべて除去する．G_{bin} は二分文法なので，規則 $A \to BC$ から生じるのは，空語導出可能な子に応じて高々 $A \to BC$，$A \to B$，$A \to C$ であり，指数的な空語導出可能記号の部分集合に関する展開は起こらない．通常の構成は各非終端記号の非空終端生成語言語を保存するので，上の長さ上界も保たれる．続いて単位閉包を計算し，非開始単位規則を除去する．各出発非終端記号と，そこから単位規則だけで到達可能な各非単位規則について，その規則を出発非終端記号にコピーする．この段階の前には非終端記号が $O(n)$ 個，非単位規則も $O(n)$ 個なので，生成される規則は高々 $O(n^2)$ 個である．単位規則消去は各非終端記号の言語を保存するため厚み上界を増加させない．最後に無用記号をトリムする．

得られる文法は縮約済みで開始記号が分離され，各非開始規則は終端規則または二項規則であり，$S_0 \to \lambda$ が唯一の可能な λ-規則である．従って SSBNF である．そのサイズは n の多項式，厚みは高々 $c_2 n^2(\tau_{G_*}+1)$ であり，すべての変換は多項式時間で実行できる． □

付録 B　linear-spine SSBNF 正規化の証明

命題 8.1 の構成は，標準的な開始記号分離，無用記号・空語導出可能規則・単位規則の除去，および二分化を組み合わせ，第 8 節で必要な単一 spine 形を保存する．

命題 8.1 の証明. $L(G) = \{\lambda\}$ なら，単一規則 $S_0 \to \lambda$ をもつ縮約済み文法を取ればよい．二項生成規則をもたないので，要求される条件は自明に成り立つ．従って以下では，$L(G)$ が空でない語を含むと仮定する．

S を元の開始記号とする．右辺に決して現れない新しい S_0 を導入し，$S_0 \to S$ を加え，さらに $\lambda \in L(G)$ なら $S_0 \to \lambda$ も加える．以後 S は非開始記号として扱う．無用記号を除去し，λ を S_0 にのみ保存しつつ非開始 λ-規則を除去し，その後で非開始単位規則を除去する．開始規則には単位規則消去を適用しないので，最終トリミング後に残る各開始規則は，要求どおり $S_0 \to A$ または $S_0 \to \lambda$ の形になる．この順序により，λ-消去によって新たに生じた単位規則も除去される．入力文法は線形なので，各右辺には空語導出可能な非終端記号が高々一つしか現れず，各生成規則から追加される代替右辺は高々一つである．ここで線形性は二箇所で使われる．第一に，空語導出可能規則の展開を多項式に抑える．第二に，消去後も，残る各非単位右辺には非終端記号が高々一つしか現れないことを保証し，これが以下の「ラッパーでない子を一つだけ持つ」分解を可能にする．単位閉包とラッパー鎖による二分化そのものは，一般 CFG に対しても多項式時間の操作である．単位規則消去では有限な単位到達可能閉包を計算する．すなわち，出発非終端記号と，到達可能な非単位生成規則の各組は，高々一つの複製規則を生じる．従って生成規則数も右辺長の総和も多項式に保たれる．

新たな単位規則を作らずに二分化するため，新鮮な終端ラッパー $W_a \to a$ を導入する．規則 $A \to a_1 \cdots a_m B b_1 \cdots b_n$ に対し，単位規則を消去済みなので $m+n>0$ である．まず $R_0 := B$ とおき，$n>0$ のとき右側の鎖

$$R_j \to R_{j-1} W_{b_j} \qquad (1 \le j \le n)$$

を作る．途中の R_j は新しい記号とする．$m=0$ の場合は $R_n := A$ として，表示した最後の規則の左辺を A とする．$m>0$ の場合には $n>0$ なら R_n は新しい記号とし，$n=0$ なら $R_0 = B$ のままとする．次に $m>0$ なら $L_m := R_n$ とおき，新たな $L_1, \ldots, L_{m-1}$ を導入して

$$A \to W_{a_1} L_1, \qquad L_i \to W_{a_{i+1}} L_{i+1} \quad (1 \le i < m)$$

とする．$m=1$ の場合には $L_1 = R_n$ である．すべての規則は二項規則で，ちょうど一つの子が新鮮な終端ラッパーとなる．元の記号 B はラッパーではない．

終端記号のみからなる規則 $A \to a_1 \cdots a_m$ については，$m=1$ なら $A \to a_1$ を残す．$m \ge 2$ では新鮮な $\Theta_2, \ldots, \Theta_m$ を導入して

$$A \to W_{a_1} \Theta_2, \qquad \Theta_i \to W_{a_i} \Theta_{i+1} \quad (2 \le i \le m-1), \qquad \Theta_m \to a_m$$

とする（$m=2$ なら中間の規則族は空である）．従って新たな非開始規則は終端規則か，ちょうど一つのラッパー子と別の非終端子をもつ二項規則である．ラッパーは二項規則のラッパー子位置にのみ

現れ，継続する非終端子にはならない．終端のみの規則の構成は，終端規則をもつ新しい非ラッパー記号で終わる．最後のトリムはこの性質，分離開始形，縮約済み性を保存する．鎖への変換のサイズは，すでに多項式に抑えられた右辺長総和に対して線形なので，全体の構成は多項式時間で実行でき，文法サイズも多項式に抑えられる． □

付録 C　短い標準生成語補題の証明

補題 *8.2* の証明. 命題 8.1 の linear-spine SSBNF 形では，各二項 spine step は $A \to W_a B$ または $A \to B W_a$ の形で，$W_a \Rightarrow a$ だから，継続する非終端記号の外側にちょうど一つの終端記号を放出する．

X が終端ラッパーなら $|\omega(X)| = 1$ である．そうでなければ，型付き spine 記号 X からの最短終端導出を取り，spine を $X = X_0, X_1, \ldots, X_t$ と書く．X_t は終端規則を用い，生成語長は $t+1$ である．もし $X_i = X_j$（$i < j$）なら，二出現の間を削除して，より少ない spine step をもつ有効な導出を得られるので最短性に反する．従って $t+1$ 個の型付き spine 記号は相異なり，すべて非開始記号なので $t+1 \le N_t$ である．よって $|\omega(X)| \le N_t$ が従う． □

参考文献

[1] M. Kanazawa. *Learnable Classes of Categorial Grammars.* CSLI Publications, 1998.

[2] M. Kanazawa. Identification in the limit of categorial grammars. *Journal of Logic, Language and Information*, 5(2):115–155, 1996. doi:10.1007/BF00173697.

[3] E. M. Gold. Language identification in the limit. *Information and Control*, 10(5):447–474, 1967.

[4] J.-E. Pin. Syntactic semigroups. In G. Rozenberg and A. Salomaa (eds.), *Handbook of Formal Languages*, Vol. 1, pp. 679–746, Springer, 1997.

[5] S. Eilenberg. *Automata, Languages, and Machines*, Vol. A. Academic Press, 1974.

[6] J.-E. Pin. *Mathematical Foundations of Automata Theory.* Lecture notes, version of March 24, 2025. `https://www.irif.fr/~jep/PDF/MPRI/MPRI.pdf`.

[7] C. de la Higuera. Characteristic sets for polynomial grammatical inference. *Machine Learning*, 27:125–138, 1997.

[8] C. de la Higuera. *Grammatical Inference: Learning Automata and Grammars.* Cambridge University Press, 2010.

[9] A. Clark and R. Eyraud. Polynomial identification in the limit of substitutable context-free languages. *Journal of Machine Learning Research*, 8:1725–1745, 2007.

[10] M. Wakatsuki and E. Tomita. A fast algorithm for checking the inclusion for very simple deterministic pushdown automata. *IEICE Transactions on Information and Systems*, E76-D(10):1224–1233, 1993.

[11] T. Kuriyama. *Learning Algorithm for Relation-Substitutable Context-Free Languages.* arXiv:1409.6247, originally posted in 2014 (v3: November 2014). `https://arxiv.org/abs/1409.6247`.

[12] R. Yoshinaka. General perspective on distributionally learnable classes. In *Proceedings of the 14th Meeting on the Mathematics of Language (MoL 14)*, pp. 87–98, 2015.

[13] A. Clark and R. Yoshinaka. Distributional learning of context-free and multiple context-free grammars. In *Topics in Grammatical Inference*, Springer, 2016.

[14] F. Coste, G. Garet, and J. Nicolas. Locally substitutable languages for enhanced inductive leaps. In *Proceedings of the Eleventh International Conference on Grammatical Inference*, PMLR 21:97–111, 2012.

[15] F. Coste and J. Nicolas. Learning local substitutable context-free languages from positive examples in polynomial time and data by reduction. In *Proceedings of the 14th International Conference on Grammatical Inference*, PMLR 93:155–168, 2019.

[16] R. Yoshinaka. Identification in the limit of k, l-substitutable context-free languages. In *Grammatical Inference: Algorithms and Applications – ICGI 2008*, LNCS 5278, pp. 266–279, Springer, 2008. doi:10.1007/978-3-540-88009-7_21.

[17] Y. Takada. Grammatical inference for even linear languages based on control sets. *Information Processing Letters*, 28(4):193–199, 1988. doi:10.1016/0020-0190(88)90208-6.

[18] Y. Takada. Learning formal languages based on control sets. In K. P. Jantke and S. Lange (Eds.), *Algorithmic Learning for Knowledge-Based Systems*, LNAI 961, pp. 316–339, Springer, 1995. doi:10.1007/3-540-60217-8_15.

[19] S. Ginsburg and E. H. Spanier. Finite-turn pushdown automata. *SIAM Journal on Control*, 4(3):429–453, 1966. doi:10.1137/0304034.

[20] F. Coste, D. Fredouille, C. Kermorvant, and C. de la Higuera. Introducing domain and typing bias in automata inference. In *ICGI 2004*, LNAI 3264, pp. 115–126, Springer, 2004. doi:10.1007/978-3-540-30195-0_11.

[21] A. Clark. Learning trees from strings: A strong learning algorithm for some context-free grammars. *Journal of Machine Learning Research*, 14:3537–3559, 2013.

[22] R. Eyraud, J. Heinz, and R. Yoshinaka. Efficiency in the identification in the limit learning paradigm. In J. Heinz and J. M. Sempere (Eds.), *Topics in Grammatical Inference*, Springer, 2016. doi:10.1007/978-3-662-48395-4_2.

[23] J.-M. Autebert, J. Berstel, and L. Boasson. Context-free languages and pushdown automata. In G. Rozenberg and A. Salomaa (Eds.), *Handbook of Formal Languages*, Vol. 1, pp. 111–174, Springer, 1997.

[24] S. Ginsburg and S. A. Greibach. Deterministic context-free languages. *Information and Control*, 9:620–648, 1966.

[25] A. Clark. Distributional learning of some context-free languages with a minimally adequate teacher. In *Proceedings of ICGI 2010*, LNCS 6339, pp. 24–37, Springer, 2010. doi:10.1007/978-3-642-15488-1_4.