固定有限半群型付けの下での文脈自由言語の分布学習

Takayuki Kuriyama
独立研究者
growup.kuriyama@gmail.com

概要

非空因子を有限半群への固定準同型 $s : \Sigma^+ \to \mathsf{S}$ で型付けした文脈自由言語について，正例学習を研究する．多項式時間の集合駆動型作用素は，代入可能な標的を有限の正例証拠から再構成し，別の保守的学習器は非空標的を Gold の意味で極限同定する．特徴データの総符号長は，文法サイズと型付き最短生成語長の多項式で抑えられる．固定接頭辞 – 接尾辞窓と有限群値で型が決まる場合は通常厚みで十分であり，線形標的では線形文法のサイズだけで足りる．一方，固定二元半束型付けの下では，文法サイズと通常厚みがともに $O(n)$ の有限標的族にも指数長の特徴標本が必要となる．この下界は，当該固定型付けクラス全体に特徴標本をもつ任意の集合駆動型作用素にも及ぶ．型付けを変更したときの閉包性，固定窓を超える例，および Dyck 言語による障害により，本枠組みの範囲を明らかにする．

キーワード： 文法推論；文脈自由言語；分布学習；正例からの同定；有限半群

1 序論

1.1 背景と動機

Gold [1] は正例だけによる極限同定の限界を示した．分布学習は対象クラスを制限することで正の結果を得る．代表例は Clark–Eyraud の代入可能性 [2] と Yoshinaka の (k, ℓ)-代入可能性 [3] である．一般的な背景は de la Higuera [4]，相補的な範疇文法の正例学習は Kanazawa [5, 6] を参照されたい．

■先行研究との関係． 著者の 2014 年のプレプリント [7] は，可認識同値関係に相対化した代入可能性を導入し，Yoshinaka の一般的な多ソート signature 理論 [8] の公刊に先行する．固定半群準同型 $s : \Sigma^+ \to \mathsf{S}$ の非空語ファイバーは，型付き連接演算と語全体のソートへの昇格演算を備えた互いに素なソートとして表現できる．この特殊化により，正例からの極限同定，多項式時間の仮説更新，および型付き標的文法のサイズに関して個数が多項式の特徴証拠の存在は，Yoshinaka の一般理論 [8, Theorem 1 and Lemma 3] からすでに得られる．ただし，この具体的なソートの選択を Yoshinaka 自身の構成として帰属させるものではない．

以下の構成は固定有限半群型付けでの具体化であり，空規則・単位規則を含む直接的な完全性証明を与える．学習可能性・更新時間・証拠の個数そのものを独立の新規成果とは主張しない．本稿の中心は特徴データの**総符号長**，その多項式上界と指数下界，および有限型付けの代数的・表現力的帰結にある．局所自明半群による固定窓の特徴づけ自体は古典的である．

本論文では，この研究計画の可認識合同関係版を考える．$s : \Sigma^+ \to \mathsf{S}$ を有限半群への準同型と

し，$\sim_s := \ker s \subseteq \Sigma^+ \times \Sigma^+$ とする．$x \in \Sigma^*$ に対し $\mathcal{D}_L(x) := \{(u, v) : uxv \in L\}$ と書く．言語 L が $\sim_s$-**代入可能**であるとは，非空の x, y について $s(x) = s(y)$ かつ $\mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \emptyset$ ならば $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ が成り立つことをいう．文脈自由な $\sim_s$-代入可能言語のクラスを $\mathcal{C}_s^{\mathrm{cf}}$ と書き，これを *fixed-s slice* と呼ぶ．したがって，分布の完全な一致を要求するのは，固定された有限代数的比較の下ですでに一致する因子だけである．

例えば $\Sigma = \{a\}$，$L = \{a, aa\}$ を考える．$(\lambda, \lambda) \in \mathcal{D}_L(a) \cap \mathcal{D}_L(aa)$ であるが，$(a, \lambda) \in \mathcal{D}_L(a) \setminus \mathcal{D}_L(aa)$ である．したがって，L は Clark–Eyraud 代入可能でない [2, Section 6.1]．一方，長さの偶奇を記録する準同型 $s(a^n) = n \bmod 2$（値域 $\mathbb{Z}/2\mathbb{Z}$）を用いれば，a と aa は異なる型をもち，$L \in \mathcal{C}_s^{\mathrm{cf}}$ となる．

Σ^+ 上の有限指数半群合同関係，すなわち有限半群準同型の核は，有限型付けを与える．固定した s に対し，文脈自由性を仮定しないすべての $\sim_s$-代入可能言語のクラスを RS_s と書く．表現力の比較のため，$\mathsf{RS} := \bigcup_s \mathsf{RS}_s$ と定める．ここで s は Σ^+ 上の有限半群準同型全体を動く．すべての正則言語はこの和に属する．一方，本論文の学習結果は一つの s をクラス全体に固定した $\mathcal{C}_s^{\mathrm{cf}}$ だけを対象とし，RS 全体の学習可能性は主張しない．

一つの固定接頭辞 – 接尾辞窓と異なり，s は独立な有限状態の因子特徴を積によって組み合わせられる．このように有限型付けそのものを精密化してよいなら，正則フィルタとの交わりや，消去を許す任意の逆準同型像を，再び有限型付けの枠内で扱える（命題 3.2）．これは一つの fixed-s slice を同じ s のまま閉じるという主張ではない．代数的な判定条件で固定接頭辞 – 接尾辞窓が非空因子の型を決める場合を特徴づけ（命題 3.5），さらに有限群値を加えた型付けにも特徴データ上界を与える（系 7.5）．後述の非正則線形例と非線形例は固定窓を超える表現力を示し，カウンタや Dyck 言語に関する障害はその表現力の限界を示す．

s は終端因子に対する型付けバイアスであり，因子の出現位置の外側文脈は型に含めない [9]．正則制御集合との接点 [10, 11] は線形文法に限る（第 8 節）．

1.2 貢献と主要結果

有限半群型付け s は，標的言語ごとに与えられるのではなく，標的クラス $\mathcal{C}_s^{\mathrm{cf}}$ 全体に対する事前情報として固定され，正例データから推定する対象ではない．本稿では，集合駆動型の再構成作用素 Rec_s と，それとは別の保守的な Gold 学習器 Learn_s を与える．これらの定性的な学習保証と多項式時間性は，Yoshinaka の一般理論 [8] を，既知の部分語に基づく文法構成 [3] を用いて具体化したものであり，独立した新規成果として主張しない．以下の特徴データの上界は Rec_s に関するものであり，Learn_s に対する逐次的な多項式データ保証は主張しない．本稿の主要な貢献は次の通りである．

(1) **有限型付けに伴う特徴データの定量的負担．**任意の固定 s について，標準化された文法における型付き最短生成語長から，特徴データの総符号長を抑えられる（系 6.3）．s が固定長の接頭辞・接尾辞窓と有限群の値から決まる場合には，元の縮約済み CFG のサイズと通常の最短生成語長に基づく厚みで十分である（系 7.5）．同値な代数的条件は，正語像 $s(\Sigma^+)$ が局所自明有限半群と有限群の直積の部分半群の準同型像となることであり，この半群のクラスを $\mathbf{LI} \vee \mathbf{Grp}$ と書く．線形標的に対しては，任意の線形 CFG のサイズだけで十分である（定理 8.3）．なお，固定窓の場合の特徴データの総符号長に関する多項式上界は，Yoshinaka [3, Theorem 1] によって既に得られている．

これとは対照的に，固定した二元半束型付けの下では，サイズと通常厚みがともに $O(n)$ の縮約済み文法で表される有限標的 L_n であっても，すべての特徴標本が長さ $3\cdot 2^n - 2$ の語 w_n^* を含まなければならない．この下界は，同じ固定型付けクラスに属する L_n と $L_n^- := L_n \setminus \{w_n^*\}$ の双方について特徴標本をもつ任意の集合駆動型作用素に成立する（命題 6.4）．L_n は自明型付けの下では多項式長の特徴データをもつ．

(2) **表現力の範囲と限界．** あらゆる固定窓クラスの外側にある非正則な線形標的（命題 8.4）と非線形標的（命題 9.1）を構成する．また，上限のないカウンタ言語 CTR と一種類の括弧による Dyck 言語 D_1 は，RS の外側にあることを示す（第 9.3 節）．さらに，文脈自由な固定型付けクラスが Clark の合同的言語族に含まれることを示す（命題 9.7）．

型付けの変更に関する初等的閉包性と，固定窓型付けの古典的な特徴づけは，第 3 節に記録する．

2 準備

Σ を有限アルファベットとし，Σ^* を単位元 λ をもつ自由モノイドとする．また $\Sigma^+ := \Sigma^* \setminus \{\lambda\}$ とおく．対 $(u, v) \in \Sigma^* \times \Sigma^*$ を **終端文脈** と呼ぶ．$L \subseteq \Sigma^*$ と $x \in \Sigma^*$ に対し，L における x の **分布** を $\mathcal{D}_L(x) := \{(u, v) \in \Sigma^* \times \Sigma^* : uxv \in L\}$ と定める．L の **構文合同関係** は，$x, y \in \Sigma^*$ に対して $x \equiv_L y \iff \mathcal{D}_L(x) = \mathcal{D}_L(y)$ により定める．$x \equiv_L y$ のとき，x と y は **構文合同** であるという [12, Chapter III, Proposition 10.2]．通常通り，$\equiv_L$ はモノイド合同であり，$x \equiv_L x'$ かつ $y \equiv_L y'$ ならば $xy \equiv_L x'y'$ である．

語 $w \in \Sigma^*$ と文字 $a \in \Sigma$ に対し，$|w|_a$ は w における a の出現回数を表す．

文脈自由文法（CFG）は有限非終端記号集合 V，開始記号 $S \in V$，および $A \in V$, $\alpha \in (V \cup \Sigma)^*$ に対する生成規則 $A \to \alpha$ からなる組 $G = (V, \Sigma, P, S)$ である．**文形式**とは $(V \cup \Sigma)^*$ の任意の語である．G における一段階導出を $\alpha \Rightarrow_G \beta$ と書き，その反射推移閉包を $\Rightarrow_G^*$ と書く．したがって $L(G) := \{w \in \Sigma^* : S \Rightarrow_G^* w\}$．$A \in V$ に対して $L_G(A) := \{w \in \Sigma^* : A \Rightarrow_G^* w\}$ とおく．非終端記号 $X \in V$ に対し，$S \Rightarrow_G^* uXv$ が成り立つとき，終端文脈 (u, v) を G における X の **終端到達文脈** と呼ぶ．非終端記号が S から到達可能な文形式中に現れるとき **到達可能** であるといい，終端語を導出するとき **生産的** であるという．到達可能性または生産性の少なくとも一方を欠く非終端記号を **無用** といい，λ を導出する非終端記号を **空語導出可能**（*nullable*）という．$A, B \in V$ に対する生成規則 $A \to B$ を **単位規則** という．**単位閉包**とは，単位生成規則が非終端記号上に誘導する関係の反射推移閉包である．すべての非終端記号が到達可能かつ生産的である文法を **縮約済み** という．非空言語を生成する文法について，その **トリム**（縮約部分）とは，まず生産的でない非終端記号とそれらに接続する生成規則を削除し，次に残った文法で開始記号から到達不能な非終端記号とそれらに接続する生成規則を削除して得られる部分文法をいう．各右辺に高々一つの非終端記号しか現れない CFG を **線形** という．**二分化**とは，新たな非終端記号を用いて長い右辺を同値な二項生成規則の鎖へ置き換えることをいう．CFL を文脈自由言語全体のクラスとする．任意の有限表現 $\mathcal{R}$ に対し，$|\mathcal{R}|$ は固定した妥当な符号化の長さを表すものとする．文法については，これは通常の生成規則中の記号数と多項式の範囲で同値である．ここでは Wakatsuki–Tomita [13] が用い，Yoshinaka [3] が採用した最短生成語に基づく**厚み**を用いる（Eyraud–Heinz–Yoshinaka [14, Definition 2.11] も参照）．縮約済

み文法を $G = (V, \Sigma, P, S)$ として

$$\tau_G := \max_{A \in V} \min\{\, |w| : A \Rightarrow_G^* w,\ w \in \Sigma^* \,\}$$

と定める．すなわち τ_G は，各非終端記号の最短終端生成語の長さを取り，その最大値をとったものである．

2.1 正例データからの学習

Gold の explanatory model [1] を用いる．H_0 を，一つの開始記号をもち生成規則をもたない固定 CFG とし，$L(H_0) = \emptyset$ とする．以下のテキスト規約は非空の標的言語に限定する．空言語はこのテキストに基づく Gold の記述から除外し，別途 H_0 により表す．同値に，通常の pause 記号をテキストに加えることで空標的を含めることもできるが，余分な記法を避けるためにここでは非空テキスト規約を用いる．非空言語 L に対し，**テキスト**とは，L の各語が少なくとも一度は現れる L 上の無限列 $\mathcal{T} = (w_1, w_2, \ldots)$ である．$\mathcal{T}[n] = (w_1, \ldots, w_n)$ および $K_n := \{w_1, \ldots, w_n\}$ と書く．学習器 Learn が非空言語 L を **極限同定**するとは，L の任意のテキスト $\mathcal{T}$ に対して，ある n_0 と文法 H が存在し，すべての $n \geq n_0$ について $\mathsf{Learn}(\mathcal{T}[n]) = H$ かつ $L(H) = L$ が成り立つことをいう．したがって，仮説表現そのものが最終的に安定する．逐次学習器が **保守的** であるとは，新たに提示された正例データが現在の仮説によって生成されない場合にのみ，その現在の仮説を変更することをいう．

この逐次学習器とは別に，**集合駆動型再構成作用素** Rec を考える．これは有限語集合から文法への写像であり，とくにその出力は提示順序や重複回数に依存しない．任意の有限標本 K に対して $K \subseteq L(\mathsf{Rec}(K))$ が成り立つとき，Rec は **標本整合的** であるという．有限集合 $\mathcal{F} \subseteq L$ が L の Rec に対する **特徴標本** であるとは，任意の有限 K について $\mathcal{F} \subseteq K \subseteq L$ ならば $L(\mathsf{Rec}(K)) = L$ が成り立つことをいう．これは de la Higuera の多項式文法推論枠組み [15] の特徴標本に対応する．学習器に相対的な特徴標本とその符号化サイズについては [4, Section 7.3.3, Definition 7.3.3] も参照されたい．ただし同書の定義は逐次的提示に対するものであり，本論文の条件は明示的に集合駆動型である．標本サイズを $\|K\| := \sum_{w \in K} (|w| + 1)$ で測る[*1]．したがって λ も 1 を寄与する．以下では **特徴データ** という語を，特徴標本 $\mathcal{F}$ の符号化サイズ $\|\mathcal{F}\|$ の略称としてのみ用いる．定量的結果では，$\mathsf{Rec}(K)$ の多項式時間構成と，多項式に抑えられる特徴データサイズを組み合わせる．多項式更新時間と多項式特徴標本サイズは別の評価基準であり [4, Sections 7.3.2–7.3.3]，それらの一方だけから逐次的な多項式時間・データ同定は導けない．Eyraud–Heinz–Yoshinaka [14, Definitions 2.5 and 2.8] は，逐次的な多項式時間・データ同定と集合ベースの基準を区別する．前者では特徴標本を観測した時点で正しい仮説に到達し，その後は仮説が安定しなければならない．後者は，特徴標本 $\mathcal{F} \subseteq L$ を含み，$\mathcal{F} \subseteq K \subseteq L$ を満たす任意の有限正例標本 K から正しく再構成できることを要求する．本論文の多項式特徴データ保証は，第 4.1 節で定義する集合駆動型の Rec_s に対するものであり，第 4.2 節で定義する逐次学習器 Learn_s の多項式データ保証ではない．後者の Gold 安定化は系 5.4 で別途示す．

[*1] $+1$ は，$K = \{\lambda\}$ のような非空標本のサイズが 0 になることを防ぐ．また $|K| \leq \|K\|$ となるため，正例数も同じサイズ尺度で抑えられる．

2.2 固定有限半群型付け

有限半群 S と全射半群準同型 $s : \Sigma^+ \twoheadrightarrow \mathsf{S}$ を固定する．S の乗法表と各 $a \in \Sigma$ の像 $s(a)$ を入力の固定情報とする．非空語に対する $s(w)$ は左から右への積により $O(|w|)$ 時間で求まる．全射性は一般性を失わない．任意の有限半群型付けは正の像半群へ終域を制限できるからである．後で直積や逆準同型像から非全射の型付けが得られる場合も，新単位元付加の前に終域を正の像半群へ制限するという規約を採用する．以下，特記しない限りアルファベットは非空とする．$\Sigma = \emptyset$ の場合，標的言語は $\emptyset$ または $\{\lambda\}$ のみであり，従来の学習器が直接処理できる．

有限半群 T の冪等元を $e^2 = e$ を満たす元とし，その集合を $E(\mathsf{T})$ と書く．すべての $e \in E(\mathsf{T})$, $t \in \mathsf{T}$ について $ete = e$ が成り立つとき T を**局所自明**と呼ぶ．非空有限半群は冪等元を持つ．従って有限半群の全射準同型によって局所自明性は保存される．実際，像の冪等元の逆像部分半群は冪等元を持つからである．

定義 2.1 (固定-s 代入可能性)**.** 言語 $L \subseteq \Sigma^*$ が $\sim_s$-代入可能 であるとは，すべての $x, y \in \Sigma^+$ について，$s(x) = s(y)$ と $\mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \varnothing$ から $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ が従うことをいう．

補題 2.2 (有限半群への標準的新単位元付加)**.** 有限半群 S に，すでに単位元がある場合もそれとは異なる新単位元 $\mathbf{1}_\sharp$ を付加して $\mathsf{S}^\sharp = \mathsf{S} \cup \{\mathbf{1}_\sharp\}$ とおく．このとき $s : \Sigma^+ \twoheadrightarrow \mathsf{S}$ は一意の全射モノイド準同型 $\widehat{s} : \Sigma^* \twoheadrightarrow \mathsf{S}^\sharp$ へ拡張され，

$$\widehat{s}(w) = \begin{cases} \mathbf{1}_\sharp, & w = \lambda, \\ s(w), & w \in \Sigma^+ \end{cases}$$

となる．さらに $\mathsf{S}^\sharp \cong \Sigma^* / \ker \widehat{s}$ である．ここで $\ker \widehat{s}$ は

$$\ker \widehat{s} = \{(x, y) \in \Sigma^* \times \Sigma^* : \widehat{s}(x) = \widehat{s}(y)\}$$

で定義される核合同を表す．特に

$$\widehat{s}(x) = \widehat{s}(y) \quad \Longleftrightarrow \quad (x = y = \lambda) \text{ または } (x, y \in \Sigma^+ \text{ かつ } s(x) = s(y))$$

が成立する．したがって定義 *2.1* は

$$\forall x, y \in \Sigma^*, \quad \big(\widehat{s}(x) = \widehat{s}(y) \wedge \mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \emptyset\big) \Longrightarrow \mathcal{D}_L(x) = \mathcal{D}_L(y)$$

と同値である．逆に，任意の有限モノイド型付け $h : \Sigma^* \to M$ は $s = h|_{\Sigma^+} : \Sigma^+ \to h(\Sigma^+)$ という有限半群型付けを与える．h による代入可能性も定義 *2.1* と同じく非空因子のみを比較する場合には，言語クラスも非空因子に関する再構成文法も変わらない．$h(\lambda)$ 型の非空因子と λ まで比較する別条件との同値性は主張しない．

Proof. 新単位元の積により $\widehat{s}$ は準同型となる．s が全射で，λ が $\mathbf{1}_\sharp$ へ写るため，拡張も全射である．$\mathbf{1}_\sharp \notin \mathsf{S}$ なので核の特徴づけが成立し，非空因子の比較と全因子での $\widehat{s}$-型の比較は同値となる．逆方向も，非空語上の型の等式だけが定義および再構成規則に使われることから従う． □

以下，代入可能言語族・再構成作用素・型付き厚みの添字は**非空語**上の半群準同型とする．任意のアルファベットに対する一元半群への唯一の型付けを s_0 と書く．正則言語の認識や空の文脈の計算

にモノイド準同型 $h : \Sigma^* \to M$ を使う場合は，その制限 $s = h|_{\Sigma^+}$ が学習バイアスである．nullable な生成語は補題 2.2 の $\widehat{s}$ で処理し，代数的条件は正語像に課す．

任意の $x \in \Sigma^*$ に対し，$\widehat{s}(x)$ をその **生成語型** と呼ぶ．非空語では $\widehat{s}(x) = s(x)$ である．文脈自由 $\sim_s$-代入可能言語のクラスを $\mathcal{C}_s^{\mathrm{cf}}$ と書き，$\mathcal{C}_s^{\mathrm{lin}} := \{L \in \mathcal{C}_s^{\mathrm{cf}} : L \text{ はある線形 CFG により生成される}\}$ と定める．したがって $\mathcal{C}_s^{\mathrm{lin}}$ は線形言語からなる部分クラスである．

3　固定可認識代入可能性

固定 s に対し $\mathsf{RS}_s := \{L \subseteq \Sigma^* : L \text{ は } \sim_s\text{-代入可能}\}$ とおく．fixed-s slice は $\mathcal{C}_s^{\mathrm{cf}} = \mathsf{RS}_s \cap \mathrm{CFL}$ であり，$\mathcal{C}_s^{\mathrm{lin}}$ はそのうち線形 CFG で生成される言語からなる．表現力の比較に限り，s を Σ^+ 上の有限半群準同型全体に動かして $\mathsf{RS} := \bigcup_s \mathsf{RS}_s$ とする．アルファベットを明示するときは $\mathsf{RS}_s(\Gamma)$, $\mathsf{RS}(\Gamma)$ と書き，以下の包含はアルファベットごとに解釈する．学習結果は常に一つの固定 s を対象とする．

命題 3.1. $L \subseteq \Sigma^*$ が正則であることと，ある有限半群型付け $s : \Sigma^+ \to \mathsf{S}$ と $\mathsf{Acc} \subseteq \mathsf{S}^\sharp$ に対して $L = \widehat{s}^{-1}(\mathsf{Acc})$ と書けることは同値である．この形で認識される言語は RS_s に属する．従ってすべての正則言語は RS に属する．

Proof. 正則言語の構文モノイド準同型 [12, Chapter III, Proposition 10.2] を非空語に制限し，終域を正の像半群へ縮小する．新単位元による拡張で，空語が L に属する場合かつその場合に限り $\mathbf{1}_\sharp$ を受理型に含めればよい．逆に有限モノイド準同型 $\widehat{s}$ で認識される言語は正則である．非空因子 x, y の s-型が等しければ，任意の文脈 u, v に対し $\widehat{s}(uxv) = \widehat{s}(uyv)$ なので $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ が成り立つ．□

非空アルファベット上では，RS も $\mathsf{RS} \cap \mathrm{CFL}$ も正例データから極限同定できない．命題 3.1 により両者はすべての有限言語と Σ^* を含むため，Gold の定理が適用されるからである．同様に Yoshinaka [3, Section 4] は，彼の設定では (k, ℓ)-代入可能な文脈自由言語クラス全体の和が正例から極限同定できないことを指摘している．その理由は，その和が λ を含まないすべての有限言語と少なくとも一つの無限言語を含むからである．以下で学習可能性を主張するのは，個別の $\mathcal{C}_s^{\mathrm{cf}}$ のみに対してである．

新単位元付加を用いると，有限半群型付け s, s', t の精緻化と直積を，モノイド合同の核として記述できる：

$$\ker \widehat{s'} \subseteq \ker \widehat{s} \iff \ker s' \subseteq \ker s, \qquad \ker \widehat{s \times t} = \ker \widehat{s} \cap \ker \widehat{t}.$$

ここで $\widehat{s \times t}$ は正の像半群 $(s \times t)(\Sigma^+)$ に新単位元を付加した拡張を表す．またその像は $\mathrm{im}(\widehat{s} \times \widehat{t})$ と同型であり，$\mathsf{S}^\sharp \times \mathsf{T}^\sharp$ の部分モノイドとなる．従って第一の包含の下で $\mathsf{RS}_s \subseteq \mathsf{RS}_{s'}$，また $\mathsf{RS}_s \cup \mathsf{RS}_t \subseteq \mathsf{RS}_{s \times t}$ が従う．ただし精緻化は定量的な型付き文法を大きくし得る．

Yoshinaka [3, Proposition 1] は，固定した k, ℓ に対する固定窓代入可能言語のクラスが，そのクラス内の二言語の交わりと，非消去準同型の逆像について閉じることを示した．同じ命題は，任意の正則言語との交わりや任意の逆準同型像に関しては閉じないことも示している．後者の反例では消去を用いる．ただし，文脈自由性も課した部分クラスは交わりについて一般には閉じないことにも注意する．命題 3.2 は，有限型付けを変更することで正則フィルタと消去を許す逆準同型像を扱えることを記録する．

命題 3.2 (有限情報に関する閉包性)**.** $s : \Sigma^+ \to \mathsf{S}$ と $t : \Sigma^+ \to \mathsf{T}$ を有限半群型付けとする．

(i) $L \in \mathsf{RS}_s$，$J \in \mathsf{RS}_t$ ならば $L \cap J \in \mathsf{RS}_{s\times t}$ である．

(ii) 任意の $\mathsf{Acc}_t \subseteq \mathsf{T}^\sharp$ に対し $R_{\mathrm{reg}} := \widehat{t}^{-1}(\mathsf{Acc}_t)$ とおく．$L \in \mathcal{C}_s^{\mathrm{cf}}$ ならば $L \cap R_{\mathrm{reg}} \in \mathcal{C}_{s\times t}^{\mathrm{cf}}$ である．

(iii) $\varphi : \Gamma^* \to \Sigma^*$ を消去的でもよい準同型とし，$r = (\widehat{s}\circ\varphi)|_{\Gamma^+} : \Gamma^+ \to \mathsf{S}^\sharp$ とおく．$L \in \mathsf{RS}_s$ ならば $\varphi^{-1}(L) \in \mathsf{RS}_r$ であり，$L \in \mathcal{C}_s^{\mathrm{cf}}$ ならば $\varphi^{-1}(L) \in \mathcal{C}_r^{\mathrm{cf}}$ である．[*2]

Proof. (i) は，共通文脈を持ち $(s\times t)$-型が等しい非空因子が，L と J のそれぞれで分布一致することから従う．(ii) は (i) と CFL の正則言語との交わりに関する閉包性による．(iii) の r はモノイド準同型 $\widehat{s}\circ\varphi$ の非空語への制限なので半群準同型である．同じ r-型を持つ非空因子 x, y の像は，双方が空語か，双方が非空で同じ s-型を持つかのいずれかである．前者では逆像の分布は直ちに一致し，後者では L における代入可能性と共通文脈の逆像から同じ結論が従う．CFL の逆準同型閉包性も用いる． □

■型付けの適合性とコスト． 補題 2.2 により，$L \in \mathsf{RS}_s$ であることと，共通文脈をもち分布が異なる因子対を $\ker\widehat{s}$ が区別することは同値である．従って型付けは有限指数モノイド合同による分離問題となる．精緻化と直積はこの条件を保つが，特徴データを指数的に増大させる場合がある（命題 6.4）．補題 9.3 は有限型付けによる分離の障害を与え，第 7 節と第 8 節は厚みを制御できる場合を示す．より強い条件 $\ker\widehat{s} \subseteq \equiv_L$ は十分だが，これを課すと L は正則になる．

3.1 古典的特殊場合

Clark–Eyraud の元の定義 5 は空語を含む因子を扱っている [2]．ここでは Clark [16] に従い λ を比較から除く．この違いは $L = a^+$ でも重要である．(a, λ) は $\mathcal{D}_L(\lambda)$ と $\mathcal{D}_L(a)$ の双方に属するが，(λ, λ) は $\mathcal{D}_L(a)$ に属し $\mathcal{D}_L(\lambda)$ には属さない．よって型による分離なしに空語も比較すると a^+ は代入可能でなくなる．一方 $\widehat{s}$ は空語を独立した型にするので，この比較は要求されない．すべての $x, y \in \Sigma^+$ について $\mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \emptyset$ から $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ が従うとき，L を *Clark–Eyraud* **代入可能**と呼ぶ．これは定義 2.1 の自明モノイドの場合，従って Yoshinaka の $(0, 0)$ の場合にちょうど一致する．

$k, \ell \geq 0$ に対し，$\mathrm{pref}_k(w)$ と $\mathrm{suf}_\ell(w)$ をそれぞれ長さ $\min\{k, |w|\}$ の接頭辞と長さ $\min\{\ell, |w|\}$ の接尾辞とする．特に $\mathrm{pref}_0(w) = \mathrm{suf}_0(w) = \lambda$ であり，短い語については語全体を返す．Yoshinaka の変数を，本稿の記法に合わせて改名する．以下では u_i, v_i を外側文脈，p, q を窓，r, s をその内側部分に用いる．L が (k, ℓ)-**代入可能** であるとは，すべての $p \in \Sigma^k$, $q \in \Sigma^\ell$ および $u_1, u_2, v_1, v_2, r_1, r_2 \in \Sigma^*$ について，$pr_1q, pr_2q \neq \lambda$ のとき

$$u_1pr_1qv_1 \in L, \quad u_1pr_2qv_1 \in L, \quad u_2pr_1qv_2 \in L \quad \Longrightarrow \quad u_2pr_2qv_2 \in L$$

が成り立つことをいう．

命題 3.3 (固定窓の有限半群による表現)**.** 任意の $k, \ell \geq 0$ に対し，全射有限半群準同型 $s_{k,\ell} : \Sigma^+ \to W_{k,\ell}$ が存在し，$L \subseteq \Sigma^*$ の (k, ℓ)-代入可能性と $\sim_{s_{k,\ell}}$-代入可能性は同値である．

[*2] $\mathsf{S}^\sharp$ の新単位元は消去フラグを代替する．自明型付け，$L = a^+$，$\varphi(a) = a$，$\varphi(b) = \lambda$ では逆像の非空因子 a, b が共通文脈を持つが分布は異なる．

Proof. $m_0 := \max\{1, k+\ell\}$ とし，非空語 w に対して

$$s_{k,\ell}(w) := \begin{cases} (\mathrm{short}, w), & 0 < |w| < m_0, \\ (\mathrm{long}, \mathrm{pref}_k(w), \mathrm{suf}_\ell(w)), & |w| \geq m_0 \end{cases}$$

と定める．この型の等値関係は Σ^+ 上の両側合同である．短語型の一致は同じ語を意味する．長語型の一致では，左右に共通の語を連接しても接頭辞と接尾辞の窓が一致する．従って有限商半群 $W_{k,\ell}$ には結合的な積が誘導され，$s_{k,\ell}$ は全射半群準同型となる．

非空 x, y の型が等しければ，$x = y$ であるか，共通の $p \in \Sigma^k$, $q \in \Sigma^\ell$ を用いて $x = pr_1q$, $y = pr_2q$ と書ける．後者では共通文脈と一方の任意の文脈に四語条件を適用し，対称性から分布の一致を得る．逆に Yoshinaka の条件の二つの非空因子は同じ $s_{k,\ell}$-型なので，相対的代入可能性から第四の語が従う． □

Yoshinaka [8, Example 4] は，(k,ℓ)-代入可能性をソート付き signature $\Sigma_{k,\ell}$ で既に表現している．命題 3.3 は，この窓による比較を誘導する有限半群の商型付けを明示するものであり，窓 signature の符号化そのものについて先取権を主張しない．

■固定窓代入可能性の反例基準． x, y が長さ $\max\{1, k+\ell\}$ 以上で，同じ長さ k の接頭辞と長さ ℓ の接尾辞をもち，共通文脈をもつ一方で分布が異なるなら，L は (k,ℓ)-代入可能ではない．最初の三条件から $s_{k,\ell}$-型が等しく共通文脈をもち，最後の条件が $\sim_{s_{k,\ell}}$-代入可能性に反するからである．

従って固定 (k,ℓ) クラスはちょうど $\mathsf{RS}_{s_{k,\ell}}$ であり，第 7 節でその多項式厚み付きデータ上界を与える．$k = \ell = 0$ では $s_{0,0}$ はすべての非空語を一つの型へ写し，Σ^+ 上で s_0 と一致する．アルファベット Γ に対し

$$\mathsf{KL}(\Gamma) := \bigcup_{k,\ell \geq 0} \{L \subseteq \Gamma^* : L \text{ は } (k,\ell)\text{-代入可能}\}$$

とし，$\mathsf{KL} := \mathsf{KL}(\Sigma)$ と略記する．

3.2 主定理

定理 3.4 (固定-s 学習定理)**.** 効率的に計算可能な全射有限半群準同型 $s : \Sigma^+ \twoheadrightarrow \mathsf{S}$ を固定する．集合駆動型再構成作用素 Rec_s と保守的逐次学習器 Learn_s が存在し，次を満たす．

(i) Rec_s は標本整合的で，$\mathsf{Rec}_s(K)$ は $\|K\|$ の多項式時間で構成できる．

(ii) すべての $L \in \mathcal{C}_s^{\mathrm{cf}}$ は Rec_s に対する有限特徴標本をもつ．

(iii) Learn_s はすべての非空 $L \in \mathcal{C}_s^{\mathrm{cf}}$ を *Gold* の意味で同定し，各更新はそれまでに見たデータの多項式時間で行える．

(iv) 正の像半群 $s(\Sigma^+)$ が有限な局所自明半群と有限群の直積の部分半群の準同型像なら，各非空標的について *(ii)* の標本は，その標的を表す任意の縮約済み *CFG* G_* に対し $|G_*|$ と $\tau_{G_*} + 1$ の多項式サイズに選べる．特に，固定窓型付けと有限群型付けに適用できる．

(v) 任意の固定 s と $L \in \mathcal{C}_s^{\mathrm{lin}}$ に対し，*(ii)* の標本は，L を表す任意の線形 *CFG* G_* について $|G_*|$ の多項式サイズに選べる．

(iv)–(v) の多項式は固定した s と Σ に依存してよいが，選んだ標的文法 G_* には依存しない．項目 *(iv)–(v)* の定量的機構と，一般の固定型付けに対するその限界は，第 *6–8* 節で扱う．

これは Gold の定理と整合する．非空アルファベット上では，クラス $\mathcal{C}_s^{\mathrm{cf}}$ はすべての有限言語を含むわけではない．$s(x) = s(y)$ を満たす相異なる非空語 x, y を取り，さらに $|z| > \max\{|x|, |y|\}$ を満たす $z \in \Sigma^*$ を取る．$\{x, y, zx\}$ では x, y は空文脈を共有するが，(z, λ) は x だけの文脈である．

■固定窓の代数的位置づけ． 以下の同値性の基礎となる局所自明有限半群の恒等式と，それに対応する接頭辞・接尾辞による正則言語の特徴づけは古典的である [17, Chapter 2, Proposition 3.5 and Theorem 3.6]．以下では，任意の有限半群型付けの正語像と核による定式化を明示して証明する．新しい半群定理としては主張しない．なお，構文半群の局所自明性によって特徴づけられる古典的な正則言語族は，*generalized definite*（接頭辞 – 接尾辞検査可能）言語と呼ばれる [18, Proposition 5.18]．ここでは構文半群に限らない固定準同型の正の像と核を扱い，その言語クラスの和への適用と，系 7.5 の学習に固有な厚みの評価を記録する．以下の代数的条件は $\mathsf{S}^\sharp$ ではなく，正の像半群 $\mathsf{S} = s(\Sigma^+)$ に課す．実際 $\mathsf{S} \neq \emptyset$ のとき，新単位元 $\mathbf{1}_\sharp$ と任意の $t \in \mathsf{S}$ について $\mathbf{1}_\sharp t \mathbf{1}_\sharp = t \neq \mathbf{1}_\sharp$ なので，$\mathsf{S}^\sharp$ 自体は局所自明でない．

命題 3.5 (局所自明型付けと固定窓)**.** 非空アルファベット上の全射有限半群準同型 $s : \Sigma^+ \twoheadrightarrow \mathsf{S}$ と $n := |\mathsf{S}| + 1$ に対し，次は同値である．

(i) S は局所自明である．

(ii) ある $k, \ell \geq 0$ について $\ker s_{k,\ell} \subseteq \ker s$ が成り立つ．

(ii) は $k = \ell = n$ で満たせる．各窓半群 $W_{k,\ell} = s_{k,\ell}(\Sigma^+)$ は局所自明であり，

$$\mathsf{KL}(\Sigma) = \bigcup_{\substack{s:\Sigma^+ \to \mathsf{S} \\ \mathsf{S} \text{ が有限局所自明}}} \mathsf{RS}_s(\Sigma)$$

が成り立つ．CFL と交わらせても同様である．

Proof. $W_{k,\ell}$ の短語型は冪等元でない．正語を二乗すると短語の代表が変わるか長語型になるためである．長語型 $e = s_{k,\ell}(x)$ と正語 u に対して xux は x と同じ窓をもち，任意の t について $ete = e$ となる．従って $W_{k,\ell}$ は局所自明である．

任意の有限半群 S に対し，$n = |\mathsf{S}| + 1$ ならば古典的な恒等式 $\mathsf{S}^n = \mathsf{S}E(\mathsf{S})\mathsf{S}$ が成り立つ [17, Chapter 1, Proposition 1.12]．さらに S が局所自明ならば，任意の冪等元 e, f と $t \in \mathsf{S}$ に対し $etf = ef$ が成り立つ [17, Chapter 2, Proposition 3.5]．$p, q \in \Sigma^n$ について $s(p) = \alpha e \beta$, $s(q) = \gamma f \delta$ と書く．$r = \lambda$ でも $\beta \widehat{s}(r) \gamma \in \mathsf{S}$ なので，$s(prq) = \alpha e (\beta \widehat{s}(r) \gamma) f \delta = \alpha e f \delta = s(pq)$ が従う．長さ $2n$ 以上では長さ n の窓が型を決定し，それより短い語は $s_{n,n}$ が区別する．逆に (ii) は $W_{k,\ell} \twoheadrightarrow \mathsf{S}$ を誘導し，局所自明性は準同型像で保存される．言語族の等式は核の精密化の単調性から従う． □

4 再構成作用素と逐次学習器

4.1 有限標本からの再構成

有限標本 $K \subseteq \Sigma^*$ に対し，

$$\widehat{V}(K) := \{[\![x]\!] : x \in \Sigma^+,\ \exists u, v \in \Sigma^* \text{ with } uxv \in K\}$$

とおく．したがって，標本中で観測された相異なる非空因子ごとに仮説非終端記号を一つだけ置く．二重角括弧は非終端記号名の一部であり，商類や終端記号を表すものではない．観測された非空因子

x, y に対し

$$x \approx_{K,s} y \quad \Longleftrightarrow \quad s(x) = s(y) \text{ かつ } \mathcal{D}_K(x) \cap \mathcal{D}_K(y) \neq \emptyset$$

と書く．文法 $\mathsf{Rec}_s(K)$ は非終端記号集合 $\widehat{V}(K) \cup \{\widehat{S}\}$ と開始記号 $\widehat{S}$ をもち，表示されたすべての角括弧付き非終端記号が $\widehat{V}(K)$ に属する場合に，次の規則をもつ：

$$\begin{array}{lll} \text{(B)} & [\![xy]\!] \to [\![x]\!][\![y]\!], & x, y \in \Sigma^+, \\ \text{(U)} & [\![x]\!] \to [\![y]\!], & x \approx_{K,s} y, \\ \text{(L)} & [\![a]\!] \to a, & a \in \Sigma, \\ \text{(S)} & \widehat{S} \to [\![w]\!], & w \in K \cap \Sigma^+. \end{array}$$

$\lambda \in K$ のときは，規則 (S) に $\widehat{S} \to \lambda$ も含める．有限標本 $K \subseteq K'$ に対して，$\mathsf{Rec}_s(K)$ のすべての非終端記号と生成規則は $\mathsf{Rec}_s(K')$ にも含まれる．従って $L(\mathsf{Rec}_s(K)) \subseteq L(\mathsf{Rec}_s(K'))$ である．ここで生成規則は集合として扱い，重複を除く．従って $\mathsf{Rec}_s(K)$ は標本 K のみに依存し，因子出現の列挙順に依存しない．

この文法は Yoshinaka [3, Section 4, Algorithm 1] の部分文字列添字付き構成に基づき，Clark [16, Section 4, Algorithm 1] も同じ構成を紹介している．特に半群型付け $s = s_{k,\ell}$ のとき，規則 (U) の非自明な場合は Yoshinaka の単位規則と一致する．すなわち相異なる非空の観測因子が共通の標本文脈をもち，同じ $s_{k,\ell}$-型をもつとき結ばれる．同値に，その二因子はともに長さ $\max\{1, k+\ell\}$ 以上で，同じ長さ k の接頭辞と長さ ℓ の接尾辞をもつ．冗長な恒等規則，初期規則を別の開始記号で表す点，および λ の扱いを除けば，両構成は一致する．一般の固定 s では，この接頭辞 – 接尾辞の比較を s-型の一致で置き換える．

補題 4.1 (標本整合性)**.** 任意の有限正例標本 K に対して，$K \subseteq L(\mathsf{Rec}_s(K))$ が成り立つ．

Proof. $w = a_1 \cdots a_m \in K \cap \Sigma^+$ とする．規則 (S) により $[\![w]\!]$ に入る．w の任意の二分木分解に沿って規則 (B) を繰り返すと一文字因子へ到達し，それらはすべて同じ標本語中に現れるので観測済みである．最後に規則 (L) が $a_1 \cdots a_m$ を生成する．$\lambda \in K$ の場合は開始規則が直接生成する． □

定理 4.2 (健全性)**.** $K \subseteq L$ かつ L が $\sim_s$-代入可能ならば，$L(\mathsf{Rec}_s(K)) \subseteq L$ である．

Proof. $[\![x]\!]$ を根とする導出木の高さについて帰納法を行い，

$$[\![x]\!] \Rightarrow^*_{\mathsf{Rec}_s(K)} w \quad \Longrightarrow \quad x \equiv_L w \text{ かつ } s(w) = s(x) \tag{1}$$

を示す．因子非終端記号は観測された非空語を添字にもつので，規則 (U) で比較する因子は定義 2.1 の非空条件を満たす．また規則 (B)–(L) は，因子非終端記号から λ を導出しない．規則 (L) は明らかである．規則 (U) で $[\![x]\!] \to [\![y]\!]$ とする．定義から，ある標本文脈 (u, v) が存在して $uxv, uyv \in K \subseteq L$ かつ $s(x) = s(y)$ である．fixed-s 代入可能性により $x \equiv_L y$ であり，帰納法の仮定から $y \equiv_L w$ と $s(w) = s(y)$ が従うので (1) を得る．

規則 (B) について，$[\![xy]\!] \to [\![x]\!][\![y]\!]$ から得られる終端語を $w_1 w_2$ と書く．帰納法の仮定より $x \equiv_L w_1$, $y \equiv_L w_2$, $s(w_1) = s(x)$, $s(w_2) = s(y)$ である．$\equiv_L$ はモノイド合同なので $xy \equiv_L w_1 w_2$ であり，準同型性から $s(w_1 w_2) = s(xy)$ である．

最後に開始規則 $\widehat{S} \to [\![x]\!]$ を用いたなら $x \in K \subseteq L$ なので $(\lambda, \lambda) \in \mathcal{D}_L(x)$ である．不変量から $\mathcal{D}_L(w) = \mathcal{D}_L(x)$ だから $w \in L$ を得る．λ の直接規則は $\lambda \in K \subseteq L$ の場合にしか存在しない． □

4.2 逐次学習器

Rec_s を各データ到着時に再計算しても，文法表現は一般には安定しない．たとえば $L_{\mathrm{c}} = \{a^n c b^n : n \geq 0\}$ では，長い正例から $[\![a^n c b^n]\!]$ のような新しい因子非終端記号が生じる．そこで Clark–Eyraud の Substitution Graph Learner (SGL, Algorithm 2) および Yoshinaka の (k,ℓ)-Substitutable Grammar Learner ((k,ℓ)-SGL, Algorithm 1) と同じ保守的ラッパーを用いる [2, 3]．集合駆動型再構成と逐次学習の区別については Eyraud–Heinz–Yoshinaka [14, Appendix] も参照されたい．固定空文法 H_0 から始め，w_n を読んだ後

$$H_n := \begin{cases} H_{n-1}, & w_n \in L(H_{n-1}), \\ \mathsf{Rec}_s(K_n), & w_n \notin L(H_{n-1}), \end{cases} \qquad \mathsf{Learn}_s(\mathcal{T}[n]) := H_n$$

とする．再構成は常に蓄積標本全体 K_n を用いる．Rec_s は集合駆動型だが，Learn_s の最終文法は提示順序に依存し得る．実際，無限標的 L のテキスト $\mathcal{T}$ を固定し，最後の再構成時点のすべての標本語より長い $w \in L$ を選ぶ．$\mathcal{T}$ に対する最終文法には $[\![w]\!]$ が存在しない一方，冒頭に w を追加したテキストでは最初の再構成に w が含まれ，その後の再構成でも $[\![w]\!]$ が残る．両方とも標的 L を生成するが，最終的な文法は異なる．主張するのは構文的な極限安定化である（系 5.4）．Clark [16, Section 4, Example 1] も参照されたい．

5 有限証拠・厳密再構成・計算量

5.1 標的の精密化と有限証拠

定性的な完全性のためには，任意の標的 CFG を $\mathsf{S}^\sharp$ 上で型付けすればよい．仮説文法 $\mathsf{Rec}_s(K)$ は変更せず，従来どおり観測された非空因子を用い，λ は開始規則から直接扱う．

非空言語 L を生成する任意の CFG $G = (V, \Sigma, P, S_0)$ を取る．その規則を $\pi : A \to u_0 B_1 u_1 \cdots B_r u_r$ と書く．ここで $u_i \in \Sigma^*$，$B_i \in V$，$r \geq 0$ である．各 $(\mu_1, \ldots, \mu_r) \in (\mathsf{S}^\sharp)^r$ に対して $\mu = \widehat{s}(u_0) \prod_{i=1}^{r} (\mu_i \widehat{s}(u_i))$ とし，次の型付き規則を加える：

$$A_\mu \to u_0 (B_1)_{\mu_1} u_1 \cdots (B_r)_{\mu_r} u_r.$$

この構成は，終端記号のみの規則，空語規則，単位規則も扱う．新しい開始記号 $\widetilde{S}$ を加え，すべての $\mu \in \mathsf{S}^\sharp$ に対して $\widetilde{S} \to (S_0)_\mu$ を置く．非到達・非生産的な記号を削除した縮約済み文法を $\widetilde{G}$ と書く．この精密化は有限であるが，サイズは指数的になり得る．学習アルゴリズムの一部ではない．

残った型付き記号はすべて到達可能かつ生産的で，その終端生成語は指定された型をもつ．とくに $A_{\mathbf{1}_\sharp}$ は λ だけを生成し，$\mu \neq \mathbf{1}_\sharp$ の A_μ は空語を生成しない．残存する各非開始記号 X に対し，その終端生成語のうち shortlex 順序で最小のものを $\omega(X)$ とする．$\omega(X) = \lambda$ も許す．型付けにより，$\omega(X)$ と X の各規則の標準右辺生成語は同じ型をもつ．外側の到達文脈には型注釈を付けない．

命題 5.1 (型付き持ち上げと生成語不変量)**.** *任意の CFG G の型付き精密化は $L(\widetilde{G}) = L(G)$ を満たす．元の開始記号 S_0 の型付きコピーも含め，残存する任意の A_μ に対して*

$$L_{\widetilde{G}}(A_\mu) = L_G(A) \cap \widehat{s}^{-1}(\{\mu\}).$$

とくに $A_\mu \Rightarrow_{\widetilde{G}}^{*} w$ ならば $\widehat{s}(w) = \mu$ である．

Proof. 型添字を消去すると G の導出を得る．逆に，G の導出木の各節点に終端生成語の型を注釈すれば，空語を生成する子も含めて型付き導出木となる．成功する型付き導出は縮約後にも残る．残存する A_μ の到達可能な出現箇所に，型が μ の任意の $w \in L_G(A)$ の注釈付き導出木を接ぎ木することで，各ファイバーについての等式と開始言語の等式が得られる． □

残存する各非開始記号 X に対し，**標準到達文脈** $\chi(X) = (u_X, v_X)$ を選ぶ．まず $|u_X| + |v_X|$ を最小化し，同点の場合は u_X，次いで v_X の shortlex 順序で選ぶ．$\widetilde{G}$ は縮約済みなので，この文脈は存在する．非開始記号を左辺にもつ型付き規則 $\pi : X \to u_0 Y_1 u_1 \cdots Y_r u_r$ に対し，その **標準右辺生成語** を

$$t_\pi := u_0 \omega(Y_1) u_1 \cdots \omega(Y_r) u_r$$

と定める．t_π と $\omega(X)$ はいずれも $L_{\widetilde{G}}(X)$ に属し，同じ型をもつ．有限な **標準正例証拠集合** を

$$\begin{aligned} \mathsf{Wit}(\widetilde{G}) := {} & \{u_X \omega(X) v_X : X \in \widetilde{V} \setminus \{\widetilde{S}\}\} \\ & \cup \{u_X t_\pi v_X : \pi = (X \to \alpha) \in \widetilde{P},\ X \neq \widetilde{S}\}. \end{aligned} \tag{2}$$

と定める．すべての証拠語は L に属する．空語型の規則では $t_\pi = \omega(X) = \lambda$ となり，その規則証拠は重複している．また $\lambda \in L$ なら，開始記号の型付きコピー $(S_0)_{\mathbf{1}_\sharp}$ は標準文脈 (λ, λ) と生成語 λ をもち，$\lambda \in \mathsf{Wit}(\widetilde{G})$ が従う．

5.2 厳密再構成と Gold 収束

定理 5.2 (有限証拠からの完全性)**.** G を非空言語 L を生成する任意の *CFG* とし，$\widetilde{G}$ をその $\mathsf{S}^\sharp$-型付き精密化とする．$\mathsf{Wit}(\widetilde{G}) \subseteq K$ ならば $L \subseteq L(\mathsf{Rec}_s(K))$ である．

代入可能性も $K \subseteq L$ も仮定しない．

Proof. 残存する非空型の $X = A_\mu$ に対し $\widehat{X} := [\![\omega(X)]\!]$ とおく．第一の証拠族により $\omega(X)$ は観測済みの非空因子である．型付き導出木の高さに関する帰納法で，$X \Rightarrow^*_{\widetilde{G}} w$ ならば $\widehat{X} \Rightarrow^*_{\mathsf{Rec}_s(K)} w$ を示す．

根の規則を $\pi : X \to u_0 Y_1 u_1 \cdots Y_r u_r$ とし，各子の生成語を w_i とする．$\omega(X)$ と $t_\pi = u_0 \omega(Y_1) u_1 \cdots \omega(Y_r) u_r$ は非空で，同じ s-型をもち，共通の文脈 (u_X, v_X) で K に現れる．よって規則 (U) により $\widehat{X} \to [\![t_\pi]\!]$ を得る．

列 $(u_0, \omega(Y_1), u_1, \ldots, \omega(Y_r), u_r)$ から空語成分を除き，残りを順に $z_1, \ldots, z_\nu$ とおく．X は非空型なので $\nu \geq 1$ であり，$t_\pi = z_1 \cdots z_\nu$ である．各成分とその連続する連接は $u_X t_\pi v_X \in K$ の非空因子なので，規則 (B) により $[\![t_\pi]\!] \Rightarrow^*_{\mathsf{Rec}_s(K)} [\![z_1]\!] \cdots [\![z_\nu]\!]$ を得る（$\nu = 1$ では零ステップ）．終端ブロックは規則 (B), (L) で生成する．非空型の子 Y_i に対応する成分では $[\![z_j]\!] = [\![\omega(Y_i)]\!] = \widehat{Y_i}$ だから，帰納法の仮定により $[\![z_j]\!] \Rightarrow^* w_i$ である．空語型の子は $w_i = \lambda$ なので省略できる．従って $\widehat{X} \Rightarrow^* u_0 w_1 u_1 \cdots w_r u_r = w$ を得る．

任意の非空な標的語 w には型付き開始コピー $(S_0)_{\widehat{s}(w)}$ があり，その標準文脈は (λ, λ) である．その標準生成語は K に属するので，開始規則 (S) と上の帰納法から $\widehat{S} \Rightarrow^* w$ を得る．また $\lambda \in L$ ならば，開始コピーの証拠により $\lambda \in K$ となり，規則 (S) がこれを直接生成する． □

定理 5.3 (厳密有限標本再構成)**.** 非空な $L \in \mathcal{C}_s^{\mathrm{cf}}$ と，これを生成する任意の *CFG* G，およびその $\mathsf{S}^\sharp$-型付き精密化 $\widetilde{G}$ に対し，$\mathsf{Wit}(\widetilde{G}) \subseteq K \subseteq L$ ならば $L(\mathsf{Rec}_s(K)) = L$ である．

Proof. G に定理 5.2 を適用して完全性を得，$K \subseteq L$ に定理 4.2 を適用して健全性を得る． □

したがって $\mathsf{Wit}(\widetilde{G})$ は $\{\lambda\}$ を含む任意の非空標的の特徴標本である．$L = \emptyset$ に対しては空標本が $L(\mathsf{Rec}_s(\emptyset)) = \emptyset$ を与える．これで定理 3.4(ii) が従う．

系 5.4 (Gold 同定)**.** 有限半群への固定全射準同型 $s : \Sigma^+ \twoheadrightarrow \mathsf{S}$ に対し，学習器 Learn_s は $\mathcal{C}_s^{\mathrm{cf}}$ の任意の非空言語を正例から極限同定する．より詳しくは，標的を表す任意の *CFG* G とその一般型付き精密化 $\widetilde{G}$ について，$\mathsf{Wit}(\widetilde{G}) \subseteq K_{n_0}$ となった後，$n \geq n_0$ で生じる仮説変更は高々一回である．

Proof. 非空な L のテキストを $\mathcal{T}$ とし，$\mathsf{Wit}(\widetilde{G}) \subseteq K_{n_0}$ を満たす n_0 を選ぶ．最初のデータ w_1 は $L(H_0) = \emptyset$ に属さないため，学習器は段階 1 で再構成する．したがって $n \geq 1$ で H_n は直近の再構成段階 $m \leq n$ における $\mathsf{Rec}_s(K_m)$ である．再構成時の標本整合性とその後の再構成条件により $K_n \subseteq L(H_n)$ であり，$K_m \subseteq L$ と健全性により $L(H_n) \subseteq L$ でもある．ある $n \geq n_0$ で再構成が起これば，定理 5.3 から $L(H_n) = L$ となり，以後は変更しない．再構成が一度も起こらなければ，$n \geq n_0$ で $H_n = H_{n_0}$ である．テキストに現れる L の各語はある K_n に含まれ，$K_n \subseteq L(H_n) = L(H_{n_0})$ なので $L(H_{n_0}) = L$ となる．いずれの場合も段階 n_0 以後の仮説変更は高々一回である． □

5.3 再構成ステップの計算量

定理 5.5 (多項式時間再構成)**.** s を固定すると，$\mathsf{Rec}_s(K)$ は $\|K\|$ に関して多項式時間で構成できる．

Proof. $n_K := \|K\|$ とおき，観測因子出現の集合を $\mathcal{O}_K := \{(u, x, v) \in \Sigma^* \times \Sigma^+ \times \Sigma^* : uxv \in K\}$ とする．$|\mathcal{O}_K| = O(n_K^2)$ なので，因子非終端記号も高々 $O(n_K^2)$ 個である．各標本語の各開始位置から因子を一文字ずつ延長して s-値を記録すれば，固定半群中の $O(n_K^2)$ 回の積で全因子の s-値を計算できる．

規則 (B) の候補は，観測因子出現とその分割位置を選ぶので高々 $O(n_K^3)$ 個である．規則 (U) については，各 $(u, x, v) \in \mathcal{O}_K$ と各 $w \in K$ に対し，$w = uyv$ を満たす非空語 y が存在するか調べる．そのような y は存在すれば一意であり，$s(x) = s(y)$ ならば規則 $[\![x]\!] \to [\![y]\!]$ を生成する．これにより規則 (U) の候補をすべて列挙でき，その個数は高々 $|\mathcal{O}_K||K| = O(n_K^3)$ である．

終端規則と開始規則はこれより低次である．各候補について，文字列の照合と生成規則の符号化・出力は $O(n_K)$ 時間で行える．生成規則を集合として扱うため，重複は除去する．明示的な規則符号列の trie を使えば，重複の判定と除去は候補の総符号長に比例する時間で実行でき，上の上界を変えない．従って，$\mathsf{Rec}_s(K)$ は $O(n_K^4)$ 時間で構成できる． □

保守的学習器 Learn_s の各更新も，それまでに見たデータの符号化サイズに関して多項式時間で処理できる．CFG membership は文法と入力サイズに関して多項式時間であり，現在の仮説サイズと必要な再構成の計算量はいずれも定理 5.5 によって多項式に抑えられる．

補題 4.1，定理 5.3，系 5.4 と合わせて，主定理 3.4(i)–(iii) が得られる．定量的な (iv)–(v) は第 7–8 節で証明する．文法サイズだけによる上界は不可能である．Clark–Eyraud [2, Example 2] および Eyraud–Heinz–Yoshinaka [14, Example 2.3] の標準的な doubling family の添字を付け替えた例は，縮約済み BUNF 文法 $S_0 \to D_n$, $D_0 \to a$, $D_i \to D_{i-1}D_{i-1}$ をもち，生成規則記号数は $O(n)$ だが生成言語は $\{a^{2^n}\}$ である．de la Higuera の定理 3 [15] は，これと密接に関連する

simple-deterministic な変種を用いる．任意の singleton 言語は，任意の s に対して $\sim_s$-代入可能である．

6　一般の固定型付けに対する型付き厚み

定義 6.1 (二分・単位・空語標準形)**.** すべての生成規則が $A \to BC$，$A \to B$，$A \to a$，$A \to \lambda$ のいずれかである *CFG* を二分・単位・空語標準形（*BUNF*）と呼ぶ．

終端記号の分離と二分化により，同値で多項式サイズの BUNF 文法を得られる．命題 7.3 は通常厚みも制御する．ここでは BUNF を規則の型付きコピー数と導出木の分岐数の評価に用いるのであって，第 5 節の学習結果を制限するものではない．

固定 s に対し，$\mathsf{S}^\sharp$-型付き精緻化の標準生成語長から証拠サイズを評価する．$G = (V, \Sigma, P, S_0)$ を縮約済み BUNF 文法，$\widetilde{G}$ をその型付き精緻化とし，$N := |V|$，$N_t := |\widetilde{V} \setminus \{\widetilde{S}\}|$ とおく．この表現の**型付き厚み**を

$$\tau_s^{\mathrm{typ}}(G) := \max\Big(\{|\omega(X)| : X \in \widetilde{V} \setminus \{\widetilde{S}\}\} \cup \{1\}\Big)$$

と定める．これは文法表示依存の量であり，学習器への追加の仮定ではない．型付き厚みには元の開始記号の型付きコピーも含む．開始記号が右辺に現れたり空語を生成したりしても同じ定義を用いる．特に任意の非空標的 $L = L(G)$ に対し

$$\tau_s^{\mathrm{typ}}(G) \geq \max_{\mu \in \widehat{s}(L)} \min\{\, |w| : w \in L,\ \widehat{s}(w) = \mu \,\} \qquad (\spadesuit)$$

が成り立つ．実際，各 $\mu \in \widehat{s}(L)$ に対して $(S_0)_\mu$ は縮約後も残り，命題 5.1 により，その最短生成語長は右辺の対応する最小値に等しい．

補題 6.2 (型付き厚みによる証拠上界)**.** $G, \widetilde{G}$ を上記の通りとし，$\tau := \tau_s^{\mathrm{typ}}(G)$ とする．任意の非開始型付き記号 X に対して $|u_X| + |v_X| \leq (N_t - 1)\tau$，任意の $w \in \mathsf{Wit}(\widetilde{G})$ に対して $|w| \leq (N_t + 1)\tau$ が成立する．P_{ter}，P_{unit}，P_{bin} を元の文法の終端・単位・二項規則の集合とすると，

$$\|\mathsf{Wit}(\widetilde{G})\| \leq \big(N|\mathsf{S}^\sharp| + |P_{\mathrm{ter}}| + |P_{\mathrm{unit}}||\mathsf{S}^\sharp| + |P_{\mathrm{bin}}||\mathsf{S}^\sharp|^2\big)\big((N|\mathsf{S}^\sharp| + 1)\tau + 1\big).$$

従って固定した s について $|G|$ と $\tau_s^{\mathrm{typ}}(G)$ の多項式上界を得る．

Proof. 残存する非開始型付き記号の依存グラフに単位規則と二項規則の親子の辺を張る．各記号は元の開始記号の型付きコピーから到達可能であり，最短路は高々 $N_t - 1$ 辺をもつ．二項規則の経路外の子を標準生成語で展開すると，一辺あたり長さ高々 τ が加わり，単位規則の辺では語が加わらない．従って標準文脈長は $(N_t - 1)\tau$ 以下である．BUNF 規則の証拠語は，標準文脈に標準生成語を高々二つ，または終端記号一つを加えるので，語長の上界が得られる．空語型の規則証拠は標準生成語の証拠と重複するため，個数を別途数える必要はない．型付き記号は高々 $N|\mathsf{S}^\sharp|$ 個，終端・単位・二項規則の型付きコピーはそれぞれ $|P_{\mathrm{ter}}|$，$|P_{\mathrm{unit}}||\mathsf{S}^\sharp|$，$|P_{\mathrm{bin}}||\mathsf{S}^\sharp|^2$ 個である．各語の符号長 $|w| + 1$ を合計すれば主張が従う． □

系 6.3 (型付き厚みからの特徴データ)**.** s を固定する．非空な $L(G_*) \in \mathcal{C}_s^{\mathrm{cf}}$ を生成する任意の縮約済み *CFG* G_* を取り，これと同値でサイズが $|G_*|$ の多項式となる縮約済み *BUNF* 正規化 G を選ぶ．（G_* がすでに *BUNF* なら $G = G_*$ としてよい．）このとき $\mathsf{Wit}(\widetilde{G})$ は Rec_s に対する特徴標本であり，その符号化サイズは $|G_*|$ と $\tau_s^{\mathrm{typ}}(G)$ の多項式である．

Proof. 定理 5.3 は元の任意の CFG G_* から特徴標本性を与える．選んだ BUNF 正規化 G に補題 6.2 を適用し，$|G|$ が $|G_*|$ の多項式であることを用いる． □

系 6.3 の型付き厚みは，元の G_* に直接付随するのではなく，選んだ BUNF 正規化 G のパラメータである．一般の固定型付けでは元文法のサイズと通常厚みだけから多項式上界を導くことはできず，再構成作用素に対しても通常厚みは型付き厚みの代用にならない．さらに次の例は，再構成作用素そのものに指数長の正例が必要となることを示す．

■括弧付き倍増言語族． $\Gamma_{\mathrm{br}} = \{\mathsf{a}, \lfloor, \rfloor, \lceil, \rceil\}$ とする．単位元 1 と吸収元 ζ をもつ二元半束 $U_1 = \{1, \zeta\}$ を取る．$1\zeta = \zeta 1 = \zeta^2 = \zeta$ である．全射半群準同型 $s_{\mathrm{U}} : \Gamma_{\mathrm{br}}^{+} \to U_1$ は $\mathsf{a}, \lfloor, \rfloor$ を 1 に，$\lceil, \rceil$ を ζ に写す．非空語 w の型が 1 であることは ceiling 括弧を含まないことと同値であり，$\widehat{s_{\mathrm{U}}}(\lambda) = \mathbf{1}_\sharp \neq 1$ である．

$n \geq 1$ に対し縮約済み CFG G_n を

$$S_0 \to E_n, \qquad E_0 \to \mathsf{a}, \qquad E_i \to \lfloor E_{i-1} E_{i-1} \rfloor \mid \lceil E_{i-1} \rceil \quad (1 \leq i \leq n)$$

で定義し，$L_n = L(G_n)$ とおく．$|G_n| = O(n)$，$\tau_{G_n} = 2n + 1$ である．$w_0^* = \mathsf{a}$，$w_i^* = \lfloor w_{i-1}^* w_{i-1}^* \rfloor$ とおく．L_n で $\lceil, \rceil$ を含まない語は w_n^* のみで，$|w_n^*| = 3 \cdot 2^n - 2$ である．これは単項節点を除けば，高さ n の完全二分木に一意に定まるからである．

命題 6.4 (精密化による特徴データの指数的増大)**.** 任意の $n \geq 1$ に対して以下が成り立つ．

(i) L_n は *Clark–Eyraud* 代入可能であり，$L_n \in \mathcal{C}_{s_0}^{\mathrm{cf}} \cap \mathcal{C}_{s_{\mathrm{U}}}^{\mathrm{cf}}$ である．

(ii) L_n は Rec_{s_0} に対し，符号化サイズが n の多項式で抑えられる特徴標本をもつ．

(iii) 有限 $K \subseteq L_n$ に対し $w_n^* \in L(\mathsf{Rec}_{s_{\mathrm{U}}}(K))$ ならば $w_n^* \in K$ である．従って $\mathsf{Rec}_{s_{\mathrm{U}}}$ に対する任意の特徴標本 $\mathcal{F}$ は $\|\mathcal{F}\| \geq 3 \cdot 2^n - 1$ を満たす．

(iv) $L_n^- := L_n \setminus \{w_n^*\}$ とおくと $L_n^- \in \mathcal{C}_{s_{\mathrm{U}}}^{\mathrm{cf}}$ である．L_n, L_n^- の両方に特徴標本をもつ任意の集合駆動型作用素 Op について，L_n の任意の特徴標本 $\mathcal{F}$ は w_n^* を含み，$\|\mathcal{F}\| \geq 3 \cdot 2^n - 1$ を満たす．特に，固定 s_{U} クラス全体に特徴標本をもつ任意の集合駆動型作用素に対して成り立つ．

特に固定型付け s_{U} では，$\mathcal{C}_{s_{\mathrm{U}}}^{\mathrm{cf}}$ の標的を表す縮約済み *CFG* に対して，$\mathsf{Rec}_{s_{\mathrm{U}}}$ の特徴データ量を元文法サイズと通常厚みの多項式で一様に上から抑えることはできない．

Proof. (i) の代入可能性は付録 付録 C で示す．(ii) については明示的な特徴標本だけで十分である．具体的に，$u_0 = \mathsf{a}$，$u_i = \lceil u_{i-1} \rceil$ とおき，

$$\mathcal{F}_n = \{u_n\} \cup \{\lceil^{n-i} \lfloor u_{i-1} u_{i-1} \rfloor \rceil^{n-i} : 1 \leq i \leq n\}$$

とする．各 i で二つの標本語は u_i と $\lfloor u_{i-1} u_{i-1} \rfloor$ に共通文脈を与える．規則 (U)，(B) は E_i の両選択肢を再現するので，$L_n \subseteq L(\mathsf{Rec}_{s_0}(\mathcal{F}_n))$ である．さらに $\mathcal{F}_n \subseteq K \subseteq L_n$ とする．$\mathcal{F}_n \subseteq K$ から単調性により $L_n \subseteq L(\mathsf{Rec}_{s_0}(K))$ が従い，$K \subseteq L_n$ から健全性（定理 4.2）により $L(\mathsf{Rec}_{s_0}(K)) \subseteq L_n$ が従う．よって $\mathcal{F}_n$ は特徴標本であり，$|\mathcal{F}_n| = n + 1$，$\|\mathcal{F}_n\| = 3n^2 + 4n + 2$ である．

(iii)–(iv) について，削除語による標的は $L_n^- = L_n \cap \widehat{s_{\mathrm{U}}}^{-1}(\{\zeta\})$ である．同じ s_{U}-型の非空因子は共通外側文脈へ入れても $\widehat{s_{\mathrm{U}}}$-型が一致する．従ってその型ファイバーの和集合との交わりは相対的代入可能性を保ち，正則フィルタとの交わりなので $L_n^- \in \mathcal{C}_{s_{\mathrm{U}}}^{\mathrm{cf}}$ が直接従う．

(iii) $K \subseteq L_n$ が w_n^* を含まなければ $K \subseteq L_n^-$ である．健全性定理 4.2 より $L(\mathsf{Rec}_{s_{\mathrm{U}}}(K)) \subseteq L_n^-$

なので，w_n^* は再構成文法から生成できない．従って任意の特徴標本 $\mathcal{F}$ は w_n^* を含み，$\|\mathcal{F}\| \geq |w_n^*| + 1 = 3 \cdot 2^n - 1$ となる．$|G_n|, \tau_{G_n} = O(n)$ と合わせて命題末尾の主張を得る．

(iv) $\mathcal{F}$ を Op に関する L_n の特徴標本とし，$w_n^* \notin \mathcal{F}$ と仮定する．L_n^- の特徴標本 $\mathcal{F}'$ を取ると，$\mathcal{F} \cup \mathcal{F}' \subseteq L_n^- \subsetneq L_n$ である．すると同じ文法 $\mathsf{Op}(\mathcal{F} \cup \mathcal{F}')$ が両方の言語を生成しなければならず，矛盾する．

なお $n \geq 2$ では $L_n^- \notin \mathcal{C}_{s_0}^{\mathrm{cf}}$ である．実際，u_{n-1} と w_{n-1}^* は L_n^- において文脈 $(\lfloor, u_{n-1} \rfloor)$ を共有するが，文脈 $(\lfloor w_{n-1}^*, \rfloor)$ を許すのは前者だけである．従って (iv) は (ii) の自明型付けでの上界と矛盾しない． □

備考 6.5 (有限言語と線形文法サイズ)．各 L_n は有限言語なので線形言語でもあるが，上で示したサイズ $O(n)$ の文法 G_n は線形文法ではない．有限言語を生成する線形 CFG の有効な導出で，唯一の非終端記号の連鎖上に同じ非終端記号が再び現れるとき，その間に非空の終端語が生じれば，その循環を反復して無限個の語が得られるため矛盾する．空語しか生じない循環は除去できる．したがって非終端記号の反復がない導出を選べ，その生成語長は文法の全生成規則に現れる終端記号の総数以下である．$w_n^* \in L_n$ の長さは $3 \cdot 2^n - 2$ なので，L_n を生成する任意の線形 CFG の生成規則には n に関して指数個の終端記号出現が必要である．これは定理 8.3 と矛盾しない．

(iv) の矛盾は，異なる二標的の対称差に含まれる語を用いる古典的な区別対の論法に沿う（[4, Theorem 15.1.4] を参照）．ここでの固定 s に対する区別対 L_n, L_n^- と指数長の証人は，本論文の構成に固有である．

系 6.6 (文法表示によらない型付き厚みの指数下界)**.** $G = (V, \Gamma_{\mathrm{br}}, P, S_0)$ を L_n の任意の縮約済み *BUNF* 文法とすると，

$$\boxed{\tau_{s_{\mathrm{U}}}^{\mathrm{typ}}(G) \geq 3 \cdot 2^n - 2}$$

が成り立つ．文法サイズに制限はない．また L_n には文法サイズ・通常厚みがともに n の多項式となる縮約済み *BUNF* 表示が存在する．

Proof. 正語型 1 のファイバーは $L_n \cap \widehat{s_{\mathrm{U}}}^{-1}(\{1\}) = \{w_n^*\}$ であり，$1 \neq \mathbf{1}_\sharp$ である．式 (♠) より，任意の G について $\tau_{s_{\mathrm{U}}}^{\mathrm{typ}}(G) \geq |w_n^*| = 3 \cdot 2^n - 2$ が従う．通常厚みが多項式となる表示は G_n に命題 7.3 を適用して得る． □

7　固定窓を超える多項式厚み付きデータ

固定 (k, ℓ)-代入可能文脈自由言語の多項式厚み付きデータ学習可能性は，Yoshinaka [3, Theorem 1] により既に示されている．そこでは (k, ℓ)-Greibach 正規形と特徴集合の評価 [3, Lemmas 2 and 7] を用いる．本節では代わりに，Rec_s で用いる型付き精密化の最短生成語長を抑える．固定窓と有限群値を併用する場合まで，同一の証明で扱える．これらのバッチ型評価は Yoshinaka [3] と Eyraud–Heinz–Yoshinaka [14, Definition 2.12] の集合駆動型の意味での「多項式時間・厚み付きデータによる同定」(identification in polynomial time and thick data; IPTtD) を与える．同文献の Definition 2.5 が要求する，より強い逐次的な構文安定化を主張するものではない．Yoshinaka の多項式次数の改善も主張しない．一般の固定 s では，通常厚みだけでは Rec_s の特徴データを多項式で抑えられない（命題 6.4）．

$k, \ell \geq 0$ と有限群 H への準同型 $g : \Sigma^* \to \mathsf{H}$ を固定する．$s_{k,\ell}$ との直積では群成分を Σ^+ に制限する．

補題 7.1 (固定窓と有限群による BUNF 型付き生成語上界)**.** $G = (V, \Sigma, P, S_0)$ を縮約済み *BUNF* 文法とし，$N := |V| \geq 1$, $m := k + \ell$, $q := |\mathsf{H}|$ とおく．有限型付け s が $\ker\bigl(s_{k,\ell} \times (g|_{\Sigma^+})\bigr) \subseteq \ker s$ を満たせば，

$$\tau_s^{\mathrm{typ}}(G) \leq m + 1 + [1 + 2(m+q)(m+2)Nq](\tau_G + 1).$$

開始記号が右辺に現れる場合も，空語規則・単位規則も許す．

Proof. 詳細は付録 付録 A に与える．非空性を保存する保護文字と，導出木の節点数による第二の最小化を用いる． □

定理 7.2 (固定窓と有限群の精密化による多項式厚み付きデータ)**.** s, Σ を固定し，ある固定 k, ℓ と有限群準同型 g が $\ker\bigl(s_{k,\ell} \times (g|_{\Sigma^+})\bigr) \subseteq \ker s$ を満たすとする．縮約済み *BUNF* 文法 G で表される任意の非空 $L \in \mathcal{C}_s^{\mathrm{cf}}$ は，Rec_s に対し，$|G|$ と $\tau_G + 1$ の多項式符号長の特徴標本 $\mathsf{Wit}(\widetilde{G})$ をもつ．

Proof. 補題 7.1 と系 6.3 を適用する． □

群 H を自明に取れば固定窓の場合を含む．一般の CFG 表現には終端記号の分離と二分化のみを用いる．

命題 7.3 (厚みを多項式的に保存する BUNF 正規化)**.** 固定多項式 $q_{\mathrm{size}}, q_{\mathrm{thick}}$ が存在し，非空言語を生成する任意の縮約済み *CFG* G_* は，多項式時間で同値な縮約済み *BUNF* 文法 G に変換でき，

$$|G| \leq q_{\mathrm{size}}(|G_*|), \qquad \tau_G \leq q_{\mathrm{thick}}(|G_*|, \tau_{G_*} + 1)$$

を満たす．空語規則・単位規則を除去する必要はない．

証明は付録 A.2 に与える．

半群 S が半群 Q の**除数**であるとは，S が Q のある部分半群の準同型像であることをいう．

補題 7.4 (局所自明半群・有限群の除数と窓型付け)**.** 非空アルファベット上の全射有限半群準同型 $s : \Sigma^+ \twoheadrightarrow \mathsf{S}$ に対し次は同値である．

(i) S は有限局所自明半群 T と有限群 H の直積 $\mathsf{T} \times \mathsf{H}$ の除数である．

(ii) ある $k, \ell \geq 0$ と有限群 H へのモノイド準同型 $g : \Sigma^* \to \mathsf{H}$ が存在して

$$\ker\bigl(s_{k,\ell} \times (g|_{\Sigma^+})\bigr) \subseteq \ker s$$

が成り立つ．

Proof. (i) より部分半群 $V \subseteq \mathsf{T} \times \mathsf{H}$ と全射準同型 $\pi : V \to \mathsf{S}$ を選ぶ．各 $s(a)$ を V へ持ち上げて $\pi\varphi = s$ を満たす $\varphi : \Sigma^+ \to V$ を得る．射影を $\sigma : \Sigma^+ \to \mathsf{T}$ と $g_+ : \Sigma^+ \to \mathsf{H}$ とすると，後者は $g(\lambda) = 1_{\mathsf{H}}$ によって $g : \Sigma^* \to \mathsf{H}$ に拡張できる．$\sigma(\Sigma^+)$ が局所自明だから，命題 3.5 から $\ker s_{k,\ell} \subseteq \ker \sigma$ となる k, ℓ を得る．群成分も加えると (ii) となる．逆に (ii) は全射半群準同型

$$(s_{k,\ell} \times g)(\Sigma^+) \longrightarrow \mathsf{S}, \qquad (s_{k,\ell}(w), g(w)) \longmapsto s(w)$$

を誘導する．定義域は局所自明な $W_{k,\ell}$ と H の直積の部分半群だから (i) が従う． □

系 7.5 (局所自明半群と有限群による通常厚み上界)**.** $s : \Sigma^+ \twoheadrightarrow \mathsf{S}$ を固定する．S が有限な局所自明半群と有限群の直積の部分半群の準同型像であるとする．このとき，縮約済み *CFG* G_* で表される任意の非空 $L \in \mathcal{C}_s^{\mathrm{cf}}$ は，Rec_s に対して $|G_*|$ と $\tau_{G_*} + 1$ の多項式符号長の特徴データをもつ．これには局所自明な正の像半群や有限群の型付けを含む.

Proof. 補題 7.4 により，定理 7.2 の核の精密化条件が成り立つ．同定理の上界は，補題 7.1 と系 6.3 から従う．命題 7.3 の正規化を施して定理 7.2 を適用する．

□

ここで **LI** を局所自明有限半群の擬多様体，**Grp** を有限群を半群とみなした擬多様体とする．両者は有限直積で閉じているので，その擬多様体としての結合 $\mathbf{LI} \vee \mathbf{Grp}$ は，$\mathsf{S} \in \mathbf{LI}$ と $\mathsf{G} \in \mathbf{Grp}$ の直積 $\mathsf{S} \times \mathsf{G}$ の除数（部分半群の準同型像）全体に正確に一致する．局所自明半群を含む擬多様体の結合は Costa [19, 20] らによって研究されてきた．本論文で扱うのは，そこから導く文法学習の定量的帰結である．固定型付け s に関して，補題 7.4 は，定理 7.2 の核の精密化条件と $s(\Sigma^+) \in \mathbf{LI} \vee \mathbf{Grp}$ の同値性を与える．系はこの代数的条件から定量的結果を任意の縮約済み CFG 表現へ拡張する．これは多項式特徴データ上界をもつ型付けすべてを特徴づけるものではない.

補題 7.6 (二元半束は窓・群の結合の外にある)**.** $U_1 \notin \mathbf{LI} \vee \mathbf{Grp}$.

Proof. 背理法で，$\mathsf{S} \in \mathbf{LI}$ と有限群 G の直積の部分半群 $\mathsf{T} \subseteq \mathsf{S} \times \mathsf{G}$ から U_1 への全射準同型 $\pi : \mathsf{T} \to U_1$ が存在するとする．$\pi^{-1}(1)$ と $\pi^{-1}(\zeta)$ はそれぞれ空でない有限部分半群なので，冪等元 e, f を含む．$\mathsf{S} \times \mathsf{G}$ の冪等元の群成分は 1_{G} であるから，e, f の S 成分も冪等元である．S の局所自明性から $efe = e$ だが，π を作用させると $1 \cdot \zeta \cdot 1 = 1$ となり，$\zeta \neq 1$ に矛盾する． □

備考 7.7. s_{U} の正の像は U_1 であり，補題 7.6 により $\mathbf{LI} \vee \mathbf{Grp}$ に属さない．命題 6.4 は，系 7.5 の代数的仮定を外すと Rec_s の通常厚みに関する特徴データ上界が成立しない場合を示す．これは任意の固定型付けについて条件の必要性を主張するものではない．命題 6.4(iv) は二つの標的を識別するための集合駆動型作用素に依存しない特徴標本下界を与えるが，任意の Gold 学習器の実行時間・収束時点の下界は主張しない.

この多項式上界は固定型付けとアルファベットに依存してよく，窓長や群を可変とした一様な上界は主張しない.

8 線形部分クラス

線形言語はちょうど 1 ターン・プッシュダウンオートマトンによって受理される [21, 22]．以下の正規化はその文法的対応物を与える．成功導出には一つの継続する非終端記号の経路があり，これを *spine* と呼ぶ.

命題 8.1 (linear-spine BUNF 正規化)**.** 固定多項式 q_{lin} が存在し，非空言語を生成する任意の線形 *CFG* G を多項式時間で同値な縮約済み *BUNF* 文法 $G_0 = (V_0, \Sigma, P_0, S_0)$ へ変換でき，$|G_0| \le q_{\mathrm{lin}}(|G|)$ である．さらに各二項生成規則は，$W_a \to a$ を満たすちょうど一つの新鮮な終端ラッパー子と，ちょうど一つのそれ以外の非終端子をもつ.

構成は付録 付録 B に与える．$\widetilde{G}_0$ を型付き精密化，$N_t := |\widetilde{V}_0 \setminus \{\widetilde{S}\}|$ とおく．元の開始記号の型付

きコピーも数えるため $N_t \le |V_0|\,|\mathsf{S}^\sharp|$ である．

補題 8.2 (短い標準生成語)**.** $\widetilde{G}_0$ の任意の型付き非開始記号 X に対し $|\omega(X)| \le N_t$ である．従って $\tau_s^{\mathrm{typ}}(G_0) \le N_t$ である．

Proof. **継続** *spine* は各二項規則のラッパーでない方の子をたどる．ラッパー子はちょうど一文字を生成し，継続 spine には入らない．単位規則は文字を寄与せず，終端・空語規則は spine を終了する．$\omega(X)$ を与える導出のうち非終端節点数最少のものを選ぶ．同じ**型付き** spine 記号が繰り返せば，下側の部分導出を上側へ移植しても型付き導出は保たれる．その区間に二項規則があれば生成語長が真に減り，単位規則のみなら節点数が減る．いずれも選んだ導出の最小性に反する．従って spine 上の型付き記号は重複せず，終端規則の最後の一文字も含めて生成語長は高々 N_t である．ラッパー記号にも同じ上界が成立する． □

定理 8.3 (線形標的に対する多項式特徴データ)**.** s を固定する．線形 *CFG* G で表される任意の $L \in \mathcal{C}_s^{\mathrm{lin}}$ は，Rec_s に対し，$|G|$ の多項式で $\|\cdot\|$-サイズが抑えられる特徴標本をもつ．

Proof. $L = \emptyset$ と $L = \{\lambda\}$ では第 5 節の標本を用いる．それ以外では命題 8.1 の G_0 を取る．補題 8.2 から $\tau_s^{\mathrm{typ}}(G_0) \le N_t \le |V_0|\,|\mathsf{S}^\sharp|$ なので，系 6.3 により $|G_0| \le q_{\mathrm{lin}}(|G|)$ の多項式サイズの特徴標本を得る．より具体的には，補題 6.2 から $\|\mathsf{Wit}(\widetilde{G}_0)\| = O(|G_0|^3 |\mathsf{S}^\sharp|^4)$ である．元の $|G|$ に関する多項式評価には正規化の q_{lin} も使う． □

定理 5.5 と合わせると，選んだ線形 CFG 表現を基準として，$\mathcal{C}_s^{\mathrm{lin}}$ の標的には多項式時間のバッチ再構成と多項式サイズの特徴データが得られる．これは de la Higuera [15, Theorem 2] の線形言語全体についての否定結果とは矛盾しない．本定理は固定 s に対する代入可能な部分クラスだけを対象とするからである．さらに逐次学習器 Learn_s に対する多項式データ保証は主張しない．

■非正則な線形 fixed-s 例． 直前の定理は，正則標的や既知の線形代入可能クラスに限定されない．

$$L_{\pm,e} := \{a^{2m} c b^{2m} : m \ge 0\} \cup \{a^{2m+1} d b^{2m+1} : m \ge 0\} \cup \{a^n e b^n : n \ge 0\}.$$

これは線形文法

$$S \to U_{\mathrm{ev}} \mid U_e, \quad U_{\mathrm{ev}} \to c \mid a U_{\mathrm{odd}} b, \quad U_{\mathrm{odd}} \to d \mid a U_{\mathrm{ev}} b, \quad U_e \to e \mid a U_e b$$

で生成される．添字 ev と odd は，対応する非終端記号自身の生成語長の偶奇ではなく，開始点から外側を包む a, b の対の個数の偶奇を表す．

c, d, e を**中心記号**と呼ぶ．

命題 8.4. 言語 $L_{\pm,e}$ は線形かつ非正則であり，ある有限半群への準同型 s に対して $\mathcal{C}_s^{\mathrm{lin}}$ に属する．一方，*Clark–Eyraud* 代入可能ではなく，いかなる固定 $k, \ell \ge 0$ に対しても (k,ℓ)-代入可能ではない．

Proof. 線形性は表示文法から従う．有限型付けに関する代入可能性を示すため，

$$L_{\mathrm{all}} := \{a^n \xi b^n : n \ge 0,\ \xi \in \{c, d, e\}\}, \qquad R_{\mathrm{reg}} := (aa)^* c (bb)^* \cup a(aa)^* d\, b(bb)^* \cup a^* e b^*$$

とおく．線形言語 L_{all} は非空因子の規約で Clark–Eyraud 代入可能である．中心記号を含まない因子は共通文脈から一意に決まり，中心記号を一つ含む因子 $a^i \xi b^j$ の分布は $i - j$ のみに依存する．

従って自明な型付け s_0 に対し $L_{\mathrm{all}} \in \mathcal{C}^{\mathrm{lin}}_{s_0}$ である．R_{reg} は正則言語で $L_{\pm,e} = L_{\mathrm{all}} \cap R_{\mathrm{reg}}$ だから，R_{reg} を認識する有限モノイド準同型 $g : \Sigma^* \to M$ を取り，$\mathsf{T} = g(\Sigma^+)$ および $t = g|_{\Sigma^+} : \Sigma^+ \twoheadrightarrow \mathsf{T}$ とおく．$\lambda \notin R_{\mathrm{reg}}$ なので適当な受理集合 $\mathsf{Acc}_t \subseteq \mathsf{T} \subseteq \mathsf{T}^\sharp$ に対し $R_{\mathrm{reg}} = \widehat{t}^{-1}(\mathsf{Acc}_t)$ と書ける．命題 3.2(ii) と線形言語の正則交差に関する閉包性により，$L_{\pm,e} \in \mathcal{C}^{\mathrm{lin}}_{s_0 \times t}$ が従う．

また，$L_{\pm,e} \cap a^*eb^* = \{a^n e b^n : n \geq 0\}$ から非正則性が従う．因子 c, e は空文脈を共有するが，$(a, b) \in \mathcal{D}_{L_{\pm,e}}(e) \setminus \mathcal{D}_{L_{\pm,e}}(c)$ なので Clark–Eyraud 代入可能ではない．さらに $k, \ell \geq 0$ を固定し，$m_0 := \max\{1, k+\ell\}$, $w_e := a^k e b^\ell$, $w_c := a^k c b^\ell$ とおく．両因子は同じ長さ k の接頭辞と長さ ℓ の接尾辞をもち，文脈 $(a^{2m_0-k}, b^{2m_0-\ell})$ を共有する一方，$(a^{2m_0+1-k}, b^{2m_0+1-\ell}) \in \mathcal{D}_{L_{\pm,e}}(w_e) \setminus \mathcal{D}_{L_{\pm,e}}(w_c)$ である．従って固定窓代入可能性の反例基準より $L_{\pm,e} \notin \mathsf{KL}$ である． □

■四元型付けによる具体例． 上の正規フィルタによる証明では有限型付けの存在が示されたが，実際には四元型付けだけで十分である．$M_{\pm,e} := \{1, \kappa_{cd}, \kappa_e, 0\}$ を，1 が単位元で，すべての $\mu, \nu \in \{\kappa_{cd}, \kappa_e, 0\}$ に対して $\mu\nu = 0$ が成り立つモノイドとし，準同型 $s_{\pm,e} : \{a, b, c, d, e\}^+ \to M_{\pm,e}$ を

$$s_{\pm,e}(a) = s_{\pm,e}(b) = 1, \qquad s_{\pm,e}(c) = s_{\pm,e}(d) = \kappa_{cd}, \qquad s_{\pm,e}(e) = \kappa_e \tag{3}$$

で定める．このとき $L_{\pm,e}$ は $\sim_{s_{\pm,e}}$-代入可能である．実際，中心記号を含まない非空因子は共通文脈から一意に決まる．$a^i e b^j$ の分布は $i - j$ のみに依存し，$\xi \in \{c, d\}$ に対する $a^i \xi b^j$ の分布は $(i - j, \mathrm{par}(\xi) - i \bmod 2)$ のみに依存する．ただし $\mathrm{par}(c) = 0$, $\mathrm{par}(d) = 1$ とする．共通文脈はそれぞれの不変量を一致させ，同じ $s_{\pm,e}$-型であることは e-因子と c/d-因子を区別する．従って，共通文脈をもつ同型の因子の分布は一致する．

従って定理 8.3 は KL の外にある非正則線形言語にも適用される．表示文法は even-linear なので，Takada の control-set 枠組みからの分離は主張しない．

■生成語型付けが誘導する有限状態制御． 元の型付け s とその新単位元付加 $\widehat{s}$ は，同じ有限状態構成で扱える．$t : \Sigma^* \to T$ を任意の有限モノイド準同型とし，線形文法 $G = (V, \Sigma, P, S)$ の各生成規則に $\mathsf{ProdLab}$ の相異なるラベルを付ける．規則ラベル列 α をもつ導出を $A \Rightarrow^{\alpha}_{G} w$ と書く．$\mathsf{Acc}_{\mathrm{ctrl}} \subseteq T$ に対し

$$\mathsf{Ctrl}_{t,\mathsf{Acc}_{\mathrm{ctrl}}}(G) := \{\alpha \in \mathsf{ProdLab}^* : S \Rightarrow^{\alpha}_{G} w \text{ for some } w \in \Sigma^*,\ t(w) \in \mathsf{Acc}_{\mathrm{ctrl}}\}$$

とおく．これは正則である．状態 $V \times T \times T$ と一つの受理状態をもち，$(S, 1_T, 1_T)$ から開始するオートマトンで，$A \to uBv$ に対し $(A, \mu_L, \mu_R) \mapsto (B, \mu_L t(u), t(v)\mu_R)$ と遷移し，終端規則 $A \to w$ では $\mu_L t(w) \mu_R \in \mathsf{Acc}_{\mathrm{ctrl}}$ のとき受理すればよい．文形式 uAv の不変量は $(A, t(u), t(v))$ であり，制御される言語は $L(G) \cap t^{-1}(\mathsf{Acc}_{\mathrm{ctrl}})$ に等しい．

半群型付け s の制御では，モノイド拡張を用いる．$t = \widehat{s}$，開始非終端記号を A，$\mathsf{Acc}_{\mathrm{ctrl}} = \{\mu\}$ とすれば，命題 5.1 の $L_G(A) \cap \widehat{s}^{-1}(\{\mu\})$ を空語型 $\mathbf{1}_\sharp$ も含めて得る．これは Takada の正則制御言語 [11] との有限状態的な接点であるが，任意の Takada control set が生成語型付けから得られるとは主張しない．

9 表現力と境界

ここでは fixed-window 階層と，より広い文脈自由言語族の間で本枠組みを位置づける．

9.1 RS 内の非線形標的

$\Delta := \{a^n b^n : n \geq 0\}$ とおく．$z \in \{a,b\}^*$ に対し $\beta(z) := |z|_a - |z|_b$ を定め，接頭辞 p を読んだ後の**高さ**を $\beta(p)$ とする．Δ^* への所属は，総高さと ba の境界における高さによって特徴づけられる：

$$w \in \Delta^* \iff \beta(w) = 0 \text{ かつ } w = pbap' \text{ なら常に } \beta(pb) = 0. \tag{$\star$}$$

実際，Δ^* の語は $a^n b^n$ の積であり，その非自明な因子間の境界はちょうど ba の出現で，そこでの高さは 0 である．逆に，ba の各出現で切ると，残る因子は ba を含まないため a^*b^* に属する．右辺の条件から，それぞれの因子は高さ 0 で始まり高さ 0 で終わるので，$a^n b^n$ の形となる．

語 x の**境界整合入口オフセット集合**を

$$\mathcal{Q}(x) := \{\delta \in \mathbb{Z} : x = pbap' \text{ なら常に } \delta + \beta(pb) = 0\}$$

と定める．これは形式的な整数オフセットであり，実際に到達可能な非負の入口高さとは限らない．x が ba を含まなければ $\mathcal{Q}(x) = \mathbb{Z}$，含む場合は $|\mathcal{Q}(x)| \leq 1$ である．例えば $\mathcal{Q}(ab) = \mathcal{Q}(bb) = \mathbb{Z}$，$\mathcal{Q}(ba) = \{1\}$，$\mathcal{Q}(aaba) = \{-1\}$，$\mathcal{Q}(baaba) = \varnothing$ である．

$x \neq \lambda$ とする．uxv の ba の各出現は u, x, v の内部，または二つの連接境界のいずれかにある．したがって $(\star)$ により次の同値性を得る：

$$\begin{aligned} uxv \in \Delta^* \iff \beta(uxv) = 0, \quad 0 \in \mathcal{Q}(u), \quad \beta(u) \in \mathcal{Q}(x), \quad \beta(ux) \in \mathcal{Q}(v), \\ (\mathrm{lst}(u), \mathrm{fst}(x)) = (b,a) \implies \beta(u) = 0, \\ (\mathrm{lst}(x), \mathrm{fst}(v)) = (b,a) \implies \beta(ux) = 0. \end{aligned} \tag{$\star\star$}$$

ここで $\mathrm{fst}, \mathrm{lst}$ は非空語の先頭・末尾文字を表し，空語では値を $\perp$ と定める．従って uxv の所属は，x については $\beta(x)$，$\mathcal{Q}(x)$，先頭文字と末尾文字のみに依存する．

非空語 w について $s_\star(w)$ は先頭文字，末尾文字，および ba を含むか否かを記録する．連接 xy での値は x, y の値から定まる．外側の端の文字が受け継がれ，新たな ba は境界 $b|a$ の場合にのみ生じるからである．よって $\ker s_\star$ は半群合同であり，$s_\star$ はその有限正語像への全射準同型である．像は 7 元である．実際，先頭が b，末尾が a でありながら ba を含まない語は存在せず，残りの 7 通りは実現される．

命題 9.1 (非線形 fixed-$s_\star$ 標的)**.** Δ^* は決定性文脈自由・非正則・非線形で，$\sim_{s_\star}$-代入可能である．さらにどの固定 $k, \ell \geq 0$ に対しても (k,ℓ)-代入可能ではない．従って $\Delta^* \in \mathsf{RS}_{s_\star}(\{a,b\}) \cap \mathrm{CFL}$ かつ $\Delta^* \in \mathsf{RS}(\{a,b\}) \setminus \mathsf{KL}(\{a,b\})$ である．

Proof. 高さを追跡し，高さ 0 で b を読むことと，高さが非零のときに b の直後に a を読むことを拒否し，高さ 0 で受理する決定性 PDA は，$(\star)$ により Δ^* を受理する．文法 $S \to TS \mid \lambda$, $T \to aTb \mid \lambda$ もこれを生成する．$\Delta^* \cap a^*b^* = \Delta$ より非正則である．線形言語の正則言語との交わりに関する閉包性と，非線形な $\Delta^* \cap a^*b^*a^*b^* = \Delta\Delta$ [22, Section 6.1, Theorem 6.1 の直前] より，Δ^* は非線形である．

代入可能性を示す．同じ $s_\star$-型をもつ非空語 x, y が共通文脈 (u,v) をもつとする．$uxv, uyv \in \Delta^*$ と $(\star\star)$ より $\beta(x) = \beta(y)$ かつ $\beta(u) \in \mathcal{Q}(x) \cap \mathcal{Q}(y)$ を得る．x, y がともに ba を含まなければ $\mathcal{Q}(x) = \mathcal{Q}(y) = \mathbb{Z}$ である．そうでなければ両者とも ba を含み，各集合は高々一元なので

$\mathcal{Q}(x) = \{\beta(u)\} = \mathcal{Q}(y)$ となる．また x, y は先頭文字と末尾文字も共有するから，$(\star\star)$ より任意の u', v' に対し $u'xv' \in \Delta^*$ と $u'yv' \in \Delta^*$ は同値である．従って $\mathcal{D}_{\Delta^*}(x) = \mathcal{D}_{\Delta^*}(y)$ である．

固定窓との分離として $k, \ell \geq 0$ を固定し，$m_0 := \max\{1, k+\ell\}$, $x := a^{m_0}b^{m_0}$, $y := a^{m_0}b^{m_0}a^{m_0}b^{m_0}$ とおく．両者は長さ k の接頭辞と長さ ℓ の接尾辞が等しく，空文脈を共有する．さらに $axb \in \Delta^*$ だが，ayb の中央の ba ではその b の直後の高さが 1 なので $(\star)$ より $ayb \notin \Delta^*$ である．従って固定窓代入可能性の反例基準から，どの (k, ℓ) にも属さない． □

従って fixed-s 枠組みは，固定窓階層の外にある第 8 節の非正則線形例 $L_{\pm,e}$ と，非線形文脈自由言語 Δ^* の双方を含む．control-set 法一般との分離は主張しない．

9.2 上限制約つき正則カウンタ族

正則言語 $L_{\mathrm{Yreg}} = ae^*ce^*a \cup ae^*de^*a \cup be^*ce^*b$ による固定窓階層からの分離は Yoshinaka [3, Proposition 1] によって既に示されている．以下の族は，第 9.3 節の無界カウンタに対する有限状態の capped 版として残す．

$\Sigma_c := \{\uparrow, \downarrow, \#\}$ とする．$w = \delta_1 \cdots \delta_n \in \Sigma_c^*$ に対し，$\mathrm{ht}_i(w)$ を先頭 i 文字を読んだ後の高さとする．$\mathrm{ht}_0(w) = 0$ とし，$\uparrow$ で $+1$，$\downarrow$ で -1，$\#$ で 0 にリセットする．$\rho \geq 1$ に対し

$$\mathrm{CTR}_\rho := \{w \in \Sigma_c^* : 0 \leq \mathrm{ht}_i(w) \leq \rho \text{ for all } 0 \leq i \leq |w|\}$$

とおく．

任意の $\rho \geq 1$ に対し CTR_ρ は正則である．実際，決定性有限オートマトンが高さ $0, \ldots, \rho$ を記録し，範囲外に一つの sink を置き，$\#$ で 0 に戻ればよい．従って命題 3.1 から $\mathrm{CTR}_\rho \in \mathsf{RS}(\Sigma_c)$ となる．

定理 9.2. 任意の $\rho \geq 2$ に対し CTR_ρ はどの $k, \ell \geq 0$ についても (k, ℓ)-代入可能ではない．

Proof. k, ℓ を固定し $x := (\uparrow\downarrow)^k \uparrow^{\rho-1} \#^\ell$，$y := (\uparrow\downarrow)^k \uparrow^\rho \#^\ell$ とおく．両者は固定窓基準に十分長く，同じ長さ k の接頭辞と長さ ℓ の接尾辞をもち，ともに CTR_ρ に属するため空文脈を共有する．一方 $\uparrow x \in \mathrm{CTR}_\rho$ だが $\uparrow y \notin \mathrm{CTR}_\rho$ で，後者は高さ $\rho + 1$ に達する．従って分布が異なり，反例基準が適用できる． □

境界 $\rho \geq 2$ は最良である[*3]．

任意の $\rho \geq 1$ について，上の DFA が誘導する遷移モノイド準同型を $h_\rho : \Sigma_c^* \to M_\rho$ とする．学習にはその正語への制限 $s_\rho := h_\rho|_{\Sigma_c^+}$ を用いる．これは CTR_ρ を認識するので，すべての $\rho \geq 1$ に対して $\mathrm{CTR}_\rho \in \mathcal{C}^{\mathrm{cf}}_{s_\rho}$ が成り立つ．一方，$\mathrm{CTR}_\rho \notin \mathsf{KL}$ という強い結論が成り立つのは $\rho \geq 2$ の場合である．この capped family は新しい正則分離ではなく，下の無界言語 CTR と対比するためのものである．

[*3] 実際，CTR_1 は $(1,1)$-代入可能である．その所属条件は，先頭文字が $\downarrow$ でないこと，および長さ 2 の因子 $\uparrow\uparrow, \downarrow\downarrow, \#\downarrow$ が現れないことだけで記述できる．したがって共通文脈をもつ許容された非空因子については，先頭文字と末尾文字が等しければ，任意の文脈での所属可否は一致する．

9.3 RS の外にある自然な決定性文脈自由言語

補題 9.3 (有限半群障害)**.** $L \subseteq \Sigma^*$ とする．無限集合 $\Xi \subseteq \Sigma^+$ が存在し，相異なる任意の $x, y \in \Xi$ について $\mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \emptyset$ かつ $\mathcal{D}_L(x) \neq \mathcal{D}_L(y)$ が成り立つなら $L \notin \mathsf{RS}(\Sigma)$ である．

Proof. 有限 s は Ξ の二要素を同一視する．その二語は共通文脈をもち分布が異なるので $\sim_s$-代入可能性に反する． □

上限を外すと決定性文脈自由言語

$$\mathrm{CTR} := \{w \in \Sigma_c^* : \mathrm{ht}_i(w) \geq 0 \text{ for all } 0 \leq i \leq |w|\}$$

を得る．これは reset 付きの明らかな決定性プッシュダウン・カウンタで受理される．

系 9.4 (上限なしカウンタの障害)**.** $\mathrm{CTR} \notin \mathsf{RS}(\Sigma_c)$ である．

Proof. $\Xi = \{\uparrow^i : i \geq 1\}$ を用いる．$i < j$ なら $(\lambda, \downarrow^i)$ は共通文脈だが，$(\lambda, \downarrow^j)$ は $\uparrow^j$ だけの文脈である． □

一種類の括弧の Dyck 言語

$$D_1 := \{w \in \{a, b\}^* : |w'|_a \geq |w'|_b \text{ for every prefix } w',\ |w|_a = |w|_b\}$$

は標準的な決定性文脈自由言語 [23] である．ここでの D_1 は Dyck 言語全体を表し，Autebert–Berstel–Boasson [22] の規約では D_1^* と書かれる．

系 9.5. $D_1 \notin \mathsf{RS}(\{a, b\})$ である．

Proof. $\Xi = \{b^i a^i : i \geq 1\}$ を用いる．$i < j$ なら (a^j, b^j) は共通文脈だが，(a^i, b^i) は $b^i a^i$ だけの文脈である．$b^j a^j$ では接頭辞 $a^i b^j$ がアンダーフローを起こす． □

従って障害は無界スタック挙動それ自体ではない．非正則 1-turn 言語 $L_{\pm,e}$ は RS に属する．障害は，文脈的挙動が異なるにもかかわらず相互に比較可能な因子が無限族をなし，有限 s ではそれらをすべて分離できないことである．

補題 9.6 (固定語による商)**.** L が $\sim_s$-代入可能で $z \in \Sigma^*$ なら，$L/z := \{w : wz \in L\}$ も $\sim_s$-代入可能である．

Proof. L/z の共通文脈 (u, v) は L では (u, vz) になる．L で分布が等しいなら，任意の文脈 (s, t) の右に z を付加することで L/z に分布等式を移せる． □

$S \to aSS \mid b$ が生成する言語を *Łukasiewicz* **言語**と呼ぶ．Yoshinaka [3, Section 3] はすでに，この言語がどの固定 k, ℓ に対しても (k, ℓ)-代入可能でないことを指摘している．本論文の記法では $L_{\mathrm{Luk}} = D_1 b$ [22] で，これは決定性文脈自由言語でもある [23]．ここでは右商の議論により，さらに強く有限型付け全体の和の外にあることを示す．もし $L_{\mathrm{Luk}} \in \mathsf{RS}(\{a, b\})$ なら補題 9.6 により $D_1 = L_{\mathrm{Luk}}/b \in \mathsf{RS}$ となり，系 9.5 に反する．

9.4　Clark の congruential family との比較

Clark [24] は有限初期集合 $I \subseteq V$ を許し，$L_G[I] := \bigcup_{A \in I} L_G(A)$ と書く．このような文法が *congruential* であるとは，各 $L_G(A)$ が $L_G[I]$ の一つの構文合同類に含まれることをいう．Γ 上の congruential grammar が生成する言語全体を $\mathsf{CONG}(\Gamma)$ と書く．Clark はすでに substitutable および (k,ℓ)-substitutable language をこの族に位置づけている．次の命題はこの包含をすべての fixed-s slice へ拡張する．

命題 9.7 (Clark の congruential family との比較)**.** 任意の有限アルファベット Γ と有限半群型付け $s : \Gamma^+ \to \mathsf{S}$ に対して $\mathcal{C}_s^{\mathrm{cf}} \subseteq \mathsf{CONG}(\Gamma)$ である．従って $\mathsf{RS}(\Gamma) \cap \mathrm{CFL} \subseteq \mathsf{CONG}(\Gamma)$ であり，$\Gamma = \{a, b\}$ ではこの包含は真である．

Proof. 非空 $L \in \mathcal{C}_s^{\mathrm{cf}}$ の任意の CFG と，その $\mathsf{S}^\sharp$-型付き精緻化をトリムした $\widetilde{G}$ を取る．各残存型付き記号 A_μ の生成語は等しい $\widehat{s}$-型と共通の終端到達文脈をもつので，補題 2.2 により同じ構文合同類に属する．この議論は空語生成記号にも適用できる．

補助開始記号 $\widetilde{S}$ を除き，その型付き後続記号 $(S_0)_\mu$ 全体を有限初期集合とする．$\lambda \in L$ の場合も型 $\mathbf{1}_\sharp$ によって扱われるので，空語専用の初期記号は不要である．空言語は生成規則をもたない初期記号で扱える．全ての有限型付けについて和を取れば包含が従う．

$\{a, b\}$ 上で包含が真であることには，Clark [24] も論じる Dyck 例を用いる．任意の $x \in D_1$ に対し $uxv \in D_1$ と $uv \in D_1$ は同値なので $x \equiv_{D_1} \lambda$ である．従って $S \to aSbS \mid \lambda$ は congruential だが，系 9.5 より $D_1 \notin \mathsf{RS}(\{a, b\})$ である．　□

10　結論

定性的な学習可能性は文法の正規形に依存しない一方，定量的なデータ上界には型付けの代数的構造が現れる．指数的な隔たりは，さまざまな BUNF 表示の下での型付き厚み，および集合駆動型作用素の特徴標本に関するものであり，任意の Gold 学習器の収束速度に関するものではない．窓・有限群に関する仮定は十分条件であって，必要条件であるとは主張しない．$\mathsf{RS} \cap \mathrm{CFL}$ の特徴づけは未解決である．

データ利用可能性

本論文で述べた研究には実証データを使用していない．

利益相反の申告

著者は，本論文で報告した研究に影響を与えた可能性のある，既知の競合する金銭的利害関係または個人的関係が存在しないことを申告する．

研究費

本研究は，公的機関，民間企業，非営利部門のいずれの資金配分機関からも，特定の助成を受けていない．

謝辞

著者は，指導，励まし，関連文献についての助力をいただいた Makoto Kanazawa（金澤誠）氏と Ryo Yoshinaka（吉仲亮）氏，および本論文を大きく改善する慎重かつ建設的な査読報告をくださった二名の匿名査読者に感謝する．とりわけ，査読者は初回投稿版の学習アルゴリズムに含まれていた問題を指摘し，定理 9.2 における直接的な二語による証拠の提示を促した．また，本研究の初期段階にあたる ICGI 2014 において有益な助言をくださった Alexander Clark 氏にも感謝する．なお，残る誤りについてはすべて著者が責任を負う．

原稿作成過程における生成 AI および AI 支援技術の利用申告

本原稿の作成および改訂にあたり，著者は OpenAI の ChatGPT と Anthropic の Claude を，文章の編集，原稿の構成整理，および数学的議論の検討の補助に使用した．著者は AI による支援を受けた内容を自ら確認・編集しており，本論文に提示する結果および証明について全面的に責任を負う．

付録 A　固定窓証拠語上界と厚み保存正規化

A.1　補題 7.1 の証明

補題 *7.1* の証明. $m := k + \ell$，$q := |\mathsf{H}|$，$N := |V|$，$\bar{\tau} := \tau_G + 1$ とおく．元の開始記号 S_0 も許して $A \in V$ を取り，残存する型付きコピー A_μ を考える．$\mu = \mathbf{1}_\sharp$ なら生成語は λ のみなので，以下は $\mu \neq \mathbf{1}_\sharp$ とする．$\widehat{s}$-型が μ である非空語 $w_0 \in L_G(A)$ を取り，その $(s_{k,\ell} \times g)$-値を η とする．A から導出できる非空語でこの値が η となる導出木のうち，まず生成語長，次いで非終端節点数が最小のものを T とし，その生成語を w とする．核の包含から $\widehat{s}(w) = \mu$ であり，命題 5.1 により $|\omega(A_\mu)| \leq |w|$ となる．$|w| < m$ なら上界は明らかなので，以下 $|w| \geq m$ とする．

w の最初の k 文字と最後の ℓ 文字の位置は交わらない．これらを保護し，さらに任意の一文字を**非空性アンカー**として選ぶ．アンカーは既に保護されている窓位置と一致してもよい．その和集合を Prot とおくと $1 \leq d := |\mathrm{Prot}| \leq m + 1$ である．特に $m = 0$ でも短縮後の非空性が保たれる．このとき，次の最小性の帰結を使う．

(∗) w の互いに交わらない因子のうち，その出現に保護位置を含まないものだけを置換して得た語を w' とし，$g(w') = g(w)$ とする．このとき w' は非空であり，$(s_{k,\ell} \times g)$-値も η である．従って，A から w' を導出する木があっても，T より生成語長が短くなることも，同じ語長で非終端節点数が少なくなることもない．

実際，保護された最初の k 文字と最後の ℓ 文字は窓をそのまま与え，$|w'| \geq d \geq 1$ である．

T における**非終端記号の出現**だけを節点として考える．単位規則および空語規則からの節点も含める．節点 z のラベルを $X_z \in V$，生成する終端語（空語も可）を y_z，その生成範囲内の保護位置の集合を $P_z \subseteq \mathrm{Prot}$ とする．$P_z \neq \emptyset$ または $|y_z| > \bar{\tau}$ を満たす節点を**重要節点**と呼ぶ．

深さ．節点 z の真の子孫 z' が，z と同じ三つ組 $(P_z, X_z, g(y_z))$ を持つとする．z' の部分木を z の位置へ移植すると，削除される部分は保護位置と交わらず，全文字列の群値も保存される．よって $(*)$ を適用できる．移植後の語長は増えず，非終端節点数は真に減少するので最小性に矛盾する．各経路では P_z が包含関係について単調であり，異なる値は高々 $d+1$ 種類である．従って，経路上の非終端節点数は高々 $(d+1)Nq \le (m+2)Nq$ である．

幅．ある深さに重要節点が $d+q$ 個あれば，互いに交わらない生成範囲を考えると，少なくとも q 個は保護位置を含まない．そのうち q 個を左から順に取り，生成語を $a_1, \dots, a_q$ とする．それぞれ $|a_i| > \bar{\tau}$ である．各節点の非終端ラベルから導出できる $|b_i| \le \tau_G$ の語 b_i を取る．$b_i = \lambda$ も許す．$w = c_0 a_1 c_1 \cdots a_q c_q$ と表す．$1 \le j \le q$ に対し，$r_j := g(a_1 c_1 \cdots a_j c_j)$ と $t_j := g(b_1 c_1 \cdots b_j c_j)$ を定め，$x_j := t_j r_j^{-1}$，$r_0 = t_0 = x_0 := 1_{\mathsf{H}}$ とおく．鳩ノ巣原理により，$x_i = x_j$ となる $0 \le i < j \le q$ が存在する．順序を保った区間積で $r_j = r_i r_{i:j}$，$t_j = t_i t_{i:j}$ と書けば，$t_i r_i^{-1} = t_i t_{i:j} r_{i:j}^{-1} r_i^{-1}$ となる．この順序で消去して $t_{i:j} = r_{i:j}$ を得る．従って対応する二つの区間語の g-値は等しい．選んだ互いに交わらない部分木を，$b_{i+1}, \dots, b_j$ の導出木で置き換えると，群値と保護位置を保ったまま生成語長が厳密に減少し，$(*)$ に矛盾する．ここでは H の可換性を仮定しない．従ってどの深さでも重要節点数は高々 $d+q-1 \le m+q$ である．

計数．重要な非終端節点は祖先について閉じており，$d \ge 1$ なので根も重要である．従って総数は $E := (m+q)(m+2)Nq$ 以下である．G は BUNF なので，重要節点の下にぶら下がる極大な非重要部分木は高々 $2E$ 個であり，それぞれの生成語長は高々 $\bar{\tau}$ である．それ以外の終端文字は重要な終端生成規則の節点から出るが，その生成語長は $1 \le \bar{\tau}$ だから保護位置に含まれる．そのような文字は高々 d 個である．従って

$$|w| \le d + 2E\bar{\tau} \le m + 1 + [1 + 2(m+q)(m+2)Nq](\tau_G + 1). \qquad \square$$

A.2 厚みを多項式的に保存する BUNF 正規化

命題 *7.3* の証明. G_* を縮約済み CFG とし，$n := |G_*|$, $\bar{\tau} := \tau_{G_*} + 1$ とおく．元の単位規則と空語規則を保持したまま，まず長い右辺の終端記号を $W_a \to a$ というラッパーで分離し，次に右辺を二分化する．この古典的操作は元の各非終端記号の生成言語を保つ [22, Section 3.1] [25, Sections 7.1 and 7.4.2]．二分化の補助記号は元の生成規則ごとに新鮮に取る．それは右辺の高々 $O(n)$ 個の元の記号からなる連続部分に対応するため，各記号の最短生成語を代入して長さ $O(n(\tau_{G_*} + 1))$ 以下の語が得られる．元の非終端記号の生成言語・最短生成語長は変わらない．最後に非到達・非生産的な記号を除去する．得られる縮約済み BUNF 文法は元の言語を生成し，サイズは n の多項式で，厚みは $O(n(\tau_{G_*} + 1))$ である． $\square$

付録 B　linear-spine BUNF 正規化の証明

命題 *8.1* の証明. 線形 CFG の生成規則は $A \to uBv$ または $A \to w$ $(u, v, w \in \Sigma^*)$ と書ける．単位規則 $A \to B$ と空語規則 $A \to \lambda$ は残す．新しいラッパー $W_a \to a$ を各 $a \in \Sigma$ に導入し，他の補助

非終端記号は規則ごとに新たに取る．規則 $A \to a_1 \cdots a_m B b_1 \cdots b_n$（$m+n>0$）には，右鎖と左鎖

$$C_0^{\mathrm{R}} := B, \quad C_j^{\mathrm{R}} \to C_{j-1}^{\mathrm{R}} W_{b_j} \qquad (1 \le j \le n),$$
$$C_0^{\mathrm{L}} := C_n^{\mathrm{R}}, \quad C_i^{\mathrm{L}} \to W_{a_{m-i+1}} C_{i-1}^{\mathrm{L}} \quad (1 \le i \le m)$$

を作る．$m=0$ なら $C_n^{\mathrm{R}} = A$，それ以外なら $C_m^{\mathrm{L}} = A$ と同一視する．$m=n=0$ なら $A \to B$ をそのまま残す．終端のみの規則 $A \to a_1 \cdots a_k$ は $k=0,1$ なら残す．$k \ge 2$ なら $C_1^{\mathrm{T}} := A$ と新しい $C_2^{\mathrm{T}}, \ldots, C_k^{\mathrm{T}}$ により

$$C_i^{\mathrm{T}} \to W_{a_i} C_{i+1}^{\mathrm{T}} \quad (1 \le i < k), \qquad C_k^{\mathrm{T}} \to a_k$$

とする．各二項規則はちょうど一つの終端ラッパー子と一つの spine 子を持つ．最後に非到達・非生産的記号を除去すれば，同値な縮約済み BUNF 文法となり，符号化サイズは元の文法サイズの多項式である． □

付録 C　括弧付き倍増言語族の代入可能性

$L_0 = \{\mathtt{a}\}$ とおき，$i \ge 1$ に対して $L_i = \lceil L_{i-1} \rceil \cup \lfloor L_{i-1} L_{i-1} \rfloor$ と定める．従って $0 \le i \le n$ では $L_{G_n}(E_i) = L_i$，かつ $L_n = L(G_n)$ である．$n \ge 1$ を固定する．以下では，入力文字を固定したときに遷移が単射となる決定的トップダウン解析器を用いて，命題 6.4(i) を証明する．

■解析器． **スタック**とは $E_0, \ldots, E_n, \rceil, \rfloor$ 上の語であり，左端を頂点，λ を空スタックとする．任意のスタック ψ と $1 \le i \le n$ に対し，遷移は次のものに限られる．

$$E_0\psi \xrightarrow{\mathtt{a}} \psi, \quad E_i\psi \xrightarrow{\lceil} E_{i-1}\rceil\psi, \quad E_i\psi \xrightarrow{\lfloor} E_{i-1}E_{i-1}\rfloor\psi,$$
$$\rceil\psi \xrightarrow{\rceil} \psi, \quad \rfloor\psi \xrightarrow{\rfloor} \psi.$$

これ以外の遷移はなく，特に空スタックからは遷移できない．$\sigma \xrightarrow{w} \theta$ は σ から w を読んで θ に至る計算を表す．この解析器の初期スタックは E_n で，$E_n \xrightarrow{w} \lambda$ のとき w を受理する．補題 付録 C.1 により，受理言語はちょうど L_n である．次の三つの性質を用いる．

(P1) **決定性と文字ごとの単射性．**入力文字 c を固定すると，遷移はスタック上の部分単射写像を定める．すなわち，各スタックからの c-遷移先は高々一つであり，同じ遷移先をもつ二つの c-遷移の出発スタックは一致する．開き括弧では遷移先の頂部から展開前の E_i と保存された接尾部が復元でき，$\mathtt{a}, \rceil, \rfloor$ では入力文字により取り除かれた頂記号が一意に決まる．従って任意の語はスタック上の部分単射写像として作用する．すなわち，$\sigma \xrightarrow{w} \theta$ と $\sigma \xrightarrow{w} \theta'$ なら $\theta = \theta'$，また $\sigma \xrightarrow{w} \theta$ と $\sigma' \xrightarrow{w} \theta$ なら $\sigma = \sigma'$ である．

(P2) **重み．**E_i の重みを 4^i，各閉じ記号の重みを 1 とし，スタック σ の総重みを $\mathrm{wt}(\sigma)$ とする．各 pop 遷移は重みを 1 減らし，$i \ge 1$ では $4^i > 2 \cdot 4^{i-1} + 1$ だから，すべての遷移は重みを厳密に減らす．従って $\sigma \xrightarrow{w} \sigma$ なら $w = \lambda$ である．

(P3) **局所性．**遷移は頂記号だけを調べて書き換え，閉じ記号は pop されるだけである．従って $\sigma \xrightarrow{w} \theta$ なら $\sigma\psi \xrightarrow{w} \theta\psi$ も成り立つ．逆に $\sigma_1 \ne \lambda$ かつ $\sigma_1\psi \xrightarrow{w} \theta$ とする．このとき次のいずれかが成立する．

(a) 計算が ψ に到達する場合：最初の到達時点で分割すると，$w = w_1 w_2$，$\sigma_1 \xrightarrow{w_1} \lambda$，$\psi \xrightarrow{w_2} \theta$ となる．従って $\mathrm{wt}(\theta) \le \mathrm{wt}(\psi)$ である．

(b) ψ に到達しない場合：$\theta = \theta_1\psi$，$\sigma_1 \xrightarrow{w} \theta_1 \neq \lambda$ となる．従って $\mathrm{wt}(\theta) > \mathrm{wt}(\psi)$ であり，σ_1 の末尾記号が閉じ記号なら，θ_1 の末尾も同じ閉じ記号である．

よって固定した接尾部 ψ に対しては，$\mathrm{wt}(\theta)$ と $\mathrm{wt}(\psi)$ を比較すれば，いずれの場合か判定できる．

補題 付録 C.1. $0 \leq i \leq n$，任意のスタック ψ について，$E_i\psi \xrightarrow{w} \psi$ と $w \in L_i$ は同値である．特に解析器はちょうど L_n を受理する．さらに $\sigma \xrightarrow{w} \theta$ かつ $w \in L_i$ なら $\sigma = E_i\theta$ である．

Proof. $E_i\psi \xrightarrow{w} \psi$ とする．(P3) を $\sigma_1 = E_i$ として適用すると，(b) では終状態が $\theta_1\psi \neq \psi$ となるから，(a) でなければならない．従って $w = w_1w_2$，$E_i \xrightarrow{w_1} \lambda$，$\psi \xrightarrow{w_2} \psi$ と分割される．(P2) から $w_2 = \lambda$ である．(P3) の接尾部を保持した持ち上げも使えば，$E_i \xrightarrow{w} \lambda$ と $w \in L_i$ の同値性を示せば十分である．これを i に関する帰納法で示す．$i = 0$ では E_0 から唯一可能な a-遷移が空スタックに至り，その後は遷移できない．$i \geq 1$ では最初の入力文字は $\lceil$ または $\lfloor$ である．$\lceil$ の後のスタックは $E_{i-1}\rceil$ であり，これを空にする必要がある．終状態が λ なので (P3) の (b) は不可能であり，$\sigma_1 = E_{i-1}$，$\psi = \rceil$ として (a) を適用すると，残りの入力は zz' と分かれ，$E_{i-1} \xrightarrow{z} \lambda$，$\rceil \xrightarrow{z'} \lambda$ となる．従って $z' = \rceil$ である．$\lfloor$ の後は $E_{i-1}E_{i-1}\rfloor$ に同じ分割を二度適用すれば，入力は $z_1z_2\rfloor$ の形で，$E_{i-1} \xrightarrow{z_j} \lambda$ を満たす．帰納法から，$E_i \xrightarrow{w} \lambda$ と $w \in \lceil L_{i-1}\rceil \cup \lfloor L_{i-1}L_{i-1}\rfloor = L_i$ は同値であり，逆方向の計算は (P3) の持ち上げで構成できる．

最後の主張は，前半から $E_i\theta \xrightarrow{w} \theta$ が成り立つので，(P1) の単射性により $\sigma = E_i\theta$ を得る． □

補題 付録 C.2. $0 \leq i \leq n$，$w, w' \in L_i$ なら $w \equiv_{L_n} w'$ である．

Proof. $pwq \in L_n$ とする．補題 付録 C.1 により

$$E_n \xrightarrow{p} \sigma \xrightarrow{w} \theta \xrightarrow{q} \lambda$$

という計算が存在し，$\sigma = E_i\theta$ となる．同じ補題により $E_i\theta \xrightarrow{w'} \theta$ だから $pw'q \in L_n$ である．w, w' を入れ替えると逆向きの含意も成立する． □

補題 付録 C.3 (分岐同期)**.** $\sigma \xrightarrow{x} \theta$ と $\sigma \xrightarrow{y} \theta$ を満たす非空語 x, y の先頭文字が異なるとする．このとき，ある $1 \leq i \leq n$ とスタック ψ について $\sigma = E_i\psi$ であり，$x = wx'$，$y = w'y'$，$w, w' \in L_i$ と分解でき，$\psi \xrightarrow{x'} \theta$，$\psi \xrightarrow{y'} \theta$ が成り立つ．

Proof. 異なる二文字を初手で読めるのは，頂点が E_i（$i \geq 1$）の場合だけであり，その二文字は $\lceil, \lfloor$ である．$x = \lceil x_0$，$y = \lfloor y_0$ とすると，

$$E_{i-1}\rceil\psi \xrightarrow{x_0} \theta, \qquad E_{i-1}E_{i-1}\rfloor\psi \xrightarrow{y_0} \theta$$

となる．双方に共通の接尾部 ψ について (P3) を適用する．$\mathrm{wt}(\theta)$ と $\mathrm{wt}(\psi)$ の比較により，双方は同じ場合に属する．(b) なら $\theta = \theta_1\psi = \theta_2\psi$ であり，右消去律から $\theta_1 = \theta_2$ となる．しかし θ_1 の末尾は $\rceil$，θ_2 の末尾は $\rfloor$ であり矛盾する．従って (a) が成立し，$x_0 = x_1x'$ と分割されて $E_{i-1}\rceil \xrightarrow{x_1} \lambda$，$\psi \xrightarrow{x'} \theta$ を満たす．$w := \lceil x_1$ とおくと $E_i \xrightarrow{w} \lambda$ なので，補題 付録 C.1 より $w \in L_i$ である．y についても同様に $y = w'y'$ を得る． □

命題 付録 C.4. $\sigma \xrightarrow{x} \theta$ かつ $\sigma \xrightarrow{y} \theta$ なら $x \equiv_{L_n} y$ である．

Proof. $|x|+|y|$ に関する帰納法を用いる．x または y が空語なら $\sigma=\theta$ であり，(P2) から他方も空語である．$x=cx'$，$y=cy'$ と先頭文字が同じなら，決定性から $\sigma \xrightarrow{c} \sigma'$ かつ $\sigma' \xrightarrow{x'} \theta$，$\sigma' \xrightarrow{y'} \theta$ である．帰納法により $x' \equiv_{L_n} y'$，従って $x \equiv_{L_n} y$ となる．先頭文字が異なる場合は補題 付録 C.3 により $x=wx'$，$y=w'y'$ と分解できる．w, w' は非空なので帰納法から $x' \equiv_{L_n} y'$ を得る．補題 付録 C.2 より $w \equiv_{L_n} w'$ であり，構文合同のモノイド合同性から $wx' \equiv_{L_n} w'y'$ が従う． □

命題 *6.4(i)* の証明. 有限言語 L_n は文脈自由である．$x, y \in \Gamma_{\mathrm{br}}^{+}$ と $(u,v) \in \mathcal{D}_{L_n}(x) \cap \mathcal{D}_{L_n}(y)$ を取る．補題 付録 C.1 より

$$E_n \xrightarrow{u} \sigma \xrightarrow{x} \theta \xrightarrow{v} \lambda, \qquad E_n \xrightarrow{u} \sigma' \xrightarrow{y} \theta' \xrightarrow{v} \lambda$$

となる受理計算が存在する．(P1) の決定性により $\sigma=\sigma'$，さらに (P1) の単射性により $\theta=\theta'$ となる．従って命題 付録 C.4 から $x \equiv_{L_n} y$，すなわち $\mathcal{D}_{L_n}(x) = \mathcal{D}_{L_n}(y)$ である．よって L_n は Clark–Eyraud の意味で代入可能である．条件 $s(x)=s(y)$ を追加すると前提が弱まるだけなので，L_n は任意の s に関して $\sim_s$-代入可能であり，特に $L_n \in \mathcal{C}_{s_0}^{\mathrm{cf}} \cap \mathcal{C}_{s_{\mathrm{U}}}^{\mathrm{cf}}$ が従う． □

参考文献

[1] E. M. Gold. Language identification in the limit. *Information and Control*, 10(5):447–474, 1967.

[2] A. Clark and R. Eyraud. Polynomial identification in the limit of substitutable context-free languages. *Journal of Machine Learning Research*, 8:1725–1745, 2007.

[3] R. Yoshinaka. Identification in the limit of k,l-substitutable context-free languages. In *Grammatical Inference: Algorithms and Applications – ICGI 2008*, LNCS 5278, pp. 266–279, Springer, 2008. doi:10.1007/978-3-540-88009-7_21.

[4] C. de la Higuera. *Grammatical Inference: Learning Automata and Grammars*. Cambridge University Press, 2010.

[5] M. Kanazawa. Identification in the limit of categorial grammars. *Journal of Logic, Language and Information*, 5(2):115–155, 1996. doi:10.1007/BF00173697.

[6] M. Kanazawa. *Learnable Classes of Categorial Grammars*. CSLI Publications, 1998.

[7] T. Kuriyama. *Learning Algorithm for Relation-Substitutable Context-Free Languages*. arXiv:1409.6247v3, November 2014 (historical version). `https://arxiv.org/abs/1409.6247v3`.

[8] R. Yoshinaka. General perspective on distributionally learnable classes. In *Proceedings of the 14th Meeting on the Mathematics of Language (MoL 14)*, pp. 87–98, 2015.

[9] F. Coste, D. Fredouille, C. Kermorvant, and C. de la Higuera. Introducing domain and typing bias in automata inference. In *ICGI 2004*, LNCS 3264, pp. 115–126, Springer, 2004. doi:10.1007/978-3-540-30195-0_11.

[10] Y. Takada. Grammatical inference for even linear languages based on control sets. *Information Processing Letters*, 28(4):193–199, 1988. doi:10.1016/0020-0190(88)90208-6.

[11] Y. Takada. Learning formal languages based on control sets. In K. P. Jantke and S. Lange (Eds.), *Algorithmic Learning for Knowledge-Based Systems*, LNAI 961, pp. 316–339, Springer, 1995. doi:10.1007/3-540-60217-8_15.

[12] S. Eilenberg. *Automata, Languages, and Machines*, Vol. A. Academic Press, 1974.

[13] M. Wakatsuki and E. Tomita. A fast algorithm for checking the inclusion for very simple deterministic pushdown automata. *IEICE Transactions on Information and Systems*, E76-D(10):1224–1233, 1993.

[14] R. Eyraud, J. Heinz, and R. Yoshinaka. Efficiency in the identification in the limit learning paradigm. In J. Heinz and J. M. Sempere (Eds.), *Topics in Grammatical Inference*, pp. 25–46, Springer, 2016. doi:10.1007/978-3-662-48395-4_2.

[15] C. de la Higuera. Characteristic sets for polynomial grammatical inference. *Machine Learning*, 27:125–138, 1997.

[16] A. Clark. Learning trees from strings: A strong learning algorithm for some context-free grammars. *Journal of Machine Learning Research*, 14:3537–3559, 2013.

[17] J.-E. Pin. *Varieties of Formal Languages*. Translated by A. Howie. Plenum Press, New York, 1986. ISBN 0-306-42294-8.

[18] J.-E. Pin. Syntactic semigroups. In G. Rozenberg and A. Salomaa (eds.), *Handbook of Formal Languages*, Vol. 1, pp. 679–746, Springer, 1997.

[19] J. C. Costa. Some pseudovariety joins involving locally trivial semigroups. *Semigroup Forum*, 64(1):12–28, 2002. doi:10.1007/s002330010060.

[20] J. C. Costa. Some pseudovariety joins involving groups and locally trivial semigroups. In *Semigroups, Algorithms, Automata and Languages*, pp. 341–348, World Scientific, 2002. doi:10.1142/9789812776884_0013.

[21] S. Ginsburg and E. H. Spanier. Finite-turn pushdown automata. *SIAM Journal on Control*, 4(3):429–453, 1966. doi:10.1137/0304034.

[22] J.-M. Autebert, J. Berstel, and L. Boasson. Context-free languages and pushdown automata. In G. Rozenberg and A. Salomaa (Eds.), *Handbook of Formal Languages*, Vol. 1, pp. 111–174, Springer, 1997.

[23] S. Ginsburg and S. A. Greibach. Deterministic context-free languages. *Information and Control*, 9:620–648, 1966.

[24] A. Clark. Distributional learning of some context-free languages with a minimally adequate teacher. In *Proceedings of ICGI 2010*, LNCS 6339, pp. 24–37, Springer, 2010. doi:10.1007/978-3-642-15488-1_4.

[25] J. E. Hopcroft, R. Motwani, and J. D. Ullman. *Introduction to Automata Theory, Languages, and Computation*. 3rd ed., Pearson/Addison-Wesley, 2007.