

固定有限モノイド型付けの下での文脈自由言語の分布学習

Takayuki Kuriyama

独立研究者

growup.kuriyama@gmail.com

概要

本論文では、有限モノイドへの準同型 $h: \Sigma^* \rightarrow M$ の核 $\sim_h$ の下で文脈自由言語の分布学習を研究する。同じ h -値をもち、一つの文脈を共有する非空因子は、すべての文脈を共有することを要求する。固定 h に対し、集合駆動型再構成作用素 $\mathcal{B}_h$ は文脈自由 $\sim_h$ -代入可能標的を有限個の正例証拠から厳密に再構成し、別の保守的逐次学習器はすべての非空標的を Gold の意味で極限同定する。再構成と各更新は多項式時間である。標準証拠の大きさは、標的非終端記号を有限な h -値で分割した後に得られる最短生成語によって制御され、その長さは通常の文法厚みより指数的に大きくなり得る。従って一般の固定 h では、特徴データ上界は通常の文法厚みだけでなく、この型付き厚みによって自然に記述される。これに対し、任意の固定接頭辞 – 接尾辞窓 (k, ℓ) では、対応する型付けが Yoshinaka の (k, ℓ) -代入可能性をちょうど表し、縮約済み CFG サイズと通常の厚みに関して多項式の特徴データを得る。任意の固定 h の線形標的では、線形 CFG サイズに関して多項式の特徴データを得る。さらに、Yoshinaka による既知の正則分離を踏まえ、適切な固定準同型に対し、どの固定窓クラスにも属さない非正則線形・非線形文脈自由の標的を与え、一種類の括弧の Dyck 言語がどの固定型付けクラスにも属さないことを示す。

1 序論

1.1 背景と動機

Gold [2] は、すべての有限言語と少なくとも一つの無限言語を含む言語クラスは、正例データのみから極限同定できないことを示した。文脈自由言語では、比較してよい部分文字列を文脈間で制限する分布学習により正の結果が回復される。古典的な例として Clark–Eyraud の代入可能性 [6] と Yoshinaka の (k, ℓ) -代入可能性 [7] がある。一般的背景は de la Higuera [5] を、範疇文法の正例学習可能性に関する結果は Kanazawa [1] を参照されたい。

本論文では、この研究計画の可認識合同関係版を考える。 $h: \Sigma^* \rightarrow M$ を有限モノイドへの準同型とし、 $\sim_h := \ker h$ とする。 $x \in \Sigma^*$ に対し $\mathcal{D}_L(x) := \{(u, v) : uxv \in L\}$ と書く。言語 L が $\sim_h$ -代入可能であるとは、非空の x, y について $h(x) = h(y)$ かつ $\mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \emptyset$ ならば $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ が成り立つことをいう^{*1}。文脈自由な $\sim_h$ -代入可能言語のクラスを $\mathcal{C}_h^{\text{cf}}$ と書き、これを *fixed- h slice* と呼ぶ。したがって、分布の完全な一致を要求するのは、固定された有限代数的比較の下ですでに一致する因子だけである。

可認識合同関係は自然な有限型付けを与える。 $\text{Acc} \subseteq M$ に対して $L = h^{-1}(\text{Acc})$ が有限モノイド

^{*1} Clark [13] は代入可能性の比較対象を非空文字列に明示的に制限している。この規約では a^+ は代入可能だが、 λ を比較対象に含めると除外される。

準同型 $h: \Sigma^* \rightarrow M$ で認識されるなら、同じ h -値をもつ語は同じ分布をもつので、すべての正則言語は第 3 節で定義するより広いクラス RS に属する。ただし本論文の学習結果で用いるのは固定- h の状況であり、一つの準同型をクラス C_h^{cf} 全体で一様に固定する。これは Yoshinaka の階層で一つの組 (k, ℓ) を固定することに対応する。

この見方は、有用な有限型付けを選ぶ問題と、型付けが与えられた後に学習する問題を分離する。さらに、固定有限モノイド型付けは、一つの接頭辞 – 接尾辞窓より広い有限比較を一つの学習機構のまま扱える。積型付けにより RS は交わりと任意の逆準同型に関して閉じ、正規フィルタ後も context-free fixed- h slice を保つ。固定窓も通常の交わりには閉じているので、差は正規フィルタと消去的逆準同型にある [7, Proposition 1]. Yoshinaka の証明は、どの固定窓クラスにも属さない正則言語をすでに与えている。第 8–9 節では capped counter family を無界版との対比にのみ用い、さらに非正則線形・非線形文脈自由の例を与える。一方、無界カウンタや Dyck 型の挙動は、文脈的に異なる因子を無限に強制し、どの有限型付けでも捉えられない場合がある。この観点は、外部から与えられる型付け・領域バイアスを用いるオートマトン推論 [12] と方法論的に関連するが、本論文の h は出現ごとのオートマトン状態ではなく終端因子に合成的に作用する。

補完的な比較として control-set 学習がある。Takada の方法は、固定文法の生成規則列を正則制御言語で符号化して標的を表す [8, 9]. 関連する正例学習ではこのような制御に追加制限を課す [10]. これに対し、本論文の固定準同型は終端因子に型を与え、比較してよい因子を制限する。ここでは位置づけのためにこの相違を述べるだけで、両方法論の同値性・包含関係・一般的なクラス分離は主張しない。線形言語は 1 ターン・プッシュダウンオートマトンによる特徴づけをもつので、有限因子型付けが pushdown の有限制御とどのように相互作用するかをより直接に記述することは自然な次の課題であり、その特徴づけは今後の課題とする。

1.2 貢献と主要結果

本論文の主要な貢献は三つである。

- (1) **固定 h に対する学習**. 集合駆動型作用素 B_h は、 C_h^{cf} の任意の標的を有限個の標準正例証拠から厳密に再構成する。別の保守的逐次学習器 A_h はすべての非空標的を Gold の意味で同定し、再構成と各更新は蓄積標本に関して多項式時間である。
- (2) **定量的境界**. 任意の固定 h では、標的非終端記号を有限 h -型で分割した後の最短生成語は、元の文法より指数的に長くなり得る。従って、通常の元文法の厚みだけでは、一般の fixed- h 再構成で用いる型付き精密化パラメータを制御できない。一方、任意の固定窓 (k, ℓ) では通常の厚みで十分であり、任意の固定 h の線形標的では線形文法サイズに関して多項式の特徴データが得られる。
- (3) **構造上・表現力上の位置**. 積型付けにより RS は交わりと任意の逆準同型に関して閉じ、正規フィルタ後も context-free fixed- h slice を保つ。固定窓との差は正規フィルタと消去的逆準同型であり、通常の交わりではない。Yoshinaka の既知の正則分離を越えて、本論文ではどの固定窓クラスにも属さない非正則線形・非線形文脈自由の標的を与える。一種類の括弧の Dyck 言語は RS の外にあり、 $RS \cap CFL$ は Clark の congruential family に真に含まれる。

1.3 論文の構成

第 2-3 節で枠組みを準備し、第 4-5 節で学習可能性を証明する。第 6-8 節で定量的結果を与え、第 9 節で表現力を比較する。長い正規化証明は付録に置く。

2 準備

Σ を有限アルファベットとし、 Σ^* を単位元 λ をもつ自由モノイドとする。また $\Sigma^+ := \Sigma^* \setminus \{\lambda\}$ とおく。対 $(u, v) \in \Sigma^* \times \Sigma^*$ を **終端文脈** と呼ぶ。 $L \subseteq \Sigma^*$ と $x \in \Sigma^*$ に対し、 L における x の **分布** を $\mathcal{D}_L(x) := \{(u, v) \in \Sigma^* \times \Sigma^* : uxv \in L\}$ と定める。 L の **構文合同関係** は、 $x, y \in \Sigma^*$ に対して $x \equiv_L y \iff \mathcal{D}_L(x) = \mathcal{D}_L(y)$ により定める。 $x \equiv_L y$ のとき、 x と y は **構文合同** であるという。語 $w \in \Sigma^*$ と文字 $a \in \Sigma$ に対し、 $|w|_a$ は w における a の出現回数を表す。

文脈自由文法 (CFG) は有限非終端記号集合 V 、開始記号 $S \in V$ 、および $A \in V, \alpha \in (V \cup \Sigma)^*$ に対する生成規則 $A \rightarrow \alpha$ からなる組 $G = (V, \Sigma, P, S)$ である。**文形式**とは $(V \cup \Sigma)^*$ の任意の語である。 G における一段階導出を $\alpha \Rightarrow_G \beta$ と書き、その反射推移閉包を $\Rightarrow_G^*$ と書く。したがって $L(G) := \{w \in \Sigma^* : S \Rightarrow_G^* w\}$ 。 $A \in V$ に対して $L_G(A) := \{w \in \Sigma^* : A \Rightarrow_G^* w\}$ とおく。非終端記号 $X \in V$ に対し、 $S \Rightarrow_G^* uXv$ が成り立つとき、終端文脈 (u, v) を G における X の **終端到達文脈** と呼ぶ。非終端記号が S から到達可能な文形式中に現れるとき **到達可能** であるといい、終端語を導出するとき **生産的** であるという。到達可能性または生産性の少なくとも一方を欠く非終端記号を **無用** といい、 λ を導出する非終端記号を **空語導出可能 (nullable)** という。 $A, B \in V$ に対する生成規則 $A \rightarrow B$ を **単位規則** という。**単位閉包**とは、単位生成規則が非終端記号上に誘導する関係の反射推移閉包である。すべての非終端記号が到達可能かつ生産的である文法を **縮約済み** という。非空言語を生成する文法について、その **トリム**とは、すべての無用な非終端記号と、それらに接続する生成規則を削除して得られる部分文法をいう。各右辺に高々一つの非終端記号しか現れない CFG を **線形** という。**二分化**とは、新たな非終端記号を用いて長い右辺を同値な二項生成規則の鎖へ置き換えることをいう。CFL を文脈自由言語全体のクラスとする。任意の有限表現 $\mathcal{R}$ に対し、 $|\mathcal{R}|$ は固定した妥当な符号化の長さを表すものとする。文法については、これは通常の生成規則中の記号数と多項式の範囲で同値である。Yoshinaka の固定窓解析 [7] に従い、縮約済み文法 $G = (V, \Sigma, P, S)$ について**厚み**パラメータを

$$\tau_G := \max_{A \in V} \min \{ |w| : A \Rightarrow_G^* w, w \in \Sigma^* \}$$

と定める。すなわち τ_G は、各非終端記号の最短終端生成語の長さを取り、その最大値をとったものである。

2.1 正例データからの学習

Gold の explanatory model [2] を用いる。 H_0 を、一つの開始記号をもち生成規則をもたない固定 CFG とし、 $L(H_0) = \emptyset$ とする。以下のテキスト規約は非空の標的言語に限定する。空言語はこのテキストに基づく Gold の記述から除外し、別途 H_0 により表す。同値に、通常の pause 記号をテキストに加えることで空標的を含めることもできるが、余分な記法を避けるためにここでは非空テキ

スト規約を用いる。非空言語 L に対し、**テキスト**とは、 L の各語が少なくとも一度は現れる L 上の無限列 $T = (w_1, w_2, \dots)$ である。 $T[n] = (w_1, \dots, w_n)$ および $K_n := \{w_1, \dots, w_n\}$ と書く。学習器 $\mathcal{A}$ が非空言語 L を **極限同定**するとは、 L の任意のテキスト T に対して、ある n_0 と文法 H が存在し、すべての $n \geq n_0$ について $\mathcal{A}(T[n]) = H$ かつ $L(H) = L$ が成り立つことをいう。したがって、仮説表現そのものが最終的に安定する。逐次学習器が **保守的** であるとは、新たに提示された正例データが現在の仮説によって生成されない場合にのみ、その現在の仮説を変更することをいう。

この逐次学習器とは別に、**集合駆動型再構成作用素** B を考える。これは有限標本から文法への写像であり、 $B(K)$ は有限集合 K のみに依存し、提示順序や重複回数には依存しない。任意の有限標本 K に対して $K \subseteq L(B(K))$ が成り立つとき、 B は **標本整合的** であるという。有限集合 $C \subseteq L$ が B に対する **特徴標本** であるとは、任意の有限 K について $C \subseteq K \subseteq L$ ならば $L(B(K)) = L$ が成り立つことをいう。これは de la Higuera の多項式文法推論枠組み [4] における有限標本部分である。標本サイズを $\|K\| := \sum_{w \in K} (|w| + 1)$ で測る^{*2}。したがって λ も 1 を寄与する。以下では **emph 特徴データ** という語を、特徴標本 C の符号化サイズ $\|C\|$ の略称としてのみ用いる。定量的結果では、 $B(K)$ の多項式時間構成と、多項式に抑えられる特徴データサイズを組み合わせる。

2.2 固定有限モノイド型付け

有限モノイド M と準同型 $h: \Sigma^* \rightarrow M$ を固定する。これらは M の乗法表および各 $a \in \Sigma$ に対する文字像 $h(a)$ によって表現される。したがって $h(w)$ は左から右への積によって $O(|w|)$ 時間で計算できる。以下で固定準同型が **効率的に計算可能** であるというのはこの意味である。

定義 2.1 (固定- h 代入可能性). 言語 $L \subseteq \Sigma^*$ が $\sim_h$ -代入可能 であるとは、すべての $x, y \in \Sigma^+$ について、 $h(x) = h(y)$ と $\mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \emptyset$ から $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ が従うことをいう。

空語は内部の代入可能因子としては用いない。 $\lambda \in L$ の場合には、再構成において開始記号を通じて別途処理する。

非空内部因子 x に対して、 $h(x)$ をその **生成語型** と呼ぶ。文脈自由 $\sim_h$ -代入可能言語のクラスを $\mathcal{C}_h^{\text{cf}}$ と書き、

$$\mathcal{C}_h^{\text{lin}} := \{L \in \mathcal{C}_h^{\text{cf}} : L \text{ はある線形 CFG により生成される}\}$$

と定める。したがって $\mathcal{C}_h^{\text{lin}}$ は線形言語からなる部分クラスである。以下の多項式データ上界は、標的について選ばれた線形 CFG 表現を基準に測る。後で構成される再構成仮説自体は線形文法である必要はない。

3 固定可認識代入可能性

固定 h に対し $\text{RS}_h := \{L \subseteq \Sigma^* : L \text{ は } \sim_h\text{-代入可能}\}$ とおく。fixed- h slice は $\mathcal{C}_h^{\text{cf}} = \text{RS}_h \cap \text{CFL}$ であり、 $\mathcal{C}_h^{\text{lin}}$ はそのうち線形 CFG で生成される言語からなる。表現力の比較に限り、 h を Σ^* 上の有限モノイド準同型全体に動かして $\text{RS} := \bigcup_h \text{RS}_h$ とする。アルファベットを明示するときは $\text{RS}_h(\Gamma)$, $\text{RS}(\Gamma)$ と書き、以下の包含はアルファベットごとに解釈する。学習結果は常に一つの固定

^{*2} $+1$ は、 $K = \{\lambda\}$ のような非空標本のサイズが 0 になることを防ぐ。また $|K| \leq \|K\|$ となるため、正例数も同じサイズ尺度で抑えられる。

h を対象とする.

命題 3.1. 言語が正則であることと、ある有限モノイド M への準同型 $h : \Sigma^* \rightarrow M$ と $\text{Acc} \subseteq M$ に対して $h^{-1}(\text{Acc})$ の形に書けることは同値である. さらに任意の固定 h と $\text{Acc} \subseteq M$ に対し, $h^{-1}(\text{Acc})$ は $\sim_h$ -代入可能である. 従ってすべての正則言語は RS に属する.

Proof. 最初の主張は有限モノイドによる正則言語の標準的特徴づけである [3]. $L = h^{-1}(\text{Acc})$ かつ $h(x) = h(y)$ なら, すべての u, v に対し $h(uxv) = h(uyv)$ なので $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ である. $\square$

非空アルファベット上では, RS も $\text{RS} \cap \text{CFL}$ も正例データから極限同定できない. 命題 3.1 により両者はすべての有限言語と Σ^* を含むため, Gold の定理が適用されるからである.

型付けの精密化には単調性がある. $\ker h' \subseteq \ker h$ ならば, h' は比較を要求する因子対を減らすので $\text{RS}_h \subseteq \text{RS}_{h'}$ である. ただし精密化は, 後の定量解析で使う型付き文法を大きくし得る. 二つの有限型付け h, g に対し $\ker(h \times g) = \ker h \cap \ker g$ だから $\text{RS}_h \cup \text{RS}_g \subseteq \text{RS}_{h \times g}$ であり, 窓情報と別の有限特徴を標的ごとに型付けを変えずに合成できる.

命題 3.2 (有限情報に関する閉包性). $h : \Sigma^* \rightarrow M$ と $g : \Sigma^* \rightarrow N$ を有限モノイド準同型とする.

(i) $L \in \text{RS}_h$ かつ $K \in \text{RS}_g$ ならば $L \cap K \in \text{RS}_{h \times g}$ である.

(ii) $R = g^{-1}(F)$ が正規言語で $L \in \mathcal{C}_h^{\text{cf}}$ ならば $L \cap R \in \mathcal{C}_{h \times g}^{\text{cf}}$ である.

(iii) $\varphi : \Gamma^* \rightarrow \Sigma^*$ を, 消去的でもよい任意の準同型とする. $E = \{1, \zeta\}$ を零元 ζ をもつ二元モノイドとし, $\varphi(w) = \lambda$ のときかつそのときに限り $e_\varphi(w) = 1$, それ以外では $e_\varphi(w) = \zeta$ と定め, $\hat{h} = (h \circ \varphi) \times e_\varphi$ とおく. $L \in \text{RS}_h$ ならば $\varphi^{-1}(L) \in \text{RS}_{\hat{h}}$ であり, さらに $L \in \mathcal{C}_h^{\text{cf}}$ ならば $\varphi^{-1}(L) \in \mathcal{C}_{\hat{h}}^{\text{cf}}$ である.

Proof. (i) について, 非空因子 x, y が同じ $(h \times g)$ -型をもち, $L \cap K$ で文脈を共有するとする. すると L では同じ h -型で文脈を共有し, K では同じ g -型で文脈を共有する. 従って $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ かつ $\mathcal{D}_K(x) = \mathcal{D}_K(y)$ なので, $\mathcal{D}_{L \cap K}(x) = \mathcal{D}_{L \cap K}(y)$ である. (ii) は (i), 命題 3.1, および CFL の正規言語との交わりに関する閉包性から従う.

(iii) では, $\varphi(uv) = \lambda$ であることと $\varphi(u) = \varphi(v) = \lambda$ であることが同値なので, e_φ は準同型である. 同じ $\hat{h}$ -型をもち非空因子 x, y が $\varphi^{-1}(L)$ で文脈を共有するとする. $e_\varphi(x) = e_\varphi(y) = 1$ ならば $\varphi(x) = \varphi(y) = \lambda$ なので, 逆像言語での分布は自明に一致する. そうでなければ両像は非空で, 同じ h -型をもち, 共有文脈の像が L における共通文脈になる. 従って fixed- h 代入可能性から L での分布が一致し, 文脈を φ で引き戻せば $\mathcal{D}_{\varphi^{-1}(L)}(x) = \mathcal{D}_{\varphi^{-1}(L)}(y)$ を得る. context-free の主張は CFL の逆準同型に関する閉包性による. $\square$

Yoshinaka [7, Proposition 1] は, (k, ℓ) -代入可能言語が正規フィルタと一般の逆準同型には閉じない一方, 通常の変わりと λ -free な逆準同型には閉じることを示す. その証明はすでに正則な分離例

$$L_0 = ae^*ce^*a \cup ae^*de^*a \cup be^*ce^*b$$

を与え, これはどの固定窓クラスにも属さない. また context-free 部分クラスは交わりに閉じないと注記されている. 従って積型付けの構造的利点は正規フィルタと消去的逆準同型にあり, 通常の変わりではない. 下の定理 9.2 は第 9.3 節の無界カウンタ障害と対にする capped 版としてのみ残す. RS がこれらの演算による固定窓階層の閉包そのものに一致するとは主張しない.

■型付けはいつ有用か． 標的 L に対する正しさという観点では、定義 2.1 より、 h が有効であるための条件は、共通文脈をもつのに分布が異なる二つの非空因子を同じ型に入れれないことにちょうど等しい．この条件は、上の単調性により型付けの精密化で保存される．後の補題 9.3 は、そのような衝突因子の無限な pairwise family があれば有限型付け自体が存在しないという簡単な障害を与える．一方、定量的効率性は別問題である．精密化は再構成上界で用いる型付き文法を大きくし得る．備考 6.3 は元文法厚みから型付き厚みへの指数ギャップを示し、第 7 節と第 8 節は、そのコストを制御できる十分な場合を与える．

$\ker h$ を Σ^+ に制限した関係が構文合同 $\equiv_L$ を精密化するなら $L \in \text{RS}_h$ である．逆は通常の代入可能性ですでに成り立たない． $L_c := \{a^n cb^n : n \geq 0\}$ を考える．定義 2.1 の非空因子規約の下で L_c は Clark–Eyraud 代入可能だが、 $\equiv_{L_c}$ は無限指数である．実際 $1 \leq i < j$ に対して文脈 (a, cb^{i+1}) は a^i と a^j を区別する． Σ^+ への制限は本質的であり、自明モノイドの下で λ まで比較すると a^+ のような例まで誤って除外される．

3.1 古典的特殊場合

Clark–Eyraud の定義 5 は一般の文字列について量化している [6]．ここでは Clark [13] が明示する非空因子規約を採用する．この規約では a^+ は代入可能である．すべての $x, y \in \Sigma^+$ について $\mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \emptyset$ から $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ が従うとき、 L を *Clark–Eyraud 代入可能* と呼ぶ．これは定義 2.1 の自明モノイドの場合、従って Yoshinaka の $(0, 0)$ の場合にちょうど一致する．

特に、一元モノイドをとれば、すべての Clark–Eyraud 代入可能言語は RS に属する．

$k, \ell \geq 0$ に対し、 $\text{pref}_k(w)$ と $\text{suf}_\ell(w)$ をそれぞれ長さ $\min\{k, |w|\}$ の接頭辞と長さ $\min\{\ell, |w|\}$ の接尾辞とする．特に $\text{pref}_0(w) = \text{suf}_0(w) = \lambda$ であり、短い語については語全体を返す．一般の文脈記法との衝突を避けるため Yoshinaka の窓変数を改名して、 L が (k, ℓ) -代入可能 であるとは、 $p \in \Sigma^k, q \in \Sigma^\ell$ および $x_1, x_2, y_1, y_2, z_1, z_2 \in \Sigma^*$ で $py_1q, py_2q \neq \lambda$ のとき

$$\begin{aligned} x_1py_1qz_1 \in L, \quad x_1py_2qz_1 \in L, \quad x_2py_1qz_2 \in L \\ \implies x_2py_2qz_2 \in L \end{aligned}$$

が成り立つことをいう．

命題 3.3. 任意の固定 $k, \ell \geq 0$ に対して有限モノイド準同型 $h_{k, \ell}$ が存在し、任意の $L \subseteq \Sigma^*$ について、 L が (k, ℓ) -代入可能であることと $\sim_{h_{k, \ell}}$ -代入可能であることは同値である．

Proof. $m_0 := \max\{1, k + \ell\}$ とし、 $|w| < m_0$ なら $h_{k, \ell}(w) := w$ 、それ以外では、二つの場合を区別するタグを付けて $h_{k, \ell}(w) := \langle \text{pref}_k(w), \text{suf}_\ell(w) \rangle$ とする．有限像を $M_{k, \ell} := h_{k, \ell}(\Sigma^*)$ と書く．短い語 x, y について

$$\begin{aligned} x \cdot y &:= h_{k, \ell}(xy), & x \cdot \langle p, q \rangle &:= \langle \text{pref}_k(xp), q \rangle, \\ \langle p, q \rangle \cdot y &:= \langle p, \text{suf}_\ell(qy) \rangle, & \langle p, q \rangle \cdot \langle p', q' \rangle &:= \langle p, q' \rangle \end{aligned}$$

と積を定める．すると $h_{k, \ell}(xy) = h_{k, \ell}(x) \cdot h_{k, \ell}(y)$ であり、全射性から結合律が従い、 $h_{k, \ell}(\lambda)$ が単位元になる．

非空 s, t の型が等しいことは、 $s = t$ であるか、共通の長さ k の接頭辞 p と長さ ℓ の接尾辞 q を用いて $s = py_1q, t = py_2q$ と書けることを意味する ($k = \ell = 0$ も含む)． L が (k, ℓ) -代入可能な

ら、共通文脈と片方の任意の文脈から Yoshinaka の四語条件を適用し、対称性により分布が一致する。逆に Yoshinaka の前提では $s := py_1q$, $t := py_2q$ は非空で、長語側の符号化に属するため同じ $h_{k,\ell}$ -型をもつ。固定- $h_{k,\ell}$ 代入可能性が第三の文脈を移送し、第四の語を与える。 $\square$

■固定窓代入可能性の反例基準。 $m_0 := \max\{1, k + \ell\}$ とする。 s, t が長さ m_0 以上で、同じ長さ k の接頭辞と長さ ℓ の接尾辞をもち、共通文脈をもつ一方で分布が異なるなら、 L は (k, ℓ) -代入可能ではない。最初の三条件から $h_{k,\ell}$ -型が等しく共通文脈をもち、最後の条件が $\sim_{h_{k,\ell}}$ -代入可能性に反するからである。

従って固定 (k, ℓ) クラスはちょうど $RS_{h_{k,\ell}}$ であり、第 7 節でその多項式厚み付きデータ上界を与える。 $k = \ell = 0$ では $h_{0,0}$ は λ と非空語を区別するだけで、一元モノイドと同じ代入可能性条件を誘導する。アルファベット Γ に対し

$$KL(\Gamma) := \bigcup_{k, \ell \geq 0} \{L \subseteq \Gamma^* : L \text{ は } (k, \ell)\text{-代入可能}\}$$

とし、 $KL := KL(\Sigma)$ と略記する。

3.2 主定理

定理 3.4 (固定- h 学習定理). 効率的に計算可能な有限モノイド準同型 $h : \Sigma^* \rightarrow M$ を固定する。集合駆動型再構成作用素 B_h と保守的逐次学習器 A_h が存在し、次を満たす。

- (i) B_h は標本整合的で、 $B_h(K)$ は $\|K\|$ の多項式時間で構成できる。
- (ii) すべての $L \in \mathcal{C}_h^{\text{cf}}$ は B_h に対する有限特徴標本をもつ。
- (iii) A_h はすべての非空 $L \in \mathcal{C}_h^{\text{cf}}$ を *Gold* の意味で同定し、各更新はそれまでに見たデータの多項式時間で行える。
- (iv) 固定 (k, ℓ) に対し $h = h_{k,\ell}$ とすると、(ii) の標本は、標的を表す任意の縮約済み CFG R について $|R|$ と τ_R の多項式サイズに選べる。
- (v) 任意の固定 h と $L \in \mathcal{C}_h^{\text{lin}}$ に対し、(ii) の標本は、 L を表す任意の線形 CFG R について $|R|$ の多項式サイズに選べる。

項目 (iv)–(v) の定量的機構と、一般の固定型付けに対するその限界は、第 6–8 節で扱う。

非空アルファベット上では、クラス $\mathcal{C}_h^{\text{cf}}$ はすべての有限言語を含むわけではない。 $h(x) = h(y)$ を満たす相異なる非空語 x, y を取り、さらに $|z| > \max\{|x|, |y|\}$ を満たす $z \in \Sigma^*$ を取る。 $\{x, y, zx\}$ では x, y は空文脈を共有するが、 (z, λ) は x だけの文脈である。

4 再構成作用素と逐次学習器

4.1 有限標本からの再構成

有限標本 $K \subseteq \Sigma^*$ に対し、 $\hat{V}(K) := \{[x : u, v] : uxv \in K, x \in \Sigma^+\}$ とおく。これらは構文的三つ組である。すなわち規約として、 $[x : u, v] = [x' : u', v'] \iff x = x', u = u', v = v'$ とする。特に、同じ標本語から生じる場合であっても、因子文字列または文脈文字列が異なる二つの出現は、異なる仮説非終端記号である。文法 $B_h(K) = \hat{G}(K)$ は、非終端記号集合 $\hat{V}(K) \cup \{\hat{S}\}$ と開始記号 $\hat{S}$

231 をもつ。表示されるすべての角括弧付き非終端記号が $\widehat{V}(K)$ に属する場合に、次の生成規則をもつ。

$$\begin{aligned}
(R1) \quad & [xy : u, v] \rightarrow [x : u, yv][y : ux, v], & x, y \in \Sigma^+, \\
(R2) \quad & [x : u, v] \rightarrow [x : u', v'], & uxv, u'xv' \in K, \\
(R3) \quad & [x : u, v] \rightarrow [x' : u, v], & h(x) = h(x'), \\
(R4) \quad & [a : u, v] \rightarrow a, & a \in \Sigma, \\
(R5) \quad & \widehat{S} \rightarrow [w : \lambda, \lambda], & w \in K \cap \Sigma^+.
\end{aligned}$$

232 $\lambda \in K$ のときは、規則 (R5) に $\widehat{S} \rightarrow \lambda$ も含める。直観的には、 $[x : u, v]$ は観測された因子 x を文脈
233 (u, v) の中で置き換える候補を表す。 $\sim_h$ -代入可能な標的に対しては、以下の健全性不変量により、導
234 出されるすべての語が x と同じ h -型をもち、分布的に交換可能であることが保証される。規則 (R2)
235 は文脈輸送規則である。同じ観測因子は、その因子自身が観測された任意の文脈で表現できる。二つ
236 の周囲文脈の h -型に関する条件は不要である。規則 (R3) は、一つの固定生成語型の内部で代表元を
237 変更する。その条件 $h(x) = h(x')$ は、健全性不変量の生成語型部分を保存するためにまさに用いら
238 れる。その不変量はその後規則 (R1) および (R2) で代入可能性を適用するときに用いられる。

239 **補題 4.1** (標本整合性). 任意の有限正例標本 K に対して、 $K \subseteq L(\mathcal{B}_h(K))$ が成り立つ。

240 *Proof.* $w = a_1 \cdots a_m \in K \cap \Sigma^+$ とする。規則 (R5) により $[w : \lambda, \lambda]$ に入る。この w の出現を任意
241 に二分木分解し、それに沿って規則 (R1) を繰り返し適用すると、一文字因子へ到達する。中間で必
242 要となる観測非終端記号はすべて、同じ標本語の因子と、それによって誘導される文脈から生じるた
243 め存在する。最後に規則 (R4) が $a_1 \cdots a_m$ を出力する。 $\lambda \in K$ の場合は、開始規則がこれを直接出
244 力する。 $\square$

245 また $K \subseteq K'$ ならば、 K から作られたすべての観測非終端記号と規則 (R1)–(R5) のすべてのイ
246 ンスタンスは K' に対しても残る。したがって $\widehat{G}(K)$ は $\widehat{G}(K')$ の部分文法であり、 $L(\mathcal{B}_h(K)) \subseteq$
247 $L(\mathcal{B}_h(K'))$ 。ゆえに保守的学習器が再構成を行うとき、仮説言語は拡大することしかない。

248 **定理 4.2** (健全性). $K \subseteq L$ かつ L が $\sim_h$ -代入可能ならば、 $L(\widehat{G}(K)) \subseteq L$ である。

249 *Proof.* $[x : u, v]$ を根とする導出木の高さについて帰納法を行い、次を同時に証明する。

$$[x : u, v] \Rightarrow_{\widehat{G}(K)}^* w \implies uwv \in L \text{ かつ } h(w) = h(x). \quad (1)$$

250 規則 (R1)–(R4) から開始記号以外の仮説非終端記号が空語を導出することではなく、規則 (R4) は
251 一つの終端記号を出力する。したがって、開始記号以外の仮説非終端記号から導出されるすべての
252 終端語は非空である。特に、以下で定義 2.1 を適用する語 w, w_1, w_2 は Σ^+ に属する。規則 (R4)
253 の場合は明らかである。規則 (R3) については、帰納法の仮定から $h(w) = h(x') = h(x)$ が得ら
254 れ、またすでに $uwv \in L$ が得られる。規則 (R2) については、帰納法の仮定から $u'wv' \in L$ およ
255 び $h(w) = h(x)$ が得られる。さらに $[x : u', v']$ と $[x : u, v]$ は $\widehat{V}(K)$ に属するので、その定義か
256 ら $u'xv', uxv \in K \subseteq L$ である。したがって x と w は文脈 (u', v') を共有し、代入可能性により
257 $\mathcal{D}_L(x) = \mathcal{D}_L(w)$ を得る。よって $uwv \in L$ である。

258 規則 (R1) について、導出語を w_1w_2 と書く。二つの帰納法の仮定から $uw_1yv \in L, uxw_2v \in L,$
259 $h(w_1) = h(x), h(w_2) = h(y)$ が得られる。 $uxyv \in K$ なので、 x と w_1 は文脈 (u, yv) を共有し、
260 同じ型をもつ。したがって両者の分布は一致する。第二の帰納法の仮定により $(u, w_2v) \in \mathcal{D}_L(x)$

である．この文脈に分布の等しさを適用すると $uw_1w_2v \in L$ を得る．さらに帰納法の仮定から $h(w_1w_2) = h(xy)$ である．これで (1) が証明された．開始規則を用いれば $L(\widehat{G}(K))$ に対する主張が従う． λ は $\lambda \in K \subseteq L$ の場合にのみ存在する． $\square$

4.2 逐次学習器

$\mathcal{B}_h$ を各データ到着時に再計算しても，文法表現は一般には安定しない．たとえば $L_c = \{a^n cb^n : n \geq 0\}$ では，長い正例から $[a^n cb^n : \lambda, \lambda]$ のような新しい三つ組が生じる．そこで Clark–Eyraud の Substitutable Grammar Learner (SGL, Algorithm 2) および Yoshinaka の (k, ℓ) -SGL (Algorithm 1) と同じ保守的ラッパーを用いる [6, 7]．集合駆動型再構成と逐次学習の区別については Eyraud–Heinz–Yoshinaka [14, Appendix] も参照されたい．固定空文法 H_0 から始め， w_n を読んだ後

$$H_n := \begin{cases} H_{n-1}, & w_n \in L(H_{n-1}), \\ \mathcal{B}_h(K_n), & w_n \notin L(H_{n-1}), \end{cases} \quad \mathcal{A}_h(T[n]) := H_n$$

とする．再構成は常に蓄積標本全体 K_n を用いる． $\mathcal{B}_h$ は集合駆動型だが， $\mathcal{A}_h$ が最終的に安定する文法は提示順序に依存し得る．主張するのは，標的言語を生成する文法への最終的な構文的安定化だけである (系 5.5)．実際，無限な $L \in \mathcal{C}_h^{\text{cf}}$ のテキスト T で学習器が安定するとき，その時点までの標本語より長い $w \in L$ を選べる． T 上の極限文法は $[w : \lambda, \lambda]$ を含まないが， w を先頭に追加したテキストでは，最初の再構成以降の全仮説がこの非終端記号を含む．従って，同じ標的に対して異なる極限文法が得られる．

5 有限証拠・厳密再構成・計算量

5.1 標的の精密化と有限証拠

再構成作用素と逐次学習器はすでに定義済みである．ここでは完全性の証明のためだけに標的側の精密化を導入する．目標は，対応する正例証拠が出現した後に，仮説文法が有限個の型付き標的導出を模倣できることを示すことである．次の標準形は証明上の道具としてのみ用いる．

定義 5.1 (開始記号分離二分標準形). $CFG\ G = (V, \Sigma, P, S_0)$ が 開始記号分離二分標準形 (SSBNF) にあるとは， S_0 がいかなる右辺にも現れず^{*3}，すべての開始規則が $S_0 \rightarrow A$ または $S_0 \rightarrow \lambda$ の形であり，すべての非開始規則が $A \rightarrow a$ または $A \rightarrow BC$ の形であることをいう．

任意の非空文脈自由言語は，標準的な開始記号分離，無用記号除去，開始記号以外での λ /単位規則除去，および二分化の手続きにより，同値な縮約済み SSBNF 文法をもつ．標的言語が空集合の場合は自明である．

$L \in \mathcal{C}_h^{\text{cf}}$ に対する縮約済み SSBNF 文法を $G = (V, \Sigma, P, S_0)$ とする．開始記号 $\tilde{S}$ と， $A \in V \setminus \{S_0\}$ ， $\mu \in M$ に対する非開始記号 A_μ をもつ次の生成語型付き文法を作る．以下，型添字の併置は M に

^{*3} 開始記号を文全体の生成入口として内部の非終端から分離し，型付き精密化と λ の特別扱いを単純に保つためである．

おける積を表す. すなわち $\mu\nu = \mu \cdot \nu$ とする. 規則は次である.

$$\begin{aligned}\tilde{S} &\rightarrow A_\mu & (S_0 \rightarrow A \in P, \mu \in M), \\ \tilde{S} &\rightarrow \lambda & (S_0 \rightarrow \lambda \in P), \\ A_{h(a)} &\rightarrow a & (A \rightarrow a \in P), \\ A_{\mu\nu} &\rightarrow B_\mu C_\nu & (A \rightarrow BC \in P, \mu, \nu \in M).\end{aligned}$$

この文法の縮約部分を $\tilde{G} = (\tilde{V}, \Sigma, \tilde{P}, \tilde{S})$ と書き, **型付き精密化**と呼ぶ. したがって, 規約として $\tilde{G}$ のすべての記号は到達可能かつ生産的である.

Σ 上に順序を一つ固定し, それが誘導する *shortlex* 順序を用いる. すなわち短い語を先に置き, 同じ長さなら辞書式順序で比較する. $\tilde{G}$ の各非開始記号 X に対し, $\omega(X)$ をその *shortlex* 最小終端生成語とし, これを X の**標準生成語**と呼ぶ. $\tilde{G}$ は縮約済みなので $\omega(X)$ は常に定義される.

生成語型の添字は完全性証明の規則 (R3) に必要である. 証明では, 型付き親記号の標準生成語と, 型付き子記号の標準生成語を接続した語とを比較する必要がある. 保持された型付き二項規則 $X = A_{\mu\nu} \rightarrow Y = B_\mu Z = C_\nu$ に対しては, 後で証明する生成語不変量から

$$h(\omega(X)) = \mu\nu = h(\omega(Y))h(\omega(Z)) = h(\omega(Y)\omega(Z))$$

が成り立ち, これが規則 (R3) を適用するための等式になる.

この分割の必要性は, 型付け前の文法ですで見える. $h(w) = |w| \bmod 2$ とし, 元の規則を $A \rightarrow a \mid BC, B \rightarrow a, C \rightarrow a$ とする. A の最短生成語として a を選べばその型は奇数である一方, B, C の最短生成語の接続 aa は偶数型である. したがって, A を生成語型で分割しなければ, 対応する規則 (R3) の遷移は保証されない. 生成語型で分割することで必要な等式が不変量となる. 一方で周囲の左文脈または右文脈には型を付けない. 再構成作用素がそのような型を一度も検査しないからである.

命題 5.2 (型付き持ち上げと生成語不変量). 型付き精密化は $L(\tilde{G}) = L(G)$ を満たす. さらに, $X = A_\mu$ が $\tilde{G}$ の非開始記号であるとき, $X \Rightarrow_{\tilde{G}}^* w$ ならば $h(w) = \mu$ である.

Proof. 型注釈を消去すれば, 任意の型付き導出は G の導出へ写る. 逆に, G の成功した導出木の各非開始節点に, その終端生成語の h -型を注釈する. 上で定めた終端規則と二項規則は, それらの型のボトムアップ伝播則そのものである. したがって注釈付き木は上で定めたトリム前の生成語型付き文法の導出であり, 成功した導出木に現れるすべての記号は trim 後も残る. 不変量は型付き導出についての帰納法から従う. $\square$

$\tilde{G}$ の各非開始記号 X に対し, X の終端到達文脈の中から $|u_X| + |v_X|$ を最小化するものとして $\chi(X) = (u_X, v_X)$ を選び, 同値な候補がある場合は u_X の *shortlex* 順序, 次に v_X の *shortlex* 順序で決める. $\chi(X)$ を X の**標準文脈**と呼ぶ. $\tilde{G}$ は縮約済みなので, このような終端到達文脈は存在する. 実際, 到達可能性により X は到達可能な文形式中に現れ, 周囲の非終端記号の生産性により, その左側および右側のすべての記号を終端文字列へ展開できる. 命題 5.2 から $h(\omega(A_\mu)) = \mu$ である. 有限証拠集合を

$$\begin{aligned}W(\tilde{G}) := & \{u_X \omega(X) v_X : X \in \tilde{V} \setminus \{\tilde{S}\}\} \\ & \cup \{u_X a v_X : X \rightarrow a \in \tilde{P}\} \\ & \cup \{u_X \omega(Y) \omega(Z) v_X : X \rightarrow YZ \in \tilde{P}\} \\ & \cup \{\lambda\} \text{ if } \lambda \in L\end{aligned} \tag{2}$$

により定める．ここに表示したすべての語は L に属し，集合は有限である．特に，二項規則 $X \rightarrow YZ$ に対応する証拠語は

$$\tilde{S} \Rightarrow^* u_X X v_X \Rightarrow u_X Y Z v_X \Rightarrow^* u_X \omega(Y) \omega(Z) v_X$$

により正当化される．第一族と第二族についても同様である． $W(\tilde{G})$ の要素を **標準正例証拠** と呼ぶ．第一族は各型付き記号の標準的な一出現を記録し，第二族と第三族はそれぞれ終端生成規則と二項生成規則を記録する．

5.2 厳密再構成と Gold 収束

定理 5.3 (有限証拠からの完全性)．非空言語 L に対する任意の縮約済み *SSBNF* 文法を G とし，固定準同型 h に関するその型付き精密化を $\tilde{G}$ とする．有限集合 K が $W(\tilde{G}) \subseteq K$ を満たすならば， $L \subseteq L(\tilde{G}(K))$ である．

ここが標的型付けが登場する箇所である．学習器とバッチ作用素は第 4 節ですでに定義されており，以下の証明は，それらの仮説非終端記号が生成語型付き標的非終端記号を模倣できることを示す．それ以外では，この主張は純粋に組合せ論的である．型付き文法と包含 $W(\tilde{G}) \subseteq K$ だけを用い，代入可能性も追加仮定 $K \subseteq L$ も必要としない．

Proof. 各非開始記号 X に対し， $\hat{X} := [\omega(X) : u_X, v_X]$ と書く．(2) の第一族の対応する語により， $\hat{X}$ は存在する．型付き導出 $X \Rightarrow^* w$ について帰納法を行い， $\hat{X} \Rightarrow_{\tilde{G}(K)}^* w$ を証明する．

最初の規則が $X \rightarrow a$ であるとする．第二族の対応する語 $u_X a v_X \in K$ により $[a : u_X, v_X]$ が存在する． $\omega(X) \neq a$ なら， $h(\omega(X)) = h(a)$ なので規則 (R3) が $\hat{X}$ を $[a : u_X, v_X]$ に変更する． $\omega(X) = a$ ならこの段階は不要である．その後規則 (R4) が a を生成する．

最初の規則が $X = A_{\mu\nu} \rightarrow B_\mu C_\nu$ であるとする． $Y := B_\mu$ および $Z := C_\nu$ とおく．(2) の第三族の対応する語により三つの観測非終端記号が得られ，規則 (R1) を適用して次を得る．

$$[\omega(Y)\omega(Z) : u_X, v_X] \rightarrow [\omega(Y) : u_X, \omega(Z)v_X][\omega(Z) : u_X\omega(Y), v_X]. \quad (3)$$

$h(\omega(X)) = \mu\nu = h(\omega(Y)\omega(Z))$ なので，必要なら規則 (R3) により $\hat{X}$ を (3) の左辺へ変更する．すでに $\omega(X) = \omega(Y)\omega(Z)$ であるならば，この段階は不要である．次に規則 (R2) により二つの子を $\hat{Y}$ および $\hat{Z}$ へ輸送する．これらはそれぞれ Y, Z の標準文脈によって定まる．二つの部分導出は帰納法の仮定により完了する．

最後に，任意の非空 $w \in L$ は $\tilde{S} \rightarrow X \Rightarrow^* w$ という持ち上げられた開始導出をもつ．開始規則そのものにより (λ, λ) は X の終端到達文脈である．その全長は 0 であり最小なので，標準選択は $\chi(X) = (\lambda, \lambda)$ となる．(2) の第一族から $\omega(X) \in K$ なので，規則 (R5) が上記の導出を開始する． $w = \lambda$ の場合は (2) と規則 (R5) から直ちに従う． $\square$

定理 5.4 (厳密有限標本再構成)． $L \in C_h^{\text{cf}}$ を非空とし， G を L の縮約済み *SSBNF* 文法， $\tilde{G}$ をその型付き精密化とする． $W(\tilde{G}) \subseteq K \subseteq L$ ならば， $L(\mathcal{B}_h(K)) = L$ である．

Proof. 定理 4.2 と 5.3 を合わせればよい． $\square$

したがって，任意の非空標的表現 G について，集合 $W(\tilde{G})$ は第 2.1 節の意味で， $\mathcal{B}_h$ に関する $L(G)$ の特徴標本である．

定理 5.4 は $\{\lambda\}$ を含むすべての非空標的を覆う．残る端点 $L = \emptyset$ については $C_L = \emptyset$ とおけば， $\mathcal{B}_h(\emptyset)$ は開始生成規則をもたない．これにより定理 3.4 の項目 (ii) が確立される．

系 5.5 (Gold 同定)．有限モノイド M への固定準同型 $h : \Sigma^* \rightarrow M$ に対し，学習器 $\mathcal{A}_h$ は C_h^{cf} のすべての非空言語を正例データから同定する．より具体的には，任意の縮約済み *SSBNF* 標的文法 G とその型付き精密化 $\tilde{G}$ に対し， $W(\tilde{G}) \subseteq K_{n_0}$ となったとき，段階 $n \geq n_0$ の範囲で生じうる仮説変更は高々一回である．

Proof. 本論文のテキスト規約の下では，Gold の主張は非空標的を対象とする． H_0 は初期空仮説である． L を非空とし， T を L のテキストとする． $w_1 \notin L(H_0) = \emptyset$ なので，学習器は段階 1 で再構成する． $W(\tilde{G}) \subseteq K_{n_0}$ を満たす n_0 を選ぶ．ある段階 $n \geq n_0$ で学習器が再構成するならば，定理 5.4 により新たな仮説はちょうど L となり，その後はいかなる正例も追加の変更を引き起こさない．この場合はこれが最後の仮説変更となる．一方，どの段階 $n \geq n_0$ でも再構成が起こらないと仮定する．健全性から $L(H_{n_0}) \subseteq L$ である．さらに，すべての n について $K_n \subseteq L(H_n)$ が成り立つ．再構成時には標本整合性があり，再構成しない段階では新たに提示されたデータがすでに変更されない仮説によって生成されるからである．したがって真の包含 $L(H_{n_0}) \subsetneq L$ ならば，段階 n_0 までまだ現れていないある $w^* \in L \setminus L(H_{n_0})$ が存在する．しかし標的のすべての語は最終的にテキストに現れるので， w^* は後の段階で現れて再構成を強制し，矛盾する．したがって $L(H_{n_0}) = L$ である．この場合，段階 n_0 以後に仮説変更は必要ない． $\square$

これは Eyraud–Heinz–Yoshinaka [14, Appendix] が指摘する delayed-rebuild 現象である．特徴標本をすでに見終えた後でも，新しい各正例が以前の誤った仮説によって生成されている限り，保守的学習器はその仮説を保持し得る．その仮説の外にある後続の正例が現れたとき，すでに特徴データを含む蓄積標本全体から再構成が行われる．上の証明は $\mathcal{B}_h$ に対するこの安定化を明示している．

5.3 再構成ステップの計算量

定理 5.6. h を固定すると， $\mathcal{B}_h(K)$ は $\|K\|$ に関して多項式時間で構成できる．

Proof. $n_K := \|K\|$ とおく．標本語には $x \neq \lambda$ を満たす分解 uxv が $O(n_K^2)$ 個あり，従って $|\hat{V}(K)| = O(n_K^2)$ である．因子の h -値も固定モノイド中の $O(n_K^2)$ 回の積でキャッシュできる．規則 (R1) の候補は $O(n_K^3)$ ，規則 (R2)–(R3) は高々 $O(n_K^4)$ 個である．多項式時間の前処理で等しい因子と文脈成分に標準識別子を割り当てられる（例えば $O(n_K^2)$ 個の因子出現をソートすればよい）．この識別子と h -値をキャッシュした後は，固定 h の下で各等値・型検査を定数時間で行える．各生成規則の符号化長は $O(n_K)$ なので，文法全体を明示的に検査・出力する時間は $O(n_K^5)$ で抑えられる． $\square$

保守的学習器 $\mathcal{A}_h$ の各更新も，それまでに見たデータの符号化サイズに関して多項式時間で処理できる．CFG membership は文法と入力サイズに関して多項式時間であり，現在の仮説サイズと必要な再構成の計算量はいずれも定理 5.6 によって多項式に抑えられる．

補題 4.1，定理 5.4，系 5.5 と合わせて，主定理 3.4(i)–(iii) が得られる．定量的な (iv)–(v) は第 7–8 節で証明する．文法サイズだけによる上界は不可能である．Clark–Eyraud [6, Example 2] および Eyraud–Heinz–Yoshinaka [14, Example 2.3] で用いられる標準的な doubling family は，縮約済み

SSBNF 文法 $S_0 \rightarrow D_n$, $D_0 \rightarrow a$, $D_i \rightarrow D_{i-1}D_{i-1}$ をもち、生成規則記号数は $O(n)$ だが生成言語は $\{a^{2^n}\}$ である. de la Higuera の定理 3 [4] は、これと密接に関連する simple-deterministic な変種を用いる. 任意の singleton 言語は、任意の h に対して $\sim_h$ -代入可能である.

6 一般の固定型付けに対する型付き厚み

6.1 型付き厚み上界と表現レベルのギャップ

任意の固定 h に対し、生成語型付けの費用を明示的に測れば、有限証拠構成から直接的な定量上界が得られる. $G = (V, \Sigma, P, S_0)$ を縮約済み SSBNF 文法, $\tilde{G}$ をその型付き精密化とし, $N := |V \setminus \{S_0\}|$, $N_t := |\tilde{V} \setminus \{\tilde{S}\}|$ とおく. この表現の **型付き厚み**を

$$\tau_h^{\text{typ}}(G) := \max\left(\{|\omega(X)| : X \in \tilde{V} \setminus \{\tilde{S}\}\} \cup \{1\}\right)$$

と定める. これは完全な生成語型分割とトリミング後の最短終端生成語を測る表現依存パラメータであり、学習器への追加仮定ではない.

補題 6.1 (型付き厚みによる証拠上界). $G, \tilde{G}$ を上の通りとし, $\tau := \tau_h^{\text{typ}}(G)$ と書く. 任意の非開始型付き記号 X に対し $|u_X| + |v_X| \leq (N_t - 1)\tau$ であり, 任意の $w \in W(\tilde{G})$ に対し $|w| \leq (N_t + 1)\tau$ である. $P_{\text{ter}}, P_{\text{bin}}$ をそれぞれ G の非開始終端規則と二項規則の集合とすると

$$\|W(\tilde{G})\| \leq (N|M| + |P_{\text{ter}}| + |P_{\text{bin}}||M|^2 + 1)((N|M| + 1)\tau + 1).$$

特に固定 h の下で、この上界は $|G|$ と $\tau_h^{\text{typ}}(G)$ の多項式である.

Proof. $\tilde{G}$ の非開始記号を頂点とし、二項規則で親から各子へ辺を張る依存有向グラフを作る. $\tilde{G}$ は縮約済みなので任意の非開始記号 X は到達可能であり、ある開始子 A から X への経路がある. 最短経路を選べば型付き記号を反復せず、辺数は高々 $N_t - 1$ である.

経路の各辺について、その辺を実現する二項規則を選び、経路外の子をその標準生成語へ展開する. $\tilde{S} \rightarrow A$ から始めれば、これらの展開は X の終端到達文脈を与える. 各経路外の標準生成語長は高々 τ なので文脈全長は $(N_t - 1)\tau$ 以下であり、標準文脈 (u_X, v_X) はそれより長くない.

第一族の語は標準文脈に標準生成語を一つ、第二族は終端記号を一つ、第三族は標準生成語を二つ加える. $\tau \geq 1$ だから、式 (2) の各語の長さは $(N_t + 1)\tau$ 以下である. さらに $N_t \leq N|M|$ であり、元の終端規則から生じる型付き終端規則は高々一つ、元の各二項規則からは高々 $|M|^2$ 個の型付き規則が生じる. 従って第一因子が λ の可能な証拠も含めた証拠個数を、第二因子が各 $|w| + 1$ を抑える. 積をとれば主張が従う. $\square$

系 6.2 (型付き厚みからの特徴データ). h を固定する. G が非空な $L(G) \in \mathcal{C}_h^{\text{cf}}$ の縮約済み SSBNF 文法なら、 $W(\tilde{G})$ は B_h に対する特徴標本であり、その符号化サイズは $|G|$ と $\tau_h^{\text{typ}}(G)$ の多項式である.

Proof. 定量上界は補題 6.1、特徴標本性は定理 5.4 による. $\square$

型付き精密化による議論では、型付き厚みを一般に元文法の通常の厚みへ置き換えられない. このような表現依存性自体は CFG 学習で既知の現象である. Clark–Eyraud [6, Example 2] は、小さい

文法でも正の特徴データに指数長の語が必要となる例を与えている。Yoshinaka [7] は fixed-window 設定で通常の文法厚みを明示的なパラメータとし、Eyraud–Heinz–Yoshinaka [14] も特徴データ基準の表現依存性を論じている。ここで必要なのはより限定された点であり、通常の元文法厚みを記録しても、本論文の fixed- h 再構成で用いる型付き精密化の最短生成語は大幅に長くなり得る。

備考 6.3 (元文法と型付き厚みの指数ギャップ). 型付き厚みは、元文法のサイズと通常の厚みの多項式では一般に抑えられない。以下にその例を示す。

$M_c = \{1, \zeta\}$ を零元 ζ をもつ二元モノイドとし、 $h_c(a) = 1, h_c(c) = \zeta$ とする。 $n \geq 1$ に対し、文法 G_n^c を

$$\begin{aligned} S_0 &\rightarrow U, & U &\rightarrow a \mid c \mid UU \mid E_n D, & D &\rightarrow c, \\ E_0 &\rightarrow a, & E_i &\rightarrow E_{i-1} E_{i-1} \mid c \quad (1 \leq i \leq n) \end{aligned}$$

で定める。これはサイズ $O(n)$ の縮約済み SSBNF 文法であり、 $L(G_n^c) = \{a, c\}^+ \in \mathcal{C}_{h_c}^{\text{cf}}$ である。

まず、 S_0, U, E_0 は a を、 D, E_i ($i \geq 1$) は c を生成できる。つまり、すべての非終端記号が長さ 1 の語を生成できるため、通常の厚みは $\tau_{G_n^c} = 1$ である。

一方、型付き精密化で型 1 に制限すると、 $h_c(c) = \zeta \neq 1$ なので、 $E_i \rightarrow c$ は使えない。また、積が 1 になるのは $1 \cdot 1$ だけである。従って帰納法により $L((E_i)_1) = \{a^{2^i}\}$ となる。さらに $\tilde{S} \rightarrow U_\zeta \rightarrow (E_n)_1 D_\zeta$ により $(E_n)_1$ はトリミング後も残る。よって型付き厚みは $\tau_{h_c}^{\text{typ}}(G_n^c) \geq 2^n$ である。

元文法のサイズは $O(n)$ 、通常の厚みは 1 なのに、型付き厚みは 2^n 以上となる。従って、この固定型付けに対してさえ、元文法のサイズと通常の厚みによる多項式上界は存在しない。

ただし、標的言語 $\{a, c\}^+$ 自体は n に依存しない。従って、これは特徴データに対する学習作用素非依存の下界ではない。ここでの役割は、通常の元文法厚みでは系 6.2 に現れる型付き精密化パラメータを制御できないことを示すことだけである。このため、一般 fixed- h の上界は型付き厚みによって記述する。

7 固定窓に対する厚み付きデータ

以下の二つの正の定量結果はいずれも τ_h^{typ} を上から抑え、系 6.2 を適用して得られる。 $h_{k,\ell}$ では、型付き非終端記号が保存すべきなのは有界な接頭辞と接尾辞だけなので型付き厚みを制御できる。備考 6.3 が示すように、一般の h にはこの移送はない。表現サイズと厚みに関して多項式の特徴標本上界は、この設定に対して Yoshinaka [7] が導入した identification in polynomial time and thick data (IPTtD) のデータ部分である。Eyraud–Heinz–Yoshinaka [14, Definition 2.12] にも同じ定式化がまとめられている。Yoshinaka の定理 1 と補題 6–7 は (k, ℓ) -代入可能性について同種の上界を与える。ここでは $\mathcal{B}_{h_{k,\ell}}$ に対応する上界を示すが、同じ正規形や同じ多項式次数は主張しない。

$k, \ell \geq 0$ を固定する。 $G = (V, \Sigma, P, S_0)$ を縮約済み SSBNF 文法、 $\tilde{G}$ をその縮約済み $h_{k,\ell}$ -型付き精密化とし、

$$N := |V \setminus \{S_0\}|, \quad N_t := |\tilde{V} \setminus \{\tilde{S}\}|, \quad \theta_{k,\ell}(G) := \begin{cases} \tau_G, & k + \ell = 0, \\ (k + \ell) + (2(k + \ell) - 1)N_{\tau_G}, & k + \ell > 0 \end{cases}$$

とおく。

補題 7.1 (固定窓型付き生成語の有界性). $\tilde{G}$ の任意の非開始型付き記号 A_μ に対し $|\omega(A_\mu)| \leq \theta_{k,\ell}(G)$ である.

Proof. 付録 付録 A を参照されたい. □

定理 7.2 (固定窓に対する多項式厚み付きデータ). 任意に固定した組 (k, ℓ) とアルファベット Σ に対し, 多項式 $q_{k,\ell}$ が存在し, $L(G) \in \mathcal{C}_{h_{k,\ell}}^{\text{cf}}$ を満たす任意の縮約済み *SSBNF* 文法 G について $\|W(\tilde{G})\| \leq q_{k,\ell}(|G|, \tau_G)$ が成り立ち, $W(\tilde{G})$ は $\mathcal{B}_{h_{k,\ell}}$ に対する特徴標本である.

Proof. 補題 7.1 より $\tau_{h_{k,\ell}}^{\text{typ}}(G) \leq \theta_{k,\ell}(G)$ であり, 固定 k, ℓ, Σ の下では右辺は $|G|, \tau_G$ の多項式である. 系 6.2 を適用すればよい. □

上の定理は縮約済み *SSBNF* 表現について述べている. 次の正規化で任意の縮約済み *CFG* へ移送する.

命題 7.3 (厚みを多項式的に保存する *SSBNF* 正規化). 固定多項式 $q_{\text{size}}, q_{\text{thick}}$ が存在し, 非空言語を生成する任意の縮約済み *CFG* R を多項式時間で同値な縮約済み *SSBNF* 文法 G へ変換でき, $|G| \leq q_{\text{size}}(|R|)$, $\tau_G \leq q_{\text{thick}}(|R|, \tau_R + 1)$ が成り立つ.

証明は付録 A.2 に与える. 文法サイズと最短非空生成語を多項式に保つため, 終端分離と二分化を非開始 λ -規則除去より先に行う.

系 7.4 (固定窓計算量の移送). 任意の固定 $k, \ell \geq 0$ と有限アルファベット Σ に対し, 縮約済み *CFG* R で表される任意の $L \in \mathcal{C}_{h_{k,\ell}}^{\text{cf}}$, 同値にそのような R で表される任意の文脈自由 (k, ℓ) -代入可能標的は, $\mathcal{B}_{h_{k,\ell}}$ に対して $|R|$ と τ_R の多項式サイズの特徴データをもつ.

Proof. 命題 7.3 と定理 7.2 を適用する. 同値性は命題 3.3 による. □

多項式は固定した窓とアルファベットに依存し, 可変な k, ℓ に関する一様上界は主張しない. これはバッチ再構成の特徴データに関する主張であり, 保守的逐次学習器の Gold 安定化は系 5.5 で別途与える.

8 線形部分クラス

線形言語はちょうど 1 ターン・プッシュダウンオートマトンによって受理される [11, 15]. 以下の正規化はその文法的対応物を与える. 成功導出には一つの継続する非終端記号の経路があり, これを *spine* と呼ぶ.

命題 8.1 (linear-spine *SSBNF* 正規化). 固定多項式 q_{lin} が存在し, 非空言語を生成する任意の線形 *CFG* G を多項式時間で同値な縮約済み *SSBNF* 文法 $G_0 = (V_0, \Sigma, P_0, S_0)$ へ変換でき, $|G_0| \leq q_{\text{lin}}(|G|)$ である. さらに各二項生成規則は, $W_a \rightarrow a$ を満たすちょうど一つの新鮮な終端ラッパー子と, ちょうど一つのそれ以外の非終端子をもつ.

構成は付録 付録 B に与える. $\tilde{G}_0$ を型付き精密化, $N_t := |\tilde{V}_0 \setminus \{\tilde{S}\}|$ とおく. 各基礎非開始記号は高々 $|M|$ 個の型付きコピーをもつので $N_t \leq |V_0 \setminus \{S_0\}| |M|$ である.

483 **補題 8.2** (短い標準生成語). $\tilde{G}_0$ の任意の型付き非開始記号 X に対し $|\omega(X)| \leq N_t$ である. 従って
 484 $\tau_h^{\text{typ}}(G_0) \leq N_t$ である.

485 証明は付録 付録 C に与える.

486 **定理 8.3** (線形標的に対する多項式特徴データ). h を固定する. 線形 CFG で表される $\mathcal{C}_h^{\text{lin}}$ の任意
 487 の言語は, $\mathcal{B}_h$ に対し, 標的表現サイズの多項式で $\|\cdot\|$ -サイズが抑えられる特徴標本をもつ.

488 *Proof.* $L = \emptyset$ と $L = \{\lambda\}$ では第 5 節の標本を用いる. それ以外では命題 8.1 の G_0 を取る. 補
 489 題 8.2 から $\tau_h^{\text{typ}}(G_0) \leq N_t \leq |V_0 \setminus \{S_0\}| |M|$ なので, 系 6.2 により $|G_0| \leq q_{\text{lin}}(|G|)$ の多項式サイ
 490 ズの特徴標本を得る. $\square$

491 定理 5.6 と合わせると, 任意の有限標本からのバッチ再構成は多項式時間であり, 選んだ線形
 492 CFG 表現に関して特徴データも多項式である. これは de la Higuera [4, Theorem 2] による線形文
 493 法表現クラス全体の否定結果とは矛盾しない. 同定理が任意の線形文法を対象とするのに対し, 定
 494 理 8.3 の対象は固定 h に対する代入可能な部分クラス $\mathcal{C}_h^{\text{lin}}$ に限られ, さらに第 2.1 節の正例データ
 495 に基づく特徴標本概念を用いている. したがって, 線形文法クラス全体が de la Higuera の意味で
 496 polynomial time-and-data identifiable であるとは主張しない. また, $\mathcal{B}_h$ に線形文法を出力するこ
 497 とも要求していない.

498 8.1 非正則な線形 fixed- h 例

499 直前の定理は, 正則標的や既知の線形代入可能クラスに限定されない.

$$L_{\pm,e} := \{a^{2m}cb^{2m} : m \geq 0\} \cup \{a^{2m+1}db^{2m+1} : m \geq 0\} \\ \cup \{a^n eb^n : n \geq 0\}.$$

500 これは線形文法

$$S \rightarrow U_{\text{ev}} \mid U_e, \quad U_{\text{ev}} \rightarrow c \mid aU_{\text{odd}}b, \quad U_{\text{odd}} \rightarrow d \mid aU_{\text{ev}}b, \\ U_e \rightarrow e \mid aU_eb$$

501 で生成される.

502 c, d, e を **中心記号** と呼ぶ. $M_{\pm,e} := \{1, \kappa_{cd}, \kappa_e, 0\}$ を, 1 が単位元で, $\mu\nu = 0$ がすべての
 503 $\mu, \nu \in \{\kappa_{cd}, \kappa_e, 0\}$ に対して成り立つ四元モノイドとする. すなわち三元 null semigroup に単位元を
 504 付加したものである. 準同型 $h_{\pm,e} : \{a, b, c, d, e\}^* \rightarrow M_{\pm,e}$ を

$$h_{\pm,e}(a) = h_{\pm,e}(b) = 1, \quad h_{\pm,e}(c) = h_{\pm,e}(d) = \kappa_{cd}, \quad h_{\pm,e}(e) = \kappa_e \quad (4)$$

505 で定める. 従って $h_{\pm,e}(w)$ は, 中心記号を含まなければ 1, ちょうど一つ含みそれが c または d な
 506 ら κ_{cd} , それが e なら κ_e , 二つ以上含めば 0 である.

507 $\text{par}(c) := 0, \text{par}(d) := 1$ とおく. $m, n \geq 0$ と $\xi \in \{c, d, e\}$ に対し

$$a^m \xi b^n \in L_{\pm,e} \iff m = n \text{ かつ } [\xi = e \text{ または } (\xi \in \{c, d\} \text{ かつ } m \equiv \text{par}(\xi) \pmod{2})]. \quad (5)$$

508 **命題 8.4.** 言語 $L_{\pm,e}$ は線形かつ非正則であり, 式 (4) の準同型に対して $\sim_{h_{\pm,e}}$ -代入可能である. 一
 509 方, Clark-Eyraud 代入可能ではなく, いかなる固定 $k, \ell \geq 0$ に対しても (k, ℓ) -代入可能ではない.

Proof. 線形性は表示文法から直ちに従い、 $L_{\pm,e} \cap a^*eb^* = \{a^n eb^n : n \geq 0\}$ から非正則性が従う。以下 $L := L_{\pm,e}$ とする。

$\sim_{h_{\pm,e}}$ -代入可能性について、同じ型の非空因子 x, y が L で共通文脈をもつとする。 L の語に現れる因子が型 0 をもつことはない。共通型が 1 なら $x, y \in a^+ \cup b^+$ であり、共通文脈は $|x|_a - |x|_b = |y|_a - |y|_b$ を強制する。この値は $a^+ \cup b^+$ の語を一意に決めるので $x = y$ である。

それ以外では $x = a^i \xi b^j$, $y = a^{i'} \xi' b^{j'}$ と書け、各因子は中心記号を一つ含む。式 (5) によりその文脈は (a^m, b^n) の形で、

$$\begin{aligned} (a^m, b^n) \in \mathcal{D}_L(a^i e b^j) &\iff n - m = i - j, \\ (a^m, b^n) \in \mathcal{D}_L(a^i \xi b^j), \xi \in \{c, d\} &\iff n - m = i - j \text{ かつ } m \equiv \text{par}(\xi) - i \pmod{2} \end{aligned}$$

である。従って e -因子の分布は $i - j$ により、 c/d -因子の分布は $(i - j, \text{par}(\xi) - i \pmod{2})$ により決まる。共通文脈は対応する不変量を一致させ、同じ $h_{\pm,e}$ -型であることは、両者がともに e -因子であるか、ともに c/d -因子であることを保証する。よって $\mathcal{D}_L(x) = \mathcal{D}_L(y)$ である。

一方 $c, e \in L$ は空文脈を共有するが $(a, b) \in \mathcal{D}_L(e) \setminus \mathcal{D}_L(c)$ なので Clark-Eyraud 代入可能ではない。さらに k, ℓ を固定し $m_0 := \max\{1, k + \ell\}$, $w_e := a^k e b^\ell$, $w_c := a^k c b^\ell$ とおく。両因子は同じ長さ k の接頭辞と長さ ℓ の接尾辞をもち、文脈 $(a^{2m_0-k}, b^{2m_0-\ell})$ を共有する一方 $(a^{2m_0+1-k}, b^{2m_0+1-\ell}) \in \mathcal{D}_L(w_e) \setminus \mathcal{D}_L(w_c)$ である。従って 固定窓代入可能性の反例基準より $L_{\pm,e} \notin \text{KL}$ である。 $\square$

従って定理 8.3 は KL の外にある非正則線形言語にも適用される。表示文法は even-linear なので、Takada の control-set 枠組みからの分離は主張しない。

9 表現力と境界

ここでは fixed-window 階層と、より広い文脈自由言語族の間で本枠組みを位置づける。

9.1 RS 内の非線形標的

$\Delta := \{a^n b^n : n \geq 0\}$ とし Δ^* を考える。 $z \in \{a, b\}^*$ に対し $\beta(z) := |z|_a - |z|_b$ とし、

$$\underline{\beta}(z) := \min\{\beta(p) : p \text{ は } z \text{ の接頭辞}\}$$

と定める。 ba の各出現の高さを、その b で終わる接頭辞の高さと呼ぶ。次の特徴づけを用いる： $(\star)$ $w \in \Delta^*$ であることと、 $\underline{\beta}(w) \geq 0$, $\beta(w) = 0$, かつすべての ba の出現高さが 0 であることは同値である。順方向は $a^n b^n$ 因子への分解から従い、逆方向は高さ 0 となる位置ごとに切れば balanced な $a^* b^*$ segment が得られる。

$\text{fst}(w), \text{lst}(w) \in \{\perp, a, b\}$ を最初と最後の記号 ($\perp$ では $\perp$) とし、 $\text{ba}(w)$ で w が ba を含むかを記録する。

$$h_\star(w) := (\text{fst}(w), \text{lst}(w), \text{ba}(w)).$$

接続の要約は二因子の要約だけから決まる。端点は明らかな仕方で接続され、新しい ba は境界 $b|a$ でのみ生じ得る。従って有限像 $M_\star := h_\star(\{a, b\}^*)$ に $h_\star(x)h_\star(y) := h_\star(xy)$ と積を入れれば、 $h_\star$ は有限モノイド準同型になる。

非空 x に対し

$$\mathcal{E}(x) := \{q \in \mathbb{Z} : q + \underline{\beta}(x) \geq 0 \text{ かつ } q + \eta = 0 \text{ が } x \text{ 内部の各 } ba \text{ の高さ } \eta \text{ について成り立つ}\}$$

と定める。

命題 9.1 (非線形 fixed- h_* 標的). Δ^* は文脈自由・非正則・非線形で, $\sim_{h_*}$ -代入可能である. さらにどの固定 $k, \ell \geq 0$ に対しても (k, ℓ) -代入可能ではない. 従って $\Delta^* \in \text{RS}_{h_*}(\{a, b\}) \cap \text{CFL}$ かつ $\Delta^* \in \text{RS}(\{a, b\}) \setminus \text{KL}(\{a, b\})$ である.

Proof. 文法 $S \rightarrow TS \mid \lambda, T \rightarrow aTb \mid \lambda$ は Δ^* を生成する. $\Delta^* \cap a^*b^* = \Delta$ から非正則であり, 線形言語の正則交差に対する閉包性と $\Delta^* \cap a^*b^*a^*b^* = \Delta\Delta$ および $\Delta\Delta$ の非線形性 [15] から非線形である.

代入可能性を示すため, 同じ h_* -型をもつ非空因子 x, y が共通文脈 (u, v) をもつとする. $uxv, uyv \in \Delta^*$ なので全体バランスから $\beta(x) = \beta(y)$ である. 任意の文脈 (u', v') を固定する. $(*)$ により, 中間因子 x を走査する際に課される条件はちょうど, x の内部で高さが負にならないことと, x 内部の各 ba が大域的高さ 0 で現れることであり, これらは $\beta(u') \in \mathcal{E}(x)$ と同値である. 境界 $u'|x$ または $x|v'$ をまたいで新たに生じ得る ba は x の最初と最後の記号だけに依存し, v' に入る高さは $\beta(u') + \beta(x)$ だけに依存する. 従って u', v' を固定すれば, 残りの membership 条件が x に依存するのは $h_*(x), \beta(x), \mathcal{E}(x)$ を通じてのみである. よって $\mathcal{E}(x) = \mathcal{E}(y)$ を示せば十分である.

両者が ba を含むなら, 内部 ba は可能な進入高さを一意に強制し, 共通文脈がその高さを供給するので $\mathcal{E}(x) = \{\beta(u)\} = \mathcal{E}(y)$ である. どちらも ba を含まなければ $x, y \in a^*b^*$ で, $\mathcal{E}(z) = \{q : q \geq -\min\{0, \beta(z)\}\}$ だから $\beta(x) = \beta(y)$ から等号が従う. 従って $\mathcal{D}_{\Delta^*}(x) = \mathcal{D}_{\Delta^*}(y)$ である.

固定窓からの分離として k, ℓ を固定し, $m := \max\{1, k + \ell\}$, $s := a^m b^m$, $t := a^m b^m a^m b^m$ とおく. 両者は同じ長さ k の接頭辞と長さ ℓ の接尾辞をもち, 空文脈を共有する. さらに $asb \in \Delta^*$ だが, atb の中央の ba は高さ 1 なので $atb \notin \Delta^*$ である. 従って固定窓代入可能性の反例基準から, Δ^* はどの (k, ℓ) にも属さない. $\square$

従って fixed- h 枠組みは, 固定窓階層の外にある第 8 節の非正則線形例 $L_{\pm, e}$ と, 非線形文脈自由言語 Δ^* の双方を含む. control-set 法一般との分離は主張しない.

9.2 上限制約つき正則カウンタ族

正則分離そのものは Yoshinaka の L_0 により既知である [7, Proposition 1]. 以下の族は, 第 9.3 節の無界カウンタに対する有限状態の capped 版として残す.

$\Sigma_c := \{\uparrow, \downarrow, \#\}$ とする. $w = \delta_1 \cdots \delta_n$ に対し $\text{ht}_0(w) = 0$ とし, $\uparrow$ で +1, $\downarrow$ で -1, $\#$ で 0 にリセットして高さを更新する. $\rho \geq 1$ に対し

$$\text{CTR}_\rho := \{w \in \Sigma_c^* : 0 \leq \text{ht}_i(w) \leq \rho \text{ for all } 0 \leq i \leq |w|\}$$

とおく.

任意の $\rho \geq 1$ に対し CTR_ρ は正則である. 実際, 決定性有限オートマトンが高さ $0, \dots, \rho$ を記録し, 範囲外に一つの sink を置き, $\#$ で 0 に戻ればよい. 従って命題 3.1 から $\text{CTR}_\rho \in \text{RS}(\Sigma_c)$ となる.

定理 9.2. 任意の $\rho \geq 2$ に対し CTR_ρ はどの $k, \ell \geq 0$ についても (k, ℓ) -代入可能ではない.

Proof. k, ℓ を固定し $s := (\uparrow\downarrow)^k \uparrow^{\rho-1} \#^\ell$, $t := (\uparrow\downarrow)^k \uparrow^\rho \#^\ell$ とおく. 両者は固定窓基準に十分長く, 同じ長さ k の接頭辞と長さ ℓ の接尾辞をもち, ともに CTR_ρ に属する. 一方 $\uparrow s \in \text{CTR}_\rho$ だが $\uparrow t \notin \text{CTR}_\rho$ で, 後者は高さ $\rho + 1$ に達する. 従って分布が異なり, 反例基準が適用できる. $\square$

$\rho \geq 2$ とすることで, 上の証人 s は境界場合 $k = \ell = 0$ でも非空になる.

従って有限認識準同型 h_ρ をとれば $\text{CTR}_\rho \in \mathcal{C}_{h_\rho}^{\text{cf}} \setminus \text{KL}$ である. ここでの CTR_ρ の役割は新しい正則分離ではなく, 下の無界言語 CTR と対になる capped 版を与えることにある.

9.3 RS の外にある自然な決定性文脈自由言語

補題 9.3 (有限モノイド障害). $L \subseteq \Sigma^*$ とする. 無限集合 $\Xi \subseteq \Sigma^+$ が存在し, 相異なる任意の $x, y \in \Xi$ について $\mathcal{D}_L(x) \cap \mathcal{D}_L(y) \neq \emptyset$ かつ $\mathcal{D}_L(x) \neq \mathcal{D}_L(y)$ が成り立つなら $L \notin \text{RS}(\Sigma)$ である.

Proof. 有限 h は Ξ の二要素を同一視する. その二語は共通文脈をもち分布が異なるので $\sim_h$ -代入可能性に反する. $\square$

上限を外すと決定性文脈自由言語

$$\text{CTR} := \{w \in \Sigma_c^* : \text{ht}_i(w) \geq 0 \text{ for all } 0 \leq i \leq |w|\}$$

を得る. これは reset 付きの明らかな決定性プッシュダウン・カウンタで受理される.

系 9.4 (上限なしカウンタの障害). $\text{CTR} \notin \text{RS}(\Sigma_c)$ である.

Proof. $\Xi = \{\uparrow^i : i \geq 1\}$ を用いる. $i < j$ なら $(\lambda, \downarrow^i)$ は共通文脈だが, $(\lambda, \downarrow^j)$ は $\uparrow^j$ だけの文脈である. $\square$

一種類の括弧の Dyck 言語

$$D_1 := \{w \in \{a, b\}^* : |w'|_a \geq |w'|_b \text{ for every prefix } w', |w|_a = |w|_b\}$$

は標準的な決定性文脈自由言語 [16] である. ここでの D_1 は Dyck 言語全体を表し, Autebert–Berstel–Boasson [15] の規約では D_1^* と書かれる.

系 9.5. $D_1 \notin \text{RS}(\{a, b\})$ である.

Proof. $\Xi = \{b^i a^i : i \geq 1\}$ を用いる. $i < j$ なら (a^j, b^j) は共通文脈だが, (a^i, b^i) は $b^i a^i$ だけの文脈である. $b^j a^j$ では接頭辞 $a^i b^j$ がアンダーフローを起こす. $\square$

従って障害は無界スタック挙動それ自体ではない. 非正則 1-turn 言語 $L_{\pm, e}$ は RS に属する. 障害は, 文脈的挙動が異なるにもかかわらず相互に比較可能な因子が無限族をなし, 有限 h ではそれらをすべて分離できないことである.

補題 9.6 (固定語による商). L が $\sim_h$ -代入可能で $z \in \Sigma^*$ なら, $L/z := \{w : wz \in L\}$ も $\sim_h$ -代入可能である.

Proof. L/z の共通文脈 (u, v) は L では (u, vz) になる. L で分布が等しいなら, 任意の文脈 (s, t) の右に z を付加することで L/z に分布等式を移せる. $\square$

$S \rightarrow aSS \mid b$ が生成する言語を *Lukasiewicz 言語* と呼ぶ. 本論文の記法では $L_{\text{Luk}} = D_1b$ [15] で, これは決定性文脈自由言語でもある [16]. もし $L_{\text{Luk}} \in \text{RS}(\{a, b\})$ なら補題 9.6 により $D_1 = L_{\text{Luk}}/b \in \text{RS}$ となり, 系 9.5 に反する.

9.4 Clark の congruential family との比較

Clark [17] は有限初期集合 $I \subseteq V$ を許し, $L_G[I] := \bigcup_{A \in I} L_G(A)$ と書く. このような文法が *congruential* であるとは, 各 $L_G(A)$ が $L_G[I]$ の一つの構文合同類に含まれることをいう. Γ 上の congruential grammar が生成する言語全体を $\text{CONG}(\Gamma)$ と書く. Clark はすでに substitutable および (k, ℓ) -substitutable language をこの族に位置づけている. 次の命題はこの包含をすべての fixed- h slice へ拡張する.

命題 9.7 (Clark の congruential family との比較). 任意の有限アルファベット Γ と有限モノイド 準同型 $h : \Gamma^* \rightarrow M$ に対して $\mathcal{C}_h^{\text{cf}} \subseteq \text{CONG}(\Gamma)$ である. 従って $\text{RS}(\Gamma) \cap \text{CFL} \subseteq \text{CONG}(\Gamma)$ であり, $\Gamma = \{a, b\}$ ではこの包含は真である.

Proof. 非空 $L \in \mathcal{C}_h^{\text{cf}}$ の縮約済み SSBNF 文法と型付き精密化 $\tilde{G}$ を取る. 任意の非開始型付き記号 $X = A_\mu$ は終端到達文脈 (u, v) をもち, 命題 5.2 より任意の $w \in L_{\tilde{G}}(X)$ は非空かつ $h(w) = \mu$ である. 従って $x, y \in L_{\tilde{G}}(X)$ は同じ型と共通文脈 (u, v) をもち, fixed- h 代入可能性から $x \equiv_L y$ となる. すなわち各型付き非終端記号は一つの構文合同類の語だけを生成する.

分離された開始記号を削除し, その型付き後続記号を有限初期集合として用いる. $\lambda \in L$ なら λ だけを生成する新しい初期記号を一つ加える. 命題 5.2 により, これで L の congruential grammar が得られる. 空言語は生成規則をもたない初期記号で扱える. h 全体に和を取れば包含が従う.

$\{a, b\}$ 上で包含が真であることには, Clark [17] も論じる Dyck 例を用いる. 任意の $x \in D_1$ に対し $uxv \in D_1$ iff $uv \in D_1$ なので $x \equiv_{D_1} \lambda$ である. 従って $S \rightarrow aSbS \mid \lambda$ は congruential だが, 系 9.5 より $D_1 \notin \text{RS}(\{a, b\})$ である. $\square$

■有限群だけでは不十分である. 有限モノイドを用いることは, 単なる記法上の一般化ではない. $\text{GRS}(\Gamma)$ を, $\text{RS}(\Gamma)$ の定義において証拠となる準同型の余域を有限群に限定して得られるクラスとする. 任意の有限群は有限モノイドなので, $\text{GRS}(\Gamma) \subseteq \text{RS}(\Gamma)$ である. しかもこの包含は, 一文字アルファベット上ですでに真である. $L_{\geq 2} := \{a^m : m \geq 2\}$ とおく. これは正則言語なので, 命題 3.1 より $L_{\geq 2} \in \text{RS}(\{a\})$ である. 一方, $h : \{a\}^* \rightarrow G$ を有限群 G への準同型とし, $g = h(a)$ とおく. g の位数を $n \geq 1$ とすれば $h(a) = h(a^{n+1})$ である. 非空因子 a と a^{n+1} は, $a^2, a^{n+2} \in L_{\geq 2}$ なので文脈 (a, λ) を共有するが, 分布は一致しない. 実際, $(\lambda, \lambda) \notin \mathcal{D}_{L_{\geq 2}}(a)$ である一方, $(\lambda, \lambda) \in \mathcal{D}_{L_{\geq 2}}(a^{n+1})$ である. 従って $L_{\geq 2} \notin \text{GRS}(\{a\})$ であり, $\text{GRS}(\{a\}) \subsetneq \text{RS}(\{a\})$ が従う. すなわち, 正則標的の段階ですでに, 非可逆な有限モノイド型付けを許すことが本質的である.

10 結論

任意の固定有限モノイド型付け h に対し, 有限個の標準正例証拠からの多項式時間の集合駆動型再構成と, それとは別の保守的 Gold 学習器を与えた. 特徴データは文法サイズと型付き厚みに関して多項式である. 上の元文法厚みから型付き厚みへの指数ギャップは, 通常元文法厚みだけでは一

般の再構成上界を制御できない理由を示す．一方，任意の固定接頭辞 – 接尾辞窓では通常の厚みで十分であり，線形 fixed- h 標的では文法サイズに関する上界が得られる．

構造的には，積型付けは任意の逆準同型に閉じ，正規フィルタ後も context-free fixed- h slice を保つ．通常の交わりは固定窓でも成り立つので，差は正規フィルタと消去的逆準同型にある．

Yoshinaka は正則分離をすでに与えている．本論文の CTR_ρ は無界版との対比のために残し，さらにどの fixed-window class にも属さない非正則線形・非線形文脈自由標的を与える．さらに，型付けの余域を有限群に制限すると一文字正則言語 $L_{\geq 2} = \{a^m : m \geq 2\}$ すら失われるため，有限群ではなく有限モノイドを用いることは本質的である．一方 $D_1 \notin \text{RS}$ であり， $\text{RS}(\Gamma) \cap \text{CFL}$ は Clark の congruential family に真に含まれる．未解決問題として， $\text{RS} \cap \text{CFL}$ の特徴づけ，有用な型付けの選択または学習，型付けが有益となる構造的条件の解明，pushdown の有限制御や control-set 法との関係の明確化，および本枠組みと効率性基準のより豊かな文法形式への拡張がある．

データ利用可能性

本研究では実証データを使用していない．

利益相反の申告

著者は，本論文で報告した研究に影響を与えたと考えられる既知の競合する金銭的利益関係または個人的関係がないことを申告する．

研究費

本研究は，公的機関，民間企業，または非営利部門のいずれの資金配分機関からも特定の助成を受けていない．

謝辞

著者は，指導・励まし・関連文献への助力をいただいた金澤誠教授と吉仲亮教授，ならびに本論文を大幅に改善する丁寧で建設的な報告をくださった二名の匿名査読者に感謝する．特に査読者は，投稿版の学習アルゴリズムの問題点を指摘し，定理 9.2 の直接的な二語反例を促してくださった．残る誤りはすべて著者の責任である．

付録 A 固定窓証拠語上界と厚み保存正規化

A.1 補題 7.1 の証明

補題 7.1 の証明. $k + \ell = 0$ のとき， $h_{0,0}$ は Σ^+ 上で定数なので， $\tilde{G}$ の非開始型付き記号 A_μ は基礎となる非終端記号 A と同じ非空生成語をもち， $|\omega(A_\mu)| \leq \tau_G$ である．

$k + \ell > 0$ とする． μ が $M_{k,\ell}$ の短語要素なら，型 μ の語はその短語自身なので，その長さは $k + \ell$ 未満である．残る長語要約要素 $\mu = \langle p, q \rangle$ について，この型をもつ A の導出木を一つ選び，最初の

669 k 個と最後の ℓ 個の終端葉を印付けする．印付け葉はちょうど $k + \ell$ 個であり，そのラベルは必要な
 670 順序で p と q を与える．根から印付け葉への経路の和を $\mathcal{U}$ とする．

671 $\mathcal{U}$ 上でちょうど一つの子だけが $\mathcal{U}$ に残る非終端ノードの極大鎖を考える．同じ基礎非終端記号が
 672 一つの鎖に二度現れたら，上側の出現を下側の部分木で置き換える．これは同じ非終端記号からの正
 673 しい導出であり，印付け葉を含まない兄弟部分木しか削除しないので，印付けられた境界終端記号と
 674 その順序は保存される．これを繰り返すと，各極大一子鎖には高々 N 個の非終端記号しか残らない．

675 各極大一子鎖を縮約すると， $k + \ell$ 個の印付け葉を結ぶ根付き二分木が得られ，その頂点数は高々
 676 $2(k + \ell) - 1$ である．したがって，最初の分岐頂点より上にあり得る初期鎖も含め，極大一子鎖は高々
 677 $2(k + \ell) - 1$ 本である． $\mathcal{U}$ の外側に省略された兄弟部分木が生じるのはこれらの鎖上のノードだけで
 678 あり，分岐ノードでは両方の子が $\mathcal{U}$ に含まれる．従って省略された兄弟部分木は高々 $(2(k + \ell) - 1)N$
 679 個である．

680 それぞれをその根の最短終端生成語で置き換えると，一つにつき高々 τ_G 個の終端記号を寄与す
 681 る．得られる語 w' は依然として A から導出され，接頭辞 p と接尾辞 q を保つので，同じ $h_{k,\ell}$ -型 μ
 682 をもち， $|w'| \leq (k + \ell) + (2(k + \ell) - 1)N\tau_G$ ．

683 命題 5.2 と同じ生成語型注釈により，この導出はトリム前の生成語型付き文法へ持ち上がる． A_μ
 684 は縮約部分 $\tilde{G}$ に属し，導出木は成功しているので，注釈された木上のすべての型付き記号は trim 後
 685 も残る．したがって w' は A_μ の型付き生成語であり，shortlex 最小の型付き生成語 $\omega(A_\mu)$ も同じ
 686 長さ上界を満たす． $\square$

687 A.2 厚みを多項式的に保存する SSBNF 正規化

688 命題 7.3 の証明． $R = (V, \Sigma, P, S)$ を縮約済みで非空言語を生成する文法とし， $n := |R|$ ， $\bar{\tau} := \tau_R + 1$
 689 とおく．文法サイズと最短終端生成語をとともに多項式的に保つ順序で標準正規化を行う．

690 まず新しい開始記号 S_0 と規則 $S_0 \rightarrow S$ を導入し， $\lambda \in L(R)$ なら最終的に $S_0 \rightarrow \lambda$ を残す．長さ
 691 2 以上の右辺に現れるすべての終端記号を新しいラッパー $W_a \rightarrow a$ で分離し，長さ 2 を越える右辺
 692 を二分化する．得られる文法を G_{bin} とする．選んだ妥当な符号化の下で，これらの操作の総サイズ
 693 は $O(n)$ である．元の各非終端記号は同じ終端生成語を保持．新たな各二分化記号は元のある右
 694 辺の連続部分を展開し，そこに含まれる元の記号数は高々 $O(n)$ である．その部分に現れる各生産的
 695 非終端記号を最短終端生成語で置き換えれば，ある定数 c_1 に対して $\tau_{G_{\text{bin}}} \leq c_1 n \bar{\tau}$ が得られる．

696 次に， G_{bin} の空語導出可能記号から得られる最短の **非空** 生成語を抑える． $A \Rightarrow_{G_{\text{bin}}}^* w$ を非空終
 697 端語への導出とし，導出木の終端葉の一つ選んで根からの経路をたどる．同じ非終端記号が二度現れ
 698 れば，上側の部分木を下側の部分木で置き換えてサイクルを削除できる．これを繰り返すと経路上の
 699 非終端記号数は高々 $|V_{G_{\text{bin}}}|$ となる．各二項ノードで経路外の兄弟記号をその最短終端生成語へ置き
 700 換えると，空語導出可能な兄弟記号は空語を寄与してよく，選んだ終端葉が一文字を寄与するので，
 701 ある定数 c_2 に対して

$$\min\{|w| > 0 : A \Rightarrow_{G_{\text{bin}}}^* w\} \leq 1 + |V_{G_{\text{bin}}}| \tau_{G_{\text{bin}}} \leq c_2 n^2 \bar{\tau}$$

702 である．

703 ここで非開始 λ -規則をすべて除去する． G_{bin} は二分文法なので，規則 $A \rightarrow BC$ から生じるのは，
 704 空語導出可能な子に応じて高々 $A \rightarrow BC$ ， $A \rightarrow B$ ， $A \rightarrow C$ であり，指數的な空語導出可能記号の

部分集合に関する展開は起こらない。通常の構成は各非終端記号の非空終端生成言語を保存するので、上の長さ上界も保たれる。続いて単位閉包を計算し、非開始単位規則を除去する。各出発非終端記号と、そこから単位規則だけで到達可能な各非単位規則について、その規則を出発非終端記号にコピーする。この段階の前には非終端記号が $O(n)$ 個、非単位規則も $O(n)$ 個なので、生成される規則は高々 $O(n^2)$ 個である。単位規則消去は各非終端記号の言語を保存するため厚み上界を増加させない。最後に無用記号をトリムする。

得られる文法は縮約済みで開始記号が分離され、各非開始規則は終端規則または二項規則であり、 $S_0 \rightarrow \lambda$ が唯一の可能な λ -規則である。従って SSBNF である。そのサイズは n の多項式、厚みは高々 $c_2 n^2(\tau_R + 1)$ であり、すべての変換は多項式時間で実行できる。 $\square$

付録 B linear-spine SSBNF 正規化の証明

命題 8.1 の構成は、標準的な開始記号分離、無用記号・空語導出可能規則・単位規則の除去、および二分化を組み合わせ、第 8 節で必要な単一 spine 形を保存する。

命題 8.1 の証明. $L(G) = \{\lambda\}$ なら、単一規則 $S_0 \rightarrow \lambda$ をもつ縮約済み文法を取ればよい。二項生成規則をもたないので、要求される条件は自明に成り立つ。従って以下では、 $L(G)$ が空でない語を含むと仮定する。

S を元の開始記号とする。右辺に決して現れない新しい S_0 を導入し、 $S_0 \rightarrow S$ を加え、さらに $\lambda \in L(G)$ なら $S_0 \rightarrow \lambda$ も加える。以後 S は非開始記号として扱う。無用記号を除去し、 λ を S_0 にのみ保存しつつ非開始 λ -規則を除去し、その後で非開始単位規則を除去する。開始規則には単位規則消去を適用しないので、最終トリミング後に残る各開始規則は、要求どおり $S_0 \rightarrow A$ または $S_0 \rightarrow \lambda$ の形になる。この順序により、 λ -消去によって新たに生じた単位規則も除去される。入力文法は線形なので、各右辺には空語導出可能な非終端記号が高々一つしか現れず、各生成規則から追加される代替右辺は高々一つである。ここで線形性は二箇所で見られる。第一に、空語導出可能規則の展開を多項式に抑える。第二に、消去後も、残る各非単位右辺には非終端記号が高々一つしか現れないことを保証し、これが以下の「ラッパーでない子を一つだけ持つ」分解を可能にする。単位閉包とラッパー鎖による二分化そのものは、一般 CFG に対しても多項式時間の操作である。単位規則消去では有限な単位到達可能閉包を計算する。すなわち、出発非終端記号と、到達可能な非単位生成規則の各組は、高々一つの複製規則を生じる。従って生成規則数も右辺長の総和も多項式に保たれる。

残るのは、新たな単位規則を作らずに二分化することである。以下の二項生成規則の子として現れる各終端記号 a に対して、新しいラッパー $W_a \rightarrow a$ を一つ導入する。同値に、すべての $a \in \Sigma$ に対してそのようなラッパーを導入してもよい。規則 $A \rightarrow uBv$ に対して、 $u = a_1 \cdots a_m$, $v = b_1 \cdots b_n$ と書く。非開始単位規則はすでに消去されているので、 $m = n = 0$ の場合（これは単位規則 $A \rightarrow B$ になる）は起こらない。従って $m + n > 0$ である。以下、場合分けを明示する。 $m = 0$ なら必ず $n > 0$ である。 $n = 1$ なら $A \rightarrow BW_{b_1}$ を用いる。 $n \geq 2$ なら、新しい $Q_1, \dots, Q_{n-1}$ を導入し、

$$Q_1 \rightarrow BW_{b_1}, \quad Q_j \rightarrow Q_{j-1}W_{b_j} \quad (2 \leq j \leq n-1), \quad A \rightarrow Q_{n-1}W_{b_n}$$

とする。次に $m > 0$ とする。 $n = 0$ なら $U := B$ と定める。ここで B はラッパー導入前の文法の非終端記号なので、この二分化で導入した新しい終端ラッパー記号の一つではない。 $n > 0$ なら新し

740 い $Q_1, \dots, Q_n$ を導入して

$$Q_1 \rightarrow BW_{b_1}, \quad Q_j \rightarrow Q_{j-1}W_{b_j} \quad (2 \leq j \leq n)$$

741 とし, $U := Q_n$ とおく. $m = 1$ なら単一の二項規則 $A \rightarrow W_{a_1}U$ を用いる. $m \geq 2$ なら, 新しい
742 $J_1, \dots, J_{m-1}$ を導入して

$$A \rightarrow W_{a_1}J_1, \quad J_i \rightarrow W_{a_{i+1}}J_{i+1} \quad (1 \leq i \leq m-2), \quad J_{m-1} \rightarrow W_{a_m}U$$

743 とする. したがって, $m+n > 0$ の下で, $m=0$ または $m \geq 1$, $n=0$ または $n \geq 1$ のすべての場
744 合が覆われる. また最も内側の二項規則は, 新しい単位規則ではなく B 自身を含む.

745 終端記号のみからなる規則 $A \rightarrow a_1 \cdots a_m$ について, $m=1$ なら $A \rightarrow a_1$ をそのまま残す. $m \geq 2$
746 なら, 新しい $\Theta_2, \dots, \Theta_m$ を導入し,

$$A \rightarrow W_{a_1}\Theta_2, \quad \Theta_i \rightarrow W_{a_i}\Theta_{i+1} \quad (2 \leq i \leq m-1), \quad \Theta_m \rightarrow a_m$$

747 とする. ($m=2$ のとき, 中間の規則族は空である.) 従って新たに得られる非開始規則は, 終端規則
748 か, あるいはちょうど一つのラッパー子と一つの別の非終端子をもつ二項規則のいずれかである. 構
749 成上, ラッパー W_a は二項規則のラッパー子位置にのみ現れ, 継続する非終端子としては決して現
750 れない. 一方, 終端記号のみの構成は, 終端規則をもつ新しい非ラッパー非終端記号で終わる. 最終
751 トリミングは, この性質, 分離開始形, および縮約済み性を保存する. ラッパーと鎖による分解は,
752 すでに多項式に抑えられた右辺長総和に対して線形であるため, 全構成のサイズは多項式であり, 多
753 項式時間で実行できる. $\square$

754 付録 C 短い標準生成語補題の証明

755 補題 8.2 の証明. 命題 8.1 の linear-spine SSBNF 形では, 各二項 spine step は $A \rightarrow W_aB$ または
756 $A \rightarrow BW_a$ の形で, $W_a \Rightarrow a$ だから, 継続する非終端記号の外側にちょうど一つの終端記号を放出
757 する.

758 X が終端ラッパーなら $|\omega(X)| = 1$ である. そうでなければ, 型付き spine 記号 X からの最短終
759 端導出を取り, spine を $X = X_0, X_1, \dots, X_t$ と書く. X_t は終端規則を用い, 生成語長は $t+1$ であ
760 る. もし $X_i = X_j$ ($i < j$) なら, 二出現の間を削除して, より少ない spine step をもつ有効な導出
761 を得られるので最短性に反する. 従って $t+1$ 個の型付き spine 記号は相異なり, すべて非開始記号
762 なので $t+1 \leq N_t$ である. よって $|\omega(X)| \leq N_t$ が従う. $\square$

763 参考文献

- 764 [1] M. Kanazawa. Identification in the limit of categorial grammars. CWI Report CS-R9351,
765 July 1993.
- 766 [2] E. M. Gold. Language identification in the limit. *Information and Control*, 10(5):447–474,
767 1967.
- 768 [3] J.-E. Pin. *Mathematical Foundations of Automata Theory*. Lecture notes, version of March
769 24, 2025. <https://www.irif.fr/~jep/PDF/MPRI/MPRI.pdf>.

- [4] C. de la Higuera. Characteristic sets for polynomial grammatical inference. *Machine Learning*, 27:125–138, 1997. 770 771
- [5] C. de la Higuera. *Grammatical Inference: Learning Automata and Grammars*. Cambridge University Press, 2010. 772 773
- [6] A. Clark and R. Eyraud. Polynomial identification in the limit of substitutable context-free languages. *Journal of Machine Learning Research*, 8:1725–1745, 2007. 774 775
- [7] R. Yoshinaka. Identification in the limit of k, l -substitutable context-free languages. In *Grammatical Inference: Algorithms and Applications – ICGI 2008*, LNCS 5278, pp. 266–279, Springer, 2008. doi:10.1007/978-3-540-88009-7_21. 776 777 778
- [8] Y. Takada. Grammatical inference for even linear languages based on control sets. *Information Processing Letters*, 28(4):193–199, 1988. doi:10.1016/0020-0190(88)90208-6. 779 780
- [9] Y. Takada. Learning formal languages based on control sets. In K. P. Jantke and S. Lange (Eds.), *Algorithmic Learning for Knowledge-Based Systems*, LNAI 961, pp. 316–339, Springer, 1995. doi:10.1007/3-540-60217-8_15. 781 782 783
- [10] T. Koshiba, E. Mäkinen, and Y. Takada. Learning deterministic even linear languages from positive examples. *Theoretical Computer Science*, 185(1):63–79, 1997. doi:10.1016/S0304-3975(97)00016-9. 784 785 786
- [11] S. Ginsburg and E. H. Spanier. Finite-turn pushdown automata. *SIAM Journal on Control*, 4(3):429–453, 1966. doi:10.1137/0304034. 787 788
- [12] F. Coste, D. Fredouille, C. Kermorvant, and C. de la Higuera. Introducing domain and typing bias in automata inference. In *ICGI 2004*, LNAI 3264, pp. 115–126, Springer, 2004. doi:10.1007/978-3-540-30195-0_11. 789 790 791
- [13] A. Clark. Learning trees from strings: A strong learning algorithm for some context-free grammars. *Journal of Machine Learning Research*, 14:3537–3559, 2013. 792 793
- [14] R. Eyraud, J. Heinz, and R. Yoshinaka. Efficiency in the identification in the limit learning paradigm. In J. Heinz and J. M. Sempere (Eds.), *Topics in Grammatical Inference*, Springer, 2016. doi:10.1007/978-3-662-48395-4_2. 794 795 796
- [15] J.-M. Autebert, J. Berstel, and L. Boasson. Context-free languages and pushdown automata. In G. Rozenberg and A. Salomaa (Eds.), *Handbook of Formal Languages*, Vol. 1, pp. 111–174, Springer, 1997. 797 798 799
- [16] S. Ginsburg and S. A. Greibach. Deterministic context-free languages. *Information and Control*, 9:620–648, 1966. 800 801
- [17] A. Clark. Distributional learning of some context-free languages with a minimally adequate teacher. In *Proceedings of ICGI 2010*, LNCS 6339, pp. 24–37, Springer, 2010. doi:10.1007/978-3-642-15488-1_4. 802 803 804